

Methodologie et Gouvernance du Projet

Cadrage methodologique, cycle de vie et processus qualite

Reference : METH-THUM-2026-001

Version : 1.0

Date : Avril 2026

Chef de Projet : Direction Projet Data

1. Cadre methodologique

1.1 Methodologie retenue : Agile adaptee Data/IA

Le projet Thumalien suit une methodologie Agile adaptee aux projets Data/IA, inspiree du framework CRISP-DM (Cross-Industry Standard Process for Data Mining) combine avec des pratiques Scrum pour la gestion iterative.

Pourquoi cette approche :

- Les projets IA sont par nature experimentaux : on ne sait pas a l'avance quel modele, quel dataset ou quel seuil donnera les meilleurs resultats
- L'approche iterative permet de livrer de la valeur incrementalement (V1 -> V1.5 -> V2 -> V3)
- Chaque iteration est un cycle complet : donnees -> modele -> evaluation -> decision

1.2 Phases CRISP-DM appliquees a Thumalien

??		
?		?
?	1. COMPREHENSION	2. COMPREHENSION
?	METIER	DES DONNEES
?	(Detecter les	(Explorer Bluesky,
?	fake news)	auditer ISOT)
?	?	?
?	????????????????????????????	?
?	?	?
?	3. PREPARATION	?
?	DES DONNEES	?
?	(Nettoyage Reuters,	?
?	integration V2)	?
?	?	?
?	4. MODELISATION	?
?	(TF-IDF + LogReg,	?
?	MLP emotions,	?
?	GridSearch)	?
?	?	?
?	5. EVALUATION	?
?	(CV 5-fold, ablation,	?
?	test Bluesky)	?

? ? ?
? 6. DEPLOIEMENT ?
? (Docker, Dashboard, ?
? API future) ?
? ? ?
? ????? Retour Phase 1 (iteration) ???-> ?
? ?
??

1.3 Cycles iteratifs du projet

Iteration	Periode	Objectif	Livrable
V1.0	Dec 2025	Baseline : TF-IDF + LogReg anglais uniquement	F1 = 0.99 (biaise par Reuters)
V1.5	Jan-Fev 2026	Correction biais, bilingue, emotions, features linguistiques	F1 = 0.986, pipeline expert complet
V2	Fev 2026	Integration datasets sociaux, adaptation textes courts	F1 = 0.897, 73.4% fiable sur Bluesky
V3 (planifie)	T3 2026	Sentence-Transformers, embeddings semantiques	F1 cible > 0.90 sur textes courts
V4 (planifie)	T4 2026	Fine-tuning CamemBERT/RoBERTa sur donnees Bluesky annotees	F1 cible > 0.92

2. Gouvernance du projet

2.1 Organisation de l'equipe

????????????????????
? Chef de Projet ?
? (Pilotage, ?
? conformite, ?
? arbitrages) ?
????????????????????
?
??
? ? ?
???????????????????? ???? ???? ????
? Pole Data ? ? Pole IA ? ? Pole Infra ?
? ? ? ? ?
? Data Engineer? ? ML Engineer? ? DevOps ?
? ? ? Data Sci. ? ? Dashboard Dev?
? ? ? MLOps ? ? ?
? ? ? Green IT ? ? ?
???????????????????? ???? ???? ???? ???? ???? ?

2.2 Instances de gouvernance

Instance	Frequence	Participants	Objectif
Daily standup	Quotidien (15 min)	Toute l'equipe	Synchronisation, blocages
Sprint review	Bi-hebdomadaire	Toute l'equipe + parties prenantes	Demo des livrables, feedback
Sprint planning	Bi-hebdomadaire	Toute l'equipe	Planification des taches
Retrospective	Bi-hebdomadaire	Equipe technique	Amelioration continue
Comite de pilotage	Mensuel	Chef de projet + direction	Avancement, risques, budget
Revue de modele	A chaque nouvelle version	ML Eng. + Data Sci. + Chef projet	Validation des performances
Audit de conformite	Trimestriel	Chef projet + DPO	Conformite RGPD/AI Act

2.3 Processus de decision

Type de decision	Decideur	Processus
Choix d'architecture technique	Data Engineer + DevOps	Proposition -> revue -> validation Chef de projet
Choix de modele/algorithme	ML Engineer + Data Scientist	Experimentation -> metriques -> revue de modele -> validation
Seuil de decision (0.44, etc.)	Data Scientist + Chef de projet	Analyse quantitative -> impact metier -> validation
Ajout de dataset	ML Engineer + Data Scientist	Evaluation qualite -> test integration -> validation
Mise en production	MLOps + Chef de projet	Tests de non-regression -> validation -> deploiement
Conformite/ethique	Chef de projet	Analyse d'impact -> avis DPO -> decision

3. Processus qualite

3.1 Qualite des donnees

La qualite des donnees est le fondement de tout projet IA. Un modele entraine sur des donnees biaisees produira des predictions biaisees (principe "Garbage In, Garbage Out").

Controles a l'ingestion

Controle	Methode	Frequence	Responsable
Completeness des champs	Validation du schema JSON (tous les champs requis presents)	Chaque insertion	Data Engineer

Deduplication	Index unique sur uri dans MongoDB	Chaque insertion	Data Engineer
Detection de langue	langdetect sur les 500 premiers caracteres	Chaque insertion	Pipeline
Longueur minimale	Rejet des textes < 3 mots	Chaque insertion	Pipeline
Volume d'ingestion	Monitoring du nombre de posts/heure	Continu	Data Engineer

Controles sur les datasets d'entrainement

Controle	Methodes	Resultat Thumalien
Biais d'agence (Reuters)	audit_reuters_leakage()	Detecte (99.2%) et corrige
Equilibre des classes	Comptage par label	True: 48.2%, Fake: 51.8% (V2)
Distribution linguistique	Comptage par langue	EN: 72%, FR: 28% (avant oversampling)
Distribution de longueur	Histogramme des word counts	Bimodale : articles (340 mots) + social (20 mots)
Corruption CSV	Detection des lignes malformees	39 lignes corrigees dans Fake.csv
Coherence des labels	Verification manuelle d'un echantillon	50 textes verifiees, 96% de coherence

3.2 Qualite des modeles

Protocole d'evaluation standard

Chaque version du modele est evaluee selon le protocole suivant :

- CROSS-VALIDATION (5-fold stratifie)**
 - Metriques : F1, Precision, Recall, Accuracy
 - Stratification par label ET par langue
 - Resultat : intervalle de confiance a 95%
- HOLDOUT TEST (20% des donnees, jamais vus en entrainement)**
 - Metriques : F1, Precision, Recall, Accuracy, matrice de confusion
 - Analyse par segment : langue (FR/EN), longueur (court/long), sujet
- TEST OPERATIONNEL (posts Bluesky reels)**
 - Echantillon : 2 000 posts reels
 - Metriques : distribution des scores, % fiable/suspect
 - Comparaison avec les attendus (70-80% fiable pour un flux non cible)
- ANALYSE D'ERREURS**
 - Les 100 plus grosses erreurs sont lues manuellement
 - Categorisation : faux positifs (fiable classe suspect) et faux negatifs
 - Identification de patterns communs -> pistes d'amelioration
- ABLATION STUDY**
 - Impact de chaque groupe de features (TF-IDF, linguistiques, emotions)
 - Identification des contributions marginales

Criteres de promotion en production

Un modele ne peut etre deploye en production que s'il satisfait TOUS les criteres suivants :

Critere	Seuil	V2 actuel
F1 CV global	≥ 0.85	0.897
F1 holdout	≥ 0.85	0.90
Accuracy holdout	$\geq 85\%$	93%
F1 EN test	≥ 0.85	0.988
F1 FR test	≥ 0.75	0.985
Ecart F1 FR-EN	< 15 points	0.3 point
% fiable sur Bluesky	60-85%	73.4%
Pas de regression vs version precedente	F1 articles longs stable	0.988 (identique V1.5)
Empreinte carbone	< 1 g CO2	0.30 g
Temps d'inference	< 100ms/texte	~50ms

3.3 Qualite du code

Pratique	Implementation	Responsable
Structure modulaire	src/collection/, src/pipeline/, dashboard/	Toute l'equipe
Versioning Git	Commits reguliers, messages descriptifs	Toute l'equipe
Documentation	Docstrings, notebooks commentes, README	Toute l'equipe
Tests	Tests d'integration (pipeline charge et predition)	ML Engineer + DevOps
Code review	Revue par un pair avant merge	Toute l'equipe
Environnement reproductible	requirements.txt, Docker, random_state=42	DevOps + ML Engineer

4. Gestion des risques

4.1 Registre des risques

ID	Risque	Probabilite	Impact	Criticite	Mitigation
R01	Changement de l'API Bluesky (breaking change)	Moyenne	Eleve	Haute	Veille sur les releases AT Protocol. Version pinee de la librairie atproto
R02	Derive du modele (concept drift)	Elevee	Moyen	Haute	Monitoring mensuel de la distribution des scores. Retraining planifie

R03	Biais non detecte dans les predictions	Moyenne	Eleve	Haute	Audit de biais trimestriel. Diversification continue des datasets
R04	Panne infrastructure (MongoDB, Docker)	Faible	Eleve	Moyenne	Volumes persistants, restart: always dans Docker Compose
R05	Depassement de la capacite de stockage	Faible	Moyen	Faible	Monitoring de l'espace disque. Politique de retention 12 mois
R06	Demande d'effacement RGPD massive	Tres faible	Moyen	Faible	Procedure d'effacement automatisee et documentee
R07	Performance insuffisante sur nouvelle thematique	Moyenne	Moyen	Moyenne	Datasets complementaires thematiques. Retraining cible
R08	Depart d'un membre cle de l'equipe	Faible	Eleve	Moyenne	Documentation exhaustive. Bus factor > 1 pour chaque composant
R09	Non-conformite reglementaire (evolution RGPD/AI Act)	Moyenne	Eleve	Haute	Veille reglementaire trimestrielle. Audit de conformite
R10	Mauvaise interpretation des scores par les utilisateurs	Moyenne	Eleve	Haute	Formation utilisateurs. Mentions explicites des limites dans le dashboard

4.2 Plan de continuite d'activite (PCA)

Scenario	Impact	Action	RTO	RPO
Panne MongoDB	Arret collecte + dashboard	Redemarrage conteneur. Donnees sur volume persistant	5 min	0 (pas de perte)
Panne collecteur	Arret collecte (pas d'impact dashboard)	Redemarrage automatique (restart: always)	1 min	5 min de posts perdus
Corruption modele .pkl	Predictions erronees	Chargement du modele precedent (V1.5 en fallback)	2 min	0

Perte de la machine	Perte totale	Restauration depuis Git (code) + backup MongoDB	1 jour	Dernier backup
API Bluesky indisponible	Arret collecte	Attente avec retry. Dashboard fonctionne sur donnees existantes	N/A	Période d'indisponibilité

RTO = Recovery Time Objective (temps maximal pour reprendre le service)

RPO = Recovery Point Objective (perte de données maximale acceptable)

5. Planification et jalons

5.1 Historique des jalons (realises)

Jalon	Date	Livrable	Statut
J0 - Cadrage projet	Dec 2025	Specification des besoins, choix technologiques	Realise
J1 - Collecteur operationnel	Dec 2025	collect_bluesky.py + MongoDB + Docker	Realise
J2 - Baseline V1.0	Dec 2025	LogReg anglais, F1=0.99 (biaise)	Realise
J3 - Audit qualite	Jan 2026	Identification biais Reuters, corruption CSV	Realise
J4 - Modele emotions	Jan 2026	MLP PyTorch bilingue, 7 emotions	Realise
J5 - Pipeline V1.5	Fev 2026	Bilingue + features linguistiques + emotions, F1=0.986	Realise
J6 - GridSearch	Fev 2026	Optimisation hyperparametres, analyse de robustesse	Realise
J7 - Pipeline V2	Fev 2026	+3 datasets sociaux, seuil 0.44, 73.4% fiable	Realise
J8 - Dashboard V2	Mars 2026	3 pages, glassmorphism, explicabilite	Realise
J9 - Documentation	Avril 2026	Rapport, guide utilisateur, CDC, RGPD	En cours

5.2 Jalons futurs (planifies)

Jalon	Date cible	Livrable	Responsable
J10 - API REST	T2 2026	FastAPI pour l'inference en temps reel	MLOps + DevOps

J11 - Monitoring derive	T2 2026	Detection automatique du concept drift	MLOps + Data Scientist
J12 - Pipeline V3	T3 2026	Sentence-Transformers, embeddings 384D	ML Engineer
J13 - Annotation Bluesky	T3 2026	1 000 posts Bluesky annotés manuellement	Data Scientist
J14 - Pipeline V4	T4 2026	Fine-tuning CamemBERT/RoBERTa	ML Engineer
J15 - Production cloud	T4 2026	Migration vers infrastructure cloud (GCP/AWS)	DevOps

6. Indicateurs de suivi (KPI projet)

6.1 KPI techniques

KPI	Methode de mesure	Frequence	Cible	Actuel
F1-score modele	Cross-validation 5-fold	A chaque retraining	≥ 0.85	0.897
% fiable sur Bluesky	Distribution des predictions sur 2 000 posts	Mensuel	60-85%	73.4%
Volume de posts collectes	db.raw_posts.countDocuments()	Quotidien	> 1 000/jour	~2 000/jour
Uptime collecteur	Logs de collecte	Mensuel	> 95%	~90% (estimé)
Temps d'inference	Benchmark sur 1 000 textes	A chaque version	< 100ms/texte	~50ms
Empreinte carbone	CodeCarbon	A chaque entraînement	< 1 g CO2	0.30 g
Taille du dataset d'entraînement	Comptage	A chaque version	> 100 000	145 703

6.2 KPI projet

KPI	Methode de mesure	Frequence	Cible
Nombre de notebooks documentes	Comptage	Mensuel	9 (00-08)
Couverture de la documentation	Checklist des livrables	Trimestriel	100%
Nombre de risques ouverts critiques	Registre des risques	Mensuel	0
Conformite RGPD	Audit trimestriel	Trimestriel	100%
Satisfaction utilisateurs	Enquete (quand applicable)	Semestriel	> 7/10

7. Communication et reporting

7.1 Matrice de communication

Public	Contenu	Format	Frequence	Canal
Equipe technique	Avancement, blocages	Standup oral	Quotidien	Reunion
Direction	Synthese, risques, decisions	Comite de pilotage	Mensuel	Presentation
Utilisateurs	Nouvelles fonctionnalites, limites	Release notes	A chaque version	Email/doc
Regulateur	Conformite, mesures	Rapport AIPD	Annuel	Document formel
Communaute academique	Resultats, methodologie	Rapport technique	A chaque publication	Document/article

7.2 Modele de rapport d'avancement

RAPPORT D'AVANCEMENT - [Mois/Annee]

1. RESUME EXECUTIF (3 lignes max)
2. JALONS ATTEINTS CETTE PERIODE
3. METRIQUES CLES (F1, volume, uptime)
4. RISQUES ET ACTIONS
5. PROCHAINES ETAPES
6. DECISIONS REQUISES

8. Gestion du changement

8.1 Processus de changement

Tout changement significatif (nouveau dataset, modification d'architecture, changement de seuil) suit le processus :

1. DEMANDE
 - Description du changement propose
 - Justification (donnees, metriques, besoin metier)
 - Impact estime (performance, securite, conformite)
2. ANALYSE
 - Le responsable technique evalue la faisabilite
 - Le Data Scientist evalue l'impact sur les metriques
 - Le Chef de projet evalue l'impact sur le planning
3. DECISION
 - Validation par le Chef de projet
 - Si impact conformite : avis DPO
 - Si impact performance : revue de modele

4. IMPLEMENTATION

- Branche Git dediee
- Tests de non-regression
- Documentation mise a jour

5. VALIDATION

- Revue par un pair
- Tests d'acceptation
- Merge et deploiement

8.2 Historique des changements majeurs

Date	Changement	Justification	Impact
Dec 2025	Creation du projet	Besoin initial	N/A
Jan 2026	Nettoyage biais Reuters	F1 biaise a 0.99 par data leakage	F1 reel mesurable
Jan 2026	Passage TensorFlow -> PyTorch	Incompatibilite Apple Silicon	Modele emotions fonctionnel
Fev 2026	Ajout features linguistiques (12)	Enrichir le signal au-dela du TF-IDF	+2 points F1 FR
Fev 2026	Integration emotions (7 features)	Signal emotionnel correle a la desinformation	+0.5 points F1
Fev 2026	3 datasets sociaux (V2)	Domain shift : 77% suspect sur Bluesky	73.4% fiable (vs 23%)
Fev 2026	Seuil 0.44 (vs 0.50)	Calibration pour textes courts	+7 points de fiabilite Bluesky
Mars 2026	Dashboard glassmorphism	Amelioration UX/UI	Dashboard professionnel

Document valide par la Direction Projet - Avril 2026

Reference : METH-THUM-2026-001 - Version 1.0