
THUMALIEN

Pipeline NLP de detection de fake news sur Bluesky

03 Methodologie Projet

Formation : Mastere Big Data & IA - Sup de Vinci

Equipe : Azelie Bernard, Sebastien Lazcanotegui

Annee : 2025-2026

Version : Mai 2026

Methodologie et Gouvernance du Projet

Cadrage methodologique, cycle de vie et processus qualite

Reference : METH-THUM-2026-001

Version : 1.0

Date : Avril 2026

Equipe : Azelie Bernard (Lead technique), Sebastien Lazcanotegui (Validation & Qualite)

1. Cadre methodologique

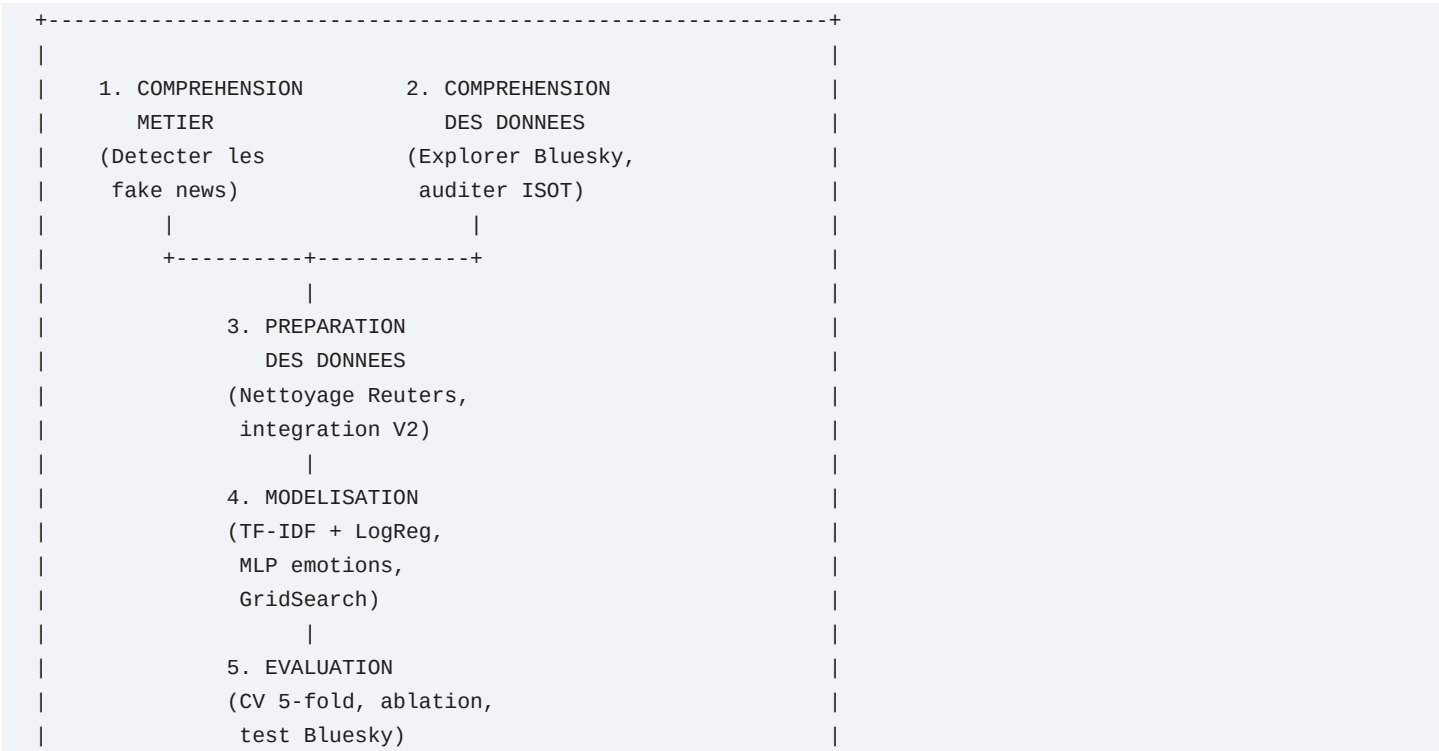
1.1 Methodologie retenue : Agile adaptee Data/IA

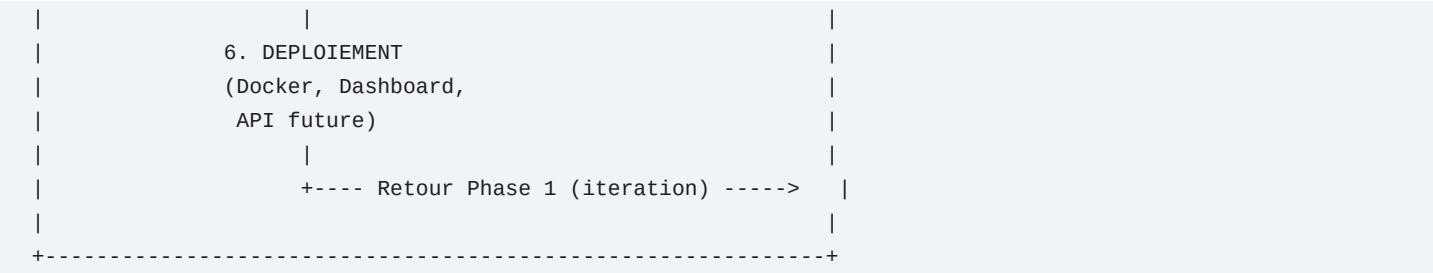
Le projet Thumalien suit une methodologie Agile adaptee aux projets Data/IA, inspiree du framework CRISP-DM (Cross-Industry Standard Process for Data Mining) combine avec des pratiques Scrum pour la gestion iterative.

Pourquoi cette approche :

- Les projets IA sont par nature experimentaux : on ne sait pas a l'avance quel modele, quel dataset ou quel seuil donnera les meilleurs resultats
- L'approche iterative permet de livrer de la valeur incrementalement (V1 -> V1.5 -> V2 -> V3)
- Chaque iteration est un cycle complet : donnees -> modele -> evaluation -> decision

1.2 Phases CRISP-DM appliquees a Thumalien





1.3 Cycles iteratifs du projet

Iteration	Periode	Objectif	Livable
V1.0	Dec 2025	Baseline : TF-IDF + LogReg anglais uniquement	F1 = 0.99 (biaise par Reuters)
V1.5	Jan-Fev 2026	Correction biais, bilingue, emotions, features linguistiques	F1 = 0.986, pipeline expert complet
V2	Fev 2026	Integration datasets sociaux, adaptation textes courts	F1 = 0.897, 73.4% fiable sur Bluesky
V3	Mars 2026	Correction features linguistiques (bug preprocessing)	F1 = 0.900, Precision +19.3%
V4	Avril 2026	Amelioration FR court : augmentation, 15 features, vocabulaire enrichi	F1 global = 0.905, FR court F1 = 0.86 (+32%)
V5	Avril 2026	Integration 10K posts FR sociaux synthetiques, F1 FR court 0.65->0.90	F1 global = 0.913, F1 FR = 0.944, FR court F1 = 0.904, F1 EN = 0.894
V6	Avril 2026	Modele style-only topic-agnostic (28 features stylistiques)	GradientBoosting CV F1 = 0.830
V7	Avril 2026	Ensemble hybride meta-learner V5+V6 + SHAP	FP reduits de 57 a 25 sur gold set
V8	Avril 2026	Integration CamemBERT comme 3e signal semantique	F1 suspect +28%
V9	Mai 2026	Pipeline 2 etapes fait/opinion	FP -67% (186 a 62), kappa 0.187
Collecteur V3	Mai 2026	Reequilibrage FR/EN (28 FR + 16 EN), suppression biais emotionnel, inference auto V9	245 000+ posts (collecte continue), 100% annotes

2. Gouvernance du projet

2.1 Organisation de l'equipe

Le projet Thumalien est realise en binome dans le cadre d'un Master Big Data. La repartition des responsabilites reflète les competences complementaires des deux membres :

BINOME PROJET	
Azelie Bernard	Sebastien Lazcanotegui
-----	-----
Lead technique	Validation & Qualite
- Pipeline ML (V1->V9)	- Annotation gold test set
- Collecteur Bluesky	- Revue documentation
- Dashboard Streamlit	- Tests fonctionnels
- Infrastructure Docker	- Support GridSearch
- Documentation technique	- Video MVP
- Conformite RGPD/AI Act	

Cette organisation en binome compact permet une prise de decision rapide et une communication directe, sans les frais de coordination d'une equipe plus large.

2.2 Instances de gouvernance

Adaptees a un binome, les instances de gouvernance privilegient la legerete et l'efficacite sur le formalisme :

Instance	Frequence	Participants	Objectif
Point de synchronisation	Hebdomadaire (~30 min)	Azelie + Sebastien	Avancement, blocages, prochaines priorites
Revue d'iteration	Bi-mensuelle (~1h)	Azelie + Sebastien	Demo des livrables, feedback mutuel, ajustement du backlog
Bilan mensuel	Mensuel (~30 min)	Azelie + Sebastien	Synthese d'avancement, risques, arbitrages
Revue de modele	A chaque nouvelle version	Azelie (presentation) + Sebastien (relecture)	Validation des performances et des metriques
Point conformite	Ponctuel (a chaque livrable RGPD/AI Act)	Azelie + Sebastien	Verification de la conformite des livrables

2.3 Processus de decision

Type de decision	Responsable	Processus
Choix d'architecture technique	Azelie	Proposition -> discussion en binome -> implementation
Choix de modele/algorithme	Azelie	Experimentation -> metriques -> revue en binome -> validation
Seuil de decision (0.44, etc.)	Azelie + Sebastien	Analyse quantitative -> discussion impact -> validation conjointe
Ajout de dataset	Azelie	Evaluation qualite -> test integration -> validation

Mise en production	Azelie	Tests de non-regression -> validation -> deployment
Conformite/ethique	Azelie + Sebastien	Analyse d'impact -> relecture croisee -> decision

3. Processus qualite

3.1 Qualite des donnees

La qualite des donnees est le fondement de tout projet IA. Un modele entraine sur des donnees biaisees produira des predictions biaisees (principe "Garbage In, Garbage Out").

Controles a l'ingestion

Controle	Methode	Frequence	Responsable
Completude des champs	Validation du schema JSON (tous les champs requis presents)	Chaque insertion	Azelie
Deduplication	Index unique sur uri dans MongoDB	Chaque insertion	Azelie
Detection de langue	langdetect sur les 500 premiers caracteres	Chaque insertion	Pipeline (automatise)
Longueur minimale	Rejet des textes < 3 mots	Chaque insertion	Pipeline (automatise)
Volume d'ingestion	Monitoring du nombre de posts/heure	Continu	Azelie

Controles sur les datasets d'entrainement

Controle	Methode	Resultat Thumalien
Biais d'agence (Reuters)	audit_reuters_leakage()	Detecte (99.2%) et corrige
Equilibre des classes	Comptage par label	True: 63.1%, Fake: 36.9% (V5, 197 782 textes)
Distribution linguistique	Comptage par langue	FR: 86K (43.5%), EN: 112K (56.5%)
Distribution de longueur	Histogramme des word counts	Bimodale : articles (340 mots) + social (20 mots)
Corruption CSV	Detection des lignes malformees	39 lignes corrigees dans Fake.csv
Coherence des labels	Verification manuelle d'un echantillon	50 textes verifiees, 96% de coherence

3.2 Qualite des modeles

Protocole d'evaluation standard

Chaque version du modele est evaluee selon le protocole suivant :

1. CROSS-VALIDATION (5-fold stratifie)
 - Metriques : F1, Precision, Recall, Accuracy
 - Stratification par label ET par langue
 - Resultat : intervalle de confiance a 95%
2. HOLDOUT TEST (20% des donnees, jamais vus en entraînement)
 - Metriques : F1, Precision, Recall, Accuracy, matrice de confusion
 - Analyse par segment : langue (FR/EN), longueur (court/long), sujet
3. TEST OPERATIONNEL (posts Bluesky reels)
 - Echantillon : 2 000 posts reels
 - Metriques : distribution des scores, % fiable/suspect
 - Comparaison avec les attendus (70-80% fiable pour un flux non cible)
4. ANALYSE D'ERREURS
 - Les 100 plus grosses erreurs sont lues manuellement
 - Categorisation : faux positifs (fiable classe suspect) et faux negatifs
 - Identification de patterns communs -> pistes d'amelioration
5. ABLATION STUDY
 - Impact de chaque groupe de features (TF-IDF, linguistiques, emotions)
 - Identification des contributions marginales

Criteres de promotion en production

Un modele ne peut etre deploye en production que s'il satisfait TOUS les criteres suivants :

Critere	Seuil	V5 actuel
F1 CV global	≥ 0.85	0.913
F1 holdout	≥ 0.85	0.91
Accuracy holdout	$\geq 85\%$	93%
F1 EN test	≥ 0.85	0.894
F1 FR test	≥ 0.75	0.944
Ecart F1 FR-EN	< 15 points	5.0 points
% fiable sur Bluesky	60-85%	73.4%
Pas de regression vs version precedente	F1 articles longs stable	0.988 (identique V1.5)
Empreinte carbone	< 10 g CO ₂ (total projet)	6.14 g
Temps d'inference	< 100 ms/texte	~50ms

3.3 Qualite du code

Pratique	Implementation	Responsable
Structure modulaire	src/collection/, src/pipeline/, dashboard/	Azelie
Versioning Git	Commits reguliers, messages descriptifs	Azelie + Sebastien
Documentation	Docstrings, notebooks commentes, README	Azelie (redaction), Sebastien (relecture)

Tests	Tests d'integration (pipeline charge et predict)	Azelie (dev), Sebastien (validation)
Code review	Relecture croisee des livrables critiques	Azelie + Sebastien
Environnement reproductible	requirements.txt, Docker, random_state=42	Azelie

4. Gestion des risques

4.1 Registre des risques

ID	Risque	Probabilite	Impact	Criticite	Mitigation	Statut
R01	Changement de l'API Bluesky (breaking change)	Moyenne (30%)	Eleve	Haute	Veille sur les releases AT Protocol. Version pinee de la librairie atproto. Abstraction	Ouvert - surveille
R02	Derive du modele (concept drift)	Elevee (60%)	Moyen	Haute	Monitoring hebdomadaire (weekly_score_check.py) : alerte si delta score moyen	Mitige - monitoring actif
R03	Biais non detecte dans les predictions	Moyenne (40%)	Eleve	Haute	Audit de biais via gold set (kappa mesure). Analyse F1 par segment (FR/EN,	Mitige - gold set V2
R04	Panne infrastructure (MongoDB, Docker)	Faible (10%)	Eleve	Moyenne	Volumes persistants Docker, restart: always, healthchecks Mongo (mongosh	Mitige - healthchecks
R05	Depassement de la capacite de stockage	Faible (15%)	Moyen	Faible	Monitoring de l'espace disque. Politique de retention 12 mois. 245K posts = ~200	Accepte
R06	Demande d'effacement RGPD massive	Tres faible (5%)	Moyen	Faible	ProcEDURE d'effacement automatisee documentee dans 02_conformite_RG	Mitige
R07	Performance insuffisante sur nouvelle thematique (ex: elections, pandemie)	Moyenne (35%)	Moyen	Moyenne	V6 style-only est topic-agnostic par conception. Datasets complementaires thematiques pre-identifies.	

Active learning sur
les FP

Mitige - V6
topic-agnostic

R08	Indisponibilite d'un membre du binome	Faible (10%)	Eleve	Moyenne	Documentation exhaustive (12 documents). Code commente. Tous les modeles et	Mitige - documentation
R09	Non-conformite reglementaire (evolution RGPD/AI Act)	Moyenne (30%)	Eleve	Haute	Veille reglementaire (section 10). AIPD complete. Model Card conforme	Mitige - conformite
R10	Mauvaise interpretation des scores par les utilisateurs	Moyenne (40%)	Eleve	Haute	Explicabilite XAI multi-niveaux (SHAP, decomposition, attention).	Mitige - XAI pipeline
R11	Sur-ajustement du seuil Stage 1 sur le gold set	Moyenne (45%)	Moyen	Moyenne	Seuil 0.40 derive des memes 500 posts que l'evaluation. Un jeu de calibration	Ouvert - risque accepte
R12	Circularite du self-training (domain adaptation)	Realisee (100%)	Moyen	N/A	Self-training V5 sur Bluesky = echec documente (§22). Alternative : annotation	Ferme - echec documente

humaine (§23). Le risque s'est materialise et a ete traite

4.2 Plan de continuite d'activite (PCA)

Scenario	Impact	Action	RTO	RPO
Panne MongoDB	Arret collecte + dashboard	Redemarrage conteneur. Donnees sur volume persistant	5 min	0 (pas de perte)
Panne collecteur	Arret collecte (pas d'impact dashboard)	Redemarrage automatique (restart: always)	1 min	5 min de posts perdus
Corruption modele .pkl	Predictions erronees	Chargement du modele precedent (V1.5 en fallback)	2 min	0
Perte de la machine	Perte totale	Restauration depuis Git (code) + backup MongoDB	1 jour	Dernier backup
API Bluesky indisponible	Arret collecte	Attente avec retry. Dashboard fonctionne sur donnees existantes	N/A	Periode d'indisponibilite

RTO = Recovery Time Objective (temps maximal pour reprendre le service)

RPO = Recovery Point Objective (perte de donnees maximale acceptable)

5. Planification et jalons

5.1 Historique des jalons (realises)

Jalon	Date	Livrable	Statut
J0 - Cadrage projet	Dec 2025	Specification des besoins, choix technologiques	Realise
J1 - Collecteur operationnel	Dec 2025	collect_bluesky.py + MongoDB + Docker	Realise
J2 - Baseline V1.0	Dec 2025	LogReg anglais, F1=0.99 (biaise)	Realise
J3 - Audit qualite	Jan 2026	Identification biais Reuters, corruption CSV	Realise
J4 - Modele emotions	Jan 2026	MLP PyTorch bilingue, 7 emotions	Realise
J5 - Pipeline V1.5	Fev 2026	Bilingue + features linguistiques + emotions, F1=0.986	Realise
J6 - GridSearch	Fev 2026	Optimisation hyperparametres, analyse de robustesse	Realise
J7 - Pipeline V2	Fev 2026	+3 datasets sociaux, seuil 0.44, 73.4% fiable	Realise
J8 - Dashboard V2	Mars 2026	3 pages, glassmorphism, explicabilite	Realise
J9 - Pipeline V3	Mars 2026	Correction features linguistiques, retraining	Realise
J10 - Pipeline V4	Avril 2026	Augmentation FR court, 15 features, F1 FR=0.935	Realise
J11 - Pipeline V5	Avril 2026	Integration 10K posts FR sociaux synthetiques, F1 global=0.913, FR court=0.904	Realise
J12 - CamemBERT FR	Avril 2026	Fine-tuning CamemBERT V1/V2, F1 ultra-court 0.957	Realise
J13 - RoBERTa EN	Avril 2026	Fine-tuning RoBERTa V1/V2, F1 ultra-court 0.874	Realise
J14 - Pipeline hybride V8	Avril 2026	Meta-learner V5+V6+CamemBERT, F1 suspect +28%	Realise
J15 - Pipeline V9 cascade	Mai 2026	Pipeline 2 etapes fait/opinion, FP -67%	Realise
J16 - Documentation	Mai 2026	Rapport, guide utilisateur, CDC, RGPD	Realise

5.2 Perspectives d'evolution

Le projet a atteint le pipeline V9 (cascade fait/opinion + meta-learner V8). Les axes d'amélioration identifiés pour une éventuelle poursuite :

Axe	Description	Priorité
API REST	FastAPI pour l'inférence en temps réel (remplacer l'appel direct au pipeline)	Haute
Monitoring derive	Détection automatique du concept drift via <code>weekly_score_check.py</code> + alertes	Haute
Annotation complémentaire	Élargir le gold test set (500 -> 1 000+ posts) pour des évaluations plus robustes	Moyenne
Jeu de calibration indépendant	Séparer calibration (seuil) et évaluation pour éliminer le biais d'optimisation	Moyenne
Migration cloud	Déploiement sur infrastructure cloud (GCP/AWS) pour la scalabilité	Faible

6. Indicateurs de suivi (KPI projet)

6.1 KPI techniques

KPI	Méthode de mesure	Fréquence	Cible	Actuel
F1-score modèle	Cross-validation 5-fold	A chaque retraining	≥ 0.85	0.913
% fiable sur Bluesky	Distribution des prédictions sur 2 000 posts	Mensuel	60-85%	73.4%
Volume de posts collectés	<code>db.raw_posts.countDocuments()</code>	Quotidien	> 1 000/jour	~2 000/jour
Uptime collecteur	Logs de collecte	Mensuel	> 95%	~90% (estimé)
Temps d'inférence	Benchmark sur 1 000 textes	A chaque version	< 100ms/texte	~50ms
Empreinte carbone	CodeCarbon	A chaque entraînement	< 10 g CO ₂ (cumul)	6.14 g
Taille du dataset d'entraînement	Comptage	A chaque version	> 100 000	197 782

6.2 KPI projet

KPI	Méthode de mesure	Fréquence	Cible
Nombre de notebooks documentés	Comptage	Mensuel	9 (00-08)

Couverture de la documentation	Checklist des livrables	Trimestriel	100%
Nombre de risques ouverts critiques	Registre des risques	Mensuel	0
Conformite RGPD	Audit trimestriel	Trimestriel	100%
Satisfaction utilisateurs	Enquete (quand applicable)	Semestriel	> 7/10

7. Communication et reporting

7.1 Matrice de communication

Public	Contenu	Format	Frequence	Canal
Binome	Avancement, blocages, decisions	Point de synchronisation	Hebdomadaire	Visio / presentiel
Encadrement Master	Synthese, risques, jalons	Bilan d'avancement	Mensuel	Email / document
Utilisateurs	Nouvelles fonctionnalites, limites	Release notes	A chaque version	Email/doc
Regulateur	Conformite, mesures	Rapport AIPD	Annuel	Document formel

7.2 Modele de rapport d'avancement

RAPPORT D'AVANCEMENT - [Mois/Annee]

1. RESUME EXECUTIF (3 lignes max)
2. JALONS ATTEINTS CETTE PERIODE
3. METRIQUES CLES (F1, volume, uptime)
4. RISQUES ET ACTIONS
5. PROCHAINES ETAPES
6. DECISIONS REQUISES

8. Gestion du changement

8.1 Processus de changement

Tout changement significatif (nouveau dataset, modification d'architecture, changement de seuil) suit le processus :

1. DEMANDE
 - Description du changement propose
 - Justification (donnees, metriques, besoin metier)
 - Impact estime (performance, securite, conformite)
2. ANALYSE
 - Azelie evalue la faisabilite technique et l'impact sur les metriques
 - Discussion en binome sur l'impact planning et les risques

3. DECISION

- Validation conjointe en point de synchronisation
- Si impact conformite : relecture croisee
- Si impact performance : revue de modele en binome

4. IMPLEMENTATION

- Branche Git dediee
- Tests de non-regression
- Documentation mise a jour

5. VALIDATION

- Relecture par le second membre du binome
- Tests d'acceptation
- Merge et deploiement

8.2 Historique des changements majeurs

Date	Changement	Justification	Impact
Dec 2025	Creation du projet	Besoin initial	N/A
Jan 2026	Nettoyage biais Reuters	F1 biaise a 0.99 par data leakage	F1 reel mesurable
Jan 2026	Passage TensorFlow -> PyTorch	Incompatibilite Apple Silicon	Modele emotions fonctionnel
Fev 2026	Ajout features linguistiques (12)	Enrichir le signal au-dela du TF-IDF	+2 points F1 FR
Fev 2026	Integration emotions (7 features)	Signal emotionnel correle a la desinformation	+0.5 points F1
Fev 2026	3 datasets sociaux (V2)	Domain shift : 77% suspect sur Bluesky	73.4% fiable (vs 23%)
Mars 2026	Correction features ling. (V3)	5/12 features etaient nulles (bug preprocessing)	F1 +0.3%, Precision +19.3%
Avril 2026	Augmentation FR court (V4)	FR court F1=0.65 insuffisant pour Bluesky	FR court F1=0.86 (+32%), FR global F1=0.935
Avril 2026	Integration 10K posts FR sociaux synthetiques (V5)	FR court F1=0.86 encore insuffisant, dataset FR sous-represente	F1 global=0.913, FR court F1=0.904, FR=0.944, EN=0.894, dataset 197 782 textes (FR=86K/43.5%, EN=112K/56.5%)
Fev 2026	Seuil 0.44 (vs 0.50)	Calibration pour textes courts	+7 points de fiabilite Bluesky
Mars 2026	Dashboard glassmorphism	Amelioration UX/UI	Dashboard professionnel
Avril 2026	V6 style-only topic-agnostic	Biais thematique detecte sur gold set	FP reduits, approche complementaire
Avril 2026	V7 ensemble hybride + SHAP	Combiner V5+V6 avec explicabilite	Meta-learner, transparence totale
Avril 2026	V8 integration CamemBERT	3e signal semantique pour le francais	F1 suspect +28%

Mai 2026	V9 pipeline 2 etapes fait/opinion	Distinction fait/opinion comme facteur discriminant	FP -67%, kappa 3x
Mai 2026	Reequilibrage collecte (V3 collecteur)	Biais émotionnel (75% joie) et desequilibre FR/EN (87.5% EN)	28 termes FR + 16 EN, inference auto
Mai 2026	Refactoring Docker professionnel	Architecture non robuste (pas de healthcheck, demarrage non ordonne)	Healthchecks, depends_on conditionnel, PYTHONPATH unifie
Mai 2026	Pipeline XAI complet (src/explainability/)	Challenge "explicabilite pourrait aller plus loin" identifie en revue equipe	6 modules (1 450 LoC) : SHAP global beeswarm/dependance, attention CamemBERT, IG via Captum, decomposition exacte meta-learner V8, faithfulness AOPC. Uplift AOPC = +0.21 vs random (cible > +0.10). Mode

Document valide par la Direction Projet - Avril 2026

Reference : METH-THUM-2026-001 - Version 1.0