

Analyse du modèle ExpertFakeNewsDetector V2 par longueur de texte

Date : 2026-04-03

Modèle : ExpertFakeNewsDetector V2 (LogReg + TF-IDF 30k features + 12 linguistiques, sans émotions)

Seuil de décision : 0.44

Données évaluées : 94603 textes provenant de 5 sources

1. Sources de données

Source	Nombre	Fiable (0)	Suspect (1)	Type
ISOT	44,124	21,416	22,708	Articles longs EN
FakeNewsNet	22,596	16,987	5,609	Titres courts EN
CONSTRAINT	8,559	4,479	4,080	Tweets COVID EN
KaggleFR	9,483	4,837	4,646	Articles FR
CredibilityCorpus	9,841	7,522	2,319	Tweets FR+EN
Total	94,603	55,241	39,362	

2. Performance par segment de longueur

Segment	N	Accuracy	F1	Precision	Recall	TP	FP	TN	FN
Ultra-court (<15 mots)	24,533	0.8462	0.7472	0.8168	0.6885	5,574	1,250	15,187	2,522
Court (15-30 mots)	16,175	0.8915	0.8442	0.9153	0.7834	4,755	440	9,665	1,315
Moyen (30-100 mots)	13,228	0.9746	0.9415	0.9455	0.9376	2,704	156	10,188	180
Long (100-300 mots)	10,516	0.9835	0.9835	0.9960	0.9713	5,170	21	5,172	153
Très long (>300 mots)	30,151	0.9884	0.9897	0.9880	0.9915	16,844	204	12,958	145

Scores de crédibilité moyens par segment

Segment	Score moyen TP (vrais .	Score moyen TN (vrais .	Écart
Ultra-court (<15 mots)	0.1548	0.8260	0.6712
Court (15-30 mots)	0.1276	0.8782	0.7507
Moyen (30-100 mots)	0.1114	0.9297	0.8182
Long (100-300 mots)	0.0761	0.9276	0.8516

Très long (>300 mots)	0.0395	0.9024	0.8628
-----------------------	--------	--------	--------

> Interprétation : Le score de crédibilité est P(fiable). Un vrai suspect (TP) devrait avoir un score bas, un vrai fiable (TN) un score élevé. L'écart mesure la séparation entre les deux classes.

3. Performance par langue

Langue	N	Accuracy	F1	Precision	Recall	TP	FP	TN	FN
FR	13,216	0.8955	0.8463	0.9927	0.7375	3,801	28	8,034	1,353
EN	79,994	0.9404	0.9283	0.9401	0.9169	30,867	1,967	44,361	2,799
OTHER	1,393	0.8284	0.7603	0.8330	0.6993	379	76	775	163

Croisement longueur x langue

Langue	Segment	N	F1	Accuracy
FR	Ultra-court (<15 mots)	2 322	0.6498	0.7145
FR	Court (15-30 mots)	4 203	0.7389	0.8344
FR	Moyen (30-100 mots)	4 760	0.9880	0.9958
FR	Long (100-300 mots)	218	1.0000	1.0000
FR	Tres long (>300 mots)	1 713	0.9992	0.9988
EN	Ultra-court (<15 mots)	20 956	0.7626	0.8624
EN	Court (15-30 mots)	11 853	0.8771	0.9118
EN	Moyen (30-100 mots)	8 451	0.9221	0.9626
EN	Long (100-300 mots)	10 297	0.9828	0.9831
EN	Tres long (>300 mots)	28 437	0.9890	0.9878

> Point critique : Le croisement FR + ultra-court affiche un F1 de 0.6498, le pire resultat de toute l'analyse. C'est precisement le cas d'usage Bluesky (posts courts en francais).

4. Analyse de calibration

ECE (Expected Calibration Error) = 0.0492

> L'ECE mesure l'écart moyen entre la confiance du modèle et la précision réelle.

> Un ECE < 0.05 indique un modèle bien calibré. Un ECE > 0.10 suggère une sur-confiance ou sous-confiance.

Bin P(suspect)	N	P(suspect) prédit	Taux réel suspect	Écart
0.0-0.1	32,429	0.0354	0.0101	0.0253
0.1-0.2	10,621	0.1449	0.0538	0.0911
0.2-0.3	6,044	0.2461	0.1191	0.1270
0.3-0.4	3,974	0.3471	0.2262	0.1209
0.4-0.5	2,918	0.4481	0.3578	0.0903
0.5-0.6	2,467	0.5492	0.5440	0.0052
0.6-0.7	2,618	0.6514	0.7086	0.0571

0.7-0.8	2,967	0.7524	0.8362	0.0838
0.8-0.9	4,900	0.8558	0.9373	0.0816
0.9-1.0	25,665	0.9736	0.9947	0.0211

5. Mots les plus discriminants (coefficients TF-IDF)

Top 30 mots poussant vers SUSPECT (coef positif)

Rang	Mot	Coefficient
1	citron	+10.0172
2	coronavirus	+9.2530
3	trump	+7.6968
4	2017	+6.6059
5	2017 0	+6.1206
6	hollande	+6.0468
7	image	+5.9633
8	corona	+5.8379
9	obama	+5.6744
10	hidalgo	+5.6566
11	swineflu	+5.6353
12	machin	+5.3370
13	corse machin	+5.3259
14	south africa	+5.1263
15	swine	+5.0298
16	hillary	+4.9111
17	atm	+4.8533
18	swine flu	+4.7781
19	flu	+4.7700
20	lockdown	+4.6963
21	virus	+4.6444
22	covid 19	+4.5942
23	septembre	+4.3850
24	cancer	+4.3826
25	fact	+4.3230
26	le cancer	+4.2697
27	exclusif	+4.2410
28	janvier 2018	+4.2374
29	africa	+4.1622
30	read more	+4.0435

Top 30 mots poussant vers FIABLE (coef négatif)

Rang	Mot	Coefficient
------	-----	-------------

1	rt	-13.2763
2	said on	-6.9920
3	facebook twitter	-6.7568
4	partage facebook	-6.2593
5	partage facebook twitter	-6.2593
6	reuters	-5.7967
7	partage	-5.7754
8	said	-5.7056
9	u	-4.9355
10	on tuesday	-4.9224
11	on wednesday	-4.8582
12	â	-4.4788
13	on thursday	-4.4429
14	uefa	-4.3099
15	le	-4.2271
16	libération	-4.2146
17	on friday	-4.2088
18	on monday	-4.0033
19	said in	-3.9993
20	mardi	-3.9114
21	amp	-3.9105
22	and	-3.7984
23	u s	-3.7665
24	indiafightscorona	-3.6472
25	data	-3.6304
26	coronavirusupdates	-3.6156
27	said the	-3.5891
28	u s president	-3.5012
29	told reuters	-3.4785
30	libé	-3.4715

Coefficients des features linguistiques

Feature	Coefficient	Direction
lexical_diversity	-3.6434	FIABLE
numeric_density	+1.7577	SUSPECT
sensationalism_score	+0.3290	SUSPECT
has_url	+0.3277	SUSPECT
sentence_count	+0.2072	SUSPECT
avg_word_length	+0.1794	SUSPECT
word_count	-0.0004	FIABLE
avg_sentence_length	-0.0004	FIABLE
caps_ratio	+0.0000	FIABLE

exclamation_count	+0.0000	FIABLE
question_count	+0.0000	FIABLE
punct_density	+0.0000	FIABLE

6. Mise à jour recommandée des listes de mots sensationnalistes

Analyse critique des coefficients TF-IDF

Constat important : Les mots avec les plus forts coefficients SUSPECT ne sont pas des mots sensationnalistes au sens rhétorique. Ce sont principalement des marqueurs thématiques liés aux sujets sur-représentés dans les fake news du corpus d'entraînement :

- Santé/COVID : coronavirus (+9.25), corona (+5.84), virus (+4.64), covid 19 (+4.59), cancer (+4.38), flu (+4.77)
- Politique US : trump (+7.70), obama (+5.67), hillary (+4.91)
- Politique FR : hollande (+6.05), hidalgo (+5.66), machin (+5.34)
- Rumeurs spécifiques : citron (+10.02, remède miracle), swineflu (+5.64)

Ces mots ne doivent pas être ajoutés aux listes sensationnalistes car ils reflètent un biais thématique du corpus, pas un signal rhétorique de désinformation.

Efficacité des listes actuelles

SENSATIONALIST_EN (22 termes) -- 17/22 présents dans le vocabulaire TF-IDF :

Mot	Coefficient	Pertinence
hoax	+2.8695	Fort signal SUSPECT
breaking	+2.6089	Fort signal SUSPECT
exclusive	+1.2259	Signal SUSPECT
banned	+1.1625	Signal SUSPECT
secret	+0.9561	Signal SUSPECT
conspiracy	+0.6930	Signal SUSPECT
bombshell	+0.6364	Signal SUSPECT
mainstream media	+0.5707	Signal SUSPECT
shocking	+0.5023	Signal SUSPECT
deep state	+0.3555	Signal SUSPECT
exposed	+0.0471	Faible signal
alert	-0.0156	Non pertinent (neutre)
unbelievable	-0.0465	Non pertinent
wake up	-0.2124	Inversé (FIABLE)
revealed	-0.9083	Inversé (FIABLE)
scandal	-1.1914	Inversé (FIABLE)
urgent	-1.2988	Inversé (FIABLE)

Mots absents du vocabulaire TF-IDF : big pharma, censored, cover-up, coverup, they dont want

SENSATIONALIST_FR (52 termes) -- seulement 10/52 dans le vocabulaire TF-IDF :

Mot	Coefficient	Pertinence
-----	-------------	------------

exclusif	+4.2410	Tres fort signal SUSPECT
révélation	+2.6530	Fort signal SUSPECT
choc	+2.3483	Fort signal SUSPECT
complot	+2.2587	Fort signal SUSPECT
incroyable	+2.0868	Fort signal SUSPECT
alerte	+1.0243	Signal SUSPECT
corruption	-0.1841	Non pertinent
collusion	-0.7360	Inversé
urgent	-1.2988	Inversé
scandale	-1.5133	Inversé

42 termes FR absents du vocabulaire (expressions multi-mots, termes rares).

Recommandations concrètes

Mots à retirer ou reclasser (coefficient négatif = poussent vers FIABLE) :

- EN : scandal, revealed, urgent, wake up -- utilisés aussi en journalisme sérieux
- FR : scandale, urgent -- meme constat

Mots à ajouter (vrais signaux rhétoriques manquants) :

Pour SENSATIONALIST_EN :

- read more (coef +4.04) -- clickbait typique
- lockdown (coef +4.70) -- contexte COVID alarmiste

Pour SENSATIONALIST_FR :

- citron (coef +10.02) -- associé aux remèdes miracles
- Expressions de type "remède miracle", "guérison naturelle"

Restructuration recommandée : Transformer les listes en catégories pondérées plutôt qu'un simple comptage binaire :

- Clickbait : breaking, exclusive, read more, exclusif
- Complotisme : conspiracy, hoax, deep state, complot
- Alarmisme santé : virus, cancer, citron (remède miracle)

État actuel des listes

- SENSATIONALIST_EN : 22 termes (12 pertinents, 5 inversés, 5 absents du vocabulaire)
- SENSATIONALIST_FR : 52 termes (6 pertinents, 4 inversés/neutres, 42 absents du vocabulaire)

7. Recommandations pour la V3

Constats principaux

- Ecart massif par longueur : F1 passe de 0.7472 (ultra-court) à 0.9897 (tres long), soit un écart de 24 points. Le modèle perd significativement en performance sous 30 mots.
- FR sous-performe vs EN : F1 FR = 0.8463 vs F1 EN = 0.9283 (-8 points). Le recall FR (0.7375) est le point faible : le modèle manque 26% des fake news françaises.

- FR ultra-court est le pire cas : $F1 = 0.6498$ avec seulement 71% d'accuracy. C'est le cas d'usage le plus frequent sur Bluesky (posts courts en francais).
- Calibration correcte : $ECE = 0.0492$ (juste sous le seuil de 0.05). Les bins intermediaires (0.2-0.4) montrent une sur-confiance notable (ecart > 0.12).
- Biais thematique dans le TF-IDF : Les plus forts coefficients sont des topics (COVID, politique) et non des signaux rheoriques, ce qui indique un apprentissage partiel du style vs le sujet.
- Features linguistiques sous-exploitees : `lexical_diversity` (-3.64) est la plus forte feature linguistique ; `caps_ratio`, `exclamation_count`, `question_count` ont des coefficients quasi-nuls, suggerant que le nettoyage ML les a neutralisees.
- Mots fiables = biais residuel : `rt` (-13.28), `reuters` (-5.80), `said on` (-6.99) montrent que le modele utilise encore des marqueurs de source journalistique comme signal de fiabilite.

Pistes d'amelioration (priorite decroissante)

- Architecture a deux etages pour textes courts : Implementer un systeme de routing par longueur (< 30 mots vs ≥ 30 mots) avec un modele specialise court-texte. Envisager des embeddings pre-entraines (sentence-transformers) pour les textes courts ou le TF-IDF manque de signal.
- Supprimer le biais residuel de source : Les tokens `rt`, `reuters`, `said on`, `on tuesday/wednesday/...` ne sont pas des signaux de veracite. Les ajouter aux patterns de nettoyage dans `DatasetCleaner.AGENCY_PATTERNS` ou les exclure du vocabulaire TF-IDF via `stop_words`.
- Calibration post-hoc : Appliquer une regression isotonique sur les bins 0.1-0.4 ou l'ecart predit/reel depasse 0.09. Alternative : `CalibratedClassifierCV(method='isotonic')` sur un jeu de calibration separe.
- Renforcer les features linguistiques : Les features `caps_ratio`, `exclamation_count`, `question_count` sont neutralisees par le nettoyage `clean_for_ml()` qui convertit en minuscules et supprime la ponctuation. Calculer ces features avant le nettoyage (sur `text_original`) et non sur `text_clean`.
- Augmentation des donnees FR courtes : Le corpus FR est domine par des articles longs (KaggleFR). Ajouter des sources de tweets/posts FR (factuel vs desinformation) pour equilibrer. Le `CredibilityCorpus` FR est trop petit (3 799 textes).
- Seuil adaptatif par longueur : Utiliser un seuil plus conservateur (ex: 0.50) pour les textes < 30 mots ou la precision est plus elevee que le recall, et un seuil plus agressif (0.40) pour les textes longs.
- Restructurer les listes sensationnalistes : Passer d'un comptage binaire a un score pondere par categorie (clickbait, complotisme, alarmisme sante). Retirer les mots a coefficient negatif (scandal, urgent, scandale).
- Activer les features emotionnelles : Le modele V2 a ete entraine sans le module d'emotions (`use_emotions=False`). Tester l'impact des 7 features emotionnelles sur les textes courts ou les signaux TF-IDF sont faibles.