

Evolution des Modeles - Comparatif de Progression

Projet Thumalien - Social Media Intelligence & AI Monitor

Reference : EVOL-THUM-2026-001

Version : 1.0

Date : Avril 2026

Auteur : Thumalien Team - Direction Projet Data

1. Synthese executive

Ce document retrace l'evolution complete du pipeline de detection de desinformation Thumalien, de la version V1 (decembre 2025) a la version V4 + CamemBERT (avril 2026). Chaque iteration est analysee en termes de performances, d'avantages, d'inconvenients, de limites identifiees et de marges de progression exploitees dans la version suivante.

Tableau de synthese globale

Version	Date	F1 global	F1 FR court	Precision	Recall	Dataset	Innovation.
V1.0	Dec 2025	0.996 (biaise)	N/A	0.997	0.995	44 124 EN	Baseline TF-IDF
V1.5	Jan 2026	0.986	N/A	0.983	0.989	53 607 FR+EN	Bilingue + emotions
V2.0	Fev 2026	0.897	0.650	0.891	0.903	145 703	Datasets sociaux
V3.0	Mars 2026	0.900	0.650	0.891 (+19.3%)	0.910	145 703	Bug fix features
V4.0	Avril 2026	0.905	0.860	0.897	0.914	187 782	Augmentation FR court
CamemBERT	Avril 2026	0.950	0.901	0.969	0.931	22 540 FR	Transformer FR

2. Version 1.0 - Baseline anglophone (Decembre 2025)

2.1 Architecture

- Modele : TF-IDF (20 000 features, unigrams) + LogisticRegression
- Dataset : ISOT Fake News Dataset (44 124 articles EN)

- True.csv : 21 416 articles Reuters (label 0)
- Fake.csv : 22 708 articles (label 1)
- Split : 80/20 stratifie, 5-fold CV

2.2 Resultats

Metrique	Score
Accuracy	0.997
F1	0.996
Precision	0.997
Recall	0.995
ROC AUC	0.999

2.3 Avantages

- Mise en place rapide du pipeline end-to-end
- Scores apparemment excellents
- Architecture simple et interpretable

2.4 Inconvenients et limites

- CRITIQUE : Biais Reuters - Le modele apprenait a reconnaitre les marqueurs de style Reuters ("WASHINGTON (Reuters) -", bylines, credits) et non la veracite du contenu. 99.7% d'accuracy etait un artefact.
- Aucune capacite francaise - Dataset 100% anglais
- Aucun texte court - Tous les articles font > 100 mots, inutile pour des posts Bluesky
- Pas d'analyse emotionnelle

2.5 Diagnostic ayant mene a V1.5

Analyse des coefficients TF-IDF : les mots les plus predictifs etaient "reuters", "reporting by", "editing by" - des marqueurs de source, pas de contenu. Le modele ne detectait pas les fake news, il detectait Reuters.

3. Version 1.5 - Bilingue + Emotions (Janvier-Fevrier 2026)

3.1 Architecture

- Modele : TF-IDF (30 000 features, 1-3 grams, sublinear TF) + 12 features linguistiques + 7 features emotionnelles (MLP PyTorch) + LogisticRegression
- Dataset : 53 607 textes (ISOT debiaise + Kaggle FR 9 483 articles)
- Preprocessing : Suppression du biais Reuters (remove_agency_bias), nettoyage ML
- Emotions : MLP PyTorch bilingue (vocab 25K, embedding 64, 7 classes)
- Detection de langue : LanguageRouter (langdetect)

3.2 Resultats

Metrique	EN	FR
F1	0.985	0.982
Precision	0.982	0.978
Recall	0.989	0.986

3.3 Avantages

- Suppression effective du biais Reuters (F1 passe de 0.996 a 0.985 - metriques realistes)
- Support bilingue FR/EN
- Features linguistiques (caps_ratio, exclamation, sensationnalisme) independantes du contenu
- Analyse emotionnelle (7 emotions)

3.4 Inconvenients et limites

- Domain shift : Le modele, entraine sur des articles longs, classait 77% des posts Bluesky comme SUSPECTS car il ne connaissait pas le style "texte court"
- FR tres minoritaire : 9 483 articles FR / 44 124 EN = 18% seulement
- Pas de textes sociaux : Aucun tweet, post, ou titre dans les donnees d'entrainement
- F1 trompeusement eleve : Les metriques elevees reflétaient des donnees homogenes (articles vs articles), pas la capacite a traiter des posts courts

3.5 Diagnostic ayant mene a V2

Deploiement sur Bluesky : le modele classait "Lyon 2 - Marseille 1" comme SUSPECT. Le seuil 0.50 etait trop strict, et le modele n'avait jamais vu de textes < 50 mots.

4. Version 2.0 - Datasets sociaux + Seuil adapte (Fevrier 2026)

4.1 Architecture

- Modele : Identique a V1.5 (TF-IDF 30K + 12 ling. + 7 emo. + LogReg)
- Dataset : 145 703 textes
 - ISOT EN : 44 124 articles
 - Kaggle FR : 9 483 articles (x3 oversample = 28 449)
 - FakeNewsNet : 22 596 titres courts EN (GossipCop + PolitiFact)
 - CONSTRAINT : 8 559 tweets COVID EN
 - Credibility Corpus : 9 841 tweets FR+EN
- Seuil : Abaisse de 0.50 a 0.44 (optimise sur donnees Bluesky)
- Ponderation bilingue : sample_weight par frequence inverse de langue

4.2 Resultats

Metrique	Global	FR	EN
Accuracy	0.926	0.896	0.940

F1	0.897	0.846	0.928
Precision	0.891	0.993	0.940
Recall	0.903	0.738	0.917

Par longueur (FR) :

Segment	N	F1	Accuracy
Ultra-court (<15 mots)	2 322	0.650	0.715
Court (15-30 mots)	4 203	0.739	0.834
Moyen (30-100 mots)	4 760	0.988	0.996
Long (>100 mots)	1 931	0.999	0.999

4.3 Avantages

- Integration de donnees sociales (tweets, titres) = meilleure generalisation
- Seuil 0.44 adapte aux posts courts Bluesky
- 73.4% de posts classes comme fiables sur Bluesky reel (vs 23% en V1.5)
- Ponderation bilingue ameliore l'equilibre FR/EN

4.4 Inconvenients et limites

- FR ultra-court F1 = 0.650 - Inacceptable pour le cas d'usage Bluesky
- Recall FR = 0.738 - Rate 1 fake news FR sur 4
- Desequilibre FR/EN : 75% EN / 25% FR dans le dataset
- Pas de donnees FR sociales natives : KaggleFR = articles longs, pas de tweets FR
- Biais thematique residuel : Les mots "coronavirus", "trump" ont des coefficients TF-IDF tres eleves => biais topique

4.5 Diagnostic ayant mene a V3

Analyse des coefficients TF-IDF : 5 features linguistiques sur 12 avaient des coefficients exactement a 0.0000. Investigation : bug dans `_build_features()` - les features etaient calculees sur `text_clean` (minuscules, sans ponctuation) au lieu de `text_original`.

5. Version 3.0 - Correction features linguistiques (Mars 2026)

5.1 Modification

- Bug fix unique : Dans `_build_features()`, remplacement de `texts_clean` par `texts_original` pour le calcul des features linguistiques
- Features affectees : `caps_ratio`, `exclamation_count`, `question_count`, `punct_density`, `sentence_count` - ces 5 features etaient toujours a 0 en V2

5.2 Resultats

Metrique	V2	V3	Delta

Accuracy



0.926



0.926



+0.0%

F1	0.897	0.900	+0.3%
Precision	0.891	0.891	+0.0%
Recall	0.903	0.910	+0.8%

Impact majeur : Precision sur les textes courts

Le gain global est faible (+0.3% F1) mais la precision sur les textes suspects augmente significativement : +19.3% sur les cas ou les features linguistiques (majuscules, ponctuation emotive) font la difference.

5.3 Avantages

- Correction d'un bug critique : les features linguistiques fonctionnent enfin
- Le modele capte maintenant les MAJUSCULES, les !!!, les ? multiples
- Precision accrue sur les textes conspirationalistes a forte ponctuation

5.4 Inconvenients et limites

- FR court toujours F1 = 0.65 - Le bug fix seul ne suffit pas
- Memes donnees qu'en V2 : le desequilibre FR/EN persiste
- Le modele V2 etait incompatible avec les features corrigees : il fallait retrainner

5.5 Diagnostic ayant mene a V4

L'analyse par longueur et langue (notebook 10) a revele que le vrai probleme n'etait pas les features mais les donnees : aucune donnee FR courte dans l'entrainement. Les articles KaggleFR font en moyenne 180 mots. Bluesky = 5-20 mots.

6. Version 4.0 - Amelioration FR court (Avril 2026)

6.1 Modifications majeures

- Augmentation FR courte : Methode generate_fr_short_augmentation()
 - Extraction de la 1ere phrase de chaque article KaggleFR (3-25 mots)
 - Creation de titres synthetiques (8-12 premiers mots)
 - 9 193 textes generes, oversample x3 = 27 579 textes courts FR
- french_oversample : 3 -> 5 (doublement du poids FR)
- 3 nouvelles features linguistiques (15 au total) :
 - all_caps_words_ratio : ratio de mots en MAJUSCULES (signal fort posts sociaux)
 - interpellation_score : patterns "ouvrez les yeux", "wake up", "faites tourner"
 - is_short_text : indicateur binaire texte < 20 mots
- Vocabulaire sensationnaliste enrichi :
 - FR : +16 termes (plandémie, graphène, marionnettes, traîtres, partagez massivement...)
 - EN : +3 termes (must watch, share before deleted, viral)
- max_iter : 5000 -> 10000 (convergence complete sur dataset plus gros)

6.2 Dataset V4

Source	Textes bruts	Oversample	Total	Langue
ISOT	43 767	x1	43 767	EN
Kaggle FR	7 250	x5	36 250	FR
FakeNewsNet	21 770	x2	43 540	EN
CONSTRAINT	8 542	x2	17 084	EN
Credibility Corpus	9 781	x2	19 562	FR+EN
Augmentation FR courte	9 193	x3	27 579	FR
TOTAL			187 782	FR=76K (40%), EN=112K (60%)

6.3 Resultats

Metrique	V3	V4	Delta
Accuracy CV	0.926	0.930	+0.4%
F1 CV	0.900	0.905	+0.6%
Precision	0.891	0.897	+0.7%
Recall	0.910	0.914	+0.4%

Par langue :

Langue	V3 F1	V4 F1	V3 Recall	V4 Recall	Delta F1
FR	0.846	0.935	0.738	0.942	+10.5%
EN	0.928	0.889	0.917	0.898	-4.2%

Par longueur FR (le gain critique) :

Segment	V3 F1	V4 F1	Delta
Ultra-court (<15 mots)	0.650	0.860	+32.3%
Court (15-30 mots)	0.739	0.946	+28.0%
Moyen (30-100 mots)	0.988	0.972	-1.6%
Long (100-300 mots)	1.000	1.000	=
Tres long (>300 mots)	0.999	0.999	=

6.4 Avantages

- Gain massif sur FR court : +32% F1 sur ultra-court, +28% sur court
- Recall FR corrige : 0.74 -> 0.94 (ne rate plus que 6% des fake news FR)
- Dataset plus equilibre : 40% FR au lieu de 25%
- Nouvelles features discriminantes pour les posts sociaux (CAPS, interpellation)

6.5 Inconvenients et limites

- Trade-off EN : L'EN perd ~4% F1 sur les textes courts (le modele favorise davantage le FR)
- Augmentation synthetique : Les textes courts generes sont des extraits d'articles, pas de vrais posts sociaux FR
- Biais thematique persistant : Le TF-IDF capte "vaccin", "climat" comme signaux suspects

- Convergence : Le solver LBFGS atteint 5000 iterations sans converger sur 188K textes (corrige par max_iter=10000)

6.6 Health check V4

Texte test	Score	Label	Attendu	Statut
New study published in Nature...	0.634	FIABLE	FIABLE	PASS
EXPOSED: Secret labs use 5G...	0.057	SUSPECT	SUSPECT	PASS
Le CNRS publie une etude...	0.956	FIABLE	FIABLE	PASS
SCANDALE: le gouvernement cache...	0.026	SUSPECT	SUSPECT	PASS
The weather is nice today	0.880	FIABLE	FIABLE	PASS

5/5 PASS

7. CamemBERT - Fine-tuning Transformer FR (Avril 2026)

7.1 Architecture

- Modele de base : CamemBERT-base (110M parametres, pre-entraine sur 138 Go de texte francais)
- Fine-tuning : Couches 9-11 + classification head (768 -> 256 -> 2)
- Parametres geles : Couches 0-8 + embeddings (80.2% geles, 19.8% entrainables)
- Surpoids : x2 sur les textes courts (< 30 mots) dans la loss
- Optimisation : AdamW, LR 2e-5 (base) / 2e-4 (head), cosine annealing
- Dataset : 22 540 textes FR uniquement (sans oversample)

7.2 Courbe d'entrainement

Epoch	Train Loss	Train Acc	Val F1	Val Acc
1	0.414	0.899	0.927	0.958
2	0.177	0.963	0.944	0.968
3	0.138	0.971	0.951	0.971

7.3 Resultats holdout

Metrique	Score
Accuracy	0.971
F1	0.950
Precision	0.969

Recall	0.931
--------	-------

Par longueur :

Segment	N test	Accuracy	F1	Precision	Recall
Ultra-court (<15 mots)	1 912	0.939	0.901	0.939	0.867
Court (15-30 mots)	1 330	0.992	0.980	0.982	0.978
Moyen (30-100 mots)	865	0.998	0.994	1.000	0.987
Long (>100 mots)	401	0.995	0.997	1.000	0.993

7.4 Avantages

- F1 ultra-court = 0.901 : meilleur score jamais atteint sur les textes courts FR
- Compréhension sémantique : CamemBERT capte ironie, sous-entendus, formulations conspirationnistes
- Pas besoin d'oversample : Le modèle pré-entraîne généralise mieux avec moins de données
- Précision élevée (0.969) : très peu de faux positifs

7.5 Inconvénients et limites

- Taille du modèle : ~450 MB (vs ~45 MB pour V4 TF-IDF) - impact sur le déploiement
- Inférence plus lente : ~50ms/texte (vs ~1ms pour TF-IDF)
- Généralisation hors-distribution : 3/6 au test rapide sur des phrases inventées - le modèle apprend les patterns du dataset KaggleFR mais généralise mal aux formulations qu'il n'a jamais vues
- FR uniquement : Ne traite pas l'anglais (nécessite un modèle séparé ou pipeline hybride)
- Recall = 0.867 sur ultra-court : Rate encore 13% des fake news FR très courtes

7.6 Analyse des échecs CamemBERT

Les 3 échecs au test rapide révèlent une limite structurelle :

Texte	Score	Prediction	Attendu	Analyse
"URGENT: puces 5G dans les vaccins !!"	0.716	FIABLE	SUSPECT	Le mot "vaccin" + contexte court = pas assez de signal discriminant
"La mairie organise une fête ce weekend"	0.256	SUSPECT	FIABLE	Texte trop court et neutre, le modèle sur-classifie en suspect
"Partagez avant censure !! Revelations choc"	0.984	FIABLE	SUSPECT	Pattern non vu en entraînement (KaggleFR = articles, pas posts sociaux)

Cause racine : Le dataset KaggleFR contient des articles de presse formels, pas des posts de réseaux sociaux. Les

formulations typiques des fake news FR sur les reseaux ("partagez", "avant censure", "puces 5G") sont absentes du corpus d'entrainement.

8. Comparaison globale multi-versions

8.1 Evolution du F1 par version

Version	F1 global	F1 FR global	F1 FR court (<15 m.	F1 EN global
V1.0	0.996 (biaise)	N/A	N/A	0.996
V1.5	0.986	0.982	N/A	0.985
V2.0	0.897	0.846	0.650	0.928
V3.0	0.900	0.846	0.650	0.928
V4.0	0.905	0.935	0.860	0.889
CamemBERT	0.950 (FR)	0.950	0.901	N/A

8.2 Evolution de la taille du dataset

Version	Total	FR	EN	% FR	Textes courts
V1.0	44 124	0	44 124	0%	0
V1.5	53 607	9 483	44 124	18%	~0
V2.0	145 703	~36 000	~110 000	25%	~40 000
V4.0	187 782	76 023	111 759	40%	~67 000

8.3 Evolution des features

Version	TF-IDF	Linguistiques	Emotionnelles	Transformer	Total
V1.0	20 000	0	0	0	20 000
V1.5	30 000	12	7	0	30 019
V2.0	30 000	12 (5 nulles)	7	0	30 019
V3.0	30 000	12 (corrigees)	7	0	30 019
V4.0	30 000	15	7	0	30 022
CamemBERT	0	0	0	768 (CLS)	768

9. Marges de progression identifiees

9.1 Donnees

Axe	Etat actuel	Objectif	Impact estime
Dataset FR social media natif	Aucun (augmentation synthetique)	Integrer 10K+ tweets FR fact-checkes	F1 FR court +5-10%

Donnees Bluesky annotees	0	Annoter 2000+ posts Bluesky (fiable/suspect)	Reduction du domain shift
Augmentation par paraphrase	Non implementee	LLM pour paraphraser les fake news FR	Diversite des formulations
Datasets FR émergents	Non explores	FakeCovid FR, Debunking FR corpora	+5K-20K textes FR

9.2 Modeles

Axe	Etat actuel	Objectif	Impact estime
Pipeline hybride TF-IDF + CamemBERT	Modeles separes	Combiner les scores (stacking)	F1 FR court > 0.92
CamemBERT sur donnees sociales	Fine-tune sur articles FR	Fine-tune sur tweets/posts FR	Meilleure generalisation
Modele EN dedie (RoBERTa)	TF-IDF seul pour EN	Fine-tuner RoBERTa-base pour EN	F1 EN court > 0.85
Apprentissage few-shot	Non implementee	Adapter avec 50-100 exemples Bluesky	Adaptation rapide au domaine
Distillation	CamemBERT 110M params	Distiller en modele leger (TinyBERT FR)	Inference x10, <50 MB

9.3 Features et preprocessing

Axe	Etat actuel	Objectif	Impact estime
Seuil adaptatif par langue	Seuil unique 0.44	Seuil FR / seuil EN differences	Precision +2-5%
Features de source	Non implementees	Reputation du compte, age, followers	Reduction faux positifs
Features temporelles	Non implementees	Heure de publication, viralite	Detection precoce
Embeddings cross-lingues	Non implements	paraphrase-multilingual-MiniLM	Un seul modele FR+EN

9.4 Priorites recommandees

- Court terme (1 semaine) : Implementer le pipeline hybride (stacking V4 + CamemBERT)
- Moyen terme (1 mois) : Collecter et annoter 2000 posts Bluesky FR, retrainner CamemBERT
- Long terme (3 mois) : Modele cross-lingue unique avec embeddings transformer + distillation

10. Lecons apprises

10.1 Lecons techniques

- Les metriques elevees ne garantissent pas la qualite : V1.0 affichait 99.6% F1 mais ne fonctionnait pas du tout. Il faut toujours evaluer sur des donnees representatifs du cas d'usage reel.
- Le preprocessing peut neutraliser les features : Le bug V2 (features calculees sur texte nettoye) etait invisible car les metriques globales etaient bonnes. Seule l'analyse fine des coefficients l'a revele.
- L'augmentation de donnees compense partiellement le manque de donnees natives : V4 prouve qu'on peut ameliorer significativement les performances FR court (+32%) par augmentation synthetique, mais les limites de generalisation (test rapide CamemBERT 3/6) montrent que rien ne remplace des donnees reelles du domaine cible.
- Les transformers ne sont pas une solution magique : CamemBERT excelle sur les donnees du meme type que l'entrainement mais echoue sur des formulations hors-distribution. Le TF-IDF V4 + features linguistiques est plus robuste sur les patterns explicites (MAJUSCULES, !!, mots sensationnalistes).

10.2 Lecons methodologiques

- Evaluer par segment : Les metriques globales masquent les faiblesses. L'evaluation par langue x longueur a ete decisive pour identifier le probleme FR court.
- Iterer rapidement : 5 versions en 4 mois, chacune construite sur les diagnostics de la precedente. Le cycle "analyse des erreurs -> hypothese -> correction -> evaluation" est le moteur de progression.
- Documenter les decisions : Chaque choix (seuil, oversample, features) a une raison documentee. Cela facilite la reproduction et l'audit.

11. Conclusion

Le pipeline Thumalien est passe d'un modele biaise inutilisable (V1, F1 = 0.996 artificiel) a un systeme bilingue performant (V4 + CamemBERT, F1 FR court = 0.90). Les axes d'amelioration sont clairs : donnees FR sociales natives, pipeline hybride, et evaluation continue sur des posts Bluesky reels.

La marge de progression la plus importante reside dans les donnees, pas dans les algorithmes. Un dataset de 5000 tweets FR fact-checkes aurait probablement plus d'impact que n'importe quelle amelioration architecturale.