
THUMALIEN

Pipeline NLP de detection de fake news sur Bluesky

07 Evolution Modeles Comparatif

Formation : Mastere Big Data & IA - Sup de Vinci

Equipe : Azelie Bernard, Sebastien Lazcanotegui

Annee : 2025-2026

Version : Mai 2026

Evolution des Modeles - Comparatif de Progression

Projet Thumalien - Social Media Intelligence & AI Monitor

Reference : EVOL-THUM-2026-001

Version : 1.0

Date : Avril 2026

Auteur : Thumalien Team - Direction Projet Data

1. Synthese executive

Ce document retrace l'evolution complete du pipeline de detection de desinformation Thumalien, de la version V1 (decembre 2025) a la version V5 + CamemBERT (avril 2026). Chaque iteration est analysee en termes de performances, d'avantages, d'inconvenients, de limites identifiees et de marges de progression exploitees dans la version suivante.

Tableau de synthese globale

Version	Date	F1 global	F1 FR glo.	F1 EN glo.	F1 FR cou.	F1 EN cou.	Dataset	Innovatio.
V1.0	Dec 2025	0.996 (biaise)	N/A	0.996 (biaise)	N/A	N/A	44 124 EN	Baseline TF-IDF
V1.5	Jan 2026	0.986	0.982	0.985	N/A	N/A	53 607 FR+EN	Bilingue + emotions
V2.0	Fev 2026	0.897	0.846	0.928	0.650	0.763	145 703	Datasets sociaux
V3.0	Mars 2026	0.900	0.846	0.928	0.650	0.763	145 703	Bug fix features
V4.0	Avril 2026	0.905	0.935	0.889	0.860	0.752	187 782	Augmentation FR court
CamemBERT V1	Avril 2026	0.950 (FR)	0.950	N/A	0.901	N/A	22 540 FR	Transformer FR
V5.0	Avril 2026	0.913	0.944	0.894	0.904	0.774	197 782	+10K FR social synthetique
CamemBERT V2	Avril 2026	0.966 (FR)	0.966	N/A	0.957	N/A	32 540 FR	+10K FR social, test 9/10
Hybride P1	Avril 2026	0.916	0.949	0.895	0.909	0.773	197 782	Stacking V5+CamemBERT V2

RoBERTa EN V1	Avril 2026	0.940 (EN)	N/A	0.940	N/A	0.838	111 759 EN	Transformer EN, test 6/10	
RoBERTa EN V2	Avril 2026	0.944 (EN)	N/A	0.944	N/A	0.874	121 759 EN	+10K social, 16/18	EN test

2. Version 1.0 - Baseline anglophone (Decembre 2025)

2.1 Architecture

- Modele : TF-IDF (20 000 features, unigrams) + LogisticRegression
- Dataset : ISOT Fake News Dataset (44 124 articles EN)
 - True.csv : 21 416 articles Reuters (label 0)
 - Fake.csv : 22 708 articles (label 1)
- Split : 80/20 stratifie, 5-fold CV

2.2 Resultats

Metrique	Score
Accuracy	0.997
F1	0.996
Precision	0.997
Recall	0.995
ROC AUC	0.999

2.3 Avantages

- Mise en place rapide du pipeline end-to-end
- Scores apparemment excellents
- Architecture simple et interpretable

2.4 Inconvenients et limites

- CRITIQUE : Biais Reuters - Le modele apprenait a reconnaitre les marqueurs de style Reuters ("WASHINGTON (Reuters) -", bylines, credits) et non la veracite du contenu. 99.7% d'accuracy etait un artefact.
- Aucune capacite francaise - Dataset 100% anglais
- Aucun texte court - Tous les articles font > 100 mots, inutile pour des posts Bluesky
- Pas d'analyse emotionnelle

2.5 Diagnostic ayant mene a V1.5

Analyse des coefficients TF-IDF : les mots les plus predictifs etaient "reuters", "reporting by", "editing by" - des

marqueurs de source, pas de contenu. Le modele ne detectait pas les fake news, il detectait Reuters.

3. Version 1.5 - Bilingue + Emotions (Janvier-Fevrier 2026)

3.1 Architecture

- Modele : TF-IDF (30 000 features, 1-3 grams, sublinear TF) + 12 features linguistiques + 7 features emotionnelles (MLP PyTorch) + LogisticRegression
- Dataset : 53 607 textes (ISOT debiaise + Kaggle FR 9 483 articles)
- Preprocessing : Suppression du biais Reuters (remove_agency_bias), nettoyage ML
- Emotions : MLP PyTorch bilingue (vocab 25K, embedding 64, 7 classes)
- Detection de langue : LanguageRouter (langdetect)

3.2 Resultats

Metrique	EN	FR
F1	0.985	0.982
Precision	0.982	0.978
Recall	0.989	0.986

3.3 Avantages

- Suppression effective du biais Reuters (F1 passe de 0.996 a 0.985 - metriques realistes)
- Support bilingue FR/EN
- Features linguistiques (caps_ratio, exclamation, sensationnalisme) independantes du contenu
- Analyse emotionnelle (7 emotions)

3.4 Inconvenients et limites

- Domain shift : Le modele, entraine sur des articles longs, classait 77% des posts Bluesky comme SUSPECTS car il ne connaissait pas le style "texte court"
- FR tres minoritaire : 9 483 articles FR / 44 124 EN = 18% seulement
- Pas de textes sociaux : Aucun tweet, post, ou titre dans les donnees d'entrainement
- F1 trompeusement eleve : Les metriques elevees reflétaient des donnees homogenes (articles vs articles), pas la capacite a traiter des posts courts

3.5 Diagnostic ayant mene a V2

Deploiement sur Bluesky : le modele classait "Lyon 2 - Marseille 1" comme SUSPECT. Le seuil 0.50 etait trop strict, et le modele n'avait jamais vu de textes < 50 mots.

4. Version 2.0 - Datasets sociaux + Seuil adapte (Fevrier 2026)

4.1 Architecture

- Modele : Identique a V1.5 (TF-IDF 30K + 12 ling. + 7 emo. + LogReg)
- Dataset : 145 703 textes
 - ISOT EN : 44 124 articles
 - Kaggle FR : 9 483 articles (x3 oversample = 28 449)
 - FakeNewsNet : 22 596 titres courts EN (GossipCop + PolitiFact)
 - CONSTRAINT : 8 559 tweets COVID EN
 - Credibility Corpus : 9 841 tweets FR+EN
- Seuil : Abaisse de 0.50 a 0.44 (optimise sur donnees Bluesky)
- Ponderation bilingue : sample_weight par frequence inverse de langue

4.2 Resultats

Metrique	Global	FR	EN
Accuracy	0.926	0.896	0.940
F1	0.897	0.846	0.928
Precision	0.891	0.993	0.940
Recall	0.903	0.738	0.917

Par longueur (FR) :

Segment	N	F1	Accuracy
Ultra-court (<15 mots)	2 322	0.650	0.715
Court (15-30 mots)	4 203	0.739	0.834
Moyen (30-100 mots)	4 760	0.988	0.996
Long (>100 mots)	1 931	0.999	0.999

Par longueur (EN) :

Segment	N	F1	Accuracy
Ultra-court (<15 mots)	4 519	0.763	0.804
Court (15-30 mots)	5 131	0.849	0.895
Moyen (30-100 mots)	6 042	0.971	0.982
Long (>100 mots)	6 548	0.997	0.998

Analyse EN : L'anglais beneficie de donnees sociales natives (FakeNewsNet titres, CONSTRAINT tweets) mais les textes ultra-courts EN restent a F1 = 0.763. Le volume superieur de donnees EN (75% du dataset) compense partiellement.

4.3 Avantages

- Integration de donnees sociales (tweets, titres) = meilleure generalisation
- Seuil 0.44 adapte aux posts courts Bluesky
- 73.4% de posts classes comme fiables sur Bluesky reel (vs 23% en V1.5)
- Ponderation bilingue ameliore l'equilibre FR/EN

4.4 Inconvenients et limites

- FR ultra-court F1 = 0.650 - Inacceptable pour le cas d'usage Bluesky
- EN ultra-court F1 = 0.763 - Meilleur que FR mais encore insuffisant pour un monitoring fiable
- Recall FR = 0.738 - Rate 1 fake news FR sur 4
- Recall EN = 0.917 - Correct mais pourrait beneficier d'un transformer dedie
- Desequilibre FR/EN : 75% EN / 25% FR dans le dataset
- Pas de donnees FR sociales natives : KaggleFR = articles longs, pas de tweets FR
- Biais thematique residuel : Les mots "coronavirus", "trump" ont des coefficients TF-IDF tres eleves => biais topique

4.5 Diagnostic ayant mene a V3

Analyse des coefficients TF-IDF : 5 features linguistiques sur 12 avaient des coefficients exactement a 0.0000. Investigation : bug dans `_build_features()` - les features etaient calculees sur `text_clean` (minuscules, sans ponctuation) au lieu de `text_original`.

5. Version 3.0 - Correction features linguistiques (Mars 2026)

5.1 Modification

- Bug fix unique : Dans `_build_features()`, remplacement de `texts_clean` par `texts_original` pour le calcul des features linguistiques
- Features affectees : `caps_ratio`, `exclamation_count`, `question_count`, `punct_density`, `sentence_count` - ces 5 features etaient toujours a 0 en V2

5.2 Resultats

Metrique	V2	V3	Delta
Accuracy	0.926	0.926	+0.0%
F1	0.897	0.900	+0.3%
Precision	0.891	0.891	+0.0%
Recall	0.903	0.910	+0.8%

Impact par langue :

Langue	V2 F1	V3 F1	Delta
FR	0.846	0.846	+0.0%
EN	0.928	0.928	+0.0%

Le gain global est faible (+0.3% F1). L'EN n'est pas impacte par le bug fix car les features linguistiques (`caps_ratio`, `exclamation_count`) avaient un poids marginal face au volume TF-IDF EN. Le FR global ne bouge pas non plus, mais la precision sur les textes suspects FR augmente significativement : +19.3% sur les cas ou les features linguistiques (majuscules, ponctuation emotive) font la difference.

5.3 Avantages

- Correction d'un bug critique : les features linguistiques fonctionnent enfin
- Le modele capte maintenant les MAJUSCULES, les !!!, les ? multiples
- Precision accrue sur les textes conspirationalistes a forte ponctuation

5.4 Inconvenients et limites

- FR court toujours $F1 = 0.65$ - Le bug fix seul ne suffit pas
- EN court inchange $F1 = 0.763$ - Les features linguistiques ne compensent pas le manque de volume EN court
- Memes donnees qu'en V2 : le desequilibre FR/EN persiste
- Le modele V2 etait incompatible avec les features corrigees : il fallait retrainner

5.5 Diagnostic ayant mene a V4

L'analyse par longueur et langue (notebook 10) a revele que le vrai probleme n'etait pas les features mais les donnees : aucune donnee FR courte dans l'entrainement. Les articles KaggleFR font en moyenne 180 mots. Bluesky = 5-20 mots.

6. Version 4.0 - Amelioration FR court (Avril 2026)

6.1 Modifications majeures

- Augmentation FR courte : Methode `generate_fr_short_augmentation()`
 - Extraction de la 1ere phrase de chaque article KaggleFR (3-25 mots)
 - Creation de titres synthetiques (8-12 premiers mots)
 - 9 193 textes generes, oversample $\times 3 = 27\,579$ textes courts FR
- french_oversample : 3 -> 5 (doublement du poids FR)
- 3 nouvelles features linguistiques (15 au total) :
 - all_caps_words_ratio : ratio de mots en MAJUSCULES (signal fort posts sociaux)
 - interpellation_score : patterns "ouvrez les yeux", "wake up", "faites tourner"
 - is_short_text : indicateur binaire texte < 20 mots
- Vocabulaire sensationnaliste enrichi :
 - FR : +16 termes (plandémie, graphène, marionnettes, traîtres, partagez massivement...)
 - EN : +3 termes (must watch, share before deleted, viral)
- max_iter : 5000 -> 10000 (convergence complete sur dataset plus gros)

6.2 Dataset V4

Source	Textes bruts	Oversample	Total	Langue
ISOT	43 767	x1	43 767	EN
Kaggle FR	7 250	x5	36 250	FR
FakeNewsNet	21 770	x2	43 540	EN
CONSTRAINT	8 542	x2	17 084	EN
Credibility Corpus	9 781	x2	19 562	FR+EN

Augmentation FR courte	9 193	x3	27 579	FR
TOTAL			187 782	FR=76K (40%), EN=112K (60%)

6.3 Resultats

Metrique	V3	V4	Delta
Accuracy CV	0.926	0.930	+0.4%
F1 CV	0.900	0.905	+0.6%
Precision	0.891	0.897	+0.7%
Recall	0.910	0.914	+0.4%

Par langue :

Langue	V3 F1	V4 F1	V3 Recall	V4 Recall	Delta F1
FR	0.846	0.935	0.738	0.942	+10.5%
EN	0.928	0.889	0.917	0.898	-4.2%

Par longueur FR (le gain critique) :

Segment	V3 F1	V4 F1	Delta
Ultra-court (<15 mots)	0.650	0.860	+32.3%
Court (15-30 mots)	0.739	0.946	+28.0%
Moyen (30-100 mots)	0.988	0.972	-1.6%
Long (100-300 mots)	1.000	1.000	=
Tres long (>300 mots)	0.999	0.999	=

Par longueur EN (le trade-off) :

Segment	V3 F1	V4 F1	Delta
Ultra-court (<15 mots)	0.763	0.752	-1.4%
Court (15-30 mots)	0.849	0.831	-2.1%
Moyen (30-100 mots)	0.971	0.958	-1.3%
Long (100-300 mots)	0.997	0.993	-0.4%
Tres long (>300 mots)	0.998	0.996	-0.2%

Analyse du trade-off EN : La V4 sacrifie 1-2% de F1 EN sur tous les segments. Ce recul est attendu : l'augmentation du poids FR (french_oversample x5) et l'injection de 27K textes courts FR reequilibrant le modele vers le francais. Le TF-IDF partage (30K features bilingues) a un espace de representation fini, et les features FR supplementaires "poussent" certains patterns EN. Ce trade-off est acceptable car le FR court etait le goulot d'etranglement critique du pipeline.

6.4 Avantages

- Gain massif sur FR court : +32% F1 sur ultra-court, +28% sur court
- Recall FR corrige : 0.74 -> 0.94 (ne rate plus que 6% des fake news FR)
- Dataset plus equilibre : 40% FR au lieu de 25%

- Nouvelles features discriminantes pour les posts sociaux (CAPS, interpellation)

6.5 Inconvenients et limites

- Trade-off EN generalise : L'EN perd ~4% F1 global (0.928 -> 0.889) et ~1-2% sur chaque segment de longueur. Le modele bilingue unique a un espace de representation partage : ameliorer le FR degrade mecaniquement l'EN.
- EN ultra-court F1 = 0.752 : Regression de 1.4% par rapport a V3. Les textes courts EN (titres FakeNewsNet, tweets CONSTRAINT) beneficient moins des nouvelles features orientees FR (interpellation_score contient des patterns FR).
- Augmentation synthetique : Les textes courts generes sont des extraits d'articles, pas de vrais posts sociaux FR
- Biais thematique persistant : Le TF-IDF capte "vaccin", "climat" comme signaux suspects
- Convergence : Le solver LBFGS atteint 5000 iterations sans converger sur 188K textes (corrige par max_iter=10000)
- Pas de transformer EN : L'anglais n'a pas d'equivalent CamemBERT. Un RoBERTa fine-tune pourrait recuperer les 4% perdus sur EN.

6.6 Health check V4

Texte test	Score	Label	Attendu	Statut
New study published in Nature...	0.634	FIABLE	FIABLE	PASS
EXPOSED: Secret labs use 5G...	0.057	SUSPECT	SUSPECT	PASS
Le CNRS publie une etude...	0.956	FIABLE	FIABLE	PASS
SCANDALE: le gouvernement cache...	0.026	SUSPECT	SUSPECT	PASS
The weather is nice today	0.880	FIABLE	FIABLE	PASS

5/5 PASS

7. CamemBERT - Fine-tuning Transformer FR (Avril 2026)

7.1 Architecture

- Modele de base : CamemBERT-base (110M parametres, pre-entraine sur 138 Go de texte francais)
- Fine-tuning : Couches 9-11 + classification head (768 -> 256 -> 2)
- Parametres geles : Couches 0-8 + embeddings (80.2% geles, 19.8% entrainables)
- Surpoids : x2 sur les textes courts (< 30 mots) dans la loss
- Optimisation : AdamW, LR 2e-5 (base) / 2e-4 (head), cosine annealing
- Dataset : 22 540 textes FR uniquement (sans oversample)

7.2 Courbe d'entrainement

Epoch	Train Loss	Train Acc	Val F1	Val Acc
1	0.414	0.899	0.927	0.958
2	0.177	0.963	0.944	0.968
3	0.138	0.971	0.951	0.971

7.3 Resultats holdout

Metrique	Score
Accuracy	0.971
F1	0.950
Precision	0.969
Recall	0.931

Par longueur :

Segment	N test	Accuracy	F1	Precision	Recall
Ultra-court (<15 mots)	1 912	0.939	0.901	0.939	0.867
Court (15-30 mots)	1 330	0.992	0.980	0.982	0.978
Moyen (30-100 mots)	865	0.998	0.994	1.000	0.987
Long (>100 mots)	401	0.995	0.997	1.000	0.993

7.4 Avantages

- F1 ultra-court = 0.901 : meilleur score jamais atteint sur les textes courts FR
- Comprehension semantique : CamemBERT capte ironie, sous-entendus, formulations conspirationnistes
- Pas besoin d'oversample : Le modele pre-entraine generalise mieux avec moins de donnees
- Precision elevee (0.969) : tres peu de faux positifs

7.5 Inconvenients et limites

- Taille du modele : ~450 MB (vs ~45 MB pour V4 TF-IDF) - impact sur le deploiement
- Inference plus lente : ~50ms/texte (vs ~1ms pour TF-IDF)
- Generalisation hors-distribution : 3/6 au test rapide sur des phrases inventees - le modele apprend les patterns du dataset KaggleFR mais generalise mal aux formulations qu'il n'a jamais vues
- FR uniquement : Ne traite pas l'anglais (necessite un modele separe ou pipeline hybride)
- Recall = 0.867 sur ultra-court : Rate encore 13% des fake news FR tres courtes

7.6 Analyse des echecs CamemBERT

Les 3 echecs au test rapide revelent une limite structurelle :

Texte	Score	Prediction	Attendu	Analyse
-------	-------	------------	---------	---------

"URGENT: puces 5G dans les vaccins !!"	0.716	FIABLE	SUSPECT	Le mot "vaccin" + contexte court = pas assez de signal discriminant
"La mairie organise une fete ce weekend"	0.256	SUSPECT	FIABLE	Texte trop court et neutre, le modele sur-classifie en suspect
"Partagez avant censure !! Revelations choc"	0.984	FIABLE	SUSPECT	Pattern non vu en entraînement (KaggleFR = articles, pas posts sociaux)

Cause racine : Le dataset KaggleFR contient des articles de presse formels, pas des posts de reseaux sociaux. Les formulations typiques des fake news FR sur les reseaux ("partagez", "avant censure", "puces 5G") sont absentes du corpus d'entrainement.

7.7 CamemBERT V2 - Re-fine-tuning avec donnees FR sociales (Avril 2026)

Suite au diagnostic des echecs V1 (section 7.6), le CamemBERT a ete re-fine-tune en incluant les 10 000 posts FR sociaux synthetiques dans les donnees d'entrainement. C'est la realisation de la preconisation P2.

Dataset V2 : 32 540 textes FR (vs 22 540 en V1) - inclut les 10K posts sociaux synthetiques

Courbe d'entrainement :

Epoch	Train Loss	Train Acc	Val F1	Val Acc
1	0.343	0.921	0.961	0.973
2	0.140	0.973	0.970	0.979
3	0.105	0.980	0.970	0.979

Resultats holdout :

Metrique	V1	V2	Delta
Accuracy	0.971	0.976	+0.5%
F1	0.950	0.966	+1.7%
Precision	0.969	0.969	=
Recall	0.931	0.964	+3.5%

Par longueur :

Segment	V1 F1	V2 F1	Delta
Ultra-court (<15 mots)	0.901	0.957	+6.2%
Court (15-30 mots)	0.980	0.970	-1.0%
Moyen (30-100 mots)	0.994	0.985	-0.9%
Long (>100 mots)	0.997	0.998	+0.1%

Test comparatif :

Texte	V1 Score	V1 Label	V2 Score	V2 Label	Attendu
-------	----------	----------	----------	----------	---------

SCANDALE ! On nous cache la verite sur les vaccins !	0.068	SUSPECT	0.000	SUSPECT	SUSPECT
Le CNRS publie une etude sur le climat.	0.945	FIABLE	1.000	FIABLE	FIABLE
URGENT: puces 5G dans les vaccins !!	0.716	FIABLE	0.001	SUSPECT	SUSPECT
La mairie organise une fete ce weekend.	0.256	SUSPECT	0.998	FIABLE	FIABLE
Partagez avant censure !! Revelations choc	0.984	FIABLE	0.554	FIABLE	SUSPECT
Les resultats du bac sont disponibles.	0.962	FIABLE	0.999	FIABLE	FIABLE

V1 : 3/6 -> V2 : 5/6 - Le CamemBERT V2 corrige 2 des 3 echecs V1. Seule la phrase "Partagez avant censure" reste mal classee (score=0.554, juste au-dessus du seuil).

Tests supplementaires social media :

Texte	Score	Label	Attendu
REVEILLEZ VOUS !! Le graphene dans les masques !!	0.000	SUSPECT	SUSPECT
Les cours reprennent lundi prochain.	0.998	FIABLE	FIABLE
ON NOUS MENT SUR TOUT !! Faites vos propres recherches	0.000	SUSPECT	SUSPECT
La bibliotheque municipale ouvre ses portes samedi.	0.999	FIABLE	FIABLE

4/4 PASS - Total V2 : 9/10 (vs 3/6 en V1)

Bilan CamemBERT V2 : Les 10K posts FR sociaux synthetiques ont transforme la capacite du modele a reconnaitre les formulations social media. Le F1 ultra-court passe de 0.901 a 0.957 (+6.2%). Le recall global passe de 0.931 a 0.964 (+3.5%). Entrainement en 11 min sur MPS (Apple M4 Pro), emissions 0.000467 kg CO2.

8. Version 5.0 - Integration donnees FR sociales (Avril 2026)

8.1 Modification

- Ajout unique : Integration de 10 000 posts FR sociaux synthetiques (5 000 suspect + 5 000 fiable) generes par generate_fr_social_dataset.py
- Parametres identiques a V4 : meme architecture TF-IDF(30K) + 15 features + LogReg, meme seuil 0.44
- fr_social_path : nouveau parametre dans prepare_bilingual_dataset()

8.2 Dataset V5

Source	Textes	Langue	Nouveaute V5
ISOT	43 767	EN	
Kaggle FR (x5)	36 250	FR	
FakeNewsNet (x2)	43 540	EN	
CONSTRAINT (x2)	17 084	EN	
Credibility Corpus (x2)	19 562	FR+EN	
Augmentation FR courte (x3)	27 579	FR	
FR Social Synthetique	10 000	FR	V5
TOTAL	197 782	FR=86K (43.5%), EN=112K (56.5%)	

8.3 Resultats V5

Metrique	V4	V5	Delta
Accuracy holdout	0.932	0.935	+0.3%
F1 holdout	0.908	0.913	+0.6%
Precision	0.902	0.913	+1.2%
Recall	0.915	0.914	-0.1%

Par langue :

Langue	V4 F1	V5 F1	Delta
FR	0.940	0.944	+0.4%
EN	0.891	0.894	+0.3%

Par longueur FR :

Segment	V4 F1	V5 F1	Delta
Ultra-court (<15 mots)	0.868	0.904	+4.1%
Court (15-30 mots)	0.951	0.944	-0.7%
Moyen (30-100 mots)	0.978	0.974	-0.4%
Long (>100 mots)	1.000	1.000	=

Par longueur EN :

Segment	V4 F1	V5 F1	Delta
Ultra-court (<15 mots)	0.755	0.774	+2.5%
Court (15-30 mots)	0.866	0.863	-0.3%

Moyen (30-100 mots)	0.883	0.877	-0.7%
Long (>100 mots)	0.982	0.978	-0.4%

8.4 Test bilingue V5

Texte	Score	Label	Attendu	Statut
SCANDALE !! On nous cache la verite sur les vaccins !	0.001	SUSPECT	SUSPECT	PASS
Le CNRS a publie une etude sur le changement climatique	0.980	FIABLE	FIABLE	PASS
URGENT: les vaccins contiennent des puces 5G !	0.011	SUSPECT	SUSPECT	PASS
La mairie annonce la renovation du pont.	0.910	FIABLE	FIABLE	PASS
Partagez massivement avant censure !! Info cachee	0.015	SUSPECT	SUSPECT	PASS
Les resultats du match : Lyon 2 - Marseille 1	0.981	FIABLE	FIABLE	PASS
REVEILLEZ VOUS !! Le graphene dans les masques !!	0.195	SUSPECT	SUSPECT	PASS
La meteo prévoit du soleil ce weekend.	0.584	FIABLE	FIABLE	PASS
BREAKING: Government EXPOSED in massive cover-up!	0.040	SUSPECT	SUSPECT	PASS
A new study published in Nature examines climate change	0.517	FIABLE	FIABLE	PASS
SHARE before they DELETE this!! The truth about 5G!	0.020	SUSPECT	SUSPECT	PASS
The city council approved the new budget.	0.813	FIABLE	FIABLE	PASS

12/12 PASS (vs 9/10 en V4)

8.5 Avantages

- FR ultra-court F1 = 0.904 : franchit le seuil de 0.90 grace aux donnees sociales
- Test bilingue parfait : 12/12, le modele reconnaît maintenant "partagez avant censure", "puces 5G", "graphene dans les masques"
- Temps d'entrainement divise par 25 : 30 min vs 751 min (V4) grace a max_iter=10000 deja converge
- EN stable ou en legere hausse : +0.3% F1 global, +2.5% sur ultra-court EN

8.6 Inconvenients et limites

- Trade-off FR court/moyen : Legere regression sur FR court 15-30 (-0.7%) et moyen 30-100 (-0.4%), le modele se specialise davantage sur les ultra-courts
- Donnees synthetiques : Le dataset FR social est genere par templates, pas collecte. Les formulations restent limitees aux patterns prevus par le generateur.
- EN court toujours < 0.80 : F1 EN ultra-court = 0.774, en progres mais sous l'objectif de 0.85. Confirme le besoin de RoBERTa (preconisation P4).
- Biais thematique : Les templates synthetiques couvrent 4 themes (conspiration, manipulation, pseudo-sante, politique). Les fake news sur d'autres themes restent moins bien detectees.

9. Comparaison globale multi-versions

9.1 Evolution du F1 par version

Version	F1 global	F1 FR global	F1 FR court (<15 m.	F1 EN global
V1.0	0.996 (biaise)	N/A	N/A	0.996
V1.5	0.986	0.982	N/A	0.985
V2.0	0.897	0.846	0.650	0.928
V3.0	0.900	0.846	0.650	0.928
V4.0	0.905	0.935	0.860	0.889
CamemBERT V1	0.950 (FR)	0.950	0.901	N/A
V5.0	0.913	0.944	0.904	0.894
CamemBERT V2	0.966 (FR)	0.966	0.957	N/A
Hybride P1	0.916	0.949	0.909	0.895
RoBERTa EN V1	0.940 (EN)	N/A	N/A	0.940
RoBERTa EN V2	0.944 (EN)	N/A	N/A	0.944

8.2 Evolution du F1 EN par version et segment

Version	F1 EN global	F1 EN ultra-co.	F1 EN court (1.	F1 EN moyen (3.	F1 EN long (>1.
V1.0	0.996 (biaise)	N/A	N/A	N/A	0.996
V1.5	0.985	N/A	N/A	0.984	0.986
V2.0	0.928	0.763	0.849	0.971	0.997
V3.0	0.928	0.763	0.849	0.971	0.997
V4.0	0.889	0.752	0.831	0.958	0.993
V5.0	0.894	0.774	0.863	0.877	0.978

RoBERTa EN V1	0.940	0.838	0.925	0.981	0.999
RoBERTa EN V2	0.944	0.874	0.937	0.979	0.999

Constat : L'EN connaît une regression de V2 a V4 sur les textes courts, puis une legere remontee en V5 sur les ultra-courts (+2.2% vs V4). RoBERTa EN V1 confirme l'apport des transformers : F1 EN ultra-court passe de 0.774 (V5 TF-IDF) a 0.838 (+8.2%). RoBERTa EN V2, avec les 10K posts EN sociaux synthetiques, pousse le F1 EN ultra-court a 0.874 (+4.3% vs V1, +12.9% vs V5 TF-IDF). Le test rapide passe de 6/10 (V1) a 8/10 (V2) + 8/8 tests sociaux supplementaires = 16/18 total. Le pattern est identique a CamemBERT V1->V2 : les donnees sociales synthetiques corrigent le biais sur les textes courts neutres.

8.4 Evolution de la taille du dataset

Version	Total	FR	EN	% FR	Textes courts
V1.0	44 124	0	44 124	0%	0
V1.5	53 607	9 483	44 124	18%	~0
V2.0	145 703	~36 000	~110 000	25%	~40 000
V4.0	187 782	76 023	111 759	40%	~67 000
V5.0	197 782	86 023	111 759	43.5%	~77 000

8.5 Evolution des features

Version	TF-IDF	Linguistiques	Emotionnelles	Transformer	Total
V1.0	20 000	0	0	0	20 000
V1.5	30 000	12	7	0	30 019
V2.0	30 000	12 (5 nulles)	7	0	30 019
V3.0	30 000	12 (corrigees)	7	0	30 019
V4.0	30 000	15	7	0	30 022
V5.0	30 000	15	7	0	30 022
CamemBERT	0	0	0	768 (CLS)	768

9. Marges de progression et preconisations

Cette section a ete revisee par analyse critique des axes reellement implementables et a fort impact, en ecartant les pistes theoriques peu rentables. Chaque preconisation est classee selon sa faisabilite (effort vs gain) et sa pertinence pour le cas d'usage Bluesky.

9.1 Preconisations retenues (impact fort, faisabilite prouvee)

P1 - Pipeline hybride TF-IDF V5 + CamemBERT V2 (stacking) - REALISE

- Etat : FAIT (notebook 17). Meta-learner LogReg entraine sur les scores des deux modeles.
- Architecture : 6 features meta (v5_score, camembert_score, is_fr, score_diff, score_min, score_max) -> LogisticRegression
- Resultats :

- F1 global : 0.9134 -> 0.9163 (+0.29%)
- F1 FR global : 0.9436 -> 0.9488 (+0.52%)
- F1 FR ultra-court : 0.9036 -> 0.9092 (+0.56%)
- F1 FR court (15-30) : 0.9436 -> 0.9586 (+1.49%)
- F1 EN global : 0.8937 -> 0.8951 (+0.13%)
- Test bilingue : 12/12
- Coefficients meta-learner : v5_score (-4.23) domine, camembert_score (-1.60) contribue significativement. Le flag is_fr (+0.41) confirme que CamemBERT apporte surtout en FR.
- Conclusion : Gain modeste mais reel, surtout sur FR court 15-30 (+1.49%). Le stacking ne surpasse pas radicalement les base learners car leurs erreurs ne sont pas suffisamment decorrelees - les deux modeles sont entraines sur les memes donnees. Le gain principal est la robustesse : quand V5 hesite (score ~0.5), CamemBERT tranche souvent correctement, et vice-versa.

P2 - Re-fine-tuning CamemBERT sur le dataset FR social synthetique - REALISE

- Etat : FAIT (section 7.7). CamemBERT V2 entraine avec les 10K posts FR sociaux.
- Resultats :
 - F1 holdout : 0.950 -> 0.966 (+1.7%)
 - F1 ultra-court : 0.901 -> 0.957 (+6.2%)
 - Test rapide : 3/6 -> 5/6 (+2 corrections)
 - Test social supplementaire : 4/4
 - Total : 9/10 (vs 3/6 en V1)
- Conclusion : L'hypothese etait correcte - le manque de donnees sociales etait la cause racine des echecs V1. Le seul echec restant ("Partagez avant censure", score=0.554) est un cas limite ambigu.

P3 - Seuil adaptatif par langue - TESTE, NON SIGNIFICATIF

- Etat : FAIT (notebook 15). Grid search seuils 0.30-0.60 (pas 0.01) pour FR et EN separement.
- Resultats :
 - Seuil optimal FR : 0.53 (vs 0.44 actuel)
 - Seuil optimal EN : 0.46 (vs 0.44 actuel)
 - Gain F1 global avec seuils adaptatifs : +0.17% (0.9132 -> 0.9149)
 - Gain F1 FR : +0.12% | Gain F1 EN : +0.21%
- Conclusion : Le gain est non significatif. Le seuil unique 0.44 reste suffisant pour les deux langues. La distribution des scores FR et EN est finalement assez similaire - l'hypothese initiale (scores plus extremes en FR) se verifie mais n'a pas d'impact operationnel. Le code pour les seuils par langue est neanmoins integre dans expert_detector.py (parametres threshold_fr, threshold_en) pour un usage futur si necessaire.

P4 - RoBERTa EN fine-tune pour l'anglais - REALISE (V1 + V2)

- Etat : FAIT (notebooks 18 + 19). roberta-base (125M params) fine-tune sur les textes EN.
- Architecture : Identique a CamemBERT - couches 0-8 gelees, 9-11 + head fine-tunees (17.5% parametres entrainables). Classification head : Linear(768->256)->ReLU->Dropout(0.3)->Linear(256->2). short_text_weight=2.0.

RoBERTa V1 (notebook 18) - 111 759 textes EN :

- F1 holdout : 0.9402, F1 ultra-court : 0.8378 (+8.2% vs V5 TF-IDF)
- Test rapide : 6/10 - 4/5 fiables neutres classees suspect (meme biais CamemBERT V1)
- Entrainement : 39.6 min sur MPS, 0.001692 kg CO2

RoBERTa V2 (notebook 19) - 121 759 textes EN (+10K EN social synthetique) :

- Resultats holdout (24 352 textes EN) :
 - F1 : 0.9439, Accuracy : 0.9549, Precision : 0.9574, Recall : 0.9308
 - F1 ultra-court (<15 mots) : 0.8735 (vs V1 0.8378 -> +4.3%)
 - F1 court (15-30) : 0.9368, moyen : 0.9787, long : 0.9992
- Test comparatif V1 vs V2 :

Texte	V1 Score	V1 Label	V2 Score	V2 Label	Attendu
BREAKING: Government EXPOSED in massive cover-up!	0.000	SUSPECT	0.000	SUSPECT	SUSPECT
A new study published in Nature examines climate change.	0.060	SUSPECT	0.996	FIABLE	FIABLE
SHARE before they DELETE this!! The truth about 5G!	0.000	SUSPECT	0.000	SUSPECT	SUSPECT
The city council approved the new budget.	0.395	SUSPECT	0.953	FIABLE	FIABLE
WAKE UP PEOPLE!! They're putting chemicals in the water!	0.000	SUSPECT	0.000	SUSPECT	SUSPECT
The weather forecast calls for rain tomorrow.	0.019	SUSPECT	1.000	FIABLE	FIABLE
EXPOSED: Secret labs use 5G for mind control!	0.000	SUSPECT	0.000	SUSPECT	SUSPECT
NASA announced a new mission to Mars.	0.011	SUSPECT	0.008	SUSPECT	FIABLE
DON'T TRUST the mainstream media!! They lie about EVERYTHING!	0.000	SUSPECT	0.000	SUSPECT	SUSPECT

The university published its annual research report.	0.635	FIABLE	0.285	SUSPECT	FIABLE
--	-------	--------	-------	---------	--------

V1 : 6/10 -> V2 : 8/10 - 3 corrections (Nature, city council, weather), 1 regression (university report), 1 persistant (NASA).

- Tests supplementaires social media EN :

Texte	Score	Label	Attendu
Just got back from the gym, feeling great!	1.000	FIABLE	FIABLE
The new coffee shop downtown is amazing	1.000	FIABLE	FIABLE
School board meeting tonight at 7pm	1.000	FIABLE	FIABLE
Traffic is terrible on the highway today	1.000	FIABLE	FIABLE
THEY ARE LYING TO YOU ABOUT EVERYTHING!! Wake up!!	0.000	SUSPECT	SUSPECT
Big Pharma doesn't want you to know about this cure!!	0.000	SUSPECT	SUSPECT
EXPOSED: the truth about what's really in your food!!	0.000	SUSPECT	SUSPECT
Share this before they take it down!!	0.000	SUSPECT	SUSPECT

8/8 PASS - Total V2 : 16/18 (vs 6/10 en V1)

- Entrainement V2 : 41.6 min sur MPS (Apple M4 Pro), 3 epochs, batch_size=32, lr=2e-5. Emissions : 0.001778 kg CO2.
- Conclusion : L'hypothese etait correcte - les 10K posts EN sociaux synthetiques corrigent le biais V1 sur les textes courts neutres. Le F1 EN ultra-court passe de 0.838 a 0.874 (+4.3%), et le test rapide de 6/10 a 8/10 (+3 corrections). Le pattern est identique a CamemBERT V1->V2 (3/6->9/10). Les 2 echecs restants ("NASA" et "university report") sont des phrases formelles courtes qui ressemblent structurellement aux titres FakeNewsNet - un cas limite inherent au modele.

9.2 Preconisations ecartees ou reportees (analyse critique)

Ecartee : Annotation manuelle de 2000+ posts Bluesky

- Raison : Cout humain eleve (estimation : 40-60h d'annotation), necessite un protocole d'annotation, un calcul d'inter-annotator agreement, et au moins 2 annotateurs pour eviter le biais. Le gain marginal par rapport aux 10K posts synthetiques (deja generes) ne justifie pas l'investissement dans le cadre academique du projet.
- Alternative retenue : Le dataset synthetique de 10K posts (V5) couvre deja le vocabulaire et les patterns

cibles. L'évaluation sur Bluesky reel se fait via le dashboard en production.

Ecartee : Augmentation par paraphrase LLM

- Raison : Risque de circularité - les paraphrases générées par un LLM ont un "style" reconnaissable qui peut devenir un signal parasite. Le modèle pourrait apprendre à distinguer "texte écrit par LLM" plutôt que "texte suspect". De plus, l'augmentation FR courte (V4) et le dataset synthétique (V5) apportent déjà de la diversité. Gain marginal estimé < 2% F1.
- Condition de re-évaluation : Si les résultats V5 montrent un plateau de performance FR court, la paraphrase pourrait être testée sur un sous-ensemble (<20% du dataset) avec validation croisée.

Reportee : Datasets FR émergents (FakeCovid, Debunking FR)

- Raison : Les corpus FR fact-checkés disponibles sont généralement petits (<2K textes), mal étiquetés (labels non binaires, annotations ambiguës), et thématiquement limités (COVID principalement). Leur intégration risque d'introduire du bruit sans gain significatif. À ré-évaluer si un corpus >5K textes de qualité devient disponible.
- Veille recommandée : Surveiller les publications des équipes CLEF CheckThat!, le Credibility Corpus V2, et les initiatives des agences de presse FR (AFP Factuel, Les Décodeurs).

Reportee : Embeddings cross-lingues (paraphrase-multilingual-MiniLM)

- Raison : Remplacerait l'architecture TF-IDF + features par un modèle dense unique. Potentiel élevé à long terme mais nécessite une refonte complète du pipeline. Non pertinent tant que le pipeline hybride (P1) n'a pas été évalué.

Reportee : Distillation CamemBERT -> TinyBERT

- Raison : Optimisation de déploiement prématurée. Le modèle CamemBERT (450 MB, 50ms/texte) est acceptable pour le prototype. La distillation n'a de sens qu'une fois le modèle stabilisé et valide en production.

9.3 Features à implémenter (gain rapide)

Feature	Effort	Impact	Statut
~~Seuil adaptatif FR/EN (P3)~~	~~2h~~	~~+0.17% F1~~	Teste - non significatif
Features de source Bluesky (nb followers, age compte)	1 jour	Reduction faux positifs ~10%	A faire
Score de viralité (reposts/likes ratio)	0.5 jour	Détection précoce	A faire

9.4 Feuille de route recommandée

Etape	Action	Délai	Prérequis	Livrable
1	~~Evaluer V5 (10K FR social)~~	FAIT	~~Retraining~~	F1 FR court 0.904, 12/12 test
2	~~Re-fine-tune CamemBERT V2 (P2)~~	FAIT	~~Dataset synthétique~~	F1 FR court 0.957, test 9/10 (vs 3/6)

3	~~Seuil adaptatif par langue (P3)~~	FAIT	~~V5~~	Non significatif (+0.17% F1), seuil 0.44 conserve
4	~~Pipeline hybride stacking (P1)~~	FAIT	~~V5 + CamemBERT V2~~	F1 FR +0.52%, FR court 15-30 +1.49%
5	~~RoBERTa EN V1 (P4)~~	FAIT	~~Infrastructure CamemBERT~~	F1 EN ultra-court 0.838 (+8.2% vs V5 TF-IDF), test 6/10
6	~~RoBERTa EN V2 (+10K EN social)~~	FAIT	~~Dataset EN synthetique~~	F1 EN ultra-court 0.874 (+4.3%), test 16/18
7	Integration features Bluesky (source, viralite)	2 semaines	Acces API Bluesky	Reduction faux positifs

10. Lecons apprises

10.1 Lecons techniques

- Les metriques elevees ne garantissent pas la qualite : V1.0 affichait 99.6% F1 mais ne fonctionnait pas du tout. Il faut toujours evaluer sur des donnees representatifs du cas d'usage reel.
- Le preprocessing peut neutraliser les features : Le bug V2 (features calculees sur texte nettoye) etait invisible car les metriques globales etaient bonnes. Seule l'analyse fine des coefficients l'a revele.
- L'augmentation de donnees compense partiellement le manque de donnees natives : V4 prouve qu'on peut ameliorer significativement les performances FR court (+32%) par augmentation synthetique, mais les limites de generalisation (test rapide CamemBERT 3/6) montrent que rien ne remplace des donnees reelles du domaine cible.
- Les transformers ne sont pas une solution magique : CamemBERT excelle sur les donnees du meme type que l'entrainement mais echoue sur des formulations hors-distribution. Le TF-IDF V4 + features linguistiques est plus robuste sur les patterns explicites (MAJUSCULES, !!, mots sensationnalistes).

10.2 Lecons methodologiques

- Evaluer par segment : Les metriques globales masquent les faiblesses. L'evaluation par langue x longueur a ete decisive pour identifier le probleme FR court.
- Iterer rapidement : 5 versions en 4 mois, chacune construite sur les diagnostics de la precedente. Le cycle "analyse des erreurs -> hypothese -> correction -> evaluation" est le moteur de progression.
- Documenter les decisions : Chaque choix (seuil, oversample, features) a une raison documentee. Cela facilite la reproduction et l'audit.

11. Conclusion

Le pipeline Thumalien est passe d'un modele biaise inutilisable (V1, F1 = 0.996 artificiel) a un systeme bilingue performant (V5 + CamemBERT V2). L'evolution montre deux trajectoires distinctes par langue :

Francais : Progression spectaculaire de 0 (V1, pas de FR) a F1 = 0.944 global et 0.904 sur ultra-court (V5 TF-IDF). Le parcours V3 (F1 court = 0.65) -> V4 (+32% par augmentation) -> V5 (+10.4% par donnees sociales) demontre l'importance des donnees representatives du cas d'usage. CamemBERT V2 atteint F1 = 0.966 et F1 ultra-court = 0.957, confirmant l'apport des donnees sociales synthetiques pour les transformers egalement.

Anglais : Pic a F1 = 0.928 (V2/V3), regression a 0.889 (V4), puis legere remontee a 0.894 (V5). RoBERTa EN V1 recupere les pertes (F1 EN = 0.940) et ameliore les textes ultra-courts (0.774->0.838). RoBERTa EN V2, avec les 10K posts EN sociaux synthetiques, pousse le F1 EN ultra-court a 0.874 et le test rapide de 6/10 a 16/18 - meme dynamique que CamemBERT V1->V2.

Bilan V5 + CamemBERT V2 : Le test bilingue V5 passe de 9/10 (V4) a 12/12 (V5). CamemBERT V2 passe de 3/6 (V1) a 9/10 (V2). Les deux modeles reconnaissent maintenant les formulations social media FR. L'objectif F1 FR court > 0.90 est atteint par les deux approches (TF-IDF: 0.904, CamemBERT: 0.957).

Bilan des preconisations :

- P1 : Pipeline hybride stacking - FAIT, F1 FR +0.52%, FR court 15-30 +1.49%, gain modeste mais robustesse accrue
- P2 : Re-fine-tuning CamemBERT - FAIT, F1 ultra-court 0.901 -> 0.957 (+6.2%), test 3/6 -> 9/10
- P3 : Seuil adaptatif par langue - FAIT, gain +0.17% F1 (non significatif), seuil 0.44 conserve
- P4 : RoBERTa EN V1->V2 - FAIT, F1 EN ultra-court 0.774 -> 0.838 -> 0.874 (+12.9% total), test 6/10 -> 16/18

Les 4 preconisations sont realisees, y compris les iterations V2 pour les deux transformers. Le pattern de progression est identique en FR et EN : les donnees sociales synthetiques corrigent le biais des transformers sur les textes courts neutres (CamemBERT 3/6->9/10, RoBERTa 6/10->16/18).

Configuration recommandee pour la production :

- FR : CamemBERT V2 (F1 ultra-court = 0.957, test 9/10)
- EN : RoBERTa EN V2 (F1 ultra-court = 0.874, test 16/18)
- Fallback : V5 TF-IDF bilingue (F1 FR = 0.944, F1 EN = 0.894)
- Orchestration : Pipeline hybride stacking pour la robustesse