

Evolution des Modeles - Comparatif de Progression

Projet Thumalien - Social Media Intelligence & AI Monitor

Reference : EVOL-THUM-2026-001

Version : 1.0

Date : Avril 2026

Auteur : Thumalien Team - Direction Projet Data

1. Synthese executive

Ce document retrace l'evolution complete du pipeline de detection de desinformation Thumalien, de la version V1 (decembre 2025) a la version V5 + CamemBERT (avril 2026). Chaque iteration est analysee en termes de performances, d'avantages, d'inconvenients, de limites identifiees et de marges de progression exploitees dans la version suivante.

Tableau de synthese globale

Version	Date	F1 global	F1 FR glo.	F1 EN glo.	F1 FR cou.	F1 EN cou.	Dataset	Innovatio.
V1.0	Dec 2025	0.996 (biaise)	N/A	0.996 (biaise)	N/A	N/A	44 124 EN	Baseline TF-IDF
V1.5	Jan 2026	0.986	0.982	0.985	N/A	N/A	53 607 FR+EN	Bilingue + emotions
V2.0	Fev 2026	0.897	0.846	0.928	0.650	0.763	145 703	Datasets sociaux
V3.0	Mars 2026	0.900	0.846	0.928	0.650	0.763	145 703	Bug fix features
V4.0	Avril 2026	0.905	0.935	0.889	0.860	0.752	187 782	Augmentation FR court
CamemBERT	Avril 2026	0.950 (FR)	0.950	N/A	0.901	N/A	22 540 FR	Transformer FR
V5.0	Avril 2026	0.913	0.944	0.894	0.904	0.774	197 782	+10K FR social synthetique

2. Version 1.0 - Baseline anglophone (Decembre 2025)

2.1 Architecture

- Modele : TF-IDF (20 000 features, unigrams) + LogisticRegression
- Dataset : ISOT Fake News Dataset (44 124 articles EN)
 - True.csv : 21 416 articles Reuters (label 0)
 - Fake.csv : 22 708 articles (label 1)
- Split : 80/20 stratifie, 5-fold CV

2.2 Resultats

Metrique	Score
Accuracy	0.997
F1	0.996
Precision	0.997
Recall	0.995
ROC AUC	0.999

2.3 Avantages

- Mise en place rapide du pipeline end-to-end
- Scores apparemment excellents
- Architecture simple et interpretable

2.4 Inconvenients et limites

- CRITIQUE : Biais Reuters - Le modele apprenait a reconnaitre les marqueurs de style Reuters ("WASHINGTON (Reuters) -", bylines, credits) et non la veracite du contenu. 99.7% d'accuracy etait un artefact.
- Aucune capacite francaise - Dataset 100% anglais
- Aucun texte court - Tous les articles font > 100 mots, inutile pour des posts Bluesky
- Pas d'analyse emotionnelle

2.5 Diagnostic ayant mene a V1.5

Analyse des coefficients TF-IDF : les mots les plus predictifs etaient "reuters", "reporting by", "editing by" - des marqueurs de source, pas de contenu. Le modele ne detectait pas les fake news, il detectait Reuters.

3. Version 1.5 - Bilingue + Emotions (Janvier-Fevrier 2026)

3.1 Architecture

- Modele : TF-IDF (30 000 features, 1-3 grams, sublinear TF) + 12 features linguistiques + 7 features emotionnelles (MLP PyTorch) + LogisticRegression
- Dataset : 53 607 textes (ISOT debiaise + Kaggle FR 9 483 articles)
- Preprocessing : Suppression du biais Reuters (remove_agency_bias), nettoyage ML
- Emotions : MLP PyTorch bilingue (vocab 25K, embedding 64, 7 classes)

- Detection de langue : LanguageRouter (langdetect)

3.2 Resultats

Metrique	EN	FR
F1	0.985	0.982
Precision	0.982	0.978
Recall	0.989	0.986

3.3 Avantages

- Suppression effective du biais Reuters (F1 passe de 0.996 a 0.985 - metriques realistes)
- Support bilingue FR/EN
- Features linguistiques (caps_ratio, exclamation, sensationnalisme) independantes du contenu
- Analyse emotionnelle (7 emotions)

3.4 Inconvenients et limites

- Domain shift : Le modele, entraine sur des articles longs, classait 77% des posts Bluesky comme SUSPECTS car il ne connaissait pas le style "texte court"
- FR tres minoritaire : 9 483 articles FR / 44 124 EN = 18% seulement
- Pas de textes sociaux : Aucun tweet, post, ou titre dans les donnees d'entrainement
- F1 trompeusement eleve : Les metriques elevees refletaient des donnees homogenes (articles vs articles), pas la capacite a traiter des posts courts

3.5 Diagnostic ayant mene a V2

Deploiement sur Bluesky : le modele classait "Lyon 2 - Marseille 1" comme SUSPECT. Le seuil 0.50 etait trop strict, et le modele n'avait jamais vu de textes < 50 mots.

4. Version 2.0 - Datasets sociaux + Seuil adapte (Fevrier 2026)

4.1 Architecture

- Modele : Identique a V1.5 (TF-IDF 30K + 12 ling. + 7 emo. + LogReg)
- Dataset : 145 703 textes
 - ISOT EN : 44 124 articles
 - Kaggle FR : 9 483 articles (x3 oversample = 28 449)
 - FakeNewsNet : 22 596 titres courts EN (GossipCop + PolitiFact)
 - CONSTRAINT : 8 559 tweets COVID EN
 - Credibility Corpus : 9 841 tweets FR+EN
- Seuil : Abaisse de 0.50 a 0.44 (optimise sur donnees Bluesky)
- Ponderation bilingue : sample_weight par frequence inverse de langue

4.2 Resultats

Metrique	Global	FR	EN
Accuracy	0.926	0.896	0.940
F1	0.897	0.846	0.928
Precision	0.891	0.993	0.940
Recall	0.903	0.738	0.917

Par longueur (FR) :

Segment	N	F1	Accuracy
Ultra-court (<15 mots)	2 322	0.650	0.715
Court (15-30 mots)	4 203	0.739	0.834
Moyen (30-100 mots)	4 760	0.988	0.996
Long (>100 mots)	1 931	0.999	0.999

Par longueur (EN) :

Segment	N	F1	Accuracy
Ultra-court (<15 mots)	4 519	0.763	0.804
Court (15-30 mots)	5 131	0.849	0.895
Moyen (30-100 mots)	6 042	0.971	0.982
Long (>100 mots)	6 548	0.997	0.998

Analyse EN : L'anglais beneficie de donnees sociales natives (FakeNewsNet titres, CONSTRAINT tweets) mais les textes ultra-courts EN restent a F1 = 0.763. Le volume superieur de donnees EN (75% du dataset) compense partiellement.

4.3 Avantages

- Integration de donnees sociales (tweets, titres) = meilleure generalisation
- Seuil 0.44 adapte aux posts courts Bluesky
- 73.4% de posts classes comme fiables sur Bluesky reel (vs 23% en V1.5)
- Ponderation bilingue ameliore l'equilibre FR/EN

4.4 Inconvenients et limites

- FR ultra-court F1 = 0.650 - Inacceptable pour le cas d'usage Bluesky
- EN ultra-court F1 = 0.763 - Meilleur que FR mais encore insuffisant pour un monitoring fiable
- Recall FR = 0.738 - Rate 1 fake news FR sur 4
- Recall EN = 0.917 - Correct mais pourrait beneficier d'un transformer dedie
- Desequilibre FR/EN : 75% EN / 25% FR dans le dataset
- Pas de donnees FR sociales natives : KaggleFR = articles longs, pas de tweets FR
- Biais thematique residuel : Les mots "coronavirus", "trump" ont des coefficients TF-IDF tres eleves => biais topique

4.5 Diagnostic ayant mene a V3

Analyse des coefficients TF-IDF : 5 features linguistiques sur 12 avaient des coefficients exactement a 0.0000.
Investigation : bug dans `_build_features()` - les features etaient calculees sur `text_clean` (minuscules, sans ponctuation) au lieu de `text_original`.

5. Version 3.0 - Correction features linguistiques (Mars 2026)

5.1 Modification

- Bug fix unique : Dans `_build_features()`, remplacement de `texts_clean` par `texts_original` pour le calcul des features linguistiques
- Features affectees : `caps_ratio`, `exclamation_count`, `question_count`, `punct_density`, `sentence_count` - ces 5 features etaient toujours a 0 en V2

5.2 Resultats

Metrique	V2	V3	Delta
Accuracy	0.926	0.926	+0.0%
F1	0.897	0.900	+0.3%
Precision	0.891	0.891	+0.0%
Recall	0.903	0.910	+0.8%

Impact par langue :

Langue	V2 F1	V3 F1	Delta
FR	0.846	0.846	+0.0%
EN	0.928	0.928	+0.0%

Le gain global est faible (+0.3% F1). L'EN n'est pas impacte par le bug fix car les features linguistiques (`caps_ratio`, `exclamation_count`) avaient un poids marginal face au volume TF-IDF EN. Le FR global ne bouge pas non plus, mais la precision sur les textes suspects FR augmente significativement : +19.3% sur les cas ou les features linguistiques (majuscules, ponctuation emotive) font la difference.

5.3 Avantages

- Correction d'un bug critique : les features linguistiques fonctionnent enfin
- Le modele capte maintenant les MAJUSCULES, les !!!, les ? multiples
- Precision accrue sur les textes conspirationalistes a forte ponctuation

5.4 Inconvenients et limites

- FR court toujours F1 = 0.65 - Le bug fix seul ne suffit pas
- EN court inchangé F1 = 0.763 - Les features linguistiques ne compensent pas le manque de volume EN court
- Memes donnees qu'en V2 : le desequilibre FR/EN persiste
- Le modele V2 etait incompatible avec les features corrigees : il fallait retrainner

5.5 Diagnostic ayant mene a V4

L'analyse par longueur et langue (notebook 10) a revele que le vrai probleme n'etait pas les features mais les donnees : aucune donnee FR courte dans l'entrainement. Les articles KaggleFR font en moyenne 180 mots. Bluesky = 5-20 mots.

6. Version 4.0 - Amelioration FR court (Avril 2026)

6.1 Modifications majeures

- Augmentation FR courte : Methode generate_fr_short_augmentation()
 - Extraction de la 1ere phrase de chaque article KaggleFR (3-25 mots)
 - Creation de titres synthetiques (8-12 premiers mots)
 - 9 193 textes generes, oversample x3 = 27 579 textes courts FR
- french_oversample : 3 -> 5 (doublement du poids FR)
- 3 nouvelles features linguistiques (15 au total) :
 - all_caps_words_ratio : ratio de mots en MAJUSCULES (signal fort posts sociaux)
 - interpellation_score : patterns "ouvrez les yeux", "wake up", "faites tourner"
 - is_short_text : indicateur binaire texte < 20 mots
- Vocabulaire sensationnaliste enrichi :
 - FR : +16 termes (plandémie, graphène, marionnettes, traîtres, partagez massivement...)
 - EN : +3 termes (must watch, share before deleted, viral)
- max_iter : 5000 -> 10000 (convergence complete sur dataset plus gros)

6.2 Dataset V4

Source	Textes bruts	Oversample	Total	Langue
ISOT	43 767	x1	43 767	EN
Kaggle FR	7 250	x5	36 250	FR
FakeNewsNet	21 770	x2	43 540	EN
CONSTRAINT	8 542	x2	17 084	EN
Credibility Corpus	9 781	x2	19 562	FR+EN
Augmentation FR courte	9 193	x3	27 579	FR
TOTAL			187 782	FR=76K (40%), EN=112K (60%)

6.3 Resultats

Metrique	V3	V4	Delta
Accuracy CV	0.926	0.930	+0.4%
F1 CV	0.900	0.905	+0.6%
Precision	0.891	0.897	+0.7%
Recall	0.910	0.914	+0.4%

Par langue :

Langue	V3 F1	V4 F1	V3 Recall	V4 Recall	Delta F1
FR	0.846	0.935	0.738	0.942	+10.5%
EN	0.928	0.889	0.917	0.898	-4.2%

Par longueur FR (le gain critique) :

Segment	V3 F1	V4 F1	Delta
Ultra-court (<15 mots)	0.650	0.860	+32.3%
Court (15-30 mots)	0.739	0.946	+28.0%
Moyen (30-100 mots)	0.988	0.972	-1.6%
Long (100-300 mots)	1.000	1.000	=
Tres long (>300 mots)	0.999	0.999	=

Par longueur EN (le trade-off) :

Segment	V3 F1	V4 F1	Delta
Ultra-court (<15 mots)	0.763	0.752	-1.4%
Court (15-30 mots)	0.849	0.831	-2.1%
Moyen (30-100 mots)	0.971	0.958	-1.3%
Long (100-300 mots)	0.997	0.993	-0.4%
Tres long (>300 mots)	0.998	0.996	-0.2%

Analyse du trade-off EN : La V4 sacrifie 1-2% de F1 EN sur tous les segments. Ce recul est attendu : l'augmentation du poids FR (french_oversample x5) et l'injection de 27K textes courts FR reequilibrent le modele vers le francais. Le TF-IDF partage (30K features bilingues) a un espace de representation fini, et les features FR supplementaires "poussent" certains patterns EN. Ce trade-off est acceptable car le FR court etait le goulot d'etranglement critique du pipeline.

6.4 Avantages

- Gain massif sur FR court : +32% F1 sur ultra-court, +28% sur court
- Recall FR corrige : 0.74 -> 0.94 (ne rate plus que 6% des fake news FR)
- Dataset plus equilibre : 40% FR au lieu de 25%
- Nouvelles features discriminantes pour les posts sociaux (CAPS, interpellation)

6.5 Inconvenients et limites

- Trade-off EN generalise : L'EN perd ~4% F1 global (0.928 -> 0.889) et ~1-2% sur chaque segment de longueur. Le modele bilingue unique a un espace de representation partage : ameliorer le FR degrade mecaniquement l'EN.
- EN ultra-court F1 = 0.752 : Regression de 1.4% par rapport a V3. Les textes courts EN (titres FakeNewsNet, tweets CONSTRAINT) beneficent moins des nouvelles features orientees FR (interpellation_score contient des patterns FR).
- Augmentation synthetique : Les textes courts generes sont des extraits d'articles, pas de vrais posts sociaux FR
- Biais thematique persistant : Le TF-IDF capte "vaccin", "climat" comme signaux suspects

- Convergence : Le solver LBFGS atteint 5000 iterations sans converger sur 188K textes (corrige par max_iter=10000)
- Pas de transformer EN : L'anglais n'a pas d'equivalent CamemBERT. Un RoBERTa fine-tune pourrait recuperer les 4% perdus sur EN.

6.6 Health check V4

Texte test	Score	Label	Attendu	Statut
New study published in Nature...	0.634	FIABLE	FIABLE	PASS
EXPOSED: Secret labs use 5G...	0.057	SUSPECT	SUSPECT	PASS
Le CNRS publie une etude...	0.956	FIABLE	FIABLE	PASS
SCANDALE: le gouvernement cache...	0.026	SUSPECT	SUSPECT	PASS
The weather is nice today	0.880	FIABLE	FIABLE	PASS

5/5 PASS

7. CamemBERT - Fine-tuning Transformer FR (Avril 2026)

7.1 Architecture

- Modele de base : CamemBERT-base (110M parametres, pre-entraine sur 138 Go de texte francais)
- Fine-tuning : Couches 9-11 + classification head (768 -> 256 -> 2)
- Parametres geles : Couches 0-8 + embeddings (80.2% geles, 19.8% entrainables)
- Surpoids : x2 sur les textes courts (< 30 mots) dans la loss
- Optimisation : AdamW, LR 2e-5 (base) / 2e-4 (head), cosine annealing
- Dataset : 22 540 textes FR uniquement (sans oversample)

7.2 Courbe d'entrainement

Epoch	Train Loss	Train Acc	Val F1	Val Acc
1	0.414	0.899	0.927	0.958
2	0.177	0.963	0.944	0.968
3	0.138	0.971	0.951	0.971

7.3 Resultats holdout

Metrique	Score
Accuracy	0.971

F1	0.950
Precision	0.969
Recall	0.931

Par longueur :

Segment	N test	Accuracy	F1	Precision	Recall
Ultra-court (<15 mots)	1 912	0.939	0.901	0.939	0.867
Court (15-30 mots)	1 330	0.992	0.980	0.982	0.978
Moyen (30-100 mots)	865	0.998	0.994	1.000	0.987
Long (>100 mots)	401	0.995	0.997	1.000	0.993

7.4 Avantages

- F1 ultra-court = 0.901 : meilleur score jamais atteint sur les textes courts FR
- Comprehension semantique : CamemBERT capte ironie, sous-entendus, formulations conspirationnistes
- Pas besoin d'oversample : Le modele pre-entraine generalise mieux avec moins de donnees
- Precision elevee (0.969) : tres peu de faux positifs

7.5 Inconvenients et limites

- Taille du modele : ~450 MB (vs ~45 MB pour V4 TF-IDF) - impact sur le deploiement
- Inference plus lente : ~50ms/texte (vs ~1ms pour TF-IDF)
- Generalisation hors-distribution : 3/6 au test rapide sur des phrases inventees - le modele apprend les patterns du dataset KaggleFR mais generalise mal aux formulations qu'il n'a jamais vues
- FR uniquement : Ne traite pas l'anglais (necessite un modele separe ou pipeline hybride)
- Recall = 0.867 sur ultra-court : Rate encore 13% des fake news FR tres courtes

7.6 Analyse des echecs CamemBERT

Les 3 echecs au test rapide revelent une limite structurelle :

Texte	Score	Prediction	Attendu	Analyse
"URGENT: puces 5G dans les vaccins !!"	0.716	FIABLE	SUSPECT	Le mot "vaccin" + contexte court = pas assez de signal discriminant
"La mairie organise une fete ce weekend"	0.256	SUSPECT	FIABLE	Texte trop court et neutre, le modele sur-classifie en suspect
"Partagez avant censure !! Revelations choc"	0.984	FIABLE	SUSPECT	Pattern non vu en entrainement (KaggleFR = articles, pas posts sociaux)

Cause racine : Le dataset KaggleFR contient des articles de presse formels, pas des posts de reseaux sociaux. Les formulations typiques des fake news FR sur les reseaux ("partagez", "avant censure", "puces 5G") sont absentes du corpus d'entrainement.

8. Version 5.0 - Integration donnees FR sociales (Avril 2026)

8.1 Modification

- Ajout unique : Integration de 10 000 posts FR sociaux synthetiques (5 000 suspect + 5 000 fiable) generes par `generate_fr_social_dataset.py`
- Parametres identiques a V4 : meme architecture TF-IDF(30K) + 15 features + LogReg, meme seuil 0.44
- `fr_social_path` : nouveau parametre dans `prepare_bilingual_dataset()`

8.2 Dataset V5

Source	Textes	Langue	Nouveaute V5
ISOT	43 767	EN	
Kaggle FR (x5)	36 250	FR	
FakeNewsNet (x2)	43 540	EN	
CONSTRAINT (x2)	17 084	EN	
Credibility Corpus (x2)	19 562	FR+EN	
Augmentation FR courte (x3)	27 579	FR	
FR Social Synthetique	10 000	FR	V5
TOTAL	197 782	FR=86K (43.5%), EN=112K (56.5%)	

8.3 Resultats V5

Metrique	V4	V5	Delta
Accuracy holdout	0.932	0.935	+0.3%
F1 holdout	0.908	0.913	+0.6%
Precision	0.902	0.913	+1.2%
Recall	0.915	0.914	-0.1%

Par langue :

Langue	V4 F1	V5 F1	Delta
FR	0.940	0.944	+0.4%
EN	0.891	0.894	+0.3%

Par longueur FR :

Segment	V4 F1	V5 F1	Delta
Ultra-court (<15 mots)	0.868	0.904	+4.1%

Court (15-30 mots)	0.951	0.944	-0.7%
Moyen (30-100 mots)	0.978	0.974	-0.4%
Long (>100 mots)	1.000	1.000	=

Par longueur EN :

Segment	V4 F1	V5 F1	Delta
Ultra-court (<15 mots)	0.755	0.774	+2.5%
Court (15-30 mots)	0.866	0.863	-0.3%
Moyen (30-100 mots)	0.883	0.877	-0.7%
Long (>100 mots)	0.982	0.978	-0.4%

8.4 Test bilingue V5

Texte	Score	Label	Attendu	Statut
SCANDALE !! On nous cache la verite sur les vaccins !	0.001	SUSPECT	SUSPECT	PASS
Le CNRS a publie une etude sur le changement climatique	0.980	FIABLE	FIABLE	PASS
URGENT: les vaccins contiennent des puces 5G !	0.011	SUSPECT	SUSPECT	PASS
La mairie annonce la renovation du pont.	0.910	FIABLE	FIABLE	PASS
Partagez massivement avant censure !! Info cachee	0.015	SUSPECT	SUSPECT	PASS
Les resultats du match : Lyon 2 - Marseille 1	0.981	FIABLE	FIABLE	PASS
REVEILLEZ VOUS !! Le graphene dans les masques !!	0.195	SUSPECT	SUSPECT	PASS
La meteo prevoit du soleil ce weekend.	0.584	FIABLE	FIABLE	PASS
BREAKING: Government EXPOSED in massive cover-up!	0.040	SUSPECT	SUSPECT	PASS
A new study published in Nature examines climate change	0.517	FIABLE	FIABLE	PASS
SHARE before they DELETE this!! The truth				

about 5G!

0.020	SUSPECT	SUSPECT	PASS
-------	---------	---------	------

The city council approved the new budget.	0.813	FIABLE	FIABLE	PASS
---	-------	--------	--------	------

12/12 PASS (vs 9/10 en V4)

8.5 Avantages

- FR ultra-court F1 = 0.904 : franchit le seuil de 0.90 grace aux donnees sociales
- Test bilingue parfait : 12/12, le modele reconnaît maintenant "partagez avant censure", "puces 5G", "graphene dans les masques"
- Temps d'entrainement divise par 25 : 30 min vs 751 min (V4) grace a max_iter=10000 deja converge
- EN stable ou en legere hausse : +0.3% F1 global, +2.5% sur ultra-court EN

8.6 Inconvenients et limites

- Trade-off FR court/moyen : Legere regression sur FR court 15-30 (-0.7%) et moyen 30-100 (-0.4%), le modele se specialise davantage sur les ultra-courts
- Donnees synthetiques : Le dataset FR social est genere par templates, pas collecte. Les formulations restent limitees aux patterns prevus par le generateur.
- EN court toujours < 0.80 : F1 EN ultra-court = 0.774, en progres mais sous l'objectif de 0.85. Confirme le besoin de RoBERTa (preconisation P4).
- Biais thematique : Les templates synthetiques couvrent 4 themes (conspiration, manipulation, pseudo-sante, politique). Les fake news sur d'autres themes restent moins bien detectees.

9. Comparaison globale multi-versions

9.1 Evolution du F1 par version

Version	F1 global	F1 FR global	F1 FR court (<15 m.	F1 EN global
V1.0	0.996 (biaise)	N/A	N/A	0.996
V1.5	0.986	0.982	N/A	0.985
V2.0	0.897	0.846	0.650	0.928
V3.0	0.900	0.846	0.650	0.928
V4.0	0.905	0.935	0.860	0.889
CamemBERT	0.950 (FR)	0.950	0.901	N/A
V5.0	0.913	0.944	0.904	0.894

8.2 Evolution du F1 EN par version et segment

Version	F1 EN global	F1 EN ultra-co.	F1 EN court (1.	F1 EN moyen (3.	F1 EN long (>1.
V1.0	0.996 (biaise)	N/A	N/A	N/A	0.996
V1.5	0.985	N/A	N/A	0.984	0.986
V2.0	0.928	0.763	0.849	0.971	0.997

V3.0	0.928	0.763	0.849	0.971	0.997
V4.0	0.889	0.752	0.831	0.958	0.993
V5.0	0.894	0.774	0.863	0.877	0.978

Constat : L'EN connaît une regression de V2 a V4 sur les textes courts, puis une legere remontee en V5 sur les ultra-courts (+2.2% vs V4). L'integration de donnees FR sociales n'a pas degrade l'EN - au contraire, les 10K posts supplementaires enrichissent le vocabulaire TF-IDF partage. Le F1 EN ultra-court reste sous 0.80 : la preconisation P4 (RoBERTa EN) est confirmee.

8.4 Evolution de la taille du dataset

Version	Total	FR	EN	% FR	Textes courts
V1.0	44 124	0	44 124	0%	0
V1.5	53 607	9 483	44 124	18%	~0
V2.0	145 703	~36 000	~110 000	25%	~40 000
V4.0	187 782	76 023	111 759	40%	~67 000
V5.0	197 782	86 023	111 759	43.5%	~77 000

8.5 Evolution des features

Version	TF-IDF	Linguistiques	Emotionnelles	Transformer	Total
V1.0	20 000	0	0	0	20 000
V1.5	30 000	12	7	0	30 019
V2.0	30 000	12 (5 nulles)	7	0	30 019
V3.0	30 000	12 (corrigees)	7	0	30 019
V4.0	30 000	15	7	0	30 022
V5.0	30 000	15	7	0	30 022
CamemBERT	0	0	0	768 (CLS)	768

9. Marges de progression et preconisations

Cette section a ete revisee par analyse critique des axes reellement implementables et a fort impact, en ecartant les pistes theoriques peu rentables. Chaque preconisation est classee selon sa faisabilite (effort vs gain) et sa pertinence pour le cas d'usage Bluesky.

9.1 Preconisations retenues (impact fort, faisabilite prouvee)

P1 - Pipeline hybride TF-IDF V5 + CamemBERT (priorite 1)

- Etat : Les deux modeles existent deja (V4/V5 TF-IDF + CamemBERT fine-tune)
- Principe : Stacking - combiner les scores de confiance des deux modeles via une meta-regression. Le TF-IDF capte les patterns explicites (MAJUSCULES, mots sensationnalistes), CamemBERT capte la semantique (ironie, sous-entendus).
- Effort : Faible (quelques jours). Pas besoin de retrainner, uniquement calibrer les poids du stacking.

- Impact estime : F1 FR court > 0.92. Les erreurs des deux modeles sont complementaires.
- Justification : Methode prouvee en competition ML (Kaggle). Les modeles ont deja ete entraines.

P2 - Re-fine-tuning CamemBERT sur le dataset FR social synthetique (priorite 2)

- Etat : CamemBERT a ete fine-tune sur les articles KaggleFR uniquement, d'ou le 3/6 au test rapide sur des formulations social media.
- Principe : Reprendre le fine-tuning de CamemBERT en incluant les 10K posts FR sociaux synthetiques dans les donnees d'entrainement.
- Effort : Faible (quelques heures de GPU). Le dataset et le code existent deja.
- Impact estime : Le modele reconnaitra les patterns "partagez avant censure", "puces 5G", "reveillez-vous" qu'il ne voyait pas. Test rapide attendu > 5/6.
- Justification : Le diagnostic des echecs CamemBERT (section 7.6) pointe clairement le manque de donnees sociales comme cause racine.

P3 - Seuil adaptatif par langue (priorite 3)

- Etat : Seuil unique 0.44 pour FR et EN
- Principe : Optimiser un seuil separe pour chaque langue sur le set de validation. Le FR a tendance a produire des scores plus extremes que l'EN.
- Effort : Tres faible (quelques lignes de code). Optimisation par grid search sur F1.
- Impact estime : Precision +2-5% sans perte de recall. Reduction des faux positifs en EN.
- Justification : Les distributions de scores FR et EN sont differentes (le FR a plus de scores proches de 0 ou 1), un seuil unique est sous-optimal.

P4 - RoBERTa fine-tune pour l'anglais (priorite 4)

- Etat : L'EN est traite uniquement par TF-IDF et perd ~4% F1 entre V2 et V4.
- Principe : Fine-tuner roberta-base sur les donnees EN du dataset (ISOT + FakeNewsNet + CONSTRAINT) avec la meme architecture que CamemBERT (couches 9-11 + head).
- Effort : Moyen (1-2 jours GPU). L'architecture est deja codee, il suffit de l'adapter.
- Impact estime : F1 EN court > 0.85. Recuperation des 4% perdus dans le trade-off V4.
- Justification : Si CamemBERT ameliore FR de +10% F1, RoBERTa devrait apporter un gain similaire pour EN. L'infrastructure est en place.

9.2 Preconisations ecartees ou reportees (analyse critique)

Ecartee : Annotation manuelle de 2000+ posts Bluesky

- Raison : Cout humain eleve (estimation : 40-60h d'annotation), necessite un protocole d'annotation, un calcul d'inter-annotator agreement, et au moins 2 annotateurs pour eviter le biais. Le gain marginal par rapport aux 10K posts synthetiques (deja generes) ne justifie pas l'investissement dans le cadre academique du projet.
- Alternative retenue : Le dataset synthetique de 10K posts (V5) couvre deja le vocabulaire et les patterns cibles. L'evaluation sur Bluesky reel se fait via le dashboard en production.

Ecartee : Augmentation par paraphrase LLM

- Raison : Risque de circularite - les paraphrases generees par un LLM ont un "style" reconnaissable qui peut devenir un signal parasite. Le modele pourrait apprendre a distinguer "texte ecrit par LLM" plutot que "texte

suspect". De plus, l'augmentation FR courte (V4) et le dataset synthétique (V5) apportent déjà de la diversité. Gain marginal estimé < 2% F1.

- Condition de re-évaluation : Si les résultats V5 montrent un plateau de performance FR court, la paraphrase pourrait être testée sur un sous-ensemble (<20% du dataset) avec validation croisée.

Reportee : Datasets FR émergents (FakeCovid, Debunking FR)

- Raison : Les corpus FR fact-checkés disponibles sont généralement petits (<2K textes), mal étiquetés (labels non binaires, annotations ambiguës), et thématiquement limités (COVID principalement). Leur intégration risque d'introduire du bruit sans gain significatif. À réévaluer si un corpus >5K textes de qualité devient disponible.
- Veille recommandée : Surveiller les publications des équipes CLEF CheckThat!, le Credibility Corpus V2, et les initiatives des agences de presse FR (AFP Factuel, Les Décodeurs).

Reportee : Embeddings cross-lingues (paraphrase-multilingual-MiniLM)

- Raison : Remplacerait l'architecture TF-IDF + features par un modèle dense unique. Potentiel élevé à long terme mais nécessite une refonte complète du pipeline. Non pertinent tant que le pipeline hybride (P1) n'a pas été évalué.

Reportee : Distillation CamemBERT -> TinyBERT

- Raison : Optimisation de déploiement prématurée. Le modèle CamemBERT (450 MB, 50ms/texte) est acceptable pour le prototype. La distillation n'a de sens qu'une fois le modèle stabilisé et validé en production.

9.3 Features à implémenter (gain rapide)

Feature	Effort	Impact	Justification
Seuil adaptatif FR/EN (P3)	2h	Precision +2-5%	Distributions de scores différentes par langue
Features de source Bluesky (nb followers, âge compte)	1 jour	Reduction faux positifs ~10%	Les comptes récents à faible audience sont sur-représentés dans les suspects
Score de viralité (reposts/likes ratio)	0.5 jour	Détection précoce	Les fake news ont un ratio reposts/likes anormalement élevé

9.4 Feuille de route recommandée

Étape	Action	Délai	Prérequis	Livrable
1	~~Évaluer V5 (10K FR social)~~	FAIT	~~Retraining en cours~~	F1 FR court 0.904, 12/12 test
2	Pipeline hybride stacking V5 + CamemBERT (P1)	1 semaine	V5 et CamemBERT ok	Score combiné, F1 FR court cible > 0.92
3	Re-fine-tune CamemBERT avec FR social (P2)	1 semaine	Dataset synthétique	CamemBERT V2, test rapide > 5/6
4	Seuil adaptatif par langue (P3)	2 jours	V5 ou pipeline hybride	Seuils optimisés FR/EN

5	RoBERTa EN (P4)	2 semaines	Infrastructure CamemBERT	F1 EN court > 0.85
6	Integration features Bluesky (source, viralite)	2 semaines	Acces API Bluesky	Reduction faux positifs

10. Lecons apprises

10.1 Lecons techniques

- Les metriques elevees ne garantissent pas la qualite : V1.0 affichait 99.6% F1 mais ne fonctionnait pas du tout. Il faut toujours evaluer sur des donnees representatifs du cas d'usage reel.
- Le preprocessing peut neutraliser les features : Le bug V2 (features calculees sur texte nettoye) etait invisible car les metriques globales etaient bonnes. Seule l'analyse fine des coefficients l'a revele.
- L'augmentation de donnees compense partiellement le manque de donnees natives : V4 prouve qu'on peut ameliorer significativement les performances FR court (+32%) par augmentation synthetique, mais les limites de generalisation (test rapide CamemBERT 3/6) montrent que rien ne remplace des donnees reelles du domaine cible.
- Les transformers ne sont pas une solution magique : CamemBERT excelle sur les donnees du meme type que l'entrainement mais echoue sur des formulations hors-distribution. Le TF-IDF V4 + features linguistiques est plus robuste sur les patterns explicites (MAJUSCULES, !!, mots sensationnalistes).

10.2 Lecons methodologiques

- Evaluer par segment : Les metriques globales masquent les faiblesses. L'evaluation par langue x longueur a ete decisive pour identifier le probleme FR court.
- Iterer rapidement : 5 versions en 4 mois, chacune construite sur les diagnostics de la precedente. Le cycle "analyse des erreurs -> hypothese -> correction -> evaluation" est le moteur de progression.
- Documenter les decisions : Chaque choix (seuil, oversample, features) a une raison documentee. Cela facilite la reproduction et l'audit.

11. Conclusion

Le pipeline Thumalien est passe d'un modele biaise inutilisable (V1, F1 = 0.996 artificiel) a un systeme bilingue performant (V5 + CamemBERT). L'evolution montre deux trajectoires distinctes par langue :

Francais : Progression spectaculaire de 0 (V1, pas de FR) a F1 = 0.944 global et 0.904 sur ultra-court (V5). Le parcours V3 (F1 court = 0.65) -> V4 (+32% par augmentation) -> V5 (+10.4% par donnees sociales) demontre l'importance des donnees representatives du cas d'usage. CamemBERT atteint F1 = 0.950 en parallele, ouvrant la voie a un pipeline hybride.

Anglais : Pic a F1 = 0.928 (V2/V3), regression a 0.889 (V4), puis legere remontee a 0.894 (V5). Les textes courts EN (F1 ultra-court = 0.774) restent le point faible. Un fine-tuning RoBERTa dedie (preconisation P4) est la piste prioritaire.

Bilan V5 : Le test bilingue passe de 9/10 (V4) a 12/12 (V5). Le modele reconnait maintenant les formulations social media FR ("partagez avant censure", "puces 5G", "reveillez-vous") qui echouaient systematiquement en V4. L'objectif F1 FR court > 0.90 est atteint.

Les preconisations prioritaires pour la suite sont :

- P1 : Pipeline hybride stacking V5 + CamemBERT (F1 FR court cible > 0.92)
- P2 : Re-fine-tuning CamemBERT avec les 10K posts FR sociaux
- P3 : Seuil adaptatif par langue (gain precision +2-5%)
- P4 : RoBERTa EN pour recuperer la regression EN (F1 EN court cible > 0.85)