

Planification detaillee du projet Thumalien

Diagramme de Gantt, WBS, dependances et jalons

Reference : PLAN-THUM-2026-001

Version : 1.0

Date : Avril 2026

Equipe : Azelie Bernard (Lead technique), Sebastien Lazcanotegui (Consolidation ML)

1. Work Breakdown Structure (WBS)

1.1 Decomposition hierarchique

```
THUMALIEN - Projet Etude M1
|
|-- WP1 : Cadrage & Infrastructure (Dec 2025)
|   |-- T1.1 : Analyse des besoins et specification
|   |-- T1.2 : Choix technologiques (Python, MongoDB, Docker)
|   |-- T1.3 : Mise en place environnement Docker Compose
|   |-- T1.4 : Configuration MongoDB + volumes persistants
|   |-- T1.5 : Creation du depot Git et structure projet
|
|-- WP2 : Collecte de donnees (Dec 2025 - Continu)
|   |-- T2.1 : Developpement collecteur Bluesky (AT Protocol)
|   |-- T2.2 : Validation schema JSON + deduplication
|   |-- T2.3 : Audit qualite des donnees collectees
|   |-- T2.4 : Maintenance et monitoring continu
|
|-- WP3 : Modele d'emotions (Jan 2026)
|   |-- T3.1 : Exploration datasets emotions (GoEmotions, FR tweets)
|   |-- T3.2 : Developpement MLP PyTorch (7 classes)
|   |-- T3.3 : Early stopping + class weights
|   |-- T3.4 : Evaluation et validation
|
|-- WP4 : Pipeline NLP Expert (Jan - Avril 2026)
|   |-- T4.1 : Baseline V1.0 (TF-IDF + LogReg EN)
|   |-- T4.2 : Audit biais Reuters + debiaisage
|   |-- T4.3 : V1.5 bilingue + features linguistiques
|   |-- T4.4 : V2 integration datasets sociaux + seuil 0.44
|   |-- T4.5 : V3 correction preprocessing
|   |-- T4.6 : V4 augmentation FR court + 15 features
|   |-- T4.7 : V5 + 10K posts sociaux synthetiques
|   |-- T4.8 : GridSearch hyperparametres (C, min_df, ngram)
|
|-- WP5 : Modeles Transformer (Avril 2026)
|   |-- T5.1 : Fine-tuning CamemBERT V1 (FR)
|   |-- T5.2 : CamemBERT V2 + donnees sociales
|   |-- T5.3 : Fine-tuning RoBERTa EN V1
```

```

| |-- T5.4 : RoBERTa EN V2 + 10K synthétique
| |-- T5.5 : Pipeline hybride stacking V5 + CamemBERT V2
|
|-- WP6 : Dashboard & Visualisation (Mars 2026)
| |-- T6.1 : Dashboard V1 (metriques basiques)
| |-- T6.2 : Dashboard V2 (glassmorphism, 3 pages)
| |-- T6.3 : Dashboard V3 (radar charts, live prediction)
| |-- T6.4 : Integration weighted loss + securite
|
|-- WP7 : Documentation & Conformite (Fev - Avril 2026)
| |-- T7.1 : Cahier des charges techniques
| |-- T7.2 : Conformite RGPD & AI Act
| |-- T7.3 : Rapport de projet
| |-- T7.4 : Guide utilisateur
| |-- T7.5 : Documentation technique (22 notebooks)
| |-- T7.6 : Planification et gouvernance
|
|-- WP8 : Video MVP (Avril 2026)
| |-- T8.1 : Script et storyboard
| |-- T8.2 : Tournage demo live
| |-- T8.3 : Montage et post-production
| |-- T8.4 : Livraison finale

```

2. Diagramme de Gantt

2.1 Planning macro (semaines)

Tache	Dec 25	Jan 26	Fev 26	Mars 26	Avril 26
	S1 S2 S3	S4 S5 S6	S7 S8 S9	S10S11S12	S13S14S15
-----	-----	-----	-----	-----	-----
WP1 Cadrage & Infra	[=====]				
T1.1 Analyse besoins	[===]				
T1.2 Choix techno	[===]				
T1.3 Docker Compose	[=====]				
T1.4 MongoDB config	[=====]				
T1.5 Depot Git	[==]				
WP2 Collecte donnees	[===== ===== ===== ===== =====]				
T2.1 Collecteur Bluesky	[=====]				
T2.2 Validation schema	[=====]				
T2.3 Audit qualite		[=====]			
T2.4 Monitoring continu	[== ===== ===== ===== =====]				
WP3 Modele emotions		[=====]			
T3.1 Exploration datasets		[=====]			
T3.2 MLP PyTorch		[=====]			
T3.3 Early stopping		[==]			
T3.4 Evaluation		[==]			
WP4 Pipeline NLP	[===== ===== ===== ===== =====]				
T4.1 Baseline V1.0	[=====]				
T4.2 Audit biais Reuters		[=====]			
T4.3 V1.5 bilingue		[== =====]			
T4.4 V2 datasets sociaux		[=====]			

T4.5 V3 correction preproc					[===]		
T4.6 V4 augmentation FR						[===]	
T4.7 V5 posts synthétiques						[==]	
T4.8 GridSearch				[==]			
WP5 Modeles Transformer						[=====]	
T5.1 CamemBERT V1						[===]	
T5.2 CamemBERT V2						[==]	
T5.3 RoBERTa EN V1						[===]	
T5.4 RoBERTa EN V2						[=]	
T5.5 Pipeline hybride						[=]	
WP6 Dashboard					[===== ===]		
T6.1 Dashboard V1					[===]		
T6.2 Dashboard V2					[=====]		
T6.3 Dashboard V3						[===]	
T6.4 Securite + weighted						[==]	
WP7 Documentation				[==]		[=====]	
T7.1 CDC techniques				[==]			
T7.2 RGPD & AI Act				[==]			
T7.3 Rapport projet						[=====]	
T7.4 Guide utilisateur						[=====]	
T7.5 Doc technique						[=====]	
T7.6 Planification						[=]	
WP8 Video MVP						[=]	
T8.1 Script/storyboard						[=]	
T8.2 Tournage						[=]	
T8.3 Montage						[=]	
T8.4 Livraison						[=]	

2.2 Legende

- [===] : Duree de la tache
- S1-S15 : Semaines (Dec 2025 Semaine 1 a Avril 2026 Semaine 15)


3. Calendrier formel avec dates cles


Date	Jalon	Livable	Responsable
01/12/2025	J0 - Lancement projet	Repo Git, Docker, MongoDB	Azelie
15/12/2025	J1 - Collecteur operationnel	collect_bluesky.py fonctionnel	Azelie
20/12/2025	J2 - Baseline V1.0	LogReg EN, F1=0.99 (biaise)	Azelie
10/01/2026	J3 - Audit qualite	Biais Reuters identifie	Azelie
20/01/2026	J4 - Modele emotions	MLP PyTorch 7 emotions	Azelie
05/02/2026	J5 - Pipeline V1.5	Bilingue, 12 features, F1=0.986	Azelie

15/02/2026	J6 - GridSearch	C=5.0, min_df=5, ngram=(1,2)	Sebastien
25/02/2026	J7 - Pipeline V2	+3 datasets sociaux, seuil=0.44	Azelie
10/03/2026	J8 - Dashboard V2	Glassmorphism, 3 pages	Azelie
20/03/2026	J9 - Pipeline V3	Correction features linguistiques	Azelie
05/04/2026	J10 - Pipeline V4	Augmentation FR court, 15 features	Azelie
10/04/2026	J11 - Pipeline V5	+10K FR synthetique, F1=0.913	Azelie
12/04/2026	J12 - CamemBERT V1/V2	F1 FR ultra-court = 0.957	Azelie
15/04/2026	J13 - RoBERTa EN V1/V2	F1 EN ultra-court = 0.874	Azelie
18/04/2026	J14 - Pipeline hybride	Stacking V5 + CamemBERT V2	Azelie
20/04/2026	J15 - Consolidation ML	Debiaisage, hyperparametres	Sebastien
25/04/2026	J16 - Documentation finale	Rapport, docs PDF, planification	Azelie
28/04/2026	J17 - Video MVP	Video 15 min + dossier technique	Azelie + Sebastien

4. Dependances entre taches

4.1 Graphe de dependances





T4.4 (V2) --> T6.1 (Dashboard V1) --> T6.2 (V2) --> T6.3 (V3)

T4.7 (V5) --> T7.3 (Rapport) --> T8.1 (Script video)

4.2 Matrice de dependances

Tache	Depend de	Type	Critique
T1.4 MongoDB	T1.3 Docker	Fin-Debut	Oui
T2.1 Collecteur	T1.4 MongoDB	Fin-Debut	Oui
T4.1 Baseline	T2.1 Collecteur	Fin-Debut	Oui
T4.2 Audit biais	T4.1 Baseline	Fin-Debut	Oui
T4.3 V1.5	T4.2 Audit + T3.4 Emotions	Fin-Debut	Oui
T4.4 V2	T4.3 V1.5	Fin-Debut	Oui
T4.5 V3	T4.4 V2	Fin-Debut	Oui
T4.6 V4	T4.5 V3	Fin-Debut	Oui
T4.7 V5	T4.6 V4	Fin-Debut	Oui
T5.1 CamemBERT	T4.6 V4	Fin-Debut	Non
T5.3 RoBERTa	T4.7 V5	Fin-Debut	Non
T5.5 Hybride	T5.2 CamemBERT V2 + T4.7 V5	Fin-Debut	Non
T6.1 Dashboard	T4.4 V2	Fin-Debut	Non
T7.3 Rapport	T4.7 V5	Fin-Debut (contenu)	Non
T8.1 Video	T7.3 Rapport	Fin-Debut	Oui

4.3 Chemin critique

Le chemin critique du projet est :

T1.3 -> T1.4 -> T2.1 -> T4.1 -> T4.2 -> T4.3 -> T4.4 -> T4.5 -> T4.6 -> T4.7 -> T7.3 -> T8.1

Duree totale du chemin critique : ~20 semaines (Dec 2025 - Avril 2026)

Toute tache sur le chemin critique qui prend du retard retarde la livraison finale.

5. Repartition des responsabilites (RACI)

Tache	Azelie Bernard	Sebastien Lazcanotegui
WP1 Infrastructure	R/A	I
WP2 Collecte	R/A	I
WP3 Emotions	R/A	I
WP4 Pipeline V1-V5	R/A	C (GridSearch, debiasage)
WP5 Transformers	R/A	I
WP6 Dashboard	R/A	I
WP7 Documentation	R/A	C (revue)
WP8 Video MVP	R	R

Legende RACI : R = Responsable, A = Approbateur, C = Consulte, I = Informé

5.1 Charge de travail estimee

Work Package	Azelie (heures)	Sebastien (heures)	Total
WP1 Cadrage & Infra	20	0	20
WP2 Collecte	25	0	25
WP3 Emotions	30	0	30
WP4 Pipeline NLP	80	10	90
WP5 Transformers	40	0	40
WP6 Dashboard	30	0	30
WP7 Documentation	40	5	45
WP8 Video MVP	10	10	20
Total	275	25	300

6. Outils de planification utilises

Outil	Usage	Justification
Git / GitHub	Versioning du code et des documents	Tracabilite complete des modifications, historique des commits
Docker Compose	Orchestration des services	Reproductibilite de l'environnement, deploiement standardise
Jupyter Notebooks	Experimentation ML iterative	Documentation executable des experiences
GitHub Issues	Suivi des taches et bugs	Integration native avec Git, assignation, labels
Markdown	Documentation	Versionnable, lisible, convertible en PDF
CodeCarbon	Suivi empreinte carbone	Mesure automatique de la consommation energetique

7. Indicateurs de suivi du planning

KPI	Methode	Frequence	Seuil d'alerte
Avancement reel vs planifie	Comparaison jalons	Hebdomadaire	Retard > 1 semaine
Nombre de taches completees	Comptage Git commits	Hebdomadaire	< 3 commits/semaine
F1-score progression	Metriques ML	A chaque version	Regression > 2%
Volume donnees collectees	MongoDB count	Quotidien	< 500 posts/jour
Bugs ouverts	GitHub issues	Hebdomadaire	> 5 bugs critiques

8. Gestion des risques lies au planning

Risque	Probabilite	Impact	Mitigation
Retard sur le pipeline NLP (chemin critique)	Moyenne	Eleve	Parallelisation des taches non-critiques (dashboard, docs)
Indisponibilite API Bluesky	Faible	Moyen	Cache local, retry automatique, donnees existantes suffisantes
Probleme de convergence du modele	Moyenne	Moyen	Rollback vers version precedente validee
Surcharge d'un membre de l'equipe	Moyenne	Eleve	Repartition dynamique, priorisation des taches critiques
Changement de specifications	Faible	Moyen	Methodologie agile, iterations courtes

Document valide par l'equipe projet - Avril 2026

Reference : PLAN-THUM-2026-001 - Version 1.0