
THUMALIEN

Pipeline NLP de detection de fake news sur Bluesky

08 Planification Gantt

Formation : Mastere Big Data & IA - Sup de Vinci

Equipe : Azelie Bernard, Sebastien Lazcanotegui

Annee : 2025-2026

Version : Mai 2026

Planification detaillee du projet Thumalien

Diagramme de Gantt, WBS, dependances et jalons

Reference : PLAN-THUM-2026-001

Version : 2.0

Date : Mai 2026

Equipe : Azelie Bernard (Lead technique), Sebastien Lazcanotegui (Consolidation ML)

1. Work Breakdown Structure (WBS)

1.1 Decomposition hierarchique

```
THUMALIEN - Projet Etude M1
|
|-- WP1 : Cadrage & Infrastructure (Dec 2025)
|   |-- T1.1 : Analyse des besoins et specification
|   |-- T1.2 : Choix technologiques (Python, MongoDB, Docker)
|   |-- T1.3 : Mise en place environnement Docker Compose
|   |-- T1.4 : Configuration MongoDB + volumes persistants
|   |-- T1.5 : Creation du depot Git et structure projet
|
|-- WP2 : Collecte de donnees (Dec 2025 - Continu)
|   |-- T2.1 : Developpement collecteur Bluesky (AT Protocol)
|   |-- T2.2 : Validation schema JSON + deduplication
|   |-- T2.3 : Audit qualite des donnees collectees
|   |-- T2.4 : Maintenance et monitoring continu
|
|-- WP3 : Modele d'emotions (Jan 2026)
|   |-- T3.1 : Exploration datasets emotions (GoEmotions, FR tweets)
|   |-- T3.2 : Developpement MLP PyTorch (7 classes)
|   |-- T3.3 : Early stopping + class weights
|   |-- T3.4 : Evaluation et validation
|
|-- WP4 : Pipeline NLP Expert (Jan - Avril 2026)
|   |-- T4.1 : Baseline V1.0 (TF-IDF + LogReg EN)
|   |-- T4.2 : Audit biais Reuters + debiaisage
|   |-- T4.3 : V1.5 bilingue + features linguistiques
|   |-- T4.4 : V2 integration datasets sociaux + seuil 0.44
|   |-- T4.5 : V3 correction preprocessing
|   |-- T4.6 : V4 augmentation FR court + 15 features
|   |-- T4.7 : V5 + 10K posts sociaux synthetiques
|   |-- T4.8 : GridSearch hyperparametres (C, min_df, ngram)
|
|-- WP5 : Modeles Transformer (Avril 2026)
|   |-- T5.1 : Fine-tuning CamemBERT V1 (FR)
|   |-- T5.2 : CamemBERT V2 + donnees sociales
|   |-- T5.3 : Fine-tuning RoBERTa EN V1
```

```

| |-- T5.4 : RoBERTa EN V2 + 10K synthétique
| |-- T5.5 : Pipeline hybride stacking V5 + CamemBERT V2
|
|-- WP6 : Dashboard & Visualisation (Mars 2026)
| |-- T6.1 : Dashboard V1 (metriques basiques)
| |-- T6.2 : Dashboard V2 (glassmorphism, 3 pages)
| |-- T6.3 : Dashboard V3 (radar charts, live prediction)
| |-- T6.4 : Integration weighted loss + securite
|
|-- WP7 : Documentation & Conformite (Fev - Avril 2026)
| |-- T7.1 : Cahier des charges techniques
| |-- T7.2 : Conformite RGPD & AI Act
| |-- T7.3 : Rapport de projet
| |-- T7.4 : Guide utilisateur
| |-- T7.5 : Documentation technique (22 notebooks)
| |-- T7.6 : Planification et gouvernance
|
|-- WP8 : Evaluation & Gold Test Set (Avril - Mai 2026)
| |-- T8.1 : Gold set V1 (200 posts, kappa=0.808)
| |-- T8.2 : Gold set V2 annotation (500 posts, 2 annotateurs, kappa=0.498)
| |-- T8.3 : Evaluation systematique V5-V9 sur gold
|
|-- WP9 : Iterations avancees V6-V9 (Avril - Mai 2026)
| |-- T9.1 : V6 Style-Only topic-agnostic (28 features, GBT)
| |-- T9.2 : V7 Ensemble hybride V5+V6 + SHAP
| |-- T9.3 : V8 Meta-learner V5+V6+CamemBERT
| |-- T9.4 : Self-training Bluesky (echec documente)
| |-- T9.5 : V9 Pipeline 2 etapes fait/opinion
|
|-- WP10 : Collecteur V3 & Reeequilibrage (Avril 2026)
| |-- T10.1 : Reeequilibrage termes FR/EN (28 FR + 16 EN)
| |-- T10.2 : Inference automatique emotions + V5
| |-- T10.3 : Rate limiting & backoff progressif
|
|-- WP11 : Dashboard V4-V5 (Avril - Mai 2026)
| |-- T11.1 : Dashboard V4 (V9 + SHAP + Explorateur)
| |-- T11.2 : Dashboard V5 (5 pages, accents, Performance)
|
|-- WP12 : Tests & Qualite (Mai 2026)
| |-- T12.1 : Tests unitaires (107 tests, 26% coverage)
| |-- T12.2 : Benchmark latence (1.5ms/texte)
| |-- T12.3 : Tests d'integration pipeline
|
|-- WP13 : Video MVP (Mai 2026)
| |-- T13.1 : Script et storyboard
| |-- T13.2 : Tournage demo live
| |-- T13.3 : Montage et post-production
| |-- T13.4 : Livraison finale

```

2. Diagramme de Gantt

2.1 Planning macro (semaines)

gantt

```

title Planification Projet Thumalien
dateFormat YYYY-MM-DD
axisFormat %d/%m
todayMarker off

```

section WP1 Cadrage & Infra

```

T1.5 Depot Git :done, t15, 2025-12-01, 2025-12-10
T1.1 Analyse besoins :done, t11, 2025-12-01, 2025-12-14
T1.2 Choix techno :done, t12, 2025-12-01, 2025-12-14
T1.3 Docker Compose :done, t13, 2025-12-10, 2025-12-22
T1.4 MongoDB config :done, t14, 2025-12-10, 2025-12-22
J0 Lancement projet :milestone, j0, 2025-12-01, 0d

```

section WP2 Collecte donnees

```

T2.1 Collecteur Bluesky :done, t21, 2025-12-10, 2025-12-22
T2.2 Validation schema :done, t22, 2025-12-10, 2025-12-22
T2.3 Audit qualite :done, t23, 2026-01-06, 2026-01-20
T2.4 Monitoring continu :done, t24, 2025-12-22, 2026-05-19
J1 Collecteur operationnel :milestone, j1, 2025-12-15, 0d

```

section WP3 Modele emotions

```

T3.1 Exploration datasets :done, t31, 2026-01-05, 2026-01-15
T3.2 MLP PyTorch :done, t32, 2026-01-05, 2026-01-25
T3.3 Early stopping :done, t33, 2026-01-18, 2026-01-25
T3.4 Evaluation :done, t34, 2026-01-18, 2026-01-25
J4 Modele emotions :milestone, j4, 2026-01-20, 0d

```

section WP4 Pipeline NLP V1-V5

```

T4.1 Baseline V1.0 (LogReg EN) :done, t41, 2025-12-15, 2025-12-28
T4.2 Audit biais Reuters :done, t42, 2026-01-05, 2026-01-15
T4.3 V1.5 bilingue + features :done, t43, 2026-01-18, 2026-02-08
T4.8 GridSearch hyperparametres :done, t48, 2026-02-10, 2026-02-20
T4.4 V2 datasets sociaux + seuil 0.44 :done, t44, 2026-02-20, 2026-03-05
T4.5 V3 correction preprocessing :done, t45, 2026-03-10, 2026-03-25
T4.6 V4 augmentation FR court :done, t46, 2026-04-01, 2026-04-10
T4.7 V5 +10K posts synthetiques :done, t47, 2026-04-10, 2026-04-18
J2 Baseline V1.0 :milestone, j2, 2025-12-20, 0d
J3 Audit qualite :milestone, j3, 2026-01-10, 0d
J5 Pipeline V1.5 :milestone, j5, 2026-02-05, 0d
J6 GridSearch :milestone, j6, 2026-02-15, 0d
J7 Pipeline V2 :milestone, j7, 2026-02-25, 0d
J9 Pipeline V3 :milestone, j9, 2026-03-20, 0d
J10 Pipeline V4 :milestone, j10, 2026-04-05, 0d
J11 Pipeline V5 :milestone, j11, 2026-04-10, 0d

```

section WP5 Modeles Transformer

```

T5.1 CamemBERT V1 (FR) :done, t51, 2026-04-05, 2026-04-12
T5.2 CamemBERT V2 + donnees sociales :done, t52, 2026-04-12, 2026-04-16
T5.3 RoBERTa EN V1 :done, t53, 2026-04-12, 2026-04-18
T5.4 RoBERTa EN V2 + 10K synthetique :done, t54, 2026-04-18, 2026-04-22
T5.5 Pipeline hybride stacking :done, t55, 2026-04-18, 2026-04-22
J12 CamemBERT V1/V2 :milestone, j12, 2026-04-12, 0d
J13 RoBERTa EN V1/V2 :milestone, j13, 2026-04-15, 0d
J14 Pipeline hybride :milestone, j14, 2026-04-18, 0d

```

section WP6 Dashboard V1-V3

T6.1 Dashboard V1 (metriques)	:done, t61, 2026-03-01, 2026-03-12
T6.2 Dashboard V2 (glassmorphism)	:done, t62, 2026-03-12, 2026-03-25
T6.3 Dashboard V3 (radar, prediction)	:done, t63, 2026-03-25, 2026-04-08
T6.4 Securite + weighted loss	:done, t64, 2026-04-08, 2026-04-16
J8 Dashboard V2	:milestone, j8, 2026-03-10, 0d
section WP7 Documentation	
T7.1 CDC techniques	:done, t71, 2026-02-01, 2026-02-14
T7.2 RGPD & AI Act	:done, t72, 2026-02-01, 2026-02-14
T7.3 Rapport projet	:done, t73, 2026-04-05, 2026-05-15
T7.4 Guide utilisateur	:done, t74, 2026-04-10, 2026-04-28
T7.5 Doc technique (22 notebooks)	:done, t75, 2026-04-05, 2026-05-15
T7.6 Planification	:done, t76, 2026-04-22, 2026-05-08
J24 Documentation finale	:milestone, j24, 2026-05-12, 0d
section WP8 Gold Test Set	
T8.1 Gold set V1 (200 posts)	:done, t81, 2026-04-05, 2026-04-15
T8.2 Gold set V2 (500 posts, 2 annot.)	:done, t82, 2026-04-15, 2026-04-28
T8.3 Eval V5-V9 sur gold	:done, t83, 2026-04-25, 2026-05-08
J19 Gold Test Set V2	:milestone, j19, 2026-04-25, 0d
section WP9 Iterations V6-V9	
T9.1 V6 Style-Only (GBT, 28 feat.)	:done, t91, 2026-04-15, 2026-04-22
T9.2 V7 Ensemble + SHAP	:done, t92, 2026-04-22, 2026-04-28
T9.3 V8 Meta-learner	:done, t93, 2026-04-22, 2026-04-28
T9.4 Self-training (echec documente)	:done, t94, 2026-04-25, 2026-04-28
T9.5 V9 Cascade fait/opinion	:done, t95, 2026-04-28, 2026-05-05
J15 Consolidation ML	:milestone, j15, 2026-04-20, 0d
J16 V6 Style-Only	:milestone, j16, 2026-04-20, 0d
J21 V9 Cascade	:milestone, j21, 2026-05-02, 0d
section WP10 Collecteur V3	
T10.1 Reequilibrage FR/EN	:done, t101, 2026-04-15, 2026-04-22
T10.2 Inference auto emotions + V5	:done, t102, 2026-04-15, 2026-04-25
T10.3 Rate limiting & backoff	:done, t103, 2026-04-22, 2026-04-28
J20 Collecteur V3	:milestone, j20, 2026-04-28, 0d
section WP11 Dashboard V4-V5	
T11.1 Dashboard V4 (V9 + SHAP)	:done, t111, 2026-04-25, 2026-05-02
T11.2 Dashboard V5 (5 pages, perf.)	:done, t112, 2026-05-02, 2026-05-08
J22 Dashboard V5	:milestone, j22, 2026-05-05, 0d
section WP12 Tests & Qualite	
T12.1 Tests unitaires (107 tests)	:done, t121, 2026-05-02, 2026-05-10
T12.2 Benchmark latence (1.5ms)	:done, t122, 2026-05-02, 2026-05-08
T12.3 Tests integration pipeline	:done, t123, 2026-05-08, 2026-05-14
J23 Tests & Benchmark	:milestone, j23, 2026-05-08, 0d
section WP13 Video MVP	
T13.1 Script et storyboard	:done, t131, 2026-05-08, 2026-05-13
T13.2 Tournage demo live	:done, t132, 2026-05-13, 2026-05-16
T13.3 Montage et post-production	:done, t133, 2026-05-15, 2026-05-18
T13.4 Livraison finale	:done, t134, 2026-05-18, 2026-05-19
J25 Video MVP	:milestone, j25, 2026-05-15, 0d
DEADLINE	:milestone, crit, deadline, 2026-05-19, 0d

2.2 Legende

- Toutes les taches sont marquees done (projet en phase finale)
- Les losanges representent les jalons (milestones)
- DEADLINE : 19 mai 2026


3. Calendrier formel avec dates clés


Date	Jalon	Livrable	Responsable
01/12/2025	J0 - Lancement projet	Repo Git, Docker, MongoDB	Azelie
15/12/2025	J1 - Collecteur operationnel	collect_bluesky.py fonctionnel	Azelie
20/12/2025	J2 - Baseline V1.0	LogReg EN, F1=0.99 (biaise)	Azelie
10/01/2026	J3 - Audit qualite	Biais Reuters identifie	Azelie
20/01/2026	J4 - Modele emotions	MLP PyTorch 7 emotions	Azelie
05/02/2026	J5 - Pipeline V1.5	Bilingue, 12 features, F1=0.986	Azelie
15/02/2026	J6 - GridSearch	C=5.0, min_df=5, ngram=(1,2)	Sebastien
25/02/2026	J7 - Pipeline V2	+3 datasets sociaux, seuil=0.44	Azelie
10/03/2026	J8 - Dashboard V2	Glassmorphism, 3 pages	Azelie
20/03/2026	J9 - Pipeline V3	Correction features linguistiques	Azelie
05/04/2026	J10 - Pipeline V4	Augmentation FR court, 15 features	Azelie
10/04/2026	J11 - Pipeline V5	+10K FR synthetique, F1=0.913	Azelie
12/04/2026	J12 - CamemBERT V1/V2	F1 FR ultra-court = 0.957	Azelie
15/04/2026	J13 - RoBERTa EN V1/V2	F1 EN ultra-court = 0.874	Azelie
18/04/2026	J14 - Pipeline hybride	Stacking V5 + CamemBERT V2	Azelie
20/04/2026	J15 - Consolidation ML	Debiaisage, hyperparametres	Sebastien
20/04/2026	J16 - V6 Style-Only	GradientBoosting 28 features, topic-agnostic	Azelie
22/04/2026	J17 - V7 Ensemble + SHAP	Meta-learner V5+V6, explicabilite SHAP	Azelie
24/04/2026	J18 - V8 Meta-learner	V5+V6+CamemBERT, F1 suspect +28%	Azelie
25/04/2026	J19 - Gold Test Set V2	500 posts, 2 annotateurs, kappa=0.498	Azelie

28/04/2026	J20 - Collecteur V3	Reeequilibrage FR/EN + inference auto	Azelie
02/05/2026	J21 - V9 Cascade fait/opinion	FP -67%, Fisher p=0.0005	Azelie
05/05/2026	J22 - Dashboard V5	5 pages, accents FR, page Performance	Azelie
08/05/2026	J23 - Tests & Benchmark	107 tests, 1.5ms/texte, 728 textes/sec	Azelie
12/05/2026	J24 - Documentation finale	Rapport, planification, rendus individuels	Azelie
15/05/2026	J25 - Video MVP	Video 15-20 min face-cam + dossier	Azelie + Sebastien
19/05/2026	DEADLINE	Livraison finale - dossier + video + code	Equipe

4. Dependances entre taches

4.1 Graphe de dependances





T4.4 (V2) --> T6.1 (Dashboard V1) --> T6.2 (V2) --> T6.3 (V3)

T4.7 (V5) --> T7.3 (Rapport) --> T8.1 (Script video)

4.2 Matrice de dependances

Tache	Depend de	Type	Critique
T1.4 MongoDB	T1.3 Docker	Fin-Debut	Oui
T2.1 Collecteur	T1.4 MongoDB	Fin-Debut	Oui
T4.1 Baseline	T2.1 Collecteur	Fin-Debut	Oui
T4.2 Audit biais	T4.1 Baseline	Fin-Debut	Oui
T4.3 V1.5	T4.2 Audit + T3.4 Emotions	Fin-Debut	Oui
T4.4 V2	T4.3 V1.5	Fin-Debut	Oui
T4.5 V3	T4.4 V2	Fin-Debut	Oui
T4.6 V4	T4.5 V3	Fin-Debut	Oui
T4.7 V5	T4.6 V4	Fin-Debut	Oui
T5.1 CamemBERT	T4.6 V4	Fin-Debut	Non
T5.3 RoBERTa	T4.7 V5	Fin-Debut	Non
T5.5 Hybride	T5.2 CamemBERT V2 + T4.7 V5	Fin-Debut	Non
T6.1 Dashboard	T4.4 V2	Fin-Debut	Non
T7.3 Rapport	T4.7 V5	Fin-Debut (contenu)	Non
T8.1 Gold set V1	T4.7 V5	Fin-Debut	Non
T8.3 Eval gold	T9.5 V9 + T8.2 Gold V2	Fin-Debut	Non
T9.1 V6 Style	T4.7 V5 + T8.1 Gold V1	Fin-Debut	Oui
T9.2 V7 Ensemble	T9.1 V6	Fin-Debut	Oui
T9.3 V8 Meta	T9.2 V7 + T5.2 CamemBERT V2	Fin-Debut	Oui
T9.5 V9 Cascade	T9.3 V8 + T8.2 Gold V2	Fin-Debut	Oui
T11.1 Dashboard V4	T9.3 V8	Fin-Debut	Non
T11.2 Dashboard V5	T11.1 Dashboard V4 + T9.5 V9	Fin-Debut	Non
T12.1 Tests	T9.5 V9 + T11.2 Dashboard V5	Fin-Debut	Non
T13.1 Video	T12.1 Tests + T7.3 Rapport	Fin-Debut	Oui

4.3 Chemin critique

Le chemin critique du projet est :

T1.3 -> T1.4 -> T2.1 -> T4.1 -> T4.2 -> T4.3 -> T4.4 -> T4.5 -> T4.6 -> T4.7

-> T9.1 (V6) -> T9.2 (V7) -> T9.3 (V8) -> T9.5 (V9) -> T7.3 (Rapport) -> T13.1 (Video)

Duree totale du chemin critique : ~24 semaines (Dec 2025 - Mai 2026)

Deadline de livraison : 19 mai 2026

Toute tache sur le chemin critique qui prend du retard retarde la livraison finale.

5. Repartition des responsabilites (RACI)

Tache	Azelie Bernard	Sebastien Lazcanotegui
WP1 Infrastructure	R/A	I
WP2 Collecte	R/A	C (support termes de recherche)
WP3 Emotions	R/A	I
WP4 Pipeline V1-V5	R/A	R (GridSearch, debiaisage)
WP5 Transformers	R/A	I
WP6 Dashboard	R/A	C (feedback utilisateur)
WP7 Documentation	R	R (revue, relecture, validation)
WP8 Gold Test Set	R	R (annotation 2e annotateur, kappa)
WP9 Iterations V6-V9	R/A	C (evaluation gold set)
WP10 Collecteur V3	R/A	I
WP11 Dashboard V4-V5	R/A	C (tests fonctionnels)
WP12 Tests & Qualite	R	C (validation resultats)
WP13 Video MVP	R	R (co-production)

Legende RACI : R = Responsable, A = Approbateur, C = Consulte, I = Informe

5.1 Charge de travail estimee

Work Package	Azelie (heures)	Sebastien (heures)	Total
WP1 Cadrage & Infra	20	2	22
WP2 Collecte	25	3	28
WP3 Emotions	30	0	30
WP4 Pipeline NLP (V1-V5)	80	15	95
WP5 Transformers	40	0	40
WP6 Dashboard (V1-V3)	20	3	23
WP7 Documentation	40	10	50
WP8 Gold Test Set	20	15	35
WP9 Iterations V6-V9	50	5	55
WP10 Collecteur V3	10	0	10
WP11 Dashboard V4-V5	20	3	23
WP12 Tests & Qualite	15	5	20
WP13 Video MVP	10	10	20
Total	380	71	451

6. Outils de planification utilises

Outil	Usage	Justification
Git / GitHub	Versioning du code et des documents	Tracabilite complete des modifications, historique des commits
Docker Compose	Orchestration des services	Reproductibilite de l'environnement, deploiement standardise
Jupyter Notebooks	Experimentation ML iterative	Documentation executable des experiences
GitHub Issues	Suivi des taches et bugs	Integration native avec Git, assignation, labels
Markdown	Documentation	Versionnable, lisible, convertible en PDF
CodeCarbon	Suivi empreinte carbone	Mesure automatique de la consommation energetique

7. Indicateurs de suivi du planning

KPI	Methode	Frequence	Seuil d'alerte
Avancement reel vs planifie	Comparaison jalons	Hebdomadaire	Retard > 1 semaine
Nombre de taches completees	Comptage Git commits	Hebdomadaire	< 3 commits/semaine
F1-score progression	Metriques ML	A chaque version	Regression > 2%
Volume donnees collectees	MongoDB count	Quotidien	< 500 posts/jour
Bugs ouverts	GitHub issues	Hebdomadaire	> 5 bugs critiques

8. Gestion des risques lies au planning

Risque	Probabilite	Impact	Mitigation
Retard sur le pipeline NLP (chemin critique)	Moyenne	Eleve	Parallelisation des taches non-critiques (dashboard, docs)
Indisponibilite API Bluesky	Faible	Moyen	Cache local, retry automatique, donnees existantes suffisantes
Probleme de convergence du modele	Moyenne	Moyen	Rollback vers version precedente validee

Surcharge d'un membre du binome	Moyenne	Eleve	Repartition dynamique, priorisation des taches critiques, points hebdomadaires
Changement de specifications	Faible	Moyen	Methodologie agile, iterations courtes

9. Planning previsionnel vs reel

9.1 Tableau comparatif des jalons

#	Jalon	Date prevue	Date reelle	Delta	Statut
J1	Setup infrastructure (Docker, Git, MongoDB)	Dec 2025	Dec 2025	0	A l'heure
J2	Collecte donnees operationnelle	Jan 2026	Jan 2026	0	A l'heure
J3	V1 Pipeline NLP (Baseline)	Fev 2026	Jan 2026	-1 mois	En avance
J4	Dashboard V1	Fev 2026	Fev 2026	0	A l'heure
J5	GridSearch hyperparametres	Mar 2026	Mar 2026	0	A l'heure
J6	Datasets sociaux integres	Mar 2026	Mar 2026	0	A l'heure
J7	Gold Test Set V1	Mar 2026	Mar 2026	0	A l'heure
J8	V3-V5 corrections pipeline	Avr 2026	Avr 2026	0	A l'heure
J9	V6 Style-Only (topic-agnostic)	Non prevu	Avr 2026	--	Emergent
J10	V7-V8 Meta-learners (ensemble)	Non prevu	Avr 2026	--	Emergent
J11	Annotation 500 posts (2 annotateurs)	Avr 2026	Avr 2026	0	A l'heure
J12	CamemBERT fine-tuning (FR)	Mai 2026	Avr 2026	-1 mois	En avance
J13	RoBERTa EN fine-tuning	Non prevu	Avr 2026	--	Emergent
J14	V8 Meta-learner CamemBERT	Non prevu	Avr 2026	--	Emergent
J15	V9 Pipeline Cascade fait/opinion	Mai 2026	Mai 2026	0	A l'heure

J16	Documentation finale	Mai 2026	Mai 2026	0	A l'heure
-----	----------------------	----------	----------	---	-----------

9.2 Diagramme Gantt previsionnel vs reel

```
gantt
  title Planning previsionnel vs reel - Projet Thumalien
  dateFormat YYYY-MM-DD
  axisFormat %b %Y
  todayMarker off

  section J1 Setup
  Prevu           :done, j1p, 2025-12-01, 2025-12-31
  Reel            :done, j1r, 2025-12-01, 2025-12-31

  section J2 Collecte
  Prevu           :done, j2p, 2026-01-01, 2026-01-31
  Reel            :done, j2r, 2026-01-01, 2026-01-31

  section J3 V1 Pipeline
  Prevu           :done, j3p, 2026-02-01, 2026-02-28
  Reel (en avance) :done, crit, j3r, 2026-01-10, 2026-01-31

  section J4 Dashboard V1
  Prevu           :done, j4p, 2026-02-01, 2026-02-28
  Reel            :done, j4r, 2026-02-01, 2026-02-28

  section J5 GridSearch
  Prevu           :done, j5p, 2026-03-01, 2026-03-31
  Reel            :done, j5r, 2026-03-01, 2026-03-31

  section J6 Datasets sociaux
  Prevu           :done, j6p, 2026-03-01, 2026-03-31
  Reel            :done, j6r, 2026-03-01, 2026-03-31

  section J7 Gold Test Set
  Prevu           :done, j7p, 2026-03-01, 2026-03-31
  Reel            :done, j7r, 2026-03-01, 2026-03-31

  section J8 V3-V5 corrections
  Prevu           :done, j8p, 2026-04-01, 2026-04-30
  Reel            :done, j8r, 2026-04-01, 2026-04-30

  section J9 V6 Style-Only
  Reel (emergent) :done, crit, j9r, 2026-04-15, 2026-04-22

  section J10 V7-V8 Meta-learners
  Reel (emergent) :done, crit, j10r, 2026-04-22, 2026-04-28

  section J11 Annotation 500
  Prevu           :done, j11p, 2026-04-01, 2026-04-30
  Reel            :done, j11r, 2026-04-15, 2026-04-28

  section J12 CamemBERT
  Prevu           :done, j12p, 2026-05-01, 2026-05-31
  Reel (en avance) :done, crit, j12r, 2026-04-05, 2026-04-16
```

section J13 RoBERTa EN	
Reel (emergent)	:done, crit, j13r, 2026-04-12, 2026-04-22
section J14 V8 Meta CamemBERT	
Reel (emergent)	:done, crit, j14r, 2026-04-22, 2026-04-28
section J15 V9 Cascade	
Prevu	:done, j15p, 2026-05-01, 2026-05-31
Reel	:done, j15r, 2026-04-28, 2026-05-05
section J16 Documentation	
Prevu	:done, j16p, 2026-05-01, 2026-05-31
Reel	:done, j16r, 2026-05-01, 2026-05-15

9.3 Analyse des ecarts

Synthese globale : sur 16 jalons identifiés a posteriori, 10 ont été livrés à l'heure, 2 en avance et 4 sont des jalons émergents non prévus dans la planification initiale. Aucun retard significatif n'a été constaté sur l'ensemble du projet.

Jalons en avance :

- J3 - V1 Pipeline NLP (-1 mois) : la baseline TF-IDF + Logistic Regression s'est révélée plus rapide à implémenter que prévu. Le travail préparatoire d'infrastructure (Docker, MongoDB) réalisé en décembre a permis de démarrer le pipeline dès janvier au lieu de février.
- J12 - CamemBERT (-1 mois) : initialement prévu pour mai, le fine-tuning CamemBERT a pu être lancé dès début avril grâce à l'avance accumulée sur le pipeline classique (V5 finalisée mi-avril) et à la disponibilité des données sociales annotées.

Jalons émergents (non prévus) :

- J9 - V6 Style-Only : approche topic-agnostic basée sur 28 features stylistiques pures, émergée de l'analyse du gold test set qui a révélé une dépendance au sujet dans les versions précédentes.
- J10 - V7/V8 Meta-learners : combinaisons ensemblistes des modèles V5, V6 et CamemBERT, motivées par la complémentarité observée entre les approches lexicale, stylistique et transformer.
- J13 - RoBERTa EN : ajout d'un modèle anglophone pour compléter CamemBERT, en réponse au besoin bilingue identifié dans le gold test set.
- J14 - V8 Meta CamemBERT : meta-learner intégrant CamemBERT, conséquence directe de la disponibilité anticipée de ce modèle.

Facteurs explicatifs :

- Approche agile itérative : l'évaluation systématique sur le gold test set (V1 puis V2 avec 500 posts et 2 annotateurs) a permis d'identifier les faiblesses de chaque version et d'orienter les itérations suivantes de manière empirique plutôt que planifiée.
- Parallélisation efficace : les tâches non-critiques (dashboard, documentation) ont été menées en parallèle du chemin critique NLP, absorbant les temps morts.
- Pas de retard majeur : l'absence de blocages techniques (API Bluesky stable, convergence rapide des modèles) a permis de maintenir le planning, voire de prendre de l'avance.
- Scope creep positif : les 4 jalons émergents représentent un enrichissement du périmètre sans impact sur la deadline, rendu possible par l'avance accumulée sur les jalons planifiés.

Document valide par l'equipe projet - Mai 2026

Reference : PLAN-THUM-2026-001 - Version 2.0

Deadline de livraison : 19 mai 2026