
THUMALIEN

Pipeline NLP de detection de fake news sur Bluesky

09 Pra Pca

Formation : Mastere Big Data & IA - Sup de Vinci

Equipe : Azelie Bernard, Sebastien Lazcanotegui

Annee : 2025-2026

Version : Mai 2026

22 notebooks Documentation complete	Persistence garantie restart: always	Fallback V(n-1)
<pre> +-----+ MECANISMES DE PROTECTION +-----+ </pre>		
[restart: always] Redemarrage auto Tous les conteneurs	[Volumes Docker] Survie aux crashes Donnees persistantes	[Git versioning] Historique complet Rollback possible

3.2 Mesures de continuite par composant

MongoDB (Donnees)

- Volumes Docker persistants : les donnees survivent au redemarrage des conteneurs
- Politique restart: always : redemarrage automatique en cas de crash
- Index unique sur uri : protection contre les doublons apres reprise
- Backup recommande : mongodump quotidien vers stockage externe

Collecteur Bluesky

- restart: always dans Docker Compose : reprise automatique
- Gestion des erreurs reseau : retry avec backoff exponentiel
- Deduplication : les posts deja collectes sont ignores au redemarrage
- Impact d'un arret : perte des posts publies pendant l'indisponibilite uniquement

Pipeline NLP

- Modeles versionnes dans Git : rollback instantane vers version precedente
- Fallback automatique : si le modele V5 echoue, chargement du V4 automatiquement
- Inference stateless : pas d'etat a restaurer, rechargement du modele suffit

Dashboard Streamlit

- Lecture seule : le dashboard ne modifie pas les donnees
- Redemarrage rapide : docker-compose restart streamlit
- Cache Streamlit : les donnees sont mises en cache pour des performances optimales

4. Plan de Reprise d'Activite (PRA)

4.1 Scenarios d'incidents et procedures

Scenario 1 : Crash d'un conteneur Docker

Etape	Action	Commande	Temps
1	Vérification automatique	restart: always dans docker-compose.yml	0 min

2	Vérification manuelle si échec	docker-compose ps	1 min
3	Redémarrage manuel	docker-compose restart <service>	2 min
4	Vérification des logs	docker-compose logs --tail=50 <service>	3 min

Scenario 2 : Corruption de la base MongoDB

Etape	Action	Commande	Temps
1	Arrêter le conteneur	docker-compose stop mongodb	1 min
2	Sauvegarder le volume corrompu	cp -r mongodb_data mongodb_data_backup	5 min
3	Restaurer depuis backup	mongorestore --db thumalien backup/	10 min
4	Redémarrer et vérifier	docker-compose up -d mongodb	2 min
5	Relancer la collecte	Le collecteur reprend automatiquement	1 min

Scenario 3 : Corruption ou perte d'un modèle ML

Etape	Action	Commande	Temps
1	Identifier le modèle défaillant	Vérifier les logs d'erreur	2 min
2	Restaurer depuis Git	git checkout HEAD -- models/	1 min
3	Si absent de Git : re-entraîner	Exécuter le notebook correspondant	30-60 min
4	Valider les prédictions	Tester sur un échantillon connu	5 min
5	Fallback V(n-1)	Charger la version précédente du modèle	2 min

Scenario 4 : Panne complète de la machine hôte

Etape	Action	Temps
1	Provisionner nouvelle machine	Variable
2	Installer Docker + Docker Compose	15 min
3	Cloner le dépôt Git	git clone - 5 min
4	Restaurer backup MongoDB	30 min
5	Lancer docker-compose up -d	5 min
6	Vérifier tous les services	10 min
Total		~1 heure (hors provisionnement)

Scenario 5 : API Bluesky indisponible

Etape	Action	Temps
1	Le collecteur detecte l'erreur	Automatique
2	Retry avec backoff exponentiel	1-5 min
3	Dashboard continue sur donnees existantes	0 min
4	Surveillance de l'API AT Protocol	Continu
5	Reprise automatique quand l'API revient	Automatique

5. Politique de sauvegarde

5.1 Strategie de backup

Donnee	Methode	Frequence	Retention	Stockage
Code source	Git push	A chaque commit	Illimitee	GitHub
Modeles ML	Git (LFS si > 100MB)	A chaque version	Toutes versions	GitHub
Base MongoDB	mongodump	Quotidien (recommande)	30 jours	Stockage externe
Configuration Docker	Versionnee dans Git	A chaque modification	Illimitee	GitHub
Documentation	Versionnee dans Git	A chaque modification	Illimitee	GitHub

5.2 Procedure de backup MongoDB recommandee

```
# Backup quotidien automatise (crontab)
0 2 * docker exec mongodb mongodump --out /backup/$(date +%Y%m%d)

# Backup manuel avant operation risquee
docker exec mongodb mongodump --out /backup/pre_operation

# Restauration
docker exec mongodb mongorestore --drop /backup/20260415
```

6. Tests de reprise

6.1 Plan de tests

Test	Frequence	Procedure	Critere de succes
Redemarrage conteneur	Mensuel	docker-compose restart	Tous services UP en < 5 min
Restauration modele	A chaque nouvelle version	git checkout modele precedent	Predictions coherentes

Simulation panne MongoDB	Trimestriel	Arreter MongoDB, verifier reprise	Donnees intactes apres restart
Restauration complete	Semestriel	Clone + docker-compose up sur machine neuve	Systeme fonctionnel en < 1h

6.2 Resultats des derniers tests

Date	Test	Resultat	Observations
Avril 2026	Redemarrage Docker Compose	OK	Tous services UP en 45 secondes
Avril 2026	Rollback modele V5 -> V4	OK	Predictions coherentes, F1 stable
Mars 2026	Restart MongoDB	OK	188K posts intacts, index preserves

7. Contacts et escalade

Niveau	Responsable	Action
Niveau 1 (automatique)	Docker (restart: always)	Redemarrage automatique
Niveau 2 (manuel)	Azelie Bernard	Diagnostic + redemarrage manuel
Niveau 3 (escalade)	Azelie + Sebastien	Restauration complete, re-entrainement
Niveau 4 (critique)	Equipe + encadrant	Decision sur la strategie de reprise

Document valide par l'equipe projet - Avril 2026

Reference : PRA-THUM-2026-001 - Version 1.0