

---

# THUMALIEN

Pipeline NLP de detection de fake news sur Bluesky

## 09 Pra Pca

---

Formation : Mastere Big Data & IA - Sup de Vinci

Equipe : Azelie Bernard, Sebastien Lazcanotegui

Annee : 2025-2026

Version : Mai 2026



|                                                             |                      |                    |
|-------------------------------------------------------------|----------------------|--------------------|
| 22 notebooks                                                | Persistence garantie | Fallback V(n-1)    |
| Documentation complete                                      | restart: always      |                    |
| <pre> +-----+    MECANISMES DE PROTECTION    +-----+ </pre> |                      |                    |
| [restart: always]                                           | [Volumes Docker]     | [Git versioning]   |
| Redemarrage auto                                            | Survie aux crashes   | Historique complet |
| Tous les conteneurs                                         | Donnees persistantes | Rollback possible  |

## 3.2 Mesures de continuite par composant

### MongoDB (Donnees)

- Volumes Docker persistants : les donnees survivent au redemarrage des conteneurs
- Politique restart: always : redemarrage automatique en cas de crash
- Index unique sur uri : protection contre les doublons apres reprise
- Backup recommande : mongodump quotidien vers stockage externe

### Collecteur Bluesky

- restart: always dans Docker Compose : reprise automatique
- Gestion des erreurs reseau : retry avec backoff exponentiel
- Deduplication : les posts deja collectes sont ignores au redemarrage
- Impact d'un arret : perte des posts publies pendant l'indisponibilite uniquement

### Pipeline NLP

- Modeles versionnes dans Git : rollback instantane vers version precedente
- Fallback automatique : si le modele V5 echoue, chargement du V4 automatiquement
- Inference stateless : pas d'etat a restaurer, rechargement du modele suffit

### Dashboard Streamlit

- Lecture seule : le dashboard ne modifie pas les donnees
- Redemarrage rapide : docker-compose restart streamlit
- Cache Streamlit : les donnees sont mises en cache pour des performances optimales

## 4. Plan de Reprise d'Activite (PRA)

### 4.1 Scenarios d'incidents et procedures

#### Scenario 1 : Crash d'un conteneur Docker

| Etape | Action                   | Commande                                   | Temps |
|-------|--------------------------|--------------------------------------------|-------|
| 1     | Vérification automatique | restart: always dans<br>docker-compose.yml | 0 min |

|   |                                |                                         |       |
|---|--------------------------------|-----------------------------------------|-------|
| 2 | Vérification manuelle si échec | docker-compose ps                       | 1 min |
| 3 | Redémarrage manuel             | docker-compose restart <service>        | 2 min |
| 4 | Vérification des logs          | docker-compose logs --tail=50 <service> | 3 min |

## Scénario 2 : Corruption de la base MongoDB

| Etape | Action                         | Commande                               | Temps  |
|-------|--------------------------------|----------------------------------------|--------|
| 1     | Arrêter le conteneur           | docker-compose stop mongodb            | 1 min  |
| 2     | Sauvegarder le volume corrompu | cp -r mongodb_data mongodb_data_backup | 5 min  |
| 3     | Restaurer depuis backup        | mongorestore --db thumalien backup/    | 10 min |
| 4     | Redémarrer et vérifier         | docker-compose up -d mongodb           | 2 min  |
| 5     | Relancer la collecte           | Le collecteur reprend automatiquement  | 1 min  |

## Scénario 3 : Corruption ou perte d'un modèle ML

| Etape | Action                          | Commande                                | Temps     |
|-------|---------------------------------|-----------------------------------------|-----------|
| 1     | Identifier le modèle défaillant | Vérifier les logs d'erreur              | 2 min     |
| 2     | Restaurer depuis Git            | git checkout HEAD -- models/            | 1 min     |
| 3     | Si absent de Git : re-entraîner | Exécuter le notebook correspondant      | 30-60 min |
| 4     | Valider les prédictions         | Tester sur un échantillon connu         | 5 min     |
| 5     | Fallback V(n-1)                 | Charger la version précédente du modèle | 2 min     |

## Scénario 4 : Panne complète de la machine hôte

| Etape | Action                            | Temps                           |
|-------|-----------------------------------|---------------------------------|
| 1     | Provisionner nouvelle machine     | Variable                        |
| 2     | Installer Docker + Docker Compose | 15 min                          |
| 3     | Cloner le dépôt Git               | git clone - 5 min               |
| 4     | Restaurer backup MongoDB          | 30 min                          |
| 5     | Lancer docker-compose up -d       | 5 min                           |
| 6     | Vérifier tous les services        | 10 min                          |
| Total |                                   | ~1 heure (hors provisionnement) |

## Scenario 5 : API Bluesky indisponible

| Etape | Action                                    | Temps       |
|-------|-------------------------------------------|-------------|
| 1     | Le collecteur detecte l'erreur            | Automatique |
| 2     | Retry avec backoff exponentiel            | 1-5 min     |
| 3     | Dashboard continue sur donnees existantes | 0 min       |
| 4     | Surveillance de l'API AT Protocol         | Continu     |
| 5     | Reprise automatique quand l'API revient   | Automatique |

## 5. Politique de sauvegarde

### 5.1 Strategie de backup

| Donnee               | Methode              | Frequence              | Retention       | Stockage         |
|----------------------|----------------------|------------------------|-----------------|------------------|
| Code source          | Git push             | A chaque commit        | Illimitee       | GitHub           |
| Modeles ML           | Git (LFS si > 100MB) | A chaque version       | Toutes versions | GitHub           |
| Base MongoDB         | mongodump            | Quotidien (recommande) | 30 jours        | Stockage externe |
| Configuration Docker | Versionnee dans Git  | A chaque modification  | Illimitee       | GitHub           |
| Documentation        | Versionnee dans Git  | A chaque modification  | Illimitee       | GitHub           |

### 5.2 Procedure de backup MongoDB recommandee

```
# Backup quotidien automatise (crontab)
0 2 * docker exec mongodb mongodump --out /backup/$(date +%Y%m%d)

# Backup manuel avant operation risquee
docker exec mongodb mongodump --out /backup/pre_operation

# Restauration
docker exec mongodb mongorestore --drop /backup/20260415
```

## 6. Tests de reprise

### 6.1 Plan de tests

| Test                  | Frequence                 | Procedure                     | Critere de succes           |
|-----------------------|---------------------------|-------------------------------|-----------------------------|
| Redemarrage conteneur | Mensuel                   | docker-compose restart        | Tous services UP en < 5 min |
| Restauration modele   | A chaque nouvelle version | git checkout modele precedent | Predictions coherentes      |

|                          |             |                                             |                                |
|--------------------------|-------------|---------------------------------------------|--------------------------------|
| Simulation panne MongoDB | Trimestriel | Arreter MongoDB, verifier reprise           | Donnees intactes apres restart |
| Restauration complete    | Semestriel  | Clone + docker-compose up sur machine neuve | Systeme fonctionnel en < 1h    |

## 6.2 Resultats des derniers tests

| Date       | Test                       | Resultat | Observations                        |
|------------|----------------------------|----------|-------------------------------------|
| Avril 2026 | Redemarrage Docker Compose | OK       | Tous services UP en 45 secondes     |
| Avril 2026 | Rollback modele V5 -> V4   | OK       | Predictions coherentes, F1 stable   |
| Mars 2026  | Restart MongoDB            | OK       | 188K posts intacts, index preserves |

## 7. Contacts et escalade

| Niveau                 | Responsable              | Action                                 |
|------------------------|--------------------------|----------------------------------------|
| Niveau 1 (automatique) | Docker (restart: always) | Redemarrage automatique                |
| Niveau 2 (manuel)      | Azelie Bernard           | Diagnostic + redemarrage manuel        |
| Niveau 3 (escalade)    | Azelie + Sebastien       | Restauration complete, re-entrainement |
| Niveau 4 (critique)    | Equipe + encadrant       | Decision sur la strategie de reprise   |

Document valide par l'equipe projet - Avril 2026

Reference : PRA-THUM-2026-001 - Version 1.0