

# Politique de Veille Technologique

## Projet Thumalien - Suivi des évolutions technologiques et réglementaires

Référence : VEILLE-THUM-2026-001

Version : 1.1

Date : Avril 2026

### 1. Objectif

La veille technologique permet de maintenir le projet Thumalien à l'état de l'art en matière de NLP, détection de désinformation et conformité réglementaire. Elle alimente les décisions d'évolution du pipeline et anticipe les ruptures technologiques.

### 2. Domaines de veille

#### 2.1 Veille technique (NLP / IA)

| Sujet                                                   | Sources                           | Frequence     | Responsable |
|---------------------------------------------------------|-----------------------------------|---------------|-------------|
| Modèles de langue (LLM, BERT, etc.)                     | Hugging Face blog, arXiv (cs.CL)  | Hebdomadaire  | Azélie      |
| Détection de fake news (SOTA)                           | Papers With Code, ACL Anthology   | Mensuelle     | Azélie      |
| Librairies Python (scikit-learn, PyTorch, transformers) | GitHub releases, changelogs       | Mensuelle     | Azélie      |
| Techniques d'augmentation de données                    | arXiv, blogs ML                   | Mensuelle     | Sébastien   |
| Évaluation et métriques NLP                             | Conférences (ACL, EMNLP, NeurIPS) | Trimestrielle | Azélie      |

#### 2.2 Veille réglementaire

| Sujet                            | Sources                     | Fréquence     | Responsable |
|----------------------------------|-----------------------------|---------------|-------------|
| RGPD (évolutions, jurisprudence) | CNIL, EUR-Lex               | Trimestrielle | Azélie      |
| AI Act (mise en application)     | Commission Européenne, CNIL | Trimestrielle | Azélie      |
| Éthique de l'IA                  | IEEE, ACM, rapports OCDE    | Semestrielle  | Sébastien   |

## 2.3 Veille écosystème

| Sujet                                          | Sources                              | Fréquence    | Responsable |
|------------------------------------------------|--------------------------------------|--------------|-------------|
| API AT Protocol (Bluesky)                      | GitHub bluesky-social, docs AT Proto | Hebdomadaire | Azélie      |
| Concurrents (fact-checking, outils similaires) | ProductHunt, TechCrunch              | Mensuelle    | Sébastien   |
| Frameworks dashboard (Streamlit, Gradio)       | GitHub releases                      | Mensuelle    | Azélie      |
| Docker / MongoDB (mises à jour sécurité)       | Docker Hub, MongoDB blog             | Mensuelle    | Azélie      |

## 3. Technologies identifiées et évaluées

### 3.1 Technologies adoptées (intégrées au projet)

| Technologie                 | Date évaluation | Décision | Justification                                                            |
|-----------------------------|-----------------|----------|--------------------------------------------------------------------------|
| CamemBERT (FR)              | Avril 2026      | Adopté   | F1 0.957 sur textes courts FR, supérieur au TF-IDF                       |
| RoBERTa (EN)                | Avril 2026      | Adopté   | F1 0.874 sur textes courts EN, complémentaire au pipeline                |
| Pipeline hybride (stacking) | Avril 2026      | Adopté   | Combine les forces TF-IDF (robustesse) et Transformer (précision courts) |
| CodeCarbon                  | Jan 2026        | Adopté   | Monitoring CO2 transparent, zéro impact performance                      |
| fpdf2                       | Avril 2026      | Adopté   | Génération PDF depuis Python, pas de dépendance externe                  |
| Plotly                      | Mars 2026       | Adopté   | Graphiques interactifs pour le dashboard, meilleur que matplotlib        |

### 3.2 Technologies évaluées et non retenues

| Technologie           | Date évaluation | Décision   | Justification                                                     |
|-----------------------|-----------------|------------|-------------------------------------------------------------------|
| TensorFlow (émotions) | Jan 2026        | Rejeté     | Incompatible Apple Silicon M4, remplacé par PyTorch               |
| GPT-4 pour détection  | Fév 2026        | Non retenu | Coût prohibitif en inférence, latence trop élevée, dépendance API |

|                       |           |            |                                                             |
|-----------------------|-----------|------------|-------------------------------------------------------------|
| Sentence-Transformers | Mars 2026 | Reporté    | Prometteur mais V5 + Transformers couvrent le besoin actuel |
| FastAPI (serving)     | Mars 2026 | Reporté    | Pas encore nécessaire, inférence batch suffisante           |
| Elasticsearch         | Déc 2025  | Non retenu | MongoDB suffisant pour nos volumes, complexité inutile      |

### 3.3 Technologies à surveiller (roadmap)

| Technologie                          | Intérêt pour Thumalien                                                                    | Horizon | Priorité |
|--------------------------------------|-------------------------------------------------------------------------------------------|---------|----------|
| RAG (Retrieval-Augmented Generation) | Cross-checker les claims avec une base factuelle (Wikipedia, Google Fact Check Tools API) | T3 2026 | Haute    |
| LLM-as-Judge (GPT-4o, Claude)        | Scoring zero-shot de la crédibilité, benchmark contre V7                                  | T3 2026 | Haute    |
| Active Learning (modAL)              | Cibler l'annotation sur les posts à fort disagreement V5/V6                               | T2 2026 | Haute    |
| Conformal Prediction                 | Intervalle de confiance calibrés au lieu de scores bruts                                  | T3 2026 | Moyenne  |
| ONNX Runtime                         | Export CamemBERT/RoBERTa en ONNX, -50% latence inférence                                  | T3 2026 | Moyenne  |
| MLflow / Weights & Biases            | Tracking systématique des expériences ML                                                  | T2 2026 | Moyenne  |
| Guardrails AI / NeMo Guardrails      | Framework de safety pour systèmes IA de modération                                        | T4 2026 | Moyenne  |
| DPO/RLHF pour fake news              | Fine-tuner un small LLM (Mistral 7B) avec paires vrai/faux                                | T4 2026 | Basse    |
| Détection multimodale (CLIP)         | Analyser les images associées aux posts pour détecter la manipulation visuelle            | T4 2026 | Basse    |
| Grafana + Prometheus                 | Monitoring avancé des performances système et drift detection                             | T2 2026 | Basse    |

### 3.4 Tendances 2026 en détection de désinformation

| Tendance                    | Description                                                                                                     | Impact pour Thumalien                                                                            |
|-----------------------------|-----------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------|
| LLM Fact-Checking           | Les LLMs (GPT-4o, Claude, Gemini) sont utilisés pour vérifier les claims en les comparant à des sources fiables | Possibilité d'ajouter une couche de vérification factuelle au-dessus de la détection stylistique |
| Multimodal Misinformation   | La désinformation s'appuie de plus en plus sur des images générées par IA (deepfakes, infographies truquées)    | Extension future vers l'analyse d'images avec CLIP ou BLIP-2                                     |
| Explicabilité réglementaire | L'AI Act impose la transparence des systèmes IA à risque - SHAP devient un standard industriel                  | Notre intégration SHAP anticipe cette obligation                                                 |
| Federated Learning          | Entraîner des modèles sans centraliser les données (privacy-preserving)                                         | Pertinent si Thumalien est déployé chez plusieurs clients                                        |
| Synthetic Data Augmentation | Génération de données synthétiques pour équilibrer les datasets (déjà utilisé en V4/V5)                         | Approfondir avec des LLMs pour générer des faux plus réalistes                                   |

## 4. Processus de veille

### 4.1 Workflow

#### 1. COLLECTE

Sources : arXiv, Hugging Face, GitHub, CNIL, blogs  
Outils : RSS, newsletters, alertes Google Scholar  
Fréquence : hebdomadaire

#### 2. ANALYSE

Pertinence pour Thumalien ? (oui/non)  
Impact estime (performance, cout, conformite)  
Effort d'integration

#### 3. DECISION

Adopter : integration dans le sprint suivant  
Reporter : ajouter a la roadmap  
Rejeter : documenter la justification

#### 4. INTEGRATION

Branche Git dediee  
Tests de non-regression  
Documentation mise a jour

### 4.2 Exemples concrets de veille appliquée

| Date | Découverte | Action | Résultat |
|------|------------|--------|----------|
|------|------------|--------|----------|

|            |                                                                              |                                                                                                    |                                                                               |
|------------|------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------|
| Jan 2026   | PyTorch supporte Apple Silicon nativement                                    | Migration TensorFlow -> PyTorch                                                                    | Modèle émotions fonctionnel                                                   |
| Fév 2026   | Publication sur le débiaisage des datasets de presse                         | Implémentation BODY_AGENCY_TERMS                                                                   | Réduction du biais Reuters                                                    |
| Mars 2026  | CamemBERT fine-tuné sur données courtes (blog HF)                            | Fine-tuning sur nos données FR                                                                     | F1 0.957 sur ultra-courts                                                     |
| Avril 2026 | RoBERTa performant sur tweets EN (papier ACL)                                | Fine-tuning sur données EN                                                                         | F1 0.874 sur ultra-courts                                                     |
| Avril 2026 | Technique de stacking pour NLP hybride                                       | Pipeline hybride V5+CamemBERT                                                                      | F1 FR +0.52%                                                                  |
| Avril 2026 | SHAP TreeExplainer pour GradientBoosting (papier Lundberg 2017)              | Intégration dans dashboard V7                                                                      | Explicabilité locale et globale des prédictions                               |
| Avril 2026 | Meta-learner stacking pour combiner modèles hétérogènes (technique Kaggle)   | Architecture V7 hybride V5+V6                                                                      | Réduction FP de 57 à 25 sur gold set                                          |
| Mai 2026   | Captum 0.9 (Meta) : Layer Integrated Gradients pour transformers             | Module src/explainability/integrated_gradient s.py avec LIG sur CamemBERT                          | Attribution causale par token, axiome de Completeness vérifié                 |
| Mai 2026   | Bug Captum/MPS sur Apple Silicon (issue PyTorch #128043)                     | Workaround : bascule CPU automatique pour les attributions IG                                      | ?_convergence divisé par 3 (de +0.35 à +0.04)                                 |
| Mai 2026   | ERASER benchmark (DeYoung et al., ACL 2020)                                  | Implémentation FaithfulnessEvaluator (AOPC, Comprehensiveness@k, Sufficiency@k vs random)          | Validation quantitative des explications : uplift +0.21 vs baseline aléatoire |
| Mai 2026   | Mudrakarta et al. (2018) sur les baselines IG                                | Stratégie de baseline auto (<unk> -> <pad>) avec retry n_steps escalade                            | Baseline <unk> préserve [CLS]/[SEP] = meilleure convergence Captum            |
| Mai 2026   | Recommandation Captum : expliquer la classe prédite, pas la classe théorique | Patch step_integrated_gradients pour passer target_class=preds[i]                                  | FN id=9 passe de ?=0.47 (rejet) à ?=0.04 (? pratique)                         |
| Mai 2026   | Google Model Card framework (Mitchell et al. 2019, FAT*)                     | Création docs/12_model_card.md avec section dédiée XAI (audience par persona, validation, limites) | Document auditeur conforme aux attentes AI Act art. 13                        |

## 5. Ressources de veille

### 5.1 Sources principales

- arXiv (cs.CL, cs.AI) : publications académiques pre-print
- Hugging Face Blog : nouveaux modèles, techniques, datasets
- Papers With Code : benchmarks et SOTA détection fake news
- CNIL : actualités RGPD, guides pratiques IA
- GitHub Trending : librairies émergentes Python/ML
- Google Scholar Alerts : "fake news detection", "misinformation NLP"

## 5.2 Conférences et événements suivis

| Conférence                                      | Domaine             | Période  |
|-------------------------------------------------|---------------------|----------|
| ACL (Association for Computational Linguistics) | NLP                 | Juillet  |
| EMNLP (Empirical Methods in NLP)                | NLP                 | Octobre  |
| NeurIPS                                         | Machine Learning    | Décembre |
| CNIL Open Data Day                              | Réglementation      | Variable |
| PyData                                          | Python Data Science | Variable |

---

Document validé par l'équipe projet - Avril 2026

Référence : VEILLE-THUM-2026-001 - Version 1.1