
THUMALIEN

Pipeline NLP de detection de fake news sur Bluesky

10 Veille Technologique

Formation : Mastere Big Data & IA - Sup de Vinci

Equipe : Azelie Bernard, Sebastien Lazcanotegui

Annee : 2025-2026

Version : Mai 2026

Politique de Veille Technologique

Projet Thumalien - Suivi des évolutions technologiques et réglementaires

Référence : VEILLE-THUM-2026-001

Version : 1.1

Date : Avril 2026

1. Objectif

La veille technologique permet de maintenir le projet Thumalien à l'état de l'art en matière de NLP, détection de désinformation et conformité réglementaire. Elle alimente les décisions d'évolution du pipeline et anticipe les ruptures technologiques.

2. Domaines de veille

2.1 Veille technique (NLP / IA)

Sujet	Sources	Frequence	Responsable
Modèles de langue (LLM, BERT, etc.)	Hugging Face blog, arXiv (cs.CL)	Hebdomadaire	Azélie
Détection de fake news (SOTA)	Papers With Code, ACL Anthology	Mensuelle	Azélie
Librairies Python (scikit-learn, PyTorch, transformers)	GitHub releases, changelogs	Mensuelle	Azélie
Techniques d'augmentation de données	arXiv, blogs ML	Mensuelle	Sébastien
Évaluation et métriques NLP	Conférences (ACL, EMNLP, NeurIPS)	Trimestrielle	Azélie

2.2 Veille réglementaire

Sujet	Sources	Fréquence	Responsable
RGPD (évolutions, jurisprudence)	CNIL, EUR-Lex	Trimestrielle	Azélie
AI Act (mise en application)	Commission Européenne, CNIL	Trimestrielle	Azélie
Éthique de l'IA	IEEE, ACM, rapports OCDE	Semestrielle	Sébastien

2.3 Veille écosystème

Sujet	Sources	Fréquence	Responsable
API AT Protocol (Bluesky)	GitHub bluesky-social, docs AT Proto	Hebdomadaire	Azélie
Concurrents (fact-checking, outils similaires)	ProductHunt, TechCrunch	Mensuelle	Sébastien
Frameworks dashboard (Streamlit, Gradio)	GitHub releases	Mensuelle	Azélie
Docker / MongoDB (mises à jour sécurité)	Docker Hub, MongoDB blog	Mensuelle	Azélie

3. Technologies identifiées et évaluées

3.1 Technologies adoptées (intégrées au projet)

Technologie	Date évaluation	Décision	Justification
CamemBERT (FR)	Avril 2026	Adopté	F1 0.957 sur textes courts FR, supérieur au TF-IDF
RoBERTa (EN)	Avril 2026	Adopté	F1 0.874 sur textes courts EN, complémentaire au pipeline
Pipeline hybride (stacking)	Avril 2026	Adopté	Combine les forces TF-IDF (robustesse) et Transformer (précision courts)
CodeCarbon	Jan 2026	Adopté	Monitoring CO2 transparent, zéro impact performance
fpdf2	Avril 2026	Adopté	Génération PDF depuis Python, pas de dépendance externe
Plotly	Mars 2026	Adopté	Graphiques interactifs pour le dashboard, meilleur que matplotlib

3.2 Technologies évaluées et non retenues

Technologie	Date évaluation	Décision	Justification
TensorFlow (émotions)	Jan 2026	Rejeté	Incompatible Apple Silicon M4, remplacé par PyTorch
GPT-4 pour détection	Fév 2026	Non retenu	Coût prohibitif en inférence, latence trop élevée, dépendance API

Sentence-Transformers	Mars 2026	Reporté	Prometteur mais V5 + Transformers couvrent le besoin actuel
FastAPI (serving)	Mars 2026	Reporté	Pas encore nécessaire, inférence batch suffisante
Elasticsearch	Déc 2025	Non retenu	MongoDB suffisant pour nos volumes, complexité inutile

3.3 Technologies à surveiller (roadmap)

Technologie	Intérêt pour Thumalien	Horizon	Priorité
RAG (Retrieval-Augmented Generation)	Cross-checker les claims avec une base factuelle (Wikipedia, Google Fact Check Tools API)	T3 2026	Haute
LLM-as-Judge (GPT-4o, Claude)	Scoring zero-shot de la crédibilité, benchmark contre V7	T3 2026	Haute
Active Learning (modAL)	Cibler l'annotation sur les posts à fort disagreement V5/V6	T2 2026	Haute
Conformal Prediction	Intervalle de confiance calibrés au lieu de scores bruts	T3 2026	Moyenne
ONNX Runtime	Export CamemBERT/RoBERTa en ONNX, -50% latence inférence	T3 2026	Moyenne
MLflow / Weights & Biases	Tracking systématique des expériences ML	T2 2026	Moyenne
Guardrails AI / NeMo Guardrails	Framework de safety pour systèmes IA de modération	T4 2026	Moyenne
DPO/RLHF pour fake news	Fine-tuner un small LLM (Mistral 7B) avec paires vrai/faux	T4 2026	Basse
Détection multimodale (CLIP)	Analyser les images associées aux posts pour détecter la manipulation visuelle	T4 2026	Basse
Grafana + Prometheus	Monitoring avancé des performances système et drift detection	T2 2026	Basse

3.4 Tendances 2026 en détection de désinformation

Tendance	Description	Impact pour Thumalien
LLM Fact-Checking	Les LLMs (GPT-4o, Claude, Gemini) sont utilisés pour vérifier les claims en les comparant à des sources fiables	Possibilité d'ajouter une couche de vérification factuelle au-dessus de la détection stylistique
Multimodal Misinformation	La désinformation s'appuie de plus en plus sur des images générées par IA (deepfakes, infographies truquées)	Extension future vers l'analyse d'images avec CLIP ou BLIP-2
Explicabilité réglementaire	L'AI Act impose la transparence des systèmes IA à risque - SHAP devient un standard industriel	Notre intégration SHAP anticipe cette obligation
Federated Learning	Entraîner des modèles sans centraliser les données (privacy-preserving)	Pertinent si Thumalien est déployé chez plusieurs clients
Synthetic Data Augmentation	Génération de données synthétiques pour équilibrer les datasets (déjà utilisé en V4/V5)	Approfondir avec des LLMs pour générer des faux plus réalistes

4. Processus de veille

4.1 Workflow

1. COLLECTE
Sources : arXiv, Hugging Face, GitHub, CNIL, blogs
Outils : RSS, newsletters, alertes Google Scholar
Frequence : hebdomadaire
2. ANALYSE
Pertinence pour Thumalien ? (oui/non)
Impact estime (performance, cout, conformite)
Effort d'integration
3. DECISION
Adopter : integration dans le sprint suivant
Reporter : ajouter a la roadmap
Rejeter : documenter la justification
4. INTEGRATION
Branche Git dediee
Tests de non-regression
Documentation mise a jour

4.2 Exemples concrets de veille appliquée

Date	Découverte	Action	Résultat
------	------------	--------	----------

Jan 2026	PyTorch supporte Apple Silicon nativement	Migration TensorFlow -> PyTorch	Modèle émotions fonctionnel
Fév 2026	Publication sur le débiaisage des datasets de presse	Implémentation BODY_AGENCY_TERMS	Réduction du biais Reuters
Mars 2026	CamemBERT fine-tuné sur données courtes (blog HF)	Fine-tuning sur nos données FR	F1 0.957 sur ultra-courts
Avril 2026	RoBERTa performant sur tweets EN (papier ACL)	Fine-tuning sur données EN	F1 0.874 sur ultra-courts
Avril 2026	Technique de stacking pour NLP hybride	Pipeline hybride V5+CamemBERT	F1 FR +0.52%
Avril 2026	SHAP TreeExplainer pour GradientBoosting (papier Lundberg 2017)	Intégration dans dashboard V7	Explicabilité locale et globale des prédictions
Avril 2026	Meta-learner stacking pour combiner modèles hétérogènes (technique Kaggle)	Architecture V7 hybride V5+V6	Réduction FP de 57 à 25 sur gold set
Mai 2026	Captum 0.9 (Meta) : Layer Integrated Gradients pour transformers	Module src/explainability/integrated_gradient s.py avec LIG sur CamemBERT	Attribution causale par token, axiome de Completeness vérifié
Mai 2026	Bug Captum/MPS sur Apple Silicon (issue PyTorch #128043)	Workaround : bascule CPU automatique pour les attributions IG	?_convergence divisé par 3 (de +0.35 à +0.04)
Mai 2026	ERASER benchmark (DeYoung et al., ACL 2020)	Implémentation FaithfulnessEvaluator (AOPC, Comprehensiveness@k, Sufficiency@k vs random)	Validation quantitative des explications : uplift +0.21 vs baseline aléatoire
Mai 2026	Mudrakarta et al. (2018) sur les baselines IG	Stratégie de baseline auto (<unk> -> <pad>) avec retry n_steps escalade	Baseline <unk> préserve [CLS]/[SEP] = meilleure convergence Captum
Mai 2026	Recommandation Captum : expliquer la classe prédite, pas la classe théorique	Patch step_integrated_gradients pour passer target_class=preds[i]	FN id=9 passe de ?=0.47 (rejet) à ?=0.04 (? pratique)
Mai 2026	Google Model Card framework (Mitchell et al. 2019, FAT*)	Création docs/12_model_card.md avec section dédiée XAI (audience par persona, validation, limites)	Document auditeur conforme aux attentes AI Act art. 13

5. Ressources de veille

5.1 Sources principales

- arXiv (cs.CL, cs.AI) : publications académiques pre-print
- Hugging Face Blog : nouveaux modèles, techniques, datasets
- Papers With Code : benchmarks et SOTA détection fake news
- CNIL : actualités RGPD, guides pratiques IA
- GitHub Trending : librairies émergentes Python/ML
- Google Scholar Alerts : "fake news detection", "misinformation NLP"

5.2 Conférences et événements suivis

Conférence	Domaine	Période
ACL (Association for Computational Linguistics)	NLP	Juillet
EMNLP (Empirical Methods in NLP)	NLP	Octobre
NeurIPS	Machine Learning	Décembre
CNIL Open Data Day	Réglementation	Variable
PyData	Python Data Science	Variable

Document validé par l'équipe projet - Avril 2026

Référence : VEILLE-THUM-2026-001 - Version 1.1