

Politique de Veille Technologique

Projet Thumalien - Suivi des evolutions technologiques et reglementaires

Reference : VEILLE-THUM-2026-001

Version : 1.0

Date : Avril 2026

1. Objectif

La veille technologique permet de maintenir le projet Thumalien a l'etat de l'art en matiere de NLP, detection de desinformation et conformite reglementaire. Elle alimente les decisions d'evolution du pipeline et anticipe les ruptures technologiques.

2. Domaines de veille

2.1 Veille technique (NLP / IA)

Sujet	Sources	Frequence	Responsable
Modeles de langue (LLM, BERT, etc.)	Hugging Face blog, arXiv (cs.CL)	Hebdomadaire	Azelie
Detection de fake news (SOTA)	Papers With Code, ACL Anthology	Mensuelle	Azelie
Librairies Python (scikit-learn, PyTorch, transformers)	GitHub releases, changelogs	Mensuelle	Azelie
Techniques d'augmentation de donnees	arXiv, blogs ML	Mensuelle	Sebastien
Evaluation et metriques NLP	Conferences (ACL, EMNLP, NeurIPS)	Trimestrielle	Azelie

2.2 Veille reglementaire

Sujet	Sources	Frequence	Responsable
RGPD (evolutions, jurisprudence)	CNIL, EUR-Lex	Trimestrielle	Azelie
AI Act (mise en application)	Commission Europeenne, CNIL	Trimestrielle	Azelie

Ethique de l'IA	IEEE, ACM, rapports OCDE	Semestrielle	Sebastien
-----------------	--------------------------	--------------	-----------

2.3 Veille ecosysteme

Sujet	Sources	Frequence	Responsable
API AT Protocol (Bluesky)	GitHub bluesky-social, docs AT Proto	Hebdomadaire	Azelie
Concurrents (fact-checking, outils similaires)	ProductHunt, TechCrunch	Mensuelle	Sebastien
Frameworks dashboard (Streamlit, Gradio)	GitHub releases	Mensuelle	Azelie
Docker / MongoDB (mises a jour securite)	Docker Hub, MongoDB blog	Mensuelle	Azelie

3. Technologies identifiees et evaluees

3.1 Technologies adoptees (integrees au projet)

Technologie	Date evaluation	Decision	Justification
CamemBERT (FR)	Avril 2026	Adopte	F1 0.957 sur textes courts FR, superieur au TF-IDF
RoBERTa (EN)	Avril 2026	Adopte	F1 0.874 sur textes courts EN, complementaire au pipeline
Pipeline hybride (stacking)	Avril 2026	Adopte	Combine les forces TF-IDF (robustesse) et Transformer (precision courts)
CodeCarbon	Jan 2026	Adopte	Monitoring CO2 transparent, zero impact performance
fpdf2	Avril 2026	Adopte	Generation PDF depuis Python, pas de dependance externe
Plotly	Mars 2026	Adopte	Graphiques interactifs pour le dashboard, meilleur que matplotlib

3.2 Technologies evaluees et non retenues

Technologie	Date evaluation	Decision	Justification
TensorFlow (emotions)	Jan 2026	Rejete	Incompatible Apple Silicon M4, remplace par PyTorch

GPT-4 pour detection	Fev 2026	Non retenu	Cout prohibitif en inference, latence trop elevee, dependance API
Sentence-Transformers	Mars 2026	Reporte	Prometteur mais V5 + Transformers couvrent le besoin actuel
FastAPI (serving)	Mars 2026	Reporte	Pas encore necessaire, inference batch suffisante
Elasticsearch	Dec 2025	Non retenu	MongoDB suffisant pour nos volumes, complexite inutile

3.3 Technologies a surveiller (roadmap)

Technologie	Interet pour Thumalien	Horizon	Priorite
Mistral / LLaMA 3	Detection zero-shot, pas de donnees annotees	T3 2026	Haute
RAG (Retrieval-Augmented Generation)	Enrichir la detection avec du contexte factuel	T4 2026	Moyenne
ONNX Runtime	Optimisation inference, -50% latence estimee	T3 2026	Moyenne
Grafana + Prometheus	Monitoring avance des performances systeme	T2 2026	Basse
MLflow	Tracking des experiences ML (remplacer les notebooks)	T3 2026	Moyenne

4. Processus de veille

4.1 Workflow

1. COLLECTE

Sources : arXiv, Hugging Face, GitHub, CNIL, blogs
Outils : RSS, newsletters, alertes Google Scholar
Frequence : hebdomadaire

2. ANALYSE

Pertinence pour Thumalien ? (oui/non)
Impact estime (performance, cout, conformite)
Effort d'integration

3. DECISION

Adopter : integration dans le sprint suivant
Reporter : ajouter a la roadmap
Rejeter : documenter la justification

4. INTEGRATION

Branche Git dediee
 Tests de non-regression
 Documentation mise a jour

4.2 Exemples concrets de veille appliquee

Date	Decouverte	Action	Resultat
Jan 2026	PyTorch supporte Apple Silicon nativement	Migration TensorFlow -> PyTorch	Modele emotions fonctionnel
Fev 2026	Publication sur le debiasage des datasets de presse	Implementation BODY_AGENCY_TERMS	Reduction du biais Reuters
Mars 2026	CamemBERT fine-tune sur donnees courtes (blog HF)	Fine-tuning sur nos donnees FR	F1 0.957 sur ultra-courts
Avril 2026	RoBERTa performant sur tweets EN (papier ACL)	Fine-tuning sur donnees EN	F1 0.874 sur ultra-courts
Avril 2026	Technique de stacking pour NLP hybride	Pipeline hybride V5+CamemBERT	F1 FR +0.52%

5. Ressources de veille

5.1 Sources principales

- arXiv (cs.CL, cs.AI) : publications academiques pre-print
- Hugging Face Blog : nouveaux modeles, techniques, datasets
- Papers With Code : benchmarks et SOTA detection fake news
- CNIL : actualites RGPD, guides pratiques IA
- GitHub Trending : librairies emergentes Python/ML
- Google Scholar Alerts : "fake news detection", "misinformation NLP"

5.2 Conferences et evenements suivis

Conference	Domaine	Periode
ACL (Association for Computational Linguistics)	NLP	Juillet
EMNLP (Empirical Methods in NLP)	NLP	Octobre
NeurIPS	Machine Learning	Decembre
CNIL Open Data Day	Reglementation	Variable
PyData	Python Data Science	Variable

Document valide par l'equipe projet - Avril 2026

Reference : VEILLE-THUM-2026-001 - Version 1.0