
THUMALIEN

Pipeline NLP de detection de fake news sur Bluesky

12 Model Card

Formation : Mastere Big Data & IA - Sup de Vinci

Equipe : Azelie Bernard, Sebastien Lazcanotegui

Annee : 2025-2026

Version : Mai 2026

Model Card - Thumalien V9

Document n° : MC-THUM-2026-001

Version : 1.0

Date : 2026-05-09

Auteurs : Équipe Thumalien

Format : Google Model Card (Mitchell et al. 2019), enrichi d'une section

Explicabilité conforme à l'AI Act (UE 2024/1689) art. 13.

1. Détails du modèle

Champ	Valeur
Nom	Thumalien V9 - Pipeline 2-étapes fait/opinion + ensemble hybride
Version	9.0
Type	Classifieur binaire bilingue (FR/EN) - fiable / suspect
Architecture	Stage 1 : LogReg fait/opinion · Stage 2 : ensemble V5 (TF-IDF+LogReg) + V6 (style+GradientBoosting) + CamemBERT-base fine-tuné · Méta-learner LogReg
Date de l'entraînement	Avril 2026 (V8), mai 2026 (V9 stage 1)
Cadre légal	Projet d'étude académique, Master 1 Data Analytics
License	À usage pédagogique. Non destiné à la production
Contact	équipe Thumalien - voir docs/00_INDEX.md
Citation	À compléter le cas échéant

2. Usage prévu

Cas d'usage primaires :

- Détection automatique de posts Bluesky potentiellement non fiables pour un usage de monitoring ou de recherche académique sur la désinformation.
- Aide à la modération assistée (étape de pré-filtrage), avec décision finale humaine obligatoire.

Cas d'usage hors-périmètre :

- Décisions automatiques affectant des personnes (modération sans supervision, sanctions, classement de comptes).

- Évaluation de la véracité factuelle d'un contenu (le modèle détecte des signaux de forme - style, lexique - pas la vérité d'une affirmation).
- Domaines hors actualité publique généraliste (santé spécialisée, juridique, financier).

3. Données d'entraînement

Source	Volume	Période	Langues
Kaggle FR fake news	~30k	2018-2024	FR
Credibility Corpus	~25k	2017-2023	EN
FakeNewsNet (BuzzFeed/PolitiFact)	~22k	2014-2020	EN
Constraint COVID-19	~10k	2020-2021	EN
Bluesky annotation maison	500 (kappa=0.498)	2026	FR/EN
Total	~197 782 articles	2014-2026	FR + EN

Voir docs/00_INDEX.md D02 et notebooks/00_Audit_Qualite_Donnees.ipynb pour l'audit qualité et les déséquilibres de classes.

4. Évaluation

Métrique de référence : F1 macro sur le gold test set (200 posts Bluesky annotés manuellement par 2 annotateurs indépendants, kappa de Cohen = 0.498 niveau modéré-faible - la frontière fiable/suspect est par nature subjective).

Modèle	F1 macro	F1 suspect	F1 fiable	FP	FN
V5 (TF-IDF + LogReg)	0.560	0.087	0.911	57	6
V6 (Style + GradientBoosting)	0.578	0.103	0.954	38	5
V7 (méta-learner V5+V6)	0.612	0.214	0.953	25	5
V8 (méta-learner V5+V6+CamemBERT)	0.654	0.298	0.953	23	4
V9 (V8 + filtre fait/opinion)	0.671	0.331	0.954	21	4

Voir docs/04_revue_challenge_equipe.md et notebooks/21_Gold_Test_Set_Evaluation.py pour le détail.

5. Limites et biais connus

Catégorie	Limite	Mitigation actuelle
-----------	--------	---------------------

Biais lexical	Le modèle s'appuie fortement sur des marqueurs de surface (mots en majuscules, points d'exclamation, lexique sensationnaliste). Un post fiable au style emphatique peut être mal classé (voir FP exemple)	V6 ajoute des features stylistiques diverses, V8 ajoute un signal sémantique CamemBERT
Couverture linguistique	Dégradation sur les textes non FR/EN (pas de fallback)	Détection langage avant inférence ; non-FR/EN -> score conservateur
Textes courts	F1 = 0.80 sur posts < 15 mots vs 0.92 sur > 30 mots	Seuils adaptatifs par longueur (cf. docs/06_analyse_modele_par_longueur.md)
Drift temporel	Modèle entraîné principalement sur 2014-2024. Performances dégradées sur événements récents (cf. accord Israël-Palestine 2025-2026)	Re-fine-tuning incrémental V4/V5_bluesky
Subjectivité de l'annotation	kappa = 0.498 entre annotateurs : la frontière est intrinsèquement floue	Sheet "Resolution" qui résout les désaccords ; gold consensus utilisé pour V8
Pas d'étiquetage de véracité factuelle	Le modèle détecte des signaux de forme, pas de fond	Documentation claire dans le dashboard et guide_utilisateur.md

6. Considérations éthiques

Préoccupation	Évaluation
Risque de catégorisation injuste de personnes	Élevé si déployé sans supervision. Mitigation : décision humaine obligatoire, pas de réutilisation au-delà du monitoring
Risque pour la liberté d'expression	Modéré. Mitigation : transparence complète sur le score (dashboard explicabilité) et droit de contester
Données personnelles	Posts publics Bluesky. RGPD : licéité art. 6.1.f (intérêt légitime). Voir docs/02_conformite_RGPD_AI_Act.md
Empreinte carbone	LogReg = 100× moins d'énergie que RoBERTa. CodeCarbon tracking actif (docs/10_veille_technologique.md)
AI Act (classification)	Risque limité (système d'IA non listé en Annexe III). Mesures de transparence et supervision humaine en place

7. Explicabilité (XAI)

Cette section dépasse le format Google Model Card original et anticipe l'art. 13 AI Act (transparence des systèmes d'IA).

7.1 Méthodes employées

Méthode	Couverture	Type	Module
Coefficients LogReg × valeur de feature	V5 (TF-IDF + linguistique + émotions)	Local exact	src.pipeline.expert_detector.explain_prediction
SHAP TreeExplainer	V6 (35 features stylistiques)	Local + global, exact pour modèles tree-based	dashboard/app.py, notebooks/24_*, src.explainability.shap_global
SHAP beeswarm + dependence plots	V6 - vue globale	Global, agrégé sur n=200+	src.explainability.shap_global.GlobalShapExplainer
Attention weights	CamemBERT (12 couches, 12 têtes)	Local, qualitatif (cf. Jain & Wallace 2019)	src.explainability.attention_viz.CamemBERTAttentionExplainer
Layer Integrated Gradients (Captum)	CamemBERT - embeddings	Local, causal, axiomes Completeness/Sensitivity satisfaits	src.explainability.integrated_gradient.s.IGExplainer
Décomposition exacte du méta-learner	V7 / V8 (LogReg)	Local + global, formule fermée ?-x	src.explainability.meta_decomposition.MetaLearnerDecomposer
Faithfulness test (AOPC)	V6 - validation des explications	Méta-évaluation, vs random baseline	src.explainability.faithfulness.FaithfulnessEvaluator

7.2 Validation des explications (faithfulness)

Une explication n'a de valeur que si elle reflète le comportement réel du modèle. Notre test ERASER-style (DeYoung et al. 2020) :

- AOPC attribution SHAP V6 : mesuré dynamiquement via `scripts/run_xai_pipeline.py` (voir docs/figures/xai/results.json).

Cible : > +0.10 d'uplift par rapport au baseline aléatoire.

- Comprehensiveness@5 et Sufficiency@5 : reportés pour chaque modèle dans le pipeline XAI.

- Completeness IG (axiome de Sundararajan 2017) : on cible $|?| < 0.05$ (niveau "pratique" selon Kokhlikyan et al. 2020). Sur CamemBERT-base (12 couches + head MLP non-linéaire) on observe trois régimes :

- Modèle indécis (P proche de 0.5) : convergence à $|?| < 0.02$ (axiomatique)
- Modèle confiant ($P > 0.7$ ou $P < 0.3$) : $|?| \approx 0.05-0.15$ (indicatif)
- Cas saturés (rare, gradient quasi-nul à cause du ReLU dans head : Linear -> ReLU -> Dropout -> Linear) : $|?| > 0.15$ même à $n_steps=1000$. Ce n'est pas un bug - c'est une signature de la rigidité de la décision sur ces inputs. À documenter au cas par cas.

Workarounds appliqués :

- Bascule automatique CPU sur Apple Silicon (bug Captum/MPS documenté)
- Stratégie de baseline auto (<unk> -> <pad>)
- Escalade n_steps : 200 -> 500 -> 1000 si non convergent
- Classe expliquée = classe prédite par le modèle (recommandation

Captum) : sinon les FN/FP donnent des gradients dégénérés

- Implémentation eager forcée pour les attentions (sinon SDPA bloque la backprop sur transformers >= 4.40)

7.3 Limites de l'explicabilité

- L'attention CamemBERT n'est pas une explication causale (Jain & Wallace 2019). Pour des affirmations causales, se référer à IG.
- SHAP TreeExplainer assume l'indépendance des features ; sur des features stylistiques corrélées (ex: caps_ratio et all_caps_words_ratio), les valeurs sont à interpréter avec prudence.
- L'agrégation mean(|SHAP|) masque les hétérogénéités sous-groupe : une analyse stratifiée (par langue, par longueur de texte) est dans la roadmap.
- Les méthodes ci-dessus expliquent comment le modèle décide, pas pourquoi sa décision est juste - la véracité factuelle reste hors périmètre.

7.4 Audience des explications

Audience	Méthode privilégiée	Lieu
Utilisateur du dashboard	SHAP bar plot V6 + décomposition méta-learner V8	dashboard/app.py page Analyse Temps Réel
Modérateur / annotateur	Top mots LogReg + features sensationnalistes détectées	dashboard/app.py panneau "Pourquoi ce score ?"
Régulateur / auditeur	Cette model card + docs/figures/xai/INDEX.md + results.json	Repo
Chercheur ML	Notebook 24, scripts XAI, AOPC + IG completeness	notebooks/, scripts/run_xai_pipeline.py

8. Recommandations

- Ne jamais utiliser le score V9 comme verdict : il s'agit d'un indicateur dans une chaîne de modération.
- Valider l'absence de drift trimestriellement avec un nouveau gold set.
- Re-calculer le faithfulness test à chaque changement de modèle V_x+1 pour vérifier que les explications restent fidèles.

- Documenter chaque évolution dans le journal de décision

(docs/00_INDEX.md).

9. Références

- Mitchell et al. (2019) Model Cards for Model Reporting, FAT*.
- Lundberg & Lee (2017) *A Unified Approach to Interpreting Model Predictions*, NeurIPS.
- Sundararajan, Taly & Yan (2017) *Axiomatic Attribution for Deep Networks*, ICML.
- Jain & Wallace (2019) Attention is not Explanation, NAACL.
- DeYoung et al. (2020) *ERASER: A Benchmark to Evaluate Rationalized NLP Models*, ACL.
- Reglement (UE) 2024/1689 (AI Act), notamment art. 13-14.

Cette model card est un livrable du module pédagogique "IA explicable et responsable" du projet d'étude. Elle complète docs/02_conformite_RGPD_AI_Act.md en se focalisant sur la transparence du modèle plutôt que sur le traitement des données personnelles.