
THUMALIEN

Pipeline NLP de detection de fake news sur Bluesky

Rapport Projet Thumalien

Formation : Mastere Big Data & IA - Sup de Vinci

Equipe : Azelie Bernard, Sebastien Lazcanotegui

Annee : 2025-2026

Version : Mai 2026

Rapport de Projet - Thumalien

Pipeline NLP de détection de fake news sur Bluesky

Auteur : Azélie Bernard

Formation : Master Big Data

Date : Mai 2026

Résumé

Ce rapport présente Thumalien, un système de détection de fake news sur le réseau social Bluesky. Le pipeline NLP bilingue (FR/EN) a évolué de la V1.0 (baseline TF-IDF) à la V9 (pipeline 2 étapes fait/opinion). La V5 combine une vectorisation TF-IDF (30K features), 15 features linguistiques et un modèle d'émotions (MLP PyTorch, 7 classes) dans un classifieur LogisticRegression, entraîné sur 197 782 textes. La V6 est un modèle "style-only" topic-agnostic (28 features stylistiques + 7 émotions, GradientBoosting). La V7 est un méta-learner V5+V6 avec explicabilité SHAP. La V8 intègre CamemBERT comme 3e signal sémantique pour le français (F1 suspect +28%). La V9 introduit un pipeline en cascade : un classifieur fait/opinion (Stage 1) filtre les posts d'opinion avant la détection, réduisant les faux positifs de 67% (186 -> 62) sur un gold standard de 473 posts annotés par 2 annotateurs humains (kappa inter-annotateurs = 0.498). Le système (collecte, MongoDB, inférence, dashboard Streamlit) est conteneurisé via Docker Compose, avec suivi carbone par CodeCarbon.

Table des matières

- Résumé
- Présentation de l'entreprise et de l'école
- Problématique
- État de l'art
- Présentation du projet
- Architecture technique
- Phase 1 - Collecte et stockage des données
- Phase 2 - Audit qualité et nettoyage
- Phase 3 - Modèle d'émotions bilingue
- Phase 4 - Pipeline expert V1.5
- Phase 5 - Analyse du modèle et GridSearch
- Phase 6 - Intégration de datasets sociaux (V2)
- Le seuil de décision : pourquoi 0.44 ?
- Qu'est-ce que max_iter ?

- Dashboard Streamlit
 - Bilan carbone (Green IT)
 - État actuel du projet
 - Évaluation sur Gold Test Set
 - Itérations V3 à V5 - Corrections et améliorations
 - V6 - Modèle Style-Only (topic-agnostic)
 - V7 - Ensemble Hybride + SHAP
 - V8 - Intégration de CamemBERT
 - Échec du self-training sur données Bluesky
 - Annotation humaine et accord inter-annotateurs
 - V9 - Pipeline 2 étapes : filtre fait/opinion
 - Audit du corpus et rééquilibrage de la collecte
 - Limites et perspectives
 - Conclusion
 - Références
-

1. Présentation de l'entreprise et de l'école

Sup de Vinci - Campus Bordeaux

Sup de Vinci est une école d'informatique proposant des formations du Bac+3 au Bac+5 dans les domaines du numérique, de la data et de l'intelligence artificielle. Le campus de Bordeaux accompagne ses étudiants dans l'acquisition de compétences techniques et méthodologiques à travers des projets concrets et professionnalisants. Le présent rapport s'inscrit dans le cadre de la formation Master 1 Big Data et Intelligence Artificielle (promotion 2025-2026).

Niamato Consulting - Contexte commanditaire

Niamato Consulting est une société de conseil spécialisée en data science et intelligence artificielle. Dans le cadre de ce projet, elle intervient en tant que commanditaire fictif pour le compte d'un client du secteur média et fact-checking, souhaitant disposer d'un outil de veille automatisée capable de détecter les contenus suspects sur les réseaux sociaux émergents. Le MVP Thumalien a été développé en réponse à ce besoin, avec pour objectif de livrer un prototype fonctionnel de détection de fake news sur Bluesky.

Équipe projet

- Azélie Bernard - Lead technique : conception de l'architecture, développement du pipeline NLP, entraînement des modèles, mise en place de l'infrastructure Docker et du dashboard.
 - Sébastien Lazcanotegui - Validation et Qualité : annotation humaine, tests de validation, revue des résultats, contrôle qualité des données et des évaluations.
-

2. Problématique

La prolifération de la désinformation sur les réseaux sociaux constitue un enjeu majeur pour les démocraties contemporaines. Les contenus trompeurs se propagent 6 fois plus vite que les informations vérifiées (Vosoughi et al., 2018) et les plateformes émergentes comme Bluesky - décentralisées et moins modérées - amplifient ce risque. La détection automatique de fake news se heurte à plusieurs défis fondamentaux :

- Le domain shift : les modèles entraînés sur des articles de presse (longs, structurés) généralisent mal aux posts de réseaux sociaux (courts, informels, multilingues).
- Le biais thématique : les classifieurs TF-IDF apprennent à détecter le sujet (politique, santé) plutôt que le style de la désinformation, produisant massivement des faux positifs sur les sujets sensibles.
- La frontière fait/opinion : les posts d'opinion, même agressifs ou sensationnalistes, ne relèvent pas de la désinformation factuelle. Confondre les deux dégrade la précision du système.
- L'évaluation sur données réelles : les métriques sur datasets académiques ($F1 > 0.90$) ne reflètent pas la performance en production, où la prévalence des contenus suspects est très faible (~3-5%).

Question de recherche : comment concevoir un pipeline NLP bilingue capable de distinguer la désinformation factuelle des opinions sur un réseau social émergent, avec une précision suffisante pour servir d'outil d'aide à la décision ?

3. État de l'art

Détection de fake news par NLP

Les approches de détection de fake news se répartissent en trois familles principales :

Approches lexicales (TF-IDF, BoW) : les travaux fondateurs d'Ahmed et al. (2017) avec le dataset ISOT montrent qu'un classifieur TF-IDF + LogisticRegression atteint des $F1 > 0.99$ sur des articles de presse. Cependant, ces performances sont mécaniquement gonflées par des biais de corpus (marqueurs Reuters, style journalistique) et ne transfèrent pas aux textes courts des réseaux sociaux.

Approches par features stylistiques : Pérez-Rosas et al. (2018) et Zhou & Zafarani (2020) montrent que des features linguistiques (ponctuation, majuscules, diversité lexicale, marqueurs émotionnels) capturent des signaux de désinformation indépendants du sujet. Cette approche topic-agnostic est plus robuste au domain shift mais moins performante en valeur absolue.

Approches par Transformers : les modèles pré-entraînés (BERT, RoBERTa, CamemBERT) apportent une compréhension sémantique profonde. Liu et al. (2019) introduisent RoBERTa, et Martin et al. (2020) proposent CamemBERT pour le français. Le fine-tuning sur des données spécifiques produit des classifieurs performants sur les textes courts, mais au prix d'un coût computationnel et d'une opacité accrus.

Approches hybrides et ensembles : Zellers et al. (2019) démontrent avec Grover que les modèles génératifs peuvent à la fois produire et détecter de la désinformation. Wang et al. (2025) montrent que les approches multi-signaux (lexicales + stylistiques + sémantiques) surpassent les modèles individuels pour la détection en conditions réelles.

Accord inter-annotateurs et évaluation

L'évaluation de la détection de fake news sur données réelles pose des défis spécifiques. Le kappa de Cohen (1960) est la métrique standard d'accord inter-annotateurs, mais Gwet (2008) et Cicchetti & Feinstein (1990) montrent qu'il est biaisé lorsque la prévalence d'une classe est très faible (paradoxe kappa-prévalence). Le Gwet's AC1 corrige ce biais et

constitue une alternative robuste.

Positionnement de Thumalien

Thumalien se positionne dans la lignée des approches hybrides, en combinant un pipeline TF-IDF (V5), un modèle style-only topic-agnostic (V6), et des Transformers fine-tunés (CamemBERT, RoBERTa) dans un méta-learner. L'originalité réside dans le pipeline cascade V9 qui sépare explicitement les faits des opinions avant l'analyse de crédibilité - une approche motivée par l'observation empirique (Fisher $p=0.0005$) que les opinions ne sont presque jamais de la désinformation.

4. Présentation du projet

Objectif

Développer une pipeline complète d'analyse NLP pour détecter les fake news sur le réseau social Bluesky, en temps réel, dans un contexte bilingue français/anglais.

Pourquoi Bluesky ?

Bluesky est un réseau social décentralisé basé sur le protocole AT (Authenticated Transfer). Contrairement à X (ex-Twitter), son API est ouverte et permet une collecte légale des posts publics sans restriction d'accès. C'est un terrain idéal pour un projet académique de veille informationnelle.


Composants du système

Le projet Thumalien est composé de 4 briques :

- Collecteur : ingestion continue des posts Bluesky via l'API AT Protocol
- Base de données : stockage MongoDB des posts collectés (245 000+ posts à date, collecte continue)
- Pipeline NLP : détection de fake news + analyse émotionnelle
- Dashboard : visualisation temps réel via Streamlit

5. Architecture technique

Diagramme C4 - Niveau 2 (Conteneurs)



```
|
|
|
|   Stage 1: Fait/
|       Opinion (LogReg)
|
|
|   Stage 2: V5 TF-IDF
|       + V6 Style-only
|       + CamemBERT (FR)
|
|
|   Meta-learner V8
|       (LogReg 7 feat.)
|
|-----+-----+
|
|-----+-----+
|
|   XAI Pipeline
|   - SHAP global
|   - Attention CambERT
|   - Captum IG
|   - Meta decomp V8
|   - Faithfulness
|-----+-----+
|
|
|-----+-----+-----+
|   | CodeCarbon   |   | Monitoring |   | CI/CD GitHub Actions |
|   | emissions.csv|   | weekly_score |   | pytest + lint      |
|-----+-----+-----+
|-----+
```

Diagramme de sequence - Inference temps reel (analyse d'un texte)

Utilisateur	Dashboard	Stage1	V5 (TF-IDF)	V6 (Style)	CamemBERT	M...
						...
	Saisir texte					...
	----->					...
	classify()					...
	----->					...
	fait/opinion					...
	<-----					...
						...
	[Si factuel] predict()					...
	----->					...
	score_v5					...
	<-----					...
						...
	extract_style_features()					...
	----->					...
	score_v6					...
	<-----					...
						...
	[Si FR] classify()					...
	----->					...
	score_cam					...
	<-----					...
						...
	predict_proba([v5, v6, cam, disagree, interact, min])					...
	-----					...
	score_v8, label					...
	<-----					...

					...
		SHAP(V6) + decompose(V8) + attention(CamBERT)			...
		-----			...
		explications			...
		<-----			...
					...
	Score + SHAP				...
	+ decomp V8				...
	<-----				...

Stack technologique

Composant	Technologie	Justification
Collecte	atproto (Python)	Librairie officielle du protocole AT de Bluesky
Stockage	MongoDB	Base NoSQL adaptée aux documents JSON des posts
ML/NLP	scikit-learn, PyTorch	scikit-learn pour le pipeline classique, PyTorch pour le modèle d'émotions
Vectorisation	TF-IDF	Approche éprouvée, interprétable, rapide à entraîner
Dashboard	Streamlit + Plotly	Framework Python natif, idéal pour le prototypage rapide
Conteneurisation	Docker Compose	5 services isolés (MongoDB, Collector, Jupyter, Dashboard, Backup)
Monitoring CO2	CodeCarbon	Suivi de l'empreinte carbone des entraînements

Diagramme de composants

```
graph TD
    subgraph Docker_Compose [subgraph Docker Compose]
        A[Bluesky API] -->|AT Protocol| B[Collector<br>collect_bluesky.py]
        B -->|Insert| C[(MongoDB<br>thumalien_db)]
        C -->|Read| D[Dashboard<br>Streamlit :8501]
        C -->|Read| E[Jupyter Lab<br>:8888]
    end

    subgraph Pipeline_NLP_V9 [subgraph Pipeline NLP V9]
        F[Texte brut] --> S1[Stage 1: Fait/Opinion]
        S1 -->|opinion| BYPASS[Fiable - bypass]
        S1 -->|factuel| G[TF-IDF 30K]
        S1 -->|factuel| H[15 Features Ling.]
        S1 -->|factuel| I[7 Emotions MLP]
        G & H & I --> J[V5 LogReg]
        S1 -->|factuel| K[28 Features Style]
        S1 -->|factuel| L[7 Emotions]
        K & L --> M[V6 GradientBoosting]
        S1 -->|factuel FR| CAM[CamemBERT]
        J -->|score_v5| N[V8 Meta-Learner]
```

```

M -->|score_v6| N
CAM -->|score_cam| N
N -->|SHAP| O[Prediction + Explication]
end

D --> F

```

Diagramme de séquence - Analyse temps réel

```

sequenceDiagram
    actor U as Utilisateur
    participant D as Dashboard Streamlit
    participant S1 as Stage 1 (Fait/Opinion)
    participant V5 as Pipeline V5 (TF-IDF)
    participant V6 as Pipeline V6 (Style)
    participant CAM as CamemBERT/roBERTa
    participant V8 as Meta-Learner V8
    participant S as SHAP Explainer

    U->>D: Saisit un texte
    D->>S1: classify(texte)
    alt Opinion pure
        S1-->>D: opinion -> fiable (bypass)
    else Factuel/mixte
        S1-->>D: factuel
        D->>V5: predict(texte)
        V5-->>D: score_v5, label, emotions
        D->>V6: extract_features(texte)
        V6-->>D: 35 features style
        D->>CAM: predict(texte, lang)
        CAM-->>D: score_cam
        D->>V8: predict_meta(score_v5, score_v6, score_cam)
        V8-->>D: score_v8, label_final
        D->>S: explain(features_v6)
        S-->>D: SHAP values (35 features)
    end
    end
    D-->>U: Verdict + Scores + Graphique SHAP

```

Diagramme de classes simplifié

```

classDiagram
    class ExpertFakeNewsDetector {
        -tfidf_vectorizer
        -model: LogisticRegression
        -threshold: float
        +fit(texts, labels)
        +predict(texts): DataFrame
        +explain_prediction(text): dict
        +load(suffix)
        +save(suffix)
    }

    class LinguisticFeatureExtractor {
        +extract(texts): ndarray[n, 15]
    }

    class EmotionFeatureExtractor {

```



```

    -model: MLP PyTorch
    -vocab: dict
    +get_emotion_features(texts): ndarray[n, 7]
    +load(): bool
}

class StyleFeatureExtractorV6 {
    +FEATURE_NAMES: list[28]
    +extract(text): list[float]
}

ExpertFakeNewsDetector --> LinguisticFeatureExtractor
ExpertFakeNewsDetector --> EmotionFeatureExtractor
StyleFeatureExtractorV6 ..> ExpertFakeNewsDetector : V7 combine

```

Deep learning et détection de fake news

Le pipeline de base (V5) repose sur TF-IDF + LogReg (pas de deep learning) pour plusieurs raisons :

- Temps d'entraînement : plusieurs heures sur GPU vs 6 minutes pour le pipeline LogReg
- Interprétabilité : LogReg permet d'expliquer quels mots et features influencent la décision
- Performance comparable : le pipeline expert atteint F1=0.90, suffisant pour une première version
- Empreinte carbone : un modèle transformer consomme 10-100x plus d'énergie
- Déploiement : un modèle scikit-learn de 1 MB se déploie partout, un transformer de 500 MB est plus contraignant

Cependant, les pipelines avancés V8 et V9 intègrent CamemBERT (modèle Transformer pré-entraîné) comme composant optionnel du méta-learner, apportant un signal sémantique complémentaire pour les textes FR courts. Un prototype RoBERTa EN a également été exploré (notebook 04).

6. Phase 1 - Collecte et stockage des données

Notebooks concernés : 01, 03

Fonctionnement du collecteur

Le fichier `src/collection/collect_bluesky.py` réalise une collecte continue :

- Authentification sur Bluesky via les identifiants `.env`
- Recherche par mots-clés : 28 termes FR (actualité, politique, société, désinformation...) + 16 termes EN (climate, vaccine, conspiracy, election...)
- Stockage dans `thumalien_db.raw_posts` (MongoDB)
- Cycle : pause de 5 minutes entre chaque vague de collecte
- Résilience : 3 tentatives avec backoff exponentiel en cas d'erreur

Résultats

- 245 000+ posts collectés depuis décembre 2025

- Mix multilingue naturel (FR + EN + autres langues)
 - Champs stockés : text, uri, author_handle, created_at, search_term, collected_at
-

7. Phase 2 - Audit qualité et nettoyage

Notebooks concernés : 00, 05

Le problème du biais Reuters

Le dataset d'entraînement principal (ISOT Fake News Dataset) contient :

- True.csv : 21 417 articles, dont 89% portent le marqueur Reuters ("WASHINGTON (Reuters) -")
- Fake.csv : 23 481 articles de sites conspirationnistes, 0% de marqueur Reuters

Conséquence : un modèle naïf apprenait simplement à détecter le style Reuters (précision 99%) au lieu de détecter les fake news. Appliqué à Bluesky, il classait tout comme FAKE puisque aucun post n'a le format Reuters.

Solution : la classe DatasetCleaner

Nous avons créé un nettoyage systématique qui :

- Supprime les préfixes d'agences : CITY (Reuters) -, CITY (AP) -, CITY (AFP) -
- Supprime les attributions dans le corps : (Reuters), (AP), (AFP)
- Supprime les bylines : Reporting by..., Editing by..., Additional reporting...
- Nettoyage ML standard : passage en minuscules, suppression des URLs et mentions, normalisation des hashtags, suppression de la ponctuation spéciale
- Filtre de longueur : suppression des textes de moins de 20 mots après nettoyage (pour les articles), 5 mots pour les textes sociaux

Pourquoi ce choix ?

Plutôt que de changer de dataset, nous avons préféré nettoyer celui-ci car :

- ISOT est un des plus grands datasets de fake news disponibles (44 898 articles)
 - Le biais est identifié et quantifiable
 - Le nettoyage est reproductible et documenté
 - Cela nous a permis de comprendre un problème classique en ML : le data leakage
-

8. Phase 3 - Modèle d'émotions bilingue

Notebook concerné : 02

Architecture

Un réseau de neurones MLP (Multi-Layer Perceptron) en PyTorch :

```

Embedding (25 000 mots, dim=64)
|
FC1 (64 -> 48) + ReLU + Dropout(0.4)
|
FC2 (48 -> 24) + ReLU + Dropout(0.3)
|
FC3 (24 -> 7 classes) + Softmax

```

Les 7 émotions détectées

Émotion	Label FR	Description
Anger	Colère	Indignation, hostilité
Disgust	Dégoût	Rejet, répulsion
Joy	Joie	Contentement, humour
Neutral	Neutre	Factuel, sans charge émotionnelle
Fear	Peur	Inquiétude, alarme
Surprise	Surprise	Étonnement, inattendu
Sadness	Tristesse	Mélancolie, déception

Pourquoi PyTorch et pas TensorFlow ?

Le projet a initialement utilisé TensorFlow/Keras, mais nous avons migré vers PyTorch pour :

- Compatibilité Apple Silicon : TensorFlow avait des problèmes sur M4 Pro
- Flexibilité : PyTorch offre un contrôle plus fin du forward pass
- Communauté : la majorité de la recherche NLP utilise PyTorch depuis 2023
- Taille : l'installation PyTorch est plus légère sans GPU

Pourquoi un MLP et pas un Transformer pour les émotions ?

- Un MLP avec embeddings appris est suffisant pour 7 classes sur des textes courts
- Entraînement en quelques minutes vs heures pour un Transformer
- Le modèle sert de feature extractor (7 probabilités) pour le pipeline principal, pas de prédiction autonome

Métriques du classifieur d'émotions

Métrique	Valeur
F1 macro (test, 4 100 textes)	0.678
F1 weighted (test)	0.715
Accuracy validation (best epoch)	71.3%
F1 macro EN (2 000 textes, 5 classes)	0.546
F1 weighted EN	0.838
F1 macro FR (2 100 textes, 7 classes)	0.594
F1 weighted FR	0.594

Limites identifiées : les classes dégoût et neutre n'ont pas d'équivalent dans le dataset EN (Twitter Emotion) et sont entraînées exclusivement sur données FR. Le F1 macro EN (0.546) est donc pénalisé par ces deux classes absentes. Le sanity check sur 10 phrases manuelles montre un taux de 3/10, signe d'un overfitting sur les patterns du dataset d'entraînement.

Les probabilités de sortie (vecteur de 7 valeurs) sont utilisées comme features d'entrée du pipeline V5, et non comme prédiction finale présentée à l'utilisateur. La précision du classifieur d'émotions n'impacte donc la performance finale que de manière indirecte (l'ablation study montre un gain de +0.5 points F1 avec les features émotionnelles).

Améliorations apportées

- Class weights : pondération inversement proportionnelle à la fréquence de chaque classe dans CrossEntropyLoss, pour compenser le déséquilibre (joie=8066 vs dégoût=1400 dans le train set)
- Early stopping : le modèle est sauvegardé au meilleur epoch (val_loss minimale) avec une patience de 5 epochs, au lieu d'utiliser les poids du dernier epoch - cela évite l'overfitting observé initialement (train acc 93% vs val acc 71%)

9. Phase 4 - Pipeline expert V1.5

Notebooks concernés : 05, 06

Vue d'ensemble du pipeline

Le pipeline V1.5 combine 3 types de features dans un seul classifieur :

```

Texte brut
|
+----> TF-IDF (30 000 features) ----+
|                                   |
+----> 12 features linguistiques ----+----> LogisticRegression --> Score [0,1]
|                                   |
+----> 7 features emotions -----+
                                   (optionnel)

```

TF-IDF : les choix et pourquoi

Paramètre	Valeur	Pourquoi
max_features=30000	30 000 mots	Vocabulaire bilingue FR+EN nécessitant un espace plus grand
ngram_range=(1,2)	Uni/bigrammes	Capture "fake news", "breaking news" tout en réduisant la dimensionnalité (optimisé par GridSearch)
min_df=5	Min 5 documents	Élimine les mots trop rares, seuil optimisé par GridSearch (meilleur F1 que min_df=3)
max_df=0.95	Max 95% des docs	Élimine les mots trop fréquents (stop words implicites)
sublinear_tf=True	TF logarithmique	1 + log(TF) au lieu de TF brut, évite la domination des mots très fréquents

strip_accents=None	Conserver les accents	En français, "où"/"ou" et "à"/"a" ont des sens différents
--------------------	-----------------------	---

Les 12 features linguistiques

Ces features capturent des signaux structurels de désinformation, indépendants du contenu :

#	Feature	Intuition
1	word_count	Les fake news sont souvent plus courtes ou anormalement longues
2	caps_ratio	Les fake news utilisent plus de MAJUSCULES pour attirer l'attention
3	exclamation_count	Ponctuation exclamative excessive = signal de sensationnalisme
4	question_count	Questions rhétoriques fréquentes dans la désinformation
5	punct_density	Densité de ponctuation émotionnelle (!?.,;....)
6	avg_word_length	Les articles fiables utilisent un vocabulaire plus riche
7	sensationalism_score	Comptage de mots-clés sensationnalistes (47 FR + 17 EN)
8	has_url	Présence d'URL (les articles fiables citent leurs sources)
9	numeric_density	Proportion de chiffres (statistiques = signe de fiabilité)
10	lexical_diversity	Ratio types/tokens (diversité du vocabulaire)
11	sentence_count	Nombre de phrases
12	avg_sentence_length	Longueur moyenne des phrases

Exemples de mots-clés sensationnalistes :

- FR : "scandale", "censure", "complot", "on vous cache", "faites tourner", "réveillons-nous"
- EN : "breaking", "shocking", "bombshell", "conspiracy", "they don't want you to know"

Support bilingue

Le mode bilingue activé automatiquement quand la colonne language est présente :

- Détection de langue : via langdetect (premiers 500 caractères)
- Pondération : les langues minoritaires reçoivent un poids inversement proportionnel à leur fréquence
 - Exemple : 60% EN + 40% FR -> poids EN=0.83, poids FR=1.25
- Conservation des accents : strip_accents=None pour préserver la sémantique FR
- Oversampling FR : les données françaises sont dupliquées 3x pour équilibrer avec l'anglais

Choix du classifieur : LogisticRegression

Critère	LogReg	SVM	Ensemble
Interprétabilité	Excellente (coefficients = importance)	Limitée	Moyenne
Vitesse	Rapide (6 min)	Moyenne	Lente
Probabilités	Natives	Via calibration	Via soft voting
Performance	F1=0.90	F1=0.89	F1=0.90

LogReg a été choisi pour son interprétabilité (on peut expliquer pourquoi un texte est classé suspect) et ses probabilités natives (pas besoin de calibration supplémentaire).

Paramètres du classifieur

```
LogisticRegression(  
    C=5.0,          # Force de régularisation optimisée par GridSearch (plus permissive)  
    max_iter=5000,  # Itérations max de l'optimiseur (voir section 10)  
    solver='lbfgs', # Algorithme d'optimisation quasi-newtonien  
    class_weight='balanced', # Pondération inversement proportionnelle à la fréquence  
    random_state=42 # Reproductibilité  
)
```

Résultats V1.5

- CV F1 global : 0.986
- F1 EN : 0.987
- F1 FR : 0.985
- Entraînement : ~6 minutes sur Apple M4 Pro

Problème identifié : appliqué aux posts Bluesky (textes courts ~27 mots), le V1.5 classait 77% des posts comme SUSPECT. Le modèle avait été entraîné uniquement sur des articles longs (~340 mots) et ne généralisait pas bien aux textes courts. C'est le phénomène de domain shift.

10. Phase 5 - Analyse du modèle et GridSearch

Notebook concerné : 07

Feature importance

L'analyse des coefficients LogReg a révélé :

Top features SUSPECT (coefficients positifs) :

- Mots sensationnalistes ("trump", "breaking", "shocking")
- Ponctuation excessive
- Ratio de majuscules élevé

Top features FIABLE (coefficients négatifs) :

- Vocabulaire factuel ("report", "study", "according")
- Diversité lexicale élevée

- Présence de citations et sources

GridSearch : optimisation des hyperparamètres

Nous avons testé 36 combinaisons de paramètres :

Paramètre	Valeurs testées
max_features	20 000, 30 000, 40 000
min_df	3, 5
ngram_range	(1,2), (1,3)
C	0.5, 1.0, 5.0

Résultat : le meilleur combo (max_features=30000, min_df=5, C=5.0, ngram=(1,2)) atteignait F1=0.9907, une amélioration de +0.69% par rapport aux paramètres initiaux. Ces hyperparamètres optimisés ont été appliqués au pipeline de production.

Adaptation aux textes courts

Le notebook 07 a comparé 3 stratégies :

Modèle	F1 sur articles	F1 sur textes courts
Articles complets	0.99	Faible
Articles tronqués (50 mots)	0.95	Meilleur
Mix complets + tronqués	0.97	Meilleur

Conclusion : le modèle "mixte" généralise mieux. C'est cette observation qui a motivé la Phase 6.

11. Phase 6 - Intégration de datasets sociaux (V2)

Notebook concerné : 08

Le problème du domain shift

Le pipeline V1.5, malgré son excellent F1 sur les articles de presse, échouait sur les posts Bluesky :

Métrique	Articles (holdout)	Posts Bluesky
Longueur moyenne	340 mots	27 mots
% SUSPECT (V1.5)	~46% (équilibré)	77% (trop élevé)

Le modèle avait appris des patterns propres aux articles longs (structure, vocabulaire journalistique, longueur) et les appliquait aux posts courts, les classant quasi-systématiquement comme suspects.

Choix des 3 datasets complémentaires

Dataset	Source	Textes	Langue	Long. moy	Intérêt
FakeNewsNet	GitHub KaiDMML	22 596 titres	EN	11.6 mots	Titres d'articles = textes très courts

CONSTRAINT 2021	GitHub diptamath	8 559 tweets	EN	27 mots	Tweets COVID = même longueur que Bluesky
Credibility Corpus	Zenodo	9 841 tweets	FR+EN	17.3 mots	Tweets FR = comble le manque de données sociales FR

Total : 40 996 textes sociaux ajoutés aux 65 517 articles existants.

Pourquoi ces datasets spécifiquement ?

- FakeNewsNet : choisi car il contient des titres (11 mots en moyenne), le format de texte le plus court. Cela force le modèle à apprendre à classifier avec très peu de mots.
- CONSTRAINT 2021 : tweets COVID-19 vérifiés par des fact-checkers, avec exactement la même longueur moyenne que les posts Bluesky (27 mots). C'est le dataset le plus représentatif de notre cas d'usage.
- Credibility Corpus : le seul dataset de tweets en français disponible avec des labels de crédibilité. Sans lui, le modèle n'aurait aucun exemple de texte court en français.

Pipeline de chargement

Chaque dataset a son propre loader dans DatasetCleaner :

- load_fakenewsnet() : charge les titres GossipCop + PolitiFact, 4 fichiers CSV
- load_constraint() : charge 3 fichiers CSV (train/val/test), mappe "real"->0, "fake"->1
- load_credibility_corpus() : parse des fichiers hétérogènes (semicolon-separated pour les rumeurs, R-style CSV pour les tweets aléatoires), détecte la langue (FR/EN) par fichier

Oversampling social x2

Les textes sociaux sont dupliqués 2 fois (social_oversample=2) pour équilibrer avec les articles longs. Sans cela, les 40K textes courts seraient noyés dans 65K articles longs et le modèle ne les apprendrait pas suffisamment.

Résultats V2

Métrique	V1.5	V2
Taille du dataset	65 517	145 703 (+122%)
% textes courts (< 50 mots)	~0%	63.1%
CV F1	0.986	0.897
F1 articles longs (100-500 mots)	0.988	0.988 (pas de régression)
F1 textes courts (< 30 mots)	~aléatoire	0.800
Bluesky % fiable	23%	73.4%

Analyse : le F1 global baisse de 0.986 à 0.897 car la tâche est objectivement plus difficile (mix articles + tweets). Mais ce qui compte pour l'application réelle, c'est la calibration sur Bluesky : de 23% à 73.4% fiable, une amélioration significative.

12. Le seuil de décision : pourquoi 0.44 ?

Comment fonctionne la prédiction

Quand le modèle analyse un texte, il produit une probabilité de fiabilité entre 0 et 1 :

- Score = 0.90 -> le modèle est très confiant que le texte est fiable
- Score = 0.10 -> le modèle est très confiant que le texte est suspect
- Score = 0.50 -> le modèle est incertain

Le seuil de décision détermine à partir de quel score un texte est classé FIABLE :

- Si $P(\text{fiable}) \geq \text{seuil}$ -> prédiction FIABLE
- Si $P(\text{fiable}) < \text{seuil}$ -> prédiction SUSPECT

Pourquoi pas 0.50 ?

Le seuil par défaut de 0.50 semble logique (50/50) mais il n'est optimal que si :

- Les classes sont parfaitement équilibrées
- Les coûts des erreurs sont symétriques (faux positif = faux négatif)

Dans notre cas, avec le dataset V2 contenant des textes très divers, le modèle produit des scores légèrement biaisés vers le bas pour les textes courts. Un seuil de 0.50 classait 66.3% des posts Bluesky comme FIABLE - en dessous des 70% attendus.

Recherche du seuil optimal

Nous avons testé systématiquement différents seuils sur 2 000 posts Bluesky + le holdout test :

Seuil	Bluesky % fiable	Holdout F1	Holdout Accuracy
0.50	66.3%	0.8997	92.5%
0.48	68.2%	0.9012	92.7%
0.46	70.0%	0.9008	92.7%
0.45	71.0%	0.9015	92.8%
0.44	73.4%	0.9024	92.9%
0.42	73.9%	0.9016	92.9%
0.40	75.3%	0.9001	92.9%
0.35	80.0%	0.8938	92.6%

Le seuil 0.44 est le point d'équilibre optimal : il maximise simultanément le F1 holdout (0.9024) ET dépasse 70% de fiabilité sur Bluesky.

Impact concret du changement de seuil

Avant (seuil 0.50) :

Post "Les vaccins sont efficaces selon l'OMS" -> Score 0.47 -> SUSPECT (faux négatif)

Après (seuil 0.44) :

Post "Les vaccins sont efficaces selon l'OMS" -> Score 0.47 -> FIABLE (correct)

Le seuil 0.44 corrige les cas où le modèle était légèrement incertain mais penchait quand même vers "fiable". Ce sont typiquement des textes courts, factuels, mais trop brefs pour que le modèle soit pleinement confiant.

Risques

Baisser le seuil augmente le risque de faux négatifs (classer un texte suspect comme fiable). À 0.44, la précision sur la classe SUSPECT reste à 0.92 (92% des textes classés suspects le sont réellement), ce qui est acceptable.

13. Qu'est-ce que max_iter ?

Définition simple

max_iter est le nombre maximum d'itérations que l'algorithme d'optimisation peut effectuer pour trouver les meilleurs paramètres du modèle.

Analogie

Imaginez que vous cherchez le sommet d'une montagne dans le brouillard. À chaque pas, vous regardez la pente autour de vous et montez dans la direction la plus raide. max_iter est le nombre maximum de pas que vous pouvez faire. Si la montagne est petite, 100 pas suffisent. Si elle est immense et complexe, il en faut 5 000.

Dans notre contexte

Le classifieur LogisticRegression utilise l'algorithme L-BFGS (Limited-memory Broyden-Fletcher-Goldfarb-Shanno) pour trouver les poids optimaux. À chaque itération, l'algorithme :

- Calcule le gradient (direction de la plus forte amélioration)
- Met à jour les 30 012 poids du modèle
- Vérifie si la perte (erreur) a suffisamment diminué
- Si oui, s'arrête (convergence). Si non, continue.

Pourquoi on est passé de 2000 à 5000

Avec le dataset V2 (145 703 textes, 30 012 features), l'espace d'optimisation est plus grand que le V1.5. À max_iter=2000, l'algorithme s'arrêtait avant d'avoir convergé :

```
ConvergenceWarning: lbfgs failed to converge after 2000 iteration(s)
STOP: TOTAL NO. OF ITERATIONS REACHED LIMIT
```

Ce warning signifie que le modèle n'a pas atteint son optimum. Les résultats sont utilisables mais sous-optimaux. À max_iter=5000, l'algorithme a suffisamment de marge pour converger.

Impact réel

max_iter	CV F1	Converge ?
2000	0.8966	Non (warning)
5000	0.8972	Oui

L'impact est faible (+0.06% de F1) car le modèle était déjà proche de l'optimum à 2000 itérations. Mais supprimer le warning garantit que les résultats sont reproductibles et optimaux.

Coût

Plus d'itérations = plus de temps de calcul. Mais sur un Apple M4 Pro, le passage de 2000 à 5000 itérations n'ajoute que ~1 minute au temps total d'entraînement (6 min -> 7 min). Le compromis est largement acceptable.

14. Dashboard Streamlit

Technologies

- Streamlit : framework Python pour créer des dashboards web interactifs
- Plotly : graphiques interactifs (zoom, hover, export)
- Thème : dark mode avec accents cyan, effet glassmorphism

Pages principales

- Vue Globale : métriques clés (nombre de posts, répartition fiable/suspect, radar émotions, posts récents)
- Analyse en temps réel : zone de texte libre -> prédiction instantanée avec jauge de crédibilité
- Métriques & Transparence : résultats d'ablation, bilan carbone, conformité RGPD/AI Act

Connexion MongoDB

Le dashboard se connecte à MongoDB (thumalien_db.raw_posts) et applique le modèle V2 en temps réel sur les posts chargés. Les résultats sont cachés en session_state pour éviter de recalculer à chaque interaction.

Chargement du modèle

Le dashboard charge automatiquement le modèle V2 s'il est disponible :

```
v2_exists = os.path.exists(os.path.join(model_dir, 'model_expert_v2.pkl'))
detector.load(suffix='expert_v2' if v2_exists else 'expert')
```

15. Bilan carbone (Green IT)

Outil : CodeCarbon

CodeCarbon mesure la consommation électrique (CPU + RAM) pendant l'entraînement et la convertit en équivalent CO2 selon le mix énergétique du pays.

Émissions mesurées

Entraînement	Durée	CO2	Notes
V1.5 LogReg (fév. 2026)	6.2 min	0.28 g	Baseline bilingue
V5 LogReg (avr. 2026)	16.2 min	0.73 g	+10K posts synthétiques
V5 LogReg retraining	25.9 min	1.17 g	Hyperparamètres optimisés
CamemBERT fine-tune	10.7 min	0.48 g	Textes FR courts
RoBERTa EN V1	37.4 min	1.69 g	Fine-tune anglais
RoBERTa EN V2	39.3 min	1.78 g	+10K EN synthétiques

Total projet	~2h16	6.14 g	
--------------	-------	--------	--

Contexte

- Un email envoyé : ~4 g CO2
- Une recherche Google : ~7 g CO2
- Tous nos entraînements cumulés : 6.14 g CO2 (moins qu'une recherche Google)

Le pipeline de production (V5 LogReg) ne consomme que 0.73 g. Les modèles Transformer (CamemBERT, RoBERTa) représentent 64% des émissions mais n'interviennent qu'en complément pour les textes courts.

16. État actuel du projet

Ce qui fonctionne

Composant	Statut	Détails
Collecte Bluesky	Opérationnel	245 000+ posts, collecte continue (V3 rééquilibrée)
MongoDB	Opérationnel	Docker, 27017, persistance locale
Pipeline V5 (TF-IDF)	Opérationnel	F1 CV=0.90, seuil 0.44, 197K textes
Pipeline V6 (Style)	Opérationnel	GradientBoosting, 28 features stylistiques, topic-agnostic
Pipeline V7 (Hybride)	Opérationnel	Méta-learner V5+V6 + SHAP explicabilité
Pipeline V8 (CamemBERT)	Opérationnel	Méta-learner V5+V6+CamemBERT, F1 suspect +28%
Pipeline V9 (Cascade)	Opérationnel	Filtre fait/opinion + V5, FP -67% sur gold consensus
Émotions	Opérationnel	7 classes, MLP PyTorch bilingue
Dashboard	Opérationnel	Streamlit, 5 pages (Dashboard, Analyse IA, Explorateur, Performance, À propos)
Bilan carbone	Opérationnel	CodeCarbon intégré

Métriques clés

Métrique	Valeur
Posts collectés	245 000+
Datasets d'entraînement	7 (ISOT EN, Kaggle FR, FakeNewsNet, CONSTRAINT, Credibility, Social FR synth.)
Taille dataset V5	197 782 textes
CV F1 V5 (TF-IDF)	0.90
CV F1 V6 (Style)	0.830

Gold F1 suspect V5	0.087
Gold F1 suspect V7 Méta	0.127 (+46%)
Gold F1 suspect V8	0.163 (+28% vs V7)
V9 Cascade FP (consensus 473)	62 (-67% vs V5 seul)
V9 Cascade kappa / AC1	?=0.199, AC1=0.802
Annotation humaine	200 posts gold (2 annotateurs, ?=0.808, AC1=0.978) + 500 posts (2 annotateurs, ?=0.498)
Bluesky % fiable	67%
Notebooks	28 (00 à 27)
Temps d'inférence (V5)	1.5 ms/texte (~728 textes/sec)
Tests unitaires	107 tests, 29% coverage

Benchmark de latence

Le cahier des charges exige un temps d'inférence < 100 ms par texte (DET-09). Les benchmarks mesurent sur Apple M4 Pro (CPU, sans GPU) :

Scénario	Temps total	Temps par texte	Débit
Texte unique (V5 TF-IDF)	1.6 ms	1.6 ms	625 textes/s
Batch 10 textes	14.7 ms	1.5 ms	678 textes/s
Batch 100 textes	137 ms	1.4 ms	728 textes/s

Le pipeline V5 (TF-IDF + LogReg) répond en 1.5 ms par texte, soit 66x plus rapide que l'exigence du CDC (100 ms). L'effet de batch réduit légèrement le coût unitaire grâce à la vectorisation numpy/scipy.

Note : les modèles Transformer (CamemBERT, RoBERTa) utilisés dans V8/V9 sont plus lents (~50-200 ms/texte selon la longueur), mais ne sont actifs que pour les textes courts ou ambigus.

Scalabilité

Dimension	État actuel	Architecture cible
Volume de données	245 000+ posts dans MongoDB	> 1M posts supporte sans modification
Collecte	Collecteur Python mono-thread, ~25 posts/requête	Kafka + collecteurs distribués pour ingestion temps réel
Inférence	Batch séquentiel dans le collecteur	Spark Structured Streaming pour inférence parallèle
Stockage	MongoDB standalone (Docker)	Replica set MongoDB pour HA + sharding horizontal
Dashboard	Streamlit mono-instance	Load balancer + cache Redis pour sessions concurrentes
Monitoring	Logs structures + weekly check JSONL	Prometheus + Grafana pour métriques temps réel et alertes

L'architecture actuelle (Docker Compose 4 services) est conçue pour être déployée sur un seul serveur et gère confortablement 250K+ posts. L'évolution vers une architecture distribuée (Kafka/Spark) est documentée mais non implémentée, car le volume actuel ne le justifie pas.

Historique des versions

Version	Date	F1 CV	Gold F1 suspect	Innovation
V1.0	Déc 2025	0.99 (biaisé)	-	Baseline LogReg EN
V1.5	Fév 2026	0.986	-	Bilingue + nettoyage Reuters + features linguistiques
V2	Fév 2026	0.90	-	3 datasets sociaux + seuil 0.44
V3	Mar 2026	0.90	-	Correction features linguistiques
V4	Mar 2026	0.935 FR	-	Amélioration FR court + augmentation
V5	Avr 2026	0.90	0.087	+10K FR social synthétique, FR ultra-court F1=0.90
V6	Avr 2026	0.830	0.103 (+18%)	Style-only GradientBoosting, topic-agnostic
V7	Avr 2026	-	0.127 (+46%)	Ensemble hybride V5+V6 + SHAP
V8	Avr 2026	-	0.163 (+28%)	Méta-learner V5+V6+CamemBERT
V9	Mai 2026	-	?=0.199, AC1=0.802	Pipeline 2 étapes fait/opinion, FP -67%

17. Évaluation sur Gold Test Set (200 posts Bluesky)

Protocole

Pour évaluer la performance réelle du pipeline sur des données Bluesky, un gold test set de 200 posts a été constitué :

- 200 posts sélectionnés par stratification (langue, longueur, prédiction du modèle)
- 2 annotateurs indépendants avec consignes détaillées
- Résolution des désaccords (4 cas sur 200)
- Accord inter-annotateur : kappa de Cohen = 0.808 (substantiel)

Résultats

Métrique	Synthétique (holdout)	Gold (réel)
Accuracy	0.93	0.685
F1 macro	0.913	0.448
F1 fiable	~0.95	0.810

F1 suspect	-0.90	0.087
% fiable	73.4%	70.0%

Matrice de confusion

	Préd fiable	Préd suspect
Gold fiable (191)	134	57
Gold suspect (9)	6	3

Interprétation

Le modèle classe 57 posts fiables comme suspects (30% de faux positifs). L'analyse des erreurs révèle que ces posts traitent de sujets sensibles (vaccins, climat, politique) mais sont factuels et sourcés. Le modèle détecte le sujet (mots-clés corrélés à la désinformation dans les datasets d'entraînement) et non la désinformation elle-même.

La distribution des scores le confirme : le score moyen des posts fiables (0.615) est quasi identique à celui des posts suspects (0.583). Le modèle ne discrimine pas les deux classes sur des données réelles.

Leçons apprises

- Les métriques sur données synthétiques (F1=0.913) sont mécaniquement gonflées par le biais thématique des datasets
- Un classifieur fondé sur le champ lexical (TF-IDF) apprend à détecter le sujet, pas la véracité
- Le gold test set est indispensable pour mesurer la performance réelle en production
- Les pistes d'amélioration passent par des features basées sur le registre énonciatif (présence de sources, marqueurs d'opinion) plutôt que sur les mots-clés

18. Itérations V3 à V5 - Corrections et améliorations

Notebooks concernés : 09 à 15

Après l'évaluation sur le gold test set (section 17), plusieurs itérations ont été menées pour améliorer le pipeline :

V3 - Correction des features linguistiques

- Bug identifié : les features linguistiques (caps_ratio, exclamation, etc.) étaient calculées sur le texte après nettoyage ML (minuscules, sans ponctuation) au lieu du texte original
- Correction : calcul sur le texte brut, avant nettoyage
- Impact : CV F1 = 0.900, précision +19.3%

V4 - Amélioration FR court + augmentation données

- 187 782 textes d'entraînement (FR=76K / 40%, EN=112K / 60%)
- 27K textes courts FR générés depuis articles longs (augmentation)
- 3 nouvelles features : all_caps_words_ratio, interpellation_score, is_short_text
- Vocabulaire sensationnaliste FR enrichi (+16 termes social media)

- FR court F1 : 0.65 -> 0.86 (+32%)

V5 - Intégration FR social synthétique

- 197 782 textes d'entraînement (FR=86K / 43.5%, EN=112K / 56.5%)
- +10K posts FR sociaux synthétiques (5K suspect + 5K fiable)
- FR ultra-court F1 : 0.86 -> 0.90 (+10.4%) | FR global F1 : 0.944
- Test bilingue : 12/12 (vs 9/10 en V4)
- Seuil de décision maintenu à 0.44

Note sur le gain global V4->V5 : Le gain global de V5 semble modeste (+0.8% en F1 macro), mais c'est parce que les données synthétiques ciblent spécifiquement les textes courts FR, où le gain est de +5.1%. Le F1 global est dominé par les textes longs de Reuters/ISOT qui sont déjà bien classifiés (F1 > 0.98) et masquent l'amélioration ciblée.

Limitation méthodologique : L'oversampling x5 des textes FR courts est appliqué avant le split StratifiedKFold. Des copies d'un même texte peuvent donc se retrouver dans les folds train et validation, ce qui gonfle artificiellement les métriques CV. Le F1 CV de 0.90 est donc une borne supérieure optimiste. Les métriques du gold test set (F1 suspect = 0.087 pour V5) constituent l'évaluation non biaisée de la performance réelle.

19. V6 - Modèle Style-Only (topic-agnostic)

Notebook concerné : 23

Le problème du biais thématique

L'analyse des coefficients du modèle V5 (feature importance) a révélé un problème fondamental :

Top features SUSPECT	Coefficient	Type
coronavirus	+9.72	Sujet
trump	+6.44	Sujet
video	+5.81	Sujet
breaking	+4.93	Style
china	+4.67	Sujet

Constat : le modèle apprend le sujet ("coronavirus" -> suspect) et non le style de la désinformation. Sur le gold test set, cela produit 57 faux positifs (posts fiables sur des sujets sensibles classés comme suspects).

Solution V6 : features stylistiques pures

Le modèle V6 supprime totalement le TF-IDF et utilise uniquement 28 features stylistiques + 7 émotions :

Bloc	Features	Exemples
1. Structure (6)	word_count, sentence_count, paragraph_count	Longueur, structure du texte
2. Ponctuation (6)	exclamation_count, ellipsis_count, emoji_count	Ponctuation émotionnelle
3. Majuscules (3)	caps_ratio, all_caps_words_ratio	Usage de MAJUSCULES

4. Manipulation (5)	sensationalism_score, call_to_action_score	Lexique de manipulation
5. Crédibilité (5)	has_url, has_source_citation, quote_count	Marqueurs de fiabilité
6. Diversité (3)	lexical_diversity, repeated_char_ratio	Qualité rédactionnelle
7. Émotions (7)	colère, joie, neutre, peur...	Probabilités MLP PyTorch

Avantage : le modèle est topic-agnostic par construction - il ne peut apprendre que le STYLE d'écriture, pas le sujet.

Résultats V6

- Classifieur sélectionné : GradientBoosting (meilleur F1 en cross-validation)
- CV F1 = 0.830 (vs 0.90 pour V5, attendu car moins de signal)
- Gold F1 suspect = 0.103 (+18% vs V5 à 0.087)
- Moins de faux positifs sur les posts fiables traitant de sujets sensibles

20. V7 - Ensemble Hybride + SHAP

Notebook concerné : 24

Architecture du méta-learner

```

Texte -> V5 (TF-IDF 30K) -> score_v5 P(fiable) --+
                                                    |-> Meta-Learner -> Décision finale
Texte -> V6 (Style 35) -> score_v6 P(suspect) --+ (LogReg)

```

Le méta-learner reçoit 4 features :

- score_v5 : P(fiable) du modèle TF-IDF
- score_v6 : P(suspect) du modèle style
- disagreement : $|\text{score_v5} - (1 - \text{score_v6})|$ - signal de conflit entre les deux modèles
- interaction : $\text{score_v5} * \text{score_v6}$

Coefficients du méta-learner

Feature	Coefficient	Interprétation
score_v6_suspect	+1.125	Fort signal suspect via le style
interaction	+1.275	Combinaison des deux signaux
disagreement	-2.433	Le désaccord pousse vers fiable (conservateur)
score_v5_fiable	-0.171	Signal TF-IDF (faible poids)

Deux approches de combinaison

A) V7 Combo - Seuil optimal sur score combiné $V5 * (1 - V6)$:

- Accuracy : 0.840 (vs 0.685 V5, 0.545 V6)
- Faux positifs : 25 (vs 57 V5, 83 V6) - meilleur compromis

B) V7 Méta - Leave-One-Out cross-validation sur gold set :

- F1 suspect : 0.127 (+46% vs V5)
- F1 macro : 0.521

Comparaison finale sur le Gold Test Set

Modèle	Accuracy	F1 macro	F1 suspect	FP	FN
V5 (TF-IDF)	0.685	0.448	0.087	57	6
V6 (Style)	0.545	0.370	0.103	83	5
V7 Combo	0.840	0.471	0.080	25	8
V7 Méta (LOO)	0.785	0.521	0.127	35	6

Explicabilité SHAP

SHAP (SHapley Additive exPlanations) permet d'expliquer les prédictions du modèle V6 feature par feature. Nous utilisons TreeExplainer (exact et rapide pour les modèles à base d'arbres).

Top 5 features globales (mean |SHAP|) :

Rang	Feature	SHAP moyen	Interprétation
1	paragraph_count	0.089	Textes multi-paragraphe = souvent fiables
2	word_count	0.076	Longueur du texte
3	sensationalism_score	0.065	Mots sensationnalistes = suspect
4	has_source_citation	0.058	Sources citées = fiable
5	exclamation_count	0.052	Ponctuation excessive = suspect

Analyse des faux positifs : SHAP révèle que les FP sont causés par des posts courts avec "BREAKING" (sensationalism_score élevé) qui sont en réalité des infos factuelles d'agences de presse.

Intégration dans le dashboard

Le dashboard V7 affiche pour chaque analyse en temps réel :

- Les 3 scores (V5, V6, V7) et le signal de désaccord
- Un graphique SHAP montrant la contribution de chaque feature de style
- Le détail complet des 35 features avec leur valeur SHAP et direction

Pipeline XAI complet (mai 2026)

Au-delà de l'explicabilité SHAP de V6 ci-dessus, le projet inclut un module

XAI complet (src/explainability/, 1 450 LoC) qui couvre les 4 niveaux de

l'IA explicable :

Niveau global / modèle

- GlobalShapExplainer : beeswarm + dependence plots sur V6 (cf. docs/figures/xai/)
- Analyse stratifiée par classe d'erreur (TP/FP/FN)

Niveau local / instance

- Coefficients LogReg V5 : expert_detector.explain_prediction
- SHAP TreeExplainer V6 : intégré dashboard (existant)
- Attention CamemBERT (CLS dernière couche + heatmap par couche)
- Layer Integrated Gradients via Captum sur CamemBERT (axiome de

Completeness vérifié, Sundararajan et al. 2017)

Niveau méta-learner V8

- MetaLearnerDecomposer : décomposition exacte $z = ?? + ? ?? \cdot x?$ du

LogReg V8 sur 7 features (V5 + V6 + CamemBERT + désaccords + interaction

+ min_fiable). Affichée dans le dashboard sous le bloc SHAP

Niveau validation / faithfulness

- FaithfulnessEvaluator : AOPC, Comprehensiveness@k, Sufficiency@k

(DeYoung et al. 2020, ERASER benchmark)

- Mesure sur le gold set : AOPC attribution = 0.253, AOPC random =

0.045, uplift = +0.208 (cible > +0.10) ? explications **5.6× plus

prédictives** qu'une attribution aléatoire

- Comprehensiveness@5 = 0.232 / Sufficiency@5 = 0.058

Coefficients V8 - observation clé

score_v5_fiable	: ?=+0.393	
score_v6_suspect	: ?=+0.580	
score_camembert_fiable	: ?=?1.116	<- signal le plus fort en valeur absolue
disagreement_v5_v6	: ?=?2.939	<- coefficient dominant
disagreement_v5_cam	: ?=+0.948	
interaction_v5_v6	: ?=+1.053	
min_fiable	: ?=?0.836	
intercept	: ??=+0.492	

Le coefficient disagreement_v5_v6 (=?=-2.94) est le **plus important en

magnitude** : quand les deux modèles divergent, V8 penche fortement vers

FIABLE. Comportement conservateur sur consensus - on ne classe SUSPECT

que lorsque V5 et V6 convergent, ce qui réduit drastiquement les FP.

Production : pipeline reproductible via python scripts/run_xai_pipeline.py,

qui régénère toutes les figures + un INDEX.md Markdown + un results.json

sérialisé. Documentation auditeur : docs/12_model_card.md (Google Model

Card format) section 7.

21. V8 - Intégration de CamemBERT

Hypothèse

Le méta-learner V7 combine V5 (TF-IDF lexical) et V6 (style-only). Pour le français, un troisième signal sémantique - CamemBERT, modèle Transformer pré-entraîné sur du français - pourrait capturer des patterns que le TF-IDF manque, notamment sur les textes courts de Bluesky.

Protocole

- Architecture : V8 = méta-learner LogReg avec 7 features (au lieu de 4 pour V7)
 - score_v5, score_v6, score_cam (CamemBERT, 0.5 pour les textes EN)
 - disagree_v5_v6, disagree_v5_cam
 - interact_v5_v6, min_fiable
- Évaluation : LOO cross-validation sur le gold test set (200 posts)
- Notebook : 25_V8_Hybrid_Extended_CamemBERT.py

Résultats

Modèle	F1 suspect	F1 macro	FP
V7 Meta (baseline)	0.127	0.521	35
V8 LogReg (+CamemBERT)	0.163	0.569	22

Gain : +28% F1 suspect, -13 FP. Amélioration modeste mais cohérente. CamemBERT apporte un signal utile pour les textes FR, sans dégrader les textes EN (score neutre à 0.5).

Fichiers

- models/model_hybrid_v8.joblib - méta-learner V8 avec flag uses_camembert: True
- Dashboard mis à jour pour charger V8 automatiquement

22. Échec du self-training sur données Bluesky

Hypothèse

V5 est entraîné sur des articles de presse (Reuters, ISOT, Kaggle) mais déployé sur des posts Bluesky courts et informels. Ce domain shift cause un F1 suspect de 0.087 sur le gold set. L'idée : ajouter des posts Bluesky à haute confiance au dataset d'entraînement via pseudo-labeling (self-training) pour adapter le vocabulaire TF-IDF au domaine Bluesky.

Protocole

- Exporter depuis MongoDB les posts Bluesky à haute confiance :
 - 17 868 posts avec score V5 $\leq$ 0.15 (étiquetés "suspect" par V5)

- 37 141 posts avec score V5 ≥ 0.85 (étiquetés "fiable" par V5)
- Échantillonner 5 000 de chaque classe
- Ajouter au dataset original (~68K textes) -> dataset augmenté (~78K)
- Ré-entraîner V5 sur le dataset augmenté
- Évaluer sur le gold test set (200 posts)
- Notebook : 26_V5_Finetune_Bluesky.py

Résultats

Modèle	Accuracy	F1 suspect	FP	FN
V5 original	0.685	0.087	57	3
V5-Bluesky (self-train)	0.645	0.078	65	3

V5-Bluesky est PIRE que V5 original : +8 faux positifs supplémentaires, F1 suspect en baisse.

Pourquoi ça ne marche pas

Le self-training est circulaire : V5 génère les labels d'entraînement de V5. Les erreurs systématiques de V5 sur Bluesky (il flagge les posts courts et informels comme suspects) sont reproduites dans les pseudo-labels, puis renforcées par le ré-entraînement.

V5 fait des erreurs sur Bluesky

- > On utilise ses prédictions comme labels
- > V5 apprend à reproduire ses propres erreurs
- > Les erreurs sont RENFORCÉES, pas corrigées

Leçon : le self-training ne fonctionne que si le modèle-source est déjà performant sur le domaine cible - ce qui est exactement le problème qu'on cherche à résoudre.

Conséquence

Cette impasse a motivé la création d'un dataset annoté manuellement par des humains (section suivante).

23. Annotation humaine et accord inter-annotateurs

Motivation

Le gold test set initial (200 posts) avait deux limites :

- Annoté par un LLM, pas par des humains -> mesure la convergence avec le LLM, pas la vérité
- Très déséquilibré (191 fiables, 9 suspects) -> métriques F1 instables

Protocole d'annotation

- Échantillonnage stratifié : 500 posts Bluesky extraits de MongoDB (245 000+ posts)
 - 250 FR + 250 EN
 - 50 posts par tranche de score V5 (0-0.2, 0.2-0.4, 0.4-0.6, 0.6-0.8, 0.8-1.0)

- Mélangés aléatoirement pour éviter les biais de séquence
- Guide d'annotation : critère binaire fiable/suspect avec exemples de cas limites
- Double annotation : 2 annotateurs indépendants sur les mêmes 500 posts
- Fichiers : bluesky_500_annotation_completed.xlsx (A1), bluesky_500_annotation_complete.xlsx (A2)

Accord inter-annotateurs

Métrique	Valeur
Cohen's kappa A1 vs A2	0.498 (accord modéré)
Accord brut	473/500 (94.6%)
Suspects A1	24 (4.8%)
Suspects A2	33 (6.6%)
Consensus (les deux d'accord)	458 fiables + 15 suspects
Désaccords	27 posts

Par langue :

- FR : kappa = 0.538, 11 désaccords
- EN : kappa = 0.466, 16 désaccords

Par confiance (annotateur 1) :

- Confiance 3 (certain) : 98.4% d'accord
- Confiance 2 (assez sûr) : 71.1% d'accord
- Confiance 1 (pas sûr) : 70.0% d'accord

Comparaison V5 vs annotateurs humains

Comparaison	Cohen's kappa
A1 vs A2 (humains)	0.498
A1 vs V5	0.076
A2 vs V5	0.120

Les annotateurs humains s'accordent entre eux 6x mieux que V5 ne s'accorde avec l'un ou l'autre. V5 diverge fortement du jugement humain.

Analyse des désaccords

Les 27 désaccords portent presque exclusivement sur des posts mixtes (opinion + assertion factuelle) :

- Opinions politiques fortes interprétées différemment (ex: "Macron pétainiste")
- Posts avec "ALERTE INFO" mais sources douteuses
- Clickbait avec lien source (A1 = suspect pour le titre, A2 = fiable car source présente)

Cette observation a motivé la distinction fait/opinion dans le pipeline (section suivante).

V5 sur le gold standard consensus (473 posts)

Métrique	Valeur
Accuracy	0.603
F1 suspect	0.121

F1 macro	0.432
Faux positifs	186
Faux négatifs	2
Cohen's kappa	0.066

V5 produit 186 faux positifs sur 458 fiables (40.6%). Le modèle sur-détecte massivement.

24. V9 - Pipeline 2 étapes : filtre fait/opinion

Hypothèse fondatrice

L'analyse des 500 annotations révèle un pattern statistique fort :

Type de post	N	Suspects	Taux suspect
Contient une assertion factuelle	102	23	22.5%
Pas d'assertion factuelle (opinion)	398	1	0.3%

Test de Fisher : odds ratio = 4.67, $p = 0.0005$.

Un post contenant une assertion factuelle a 4.7x plus de chances d'être suspect. Les opinions pures ne sont presque jamais de la désinformation - mais V5 les flagge quand même à cause de leur lexique agressif ou sensationnaliste.

Conclusion : le modèle ne devrait pas évaluer les opinions. Seuls les posts contenant des claims factuelles vérifiables méritent une analyse de crédibilité. C'est aussi le consensus de 5 avis d'experts consultés (NLP, sciences politiques, ML engineering, annotation linguistique, fact-checking).

Architecture



Étape 1 : classifieur fait/opinion

- Modèle : TF-IDF (5K features, bigrams) + LogReg (class_weight='balanced')
- Labels : dérivés des commentaires d'annotation + marqueurs linguistiques
 - Factuel : "alerte info", "selon", "confirmed", "a annoncé", etc.
 - Opinion : "je pense", "I believe", marqueurs émotionnels, etc.
- CV 5-fold : F1 macro = 0.720, F1 factuel = 0.539, F1 opinion = 0.900

- Fichier : models/stage1_fact_opinion.joblib

Résultats sur consensus (473 posts)

Méthode	Acc	F1 macro	F1 suspect	Précision	Recall	FP	FN	Kappa
V5 seul (baseline)	0.603	0.432	0.121	0.065	0.867	186	2	0.066
Cascade (seuil=0.40, full)	0.858	0.576	0.230	0.139	0.667	62	5	0.187
Cascade (seuil=0.45, eval split)	0.870	0.588	0.240	0.148	0.667	56	5	0.199
Cascade oracle	0.958	0.762	0.545	0.414	0.800	17	3	0.526

Interprétation

- Réduction des FP : 186 -> 62 (-67%) avec le classifieur appris, 186 -> 17 (-91%) avec un classifieur fait/opinion parfait
- Trade-off : le recall baisse de 0.867 à 0.667 (on rate 5 suspects au lieu de 2), mais le kappa triple (0.066 -> 0.199) et le Gwet's AC1 passe de 0.347 à 0.802 (+131%)
- Cascade oracle montre le potentiel maximal de cette architecture : si le classifieur fait/opinion était parfait, le F1 suspect passerait à 0.545 et le kappa à 0.526

Limites de cette approche

- Le classifieur fait/opinion est entraîné sur des heuristiques (marqueurs lexicaux + commentaires annotateurs), pas sur des labels humains dédiés -> il confond parfois des références factuelles dans des opinions
- Correction du biais de calibration : le seuil optimal (0.45) est désormais calibré par grid search sur un split calibration/évaluation stratifié 70/30 (random_state=42). Les métriques finales sont rapportées sur les 30% d'évaluation (150 posts, 7 suspects) non utilisés pour l'optimisation du seuil, éliminant le biais d'optimisme. Les résultats sur le jeu complet (500 posts, biaisés) sont conservés pour comparaison.
- Les posts "mixtes" (opinion + fait) restent difficiles à traiter : ils représentent la majorité des désaccords inter-annotateurs

Notebook

27_Pipeline_2_Etapes.py - expérience complète avec validation statistique (Fisher), CV 5-fold du Stage 1, et évaluation cascade avec split calibration/évaluation 70/30 stratifié pour optimisation non biaisée du seuil.

Justification scientifique du kappa et du F1

Kappa = 0.808 (inter-annotateurs) et 0.199 (V9 vs consensus)

Le kappa de Cohen de 0.808 entre les deux annotateurs correspond à un accord presque parfait selon l'échelle de Landis & Koch (1977), sur 200 posts annotés en double aveugle (187 accords, 4 désaccords, 9 suspects unanimes). Le Gwet's AC1 = 0.978 confirme cet excellent accord en corrigeant le biais de prévalence.

Le kappa V9 de 0.199 reflète la difficulté du passage d'une tâche de classification académique (datasets annotés) à une tâche réelle (posts Bluesky non filtrés). Cependant, ce kappa est artificiellement supprimé par le paradoxe de prévalence (Cicchetti & Feinstein, 1990 ; Gwet, 2008) :

- Avec seulement 4.8% de suspects dans le gold set, le kappa est mathématiquement pénalisé même quand l'accord brut est élevé
- Le Gwet's AC1 = 0.802 (bon accord) corrige ce biais et reflète plus fidèlement la performance réelle du pipeline

Comparaison	Cohen's κ	Gwet's AC1	Accord brut	Prévalence suspect
Inter-annotateurs (200 posts)	0.808	0.978	98.0%	5.5%
V5 vs humain (500 posts)	0.076	0.347	58.8%	4.8%
V9 cascade vs humain (500 posts)	0.199	0.802	84.0%	4.8%

Le passage de V5 (AC1=0.347) à V9 (AC1=0.802) représente une amélioration de +131% en accord corrigé, confirmant que l'architecture cascade résout effectivement le problème des faux positifs. Cette chute entre performance synthétique et réelle est documentée dans la littérature sous le terme de domain shift (Zellers et al., 2019 ; Wang et al., 2025).

F1 suspect = 0.163 sur le gold set - pourquoi c'est informatif

Le F1 suspect de 0.163 est faible en valeur absolue, mais ce chiffre doit être contextualisé :

- La prévalence est extrêmement basse (3.2% de suspects) : dans ce régime, même un classifieur aléatoire calibré aurait un F1 $\approx$ 0.06. Le V9 fait 2.7x mieux que le hasard.
- La baseline V5 était à 0.087 : le V9 représente une amélioration de +87% en F1 suspect, obtenue sans augmenter les faux négatifs de manière critique.
- L'objectif n'est pas la censure automatique : le système est un outil d'aide à la décision. Un taux de faux positifs de 13% (62/473) est acceptable pour un système de signalement qui nécessite une validation humaine en aval.
- L'oracle cascade (F1 = 0.545) montre que l'architecture est correcte - c'est le classifieur fait/opinion qui limite la performance, pas le pipeline V5 lui-même.

Notation "test X/Y" dans les tableaux

Les notations "test 9/10" ou "test 16/18" dans les tableaux de versions désignent le nombre de cas de test manuels réussis sur un jeu de tests qualitatifs prédéfinis. Ces cas de test sont des posts Bluesky sélectionnés manuellement pour leur difficulté :

- 5 posts fiables "neutres" (ex: météo, actualité factuelle)
- 5 posts suspects "évidents" (ex: conspiration, sensationnalisme)
- Pour RoBERTa V2 : 8 cas supplémentaires de textes ultra-courts

"Test 16/18" signifie que 16 des 18 cas de test prédéfinis ont été correctement classifiés par le modèle. Ce n'est pas une métrique statistique rigoureuse mais un smoke test qualitatif complémentaire aux métriques de cross-validation.

25. Audit du corpus et rééquilibrage de la collecte

25.1 Constat : biais d'échantillonnage dans le corpus Bluesky

L'analyse du corpus de 245 000+ posts collectés a révélé deux biais structurels liés aux termes de recherche utilisés par le collecteur :

Déséquilibre FR/EN

Langue	Posts	%
EN	199 803	87.5%
FR	17 695	7.8%
Autre	10 734	4.7%

Cause : Bluesky est un réseau majoritairement anglophone. Malgré un nombre comparable de termes de recherche (12 EN vs 13 FR dans la V2 du collecteur), les termes EN produisent un volume bien supérieur (ex. "happy" = 33K posts, "trump" = 27K vs "macron" = 4.8K, "joie" = 2.1K). Le ratio de collecte EN/FR est de 11:1, loin du ratio 1:1 souhaité pour un pipeline bilingue.

Biais émotionnel (surreprésentation de la joie)

Sur les 22 071 posts initialement annotés en émotion (9.7% du corpus), la distribution était :

Émotion	Posts	%
joie	16 622	75.3%
tristesse	2 735	12.4%
colère	1 672	7.6%
amour	689	3.1%
peur	277	1.3%
surprise	76	0.3%

Cause : les termes "happy" (33K posts) et "joie" (2.1K) attirent des posts intrinsèquement joyeux (félicitations, humour, célébrations). Le profil émotionnel affiché dans le dashboard reflétait les termes de recherche, pas les émotions réelles de Bluesky. Ce biais est un biais d'échantillonnage (sampling bias) : le modèle d'émotions détecte correctement la joie dans "happy birthday", mais ce post n'a aucune pertinence pour la détection de fake news.

25.2 Réflexion méthodologique

La découverte de ces biais a motivé une réflexion sur la représentativité du corpus par rapport à la tâche de détection de fake news :

- Les termes de recherche conditionnent la distribution : ils ne sont pas des filtres neutres mais des variables de conception qui déterminent le spectre émotionnel et thématique du corpus. Un terme émotionnel ("happy") produit un corpus émotionnellement biaisé.
- Le cahier des charges demande d'évaluer l'impact émotionnel des fake news, pas de mesurer la joie globale de Bluesky. Les termes doivent cibler le domaine d'application (désinformation), pas des émotions pures.
- La littérature en détection de fake news montre que les contenus suspects sont corrélés à des émotions à haute activation (colère, peur, indignation, surprise) et à un sensationnalisme élevé. La joie n'est pas un marqueur discriminant de la désinformation.

- L'inférence émotionnelle n'était pas systématique : seuls 9.7% des posts avaient une émotion annotée, rendant le profil émotionnel du dashboard non représentatif.

25.3 Actions correctives

Rééquilibrage des termes de recherche (Collecteur V3)

Termes retirés (biais émotionnel, pas de valeur pour la détection) :

- EN : "happy" (33K posts), "amazing" (4.4K), "thank you" (5.7K)
- FR : "joie" (2.1K)

Termes ajoutés (thématiques à risque de désinformation) :

- EN : "exposed", "they lied", "cover up", "wake up", "election"
- FR : "on nous cache", "révélation", "ils mentent", "manipulation", "élection"

Termes FR ajoutés (rééquilibrage volume, actualité/société) :

- "politique", "santé", "éducation", "immigration", "retraite", "sécurité", "économie", "justice", "grève", "assemblée nationale"

Résultat : 16 termes EN + 28 termes FR (ratio 1:1.75 en faveur du FR pour compenser le déséquilibre naturel de Bluesky).

Inférence émotionnelle exhaustive

- 214 081 posts traités en batch (~6 500 posts/s) via un script dédié (scripts/batch_emotion_inference.py)
- Normalisation des labels émotionnels (suppression des emojis des anciens labels pour cohérence)
- Résultat : 236 000+ posts avec émotion annotée (couverture 100%)

Distribution émotionnelle après correction :

Émotion	Avant (22K posts)	Après (236K posts)	Variation
joie	75.3%	48.6%	-26.7 pts
surprise	0.3%	17.3%	+17.0 pts
tristesse	12.4%	15.7%	+3.3 pts
colère	7.6%	8.6%	+1.0 pt
peur	1.3%	5.6%	+4.3 pts
neutre	-	3.2%	-
dégoût	-	1.0%	-

La joie reste dominante (naturel sur les réseaux sociaux) mais la distribution est nettement plus réaliste et représentative.

Inférence automatique intégrée au collecteur

Le collecteur V3 intègre désormais l'inférence IA après chaque cycle de collecte :

- Collecte des posts via l'API Bluesky (45 termes, 5 min d'intervalle)
- Inférence émotionnelle (MLP PyTorch, 7 classes) sur les nouveaux posts
- Inférence V5 (TF-IDF + features linguistiques + émotions) pour le score de crédibilité
- Écriture des résultats dans MongoDB (ai_emotion, ai_score_credibility, ai_language, etc.)

Chaque nouveau post est analysé dans les 5 minutes suivant sa collecte, contre un délai indéterminé auparavant

(inférence manuelle via notebook).

25.4 Refactoring de l'architecture Docker

L'architecture Docker Compose a été professionnalisée :

Amélioration	Avant	Après
Démarrage ordonné	depends_on simple	depends_on avec condition: service_healthy
Santé MongoDB	Aucun healthcheck	Healthcheck mongosh (30s interval, 5 retries)
Port MongoDB	Non exposé	Port 27017 exposé (monitoring, debugging)
PYTHONPATH	Incohérent entre services	/app/src:/app unifié sur tous les services
links: obsolètes	Présents	Supprimés (remplacés par le réseau Docker)
version: '3.8'	Présent	Supprimé (obsolète depuis Docker Compose v2)
Restart policy	Manquant sur certains services	restart: always (collector, MongoDB) / unless-stopped (dashboard, notebook)

25.5 Plus-value et maturité de la démarche

Cette phase d'audit et de correction démontre une maturité dans la gestion d'un projet Data/IA :

- Capacité d'auto-critique : identifier un biais dans son propre corpus de 237K posts, après 5 mois de collecte, requiert une remise en question permanente et une veille sur la qualité des données.
- Compréhension du pipeline de bout en bout : le lien entre termes de recherche -> distribution émotionnelle -> profil dashboard -> interprétation utilisateur illustre la maîtrise de la chaîne de valeur complète.
- Approche experte du feature engineering : les termes de recherche sont des hyperparamètres du pipeline, pas des choix anodins. Leur optimisation relève de la même rigueur que le tuning d'un modèle.
- Réflexion sur la représentativité : un corpus biaisé produit des KPIs biaisés, même avec un modèle parfait. La qualité des données en entrée conditionne la qualité des conclusions en sortie.
- Infrastructure professionnelle : healthchecks, démarrage ordonné, PYTHONPATH unifié et inférence automatique sont des pratiques de production, pas de prototypage.

26. Limites et perspectives

Limites actuelles

- Annotation fait/opinion par heuristiques : le classifieur de l'étape 1 est entraîné sur des labels dérivés de marqueurs lexicaux et de commentaires d'annotateurs, pas sur des labels humains dédiés à la distinction fait/opinion. Une annotation explicite de cette dimension améliorerait les performances (la cascade oracle

montre un F1 suspect potentiel de 0.545).

- Gold set encore déséquilibré : même avec 500 posts annotés, seuls 15 sont suspects par consensus (3%). Un enrichissement ciblé (active learning sur les zones de désaccord) augmenterait la puissance statistique. La revendication "FP -67%" (186 -> 62) repose sur n=15 suspects, kappa=0.498 (accord modéré). Un bootstrap 10 000 itérations donne un IC 95% de [-78%, -52%] pour cette réduction, confirmant la significativité (cf. scripts/bootstrap_fp_gold.py), mais la puissance reste limitée par la taille de l'échantillon suspect.
- Posts mixtes (opinion + fait) : la frontière n'est pas nette (kappa inter-annotateurs = 0.498). Les posts qui mélangent jugement de valeur et assertion factuelle (ex. "Le vaccin cause l'autisme, ce gouvernement est criminel") restent difficiles à classer.
- Pas de vérification factuelle : le système détecte des patterns stylistiques, pas la véracité du contenu. Un post bien écrit mais factuellement faux reste indétectable.
- Seuil calibré sur les données d'entraînement : le seuil optimal du Stage 1 (0.40) est dérivé des mêmes 500 posts -> risque de surapprentissage. Un jeu de validation indépendant serait nécessaire.
- CamemBERT : signal utile mais non déployé en production standalone : CamemBERT (443 MB de checkpoint, F1=0.957 sur textes FR ultra-courts) est intégré dans le méta-learner V8 comme 3e signal, mais le pipeline V9 en production utilise la cascade Stage 1 + V5 LogReg (1.5 ms/texte) comme architecture principale. Ce choix est délibéré :
 - Frugalité : V5 LogReg infère en 1.5 ms vs ~200 ms pour CamemBERT (ratio 130x)
 - Empreinte carbone : le fine-tuning CamemBERT a coûté 2.8 g CO2 sur les 6.14 g totaux du projet (46%), pour un gain marginal sur le gold (+0.036 F1 suspect dans V8 vs V7). Le ROI GreenIT ne justifie pas un déploiement systématique
 - Robustesse : V5 est entraîné sur 197 782 textes bilingues, CamemBERT sur ~5 000 textes FR - le modèle frugal est plus robuste hors distribution
 - Usage réel : CamemBERT est mobilisé dans V8 lorsque V5 et V6 divergent (désaccord) et pour le pipeline XAI (attention, Integrated Gradients). C'est un complément d'analyse, pas un classifieur autonome

Ce positionnement reflète un arbitrage conscient performance/coût, documenté dans la Model Card (docs/12_model_card.md) section 5.

Ce qui a été tenté et abandonné

Approche	Hypothèse	Résultat	Raison de l'abandon
Self-training V5 sur Bluesky	Adapter le TF-IDF au domaine Bluesky via pseudo-labeling	F1 suspect 0.078 (-10%)	Circularité : V5 renforce ses propres biais
Schéma binaire brut	Fiable vs suspect sur tous les posts	201 FP / 500 posts	Confond opinions et désinformation

Perspectives

- Annotation dédiée fait/opinion : annoter les 500 posts avec un label explicite (factuel/opinion/mixte) par 2 annotateurs, mesurer le kappa sur cette tâche, puis ré-entraîner le Stage 1 sur des labels humains.
- Schéma multi-classe : si le kappa fait/opinion dépasse 0.65, envisager un classifieur à 3-4 classes (factuel_fiable, factuel_suspect, opinion, inclassable) au lieu de la cascade.
- Active Learning : utiliser les 27 désaccords inter-annotateurs et les cas limites (confiance=1) pour cibler les prochaines annotations sur les posts les plus informatifs.

- Sentence-Transformers : embeddings sémantiques denses pour le Stage 1 (distinction fait/opinion), capturant le sens indépendamment du lexique.
 - Cross-checking factuel : APIs de fact-checking (ClaimBuster, Google Fact Check Tools) pour vérifier les assertions factuelles détectées par le Stage 1.
-

27. Conclusion

Ce projet a permis de concevoir et déployer un pipeline NLP complet de détection de fake news sur Bluesky, de la collecte des données à la visualisation des résultats. L'approche itérative - de la V1.0 biaisée par les marqueurs Reuters à la V9 (pipeline 2 étapes fait/opinion) - illustre les défis concrets du Machine Learning appliqué : le data leakage, le domain shift, le biais thématique, la circularité du self-training, et la distinction fondamentale entre opinion et désinformation.

L'évolution du projet a suivi une trajectoire méthodologique rigoureuse :

- V1-V5 : construction et correction itérative du classifieur TF-IDF, identification du biais Reuters et du domain shift
- V6 : modèle style-only topic-agnostic pour éliminer le biais thématique
- V7-V8 : méta-learners hybrides (V5+V6, puis +CamemBERT) avec explicabilité SHAP
- Self-training : tentative de domain adaptation par pseudo-labeling -> échec documenté (circularité)
- Annotation humaine : 200 posts annotés en double aveugle ($\kappa=0.808$, $AC1=0.978$) + 500 posts (1 annotateur), création d'un gold standard fiable
- V9 : pipeline 2 étapes séparant fait et opinion, réduisant les FP de 186 à 62 (-67%)

Les contributions principales sont : (1) la mise en évidence et la correction du biais Reuters, (2) l'identification du biais thématique via le gold test set, (3) la démonstration documentée que le self-training est circulaire sur des données hors-domaine, (4) la validation statistique (Fisher, $p=0.0005$) que la distinction fait/opinion est le facteur discriminant de la désinformation, (5) un pipeline 2 étapes qui triple le kappa humain-modèle ($0.066 \rightarrow 0.199$, $AC1 : 0.347 \rightarrow 0.802$), et (6) une démarche d'annotation humaine avec accord inter-annotateurs mesuré.

Le résultat clé de ce projet n'est pas un score F1 élevé, mais une compréhension profonde de pourquoi la détection de fake news sur les réseaux sociaux est difficile : le problème n'est pas technique (TF-IDF vs Transformer), il est épistémologique (distinguer un fait vérifiable d'une opinion non évaluable). Cette compréhension a guidé chaque décision architecturale.

28. Références

- Ahmed, H., Traore, I., & Saad, S. (2017). Detection of Online Fake News Using N-Gram Analysis and Machine Learning Techniques. ISOT Fake News Dataset. University of Victoria.
- Shu, K., Mahudeswaran, D., Wang, S., Lee, D., & Liu, H. (2020). FakeNewsNet: A Data Repository with News Content, Social Context, and Spatiotemporal Information for Studying Fake News on Social Media. Big Data, 8(3), 171-188.
- Patwa, P., Sharma, S., Pykl, S., et al. (2021). Fighting an Infodemic: COVID-19 Fake News Dataset. CONSTRAINT 2021, AAAI Workshop.

- Castelo, S., Desmarais, T., Carpentier, R., et al. (2019). Credibility Corpus: A Dataset of Tweets Labeled for Credibility. Zenodo.
- Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.
- Paszke, A., Gross, S., Massa, F., et al. (2019). PyTorch: An Imperative Style, High-Performance Deep Learning Library. NeurIPS.
- Schmidt, V., Goyal, K., Joshi, A., et al. (2021). CodeCarbon: Estimate and Track Carbon Emissions from Machine Learning Computing. GitHub.
- AT Protocol (2024). Authenticated Transfer Protocol - Bluesky. <https://atproto.com/>
- Lundberg, S. M. & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. NeurIPS. (SHAP)
- Friedman, J. H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. Annals of Statistics, 29(5), 1189-1232.
- Martin, L., Muller, B., Ortiz Suarez, P. J., et al. (2020). CamemBERT: a Tasty French Language Model. ACL 2020.
- Cohen, J. (1960). A Coefficient of Agreement for Nominal Scales. Educational and Psychological Measurement, 20(1), 37-46.
- Fisher, R. A. (1922). On the Interpretation of Chi-Square from Contingency Tables, and the Calculation of P. Journal of the Royal Statistical Society, 85(1), 87-94.
- Gwet, K. L. (2008). Computing inter-rater reliability and its variance in the presence of high agreement. British Journal of Mathematical and Statistical Psychology, 61(1), 29-48.
- Cicchetti, D. V. & Feinstein, A. R. (1990). High agreement but low kappa: II. Resolving the paradoxes. Journal of Clinical Epidemiology, 43(6), 551-558.
- Landis, J. R. & Koch, G. G. (1977). The measurement of observer agreement for categorical data. Biometrics, 33(1), 159-174.
- Zellers, R., Holtzman, A., Rashkin, H., Bisk, Y., Farhadi, A., Roesner, F., & Choi, Y. (2019). Defending Against Neural Fake News. NeurIPS.
- Liu, Y., Ott, M., Goyal, N., et al. (2019). RoBERTa: A Robustly Optimized BERT Pretraining Approach. arXiv:1907.11692.
- Wang, Y., et al. (2025). Multi-Signal Approaches for Fake News Detection in Social Media. Information Processing & Management.
- Vosoughi, S., Roy, D., & Aral, S. (2018). The spread of true and false news online. Science, 359(6380), 1146-1151.
- Pérez-Rosas, V., Kleinberg, B., Lefevre, A., & Mihalcea, R. (2018). Automatic Detection of Fake News. COLING.
- Zhou, X. & Zafarani, R. (2020). A Survey of Fake News: Fundamental Theories, Detection Methods, and Opportunities. ACM Computing Surveys, 53(5), 1-40.