
THUMALIEN

Pipeline NLP de detection de fake news sur Bluesky

Rendu Individuel Azelie Bernard

Formation : Mastere Big Data & IA - Sup de Vinci

Equipe : Azelie Bernard, Sebastien Lazcanotegui

Annee : 2025-2026

Version : Mai 2026

Rendu Individuel - Azélie Bernard

Projet Thumalien - Master Big Data, Sup de Vinci

Étudiant : Azélie Bernard

Rôle principal : Lead technique (Data Engineer, ML Engineer, DevOps, Dashboard Dev)

Date : Avril 2026

1. Mon rôle dans le projet

J'ai assuré le rôle de lead technique sur le projet Thumalien, couvrant l'ensemble de la chaîne de valeur : de la collecte des données sur Bluesky jusqu'au déploiement du dashboard de visualisation, en passant par le développement des modèles de détection de fake news.

Responsabilités principales

- Architecture technique et infrastructure Docker
 - Développement du collecteur Bluesky (AT Protocol)
 - Pipeline NLP complet (V1.0 à V9)
 - Fine-tuning des modèles Transformer (CamemBERT, RoBERTa)
 - Explicabilité SHAP
 - Gold Test Set annotation
 - Dashboard Streamlit interactif
 - Documentation technique
 - Conformité RGPD et AI Act
-

2. Contributions techniques détaillées

2.1 Infrastructure et collecte (Déc 2025)

- Mise en place de l'architecture Docker Compose (MongoDB, Jupyter, Streamlit, Collecteur)
- Développement du collecteur Bluesky avec gestion des erreurs et déduplication
- Configuration MongoDB avec index unique et volumes persistants
- Rééquilibrage FR/EN de la collecte (V3 collecteur : 28 termes FR + 16 termes EN, suppression des biais émotionnels)
- Inférence automatique intégrée au collecteur (émotions + V5 à chaque cycle)
- Résultat : 245 000+ posts collectés depuis décembre 2025 (collecte continue), 100% annotés émotionnellement

2.2 Pipeline NLP (Jan - Avril 2026)

- Baseline V1.0 : TF-IDF + LogisticRegression (F1=0.99, identifié le biais Reuters)
- Audit qualité : découverte du data leakage Reuters (99.2% identifiable par style)
- V1.5 : pipeline bilingue + 12 features linguistiques + modèle émotions
- V2.0 : intégration 3 datasets sociaux, seuil calibré 0.44
- V3.0 : correction du bug preprocessing (5/12 features nulles)
- V4.0 : augmentation FR court (+32% F1)
- V5.0 : +10K posts synthétiques, F1 global = 0.913
- V6.0 : modèle style-only topic-agnostic (28 features stylistiques + 7 émotions, GradientBoosting, CV F1=0.830)
- V7.0 : ensemble hybride meta-learner V5+V6 avec explicabilité SHAP, FP réduits de 57 à 25 sur gold set
- V8.0 : intégration CamemBERT comme 3e signal sémantique, F1 suspect +28%
- Self-training Bluesky : tentative de domain adaptation par pseudo-labeling, échec documenté (circularité)
- Annotation humaine : 500 posts annotés par 2 annotateurs, kappa inter-annotateurs = 0.498
- V9.0 : pipeline 2 étapes fait/opinion, réduction FP de 186 à 62 (-67%), validation statistique (Fisher p=0.0005)
- 40+ commits sur le dépôt Git

2.3 Modèles Transformer (Avril 2026)

- Fine-tuning CamemBERT V1/V2 pour le français (F1 ultra-court = 0.957)
- Fine-tuning RoBERTa EN V1/V2 pour l'anglais (F1 ultra-court = 0.874)
- Pipeline hybride stacking V5 + CamemBERT V2

2.4 Dashboard Streamlit (Mars - Mai 2026)

- Design glassmorphism dark theme, interface intégralement en français
- 5 pages : Dashboard (vue globale), Analyse IA (prédiction live V9), Explorateur (posts MongoDB), Performance (métriques temps réel), À propos
- Radar charts, distribution des scores, analyse SHAP intégrée, connexion MongoDB temps réel
- V4 : intégration pipeline V9 cascade fait/opinion + SHAP
- V5 : refactoring complet Plotly, accents français, page Performance avec benchmarks

2.5 Modèle d'émotions (Jan 2026)

- MLP PyTorch bilingue, 7 classes d'émotions
- Early stopping + class weights pour gérer le déséquilibre
- Intégration comme features dans le pipeline NLP

2.6 Gold Test Set et annotation humaine (Avril-Mai 2026)

- Création et annotation manuelle de 200 posts Bluesky (gold set V1, kappa = 0.808)
- Annotation de 500 posts Bluesky par 2 annotateurs indépendants (gold set V2, kappa = 0.498)
- Échantillonnage stratifié : 250 FR + 250 EN, 50 par tranche de score
- Évaluation systématique de tous les modèles V5-V9

- Identification du biais thématique (mot "coronavirus" coefficient +9.72)
- Découverte de la distinction fait/opinion comme facteur discriminant (odds ratio 4.67, $p=0.0005$)

2.7 Modèle Style-Only V6 (Avril 2026)

- Conception de 28 features stylistiques en 6 blocs (structure, ponctuation, majuscules, lexique manipulation, crédibilité, diversité)
- GradientBoosting topic-agnostic
- Gold F1 suspect = 0.103 (+18% vs V5)

2.8 Ensemble Hybride V7 + SHAP (Avril 2026)

- Meta-learner LogReg combinant scores V5 et V6
- Intégration de SHAP TreeExplainer pour l'explicabilité
- V7 Combo accuracy = 0.840 (vs 0.685 V5), FP = 25 (vs 57 V5)
- Intégration complète dans le dashboard Streamlit

2.9 Tests et qualité (Mai 2026)

- Suite de 107 tests unitaires et d'intégration (pytest) couvrant 26% du code source
- Tests des modules critiques : collecteur (validation texte, détection langue), pipeline NLP (features linguistiques, features stylistiques V6, détecteur expert V5), CamemBERT (architecture réseau, dataset PyTorch), MongoDB (agrégations, requêtes), monitoring (scoring, rapports)
- Benchmark de latence automatisé : 1.5 ms/texte (728 textes/sec), 66x sous l'exigence CDC (100 ms)
- Tests d'intégration bilingues, edge cases (textes vides, emojis, textes longs, caractères spéciaux)

3. Compétences mobilisées et acquises

3.1 Compétences techniques

Compétence	Niveau avant	Niveau après	Contexte d'application
Python avancé	Intermédiaire	Avancé	Pipeline complet, 28 notebooks (00-27)
NLP / Text Mining	Débutant	Avancé	TF-IDF, features linguistiques, tokenization
Deep Learning (PyTorch)	Débutant	Intermédiaire	MLP émotions, fine-tuning Transformers
Transformers (Hugging Face)	Débutant	Intermédiaire	CamemBERT, RoBERTa, stacking
Docker / Docker Compose	Intermédiaire	Avancé	Architecture micro-services
MongoDB	Débutant	Intermédiaire	Schéma, index, agrégations
Streamlit	Débutant	Avancé	Dashboard interactif 5 pages, Plotly avancé

Git / GitHub	Intermédiaire	Avancé	Versioning, merge, collaboration
Explicabilité IA (SHAP / Captum / faithfulness)	Débutant	Avancé	SHAP TreeExplainer (beeswarm, dependence, bar global), Layer Integrated Gradients via Captum, attention visualization sur transformers, faithfulness
Feature Engineering avancé	Intermédiaire	Avancé	28 features stylistiques, meta-features, stacking
Ensemble Learning	Débutant	Intermédiaire	Meta-learner, stacking, GradientBoosting
Tests / CI	Débutant	Intermédiaire	pytest, mocking, benchmarking, coverage

3.2 Compétences transversales

Compétence	Mise en pratique
Gestion de projet	Planification itérative, priorisation des tâches, respect des délais
Résolution de problèmes	Debugging du biais Reuters, correction preprocessing V3, migration TF->PyTorch
Communication technique	Rédaction de 10+ documents, 28 notebooks commentés
Esprit critique	Analyse des erreurs, tests de significativité, identification des biais
Autonomie	Apprentissage de PyTorch, CamemBERT, AT Protocol en autodidacte

4. Défis rencontrés et solutions

Défi	Contexte	Solution	Apprentissage
Biais Reuters (F1=0.99 biaisé)	Le modèle détectait le style Reuters, pas les fake news	Débiaisage (BODY_AGENCY_TERMS), nettoyage des artefacts	L'évaluation est aussi importante que l'entraînement
TensorFlow incompatible M4	Apple Silicon non supporté par TF	Migration vers PyTorch	Toujours vérifier la compatibilité hardware
Features nulles (5/12)	Bug de preprocessing dans le pipeline V2	Debug, correction, retraining V3	Les tests unitaires sont essentiels
F1 FR court = 0.65	Les textes courts de type réseau social mal classifiés	Augmentation + vocabulaire enrichi + CamemBERT	Les modèles généralistes ne suffisent pas pour les textes courts
Merge Git avec conflits	Dépôt recréé par un collègue	--allow-unrelated-histories + résolution manuelle	Toujours communiquer avant de restructurer un dépôt

Biais thématique (V5 détecte le sujet, pas la désinformation)	Gold test set révélait 57 FP sur posts "coronavirus" fiables	V6 style-only + V7 meta-learner réduisant FP de 57 à 25	L'évaluation sur données réelles est indispensable
---	--	---	--

5. Analyse critique et recul

Ce qui a bien fonctionné

- L'approche itérative (V1 -> V9) a permis d'améliorer continuellement les performances
- La documentation au fil de l'eau (notebooks) facilite la traçabilité
- Le choix de Docker garantit la reproductibilité
- L'ajout de CamemBERT et RoBERTa a résolu le problème des textes courts
- Le gold test set a révélé des faiblesses invisibles en cross-validation
- L'approche V6 style-only a prouvé qu'on peut détecter des patterns de désinformation sans analyser le contenu
- SHAP apporte une transparence complète sur les raisons de chaque prédiction
- Le pipeline XAI complet (SHAP global, Layer Integrated Gradients via Captum, attention CamemBERT, décomposition exacte du méta-learner V8, faithfulness test AOPC) m'a permis de valider quantitativement la fidélité des explications : uplift AOPC = +0.21 vs baseline aléatoire ? explications 5.6× plus prédictives. C'est un niveau de rigueur méthodologique que je ne maîtrisais pas en début de projet

Ce que j'aurais fait différemment

- Tests unitaires dès le début : le bug des 5 features nulles (V2->V3) aurait été détecté immédiatement avec des tests de non-régression. La suite de tests (107 tests, 26% coverage) a été ajoutée tardivement mais reste un acquis méthodologique important.
- MLflow pour le tracking : les 28 notebooks documentent chaque expérience, mais un outil dédié (MLflow, W&B) aurait permis un suivi plus systématique des hyperparamètres et des métriques.
- Annotation humaine plus précoce : le gold test set a révélé un écart majeur entre la performance en cross-validation (F1=0.90) et la performance réelle sur Bluesky. Cette prise de conscience, arrivée tardivement, a motivé les itérations V6-V9.
- Répartition de la charge : en tant que lead technique, j'ai centralisé trop de responsabilités. Déléguer certains modules (dashboard, documentation) plus tôt aurait accéléré le projet.

Axes d'amélioration identifiés

- Fact-checking réel : le pipeline détecte des signaux stylistiques de désinformation, mais ne vérifie pas les faits. L'intégration d'une API de fact-checking (ClaimBuster, Google Fact Check) serait un gain majeur.
- Gold set plus équilibré : le consensus (473 posts, 15 suspects) est très déséquilibré. Un échantillonnage ciblé de posts suspects permettrait une évaluation plus robuste.
- Labels fait/opinion dédiés : la distinction fait/opinion (V9) repose sur des heuristiques lexicales. Des labels humains explicites amélioreraient la cascade (l'oracle montre un F1 suspect potentiel de 0.545).
- Monitoring production : le weekly score check (JSONL) est fonctionnel mais rudimentaire. Prometheus +

Grafana permettrait des alertes temps réel et des dashboards de drift monitoring.

- Tests end-to-end : les tests unitaires couvrent les composants isolés, mais un test d'intégration complet (collecte -> MongoDB -> inference -> dashboard) validerait la chaîne complète.

6. Bilan personnel

Ce projet représente 6 mois de travail intensif sur un problème complexe et ouvert : la détection de désinformation sur les réseaux sociaux. En tant que lead technique, j'ai mené un projet Data/IA de bout en bout - de la collecte de 245 000+ posts Bluesky au déploiement d'un dashboard interactif, en passant par 9 itérations du pipeline NLP.

Les apprentissages clés :

- L'évaluation est plus importante que l'entraînement : un $F1=0.99$ en cross-validation masquait un biais Reuters. Le gold test set a été un tournant dans ma compréhension de l'évaluation des modèles.
- L'itération constante est la seule voie : chaque version (V1->V9) a corrigé une faiblesse identifiée en production. Les "échecs" (self-training, seuil adaptatif) sont aussi riches d'enseignements que les succès.
- Les solutions simples dominent : TF-IDF + features linguistiques (V5, 1.5ms/texte) reste plus robuste en production qu'un Transformer seul. L'architecture hybride (V8/V9) combine le meilleur des deux approches.
- L'éthique n'est pas optionnelle : la conformité RGPD, l'AI Act, le bilan carbone (CodeCarbon) et l'explicabilité (SHAP, Captum, faithfulness validation) m'ont appris que la responsabilité d'un ingénieur IA dépasse la performance technique. La Model Card formelle (docs/12_model_card.md) avec sa section dédiée XAI documentant les méthodes, l'audience, les limites et les niveaux de Completeness Captum constitue, à mon sens, le livrable le plus mature du projet.

Ce projet m'a fait passer de débutante à un niveau intermédiaire-avancé en NLP/Deep Learning. La rigueur scientifique acquise (tests de significativité, kappa inter-annotateurs, validation sur données réelles) sera un atout déterminant pour ma carrière professionnelle en data science.

Rendu individuel - Azélie Bernard - Mai 2026