

Rendu Individuel - Azelie Bernard

Projet Thumalien - Master Big Data, Sup de Vinci

Etudiant : Azelie Bernard

Role principal : Lead technique (Data Engineer, ML Engineer, DevOps, Dashboard Dev)

Date : Avril 2026

1. Mon role dans le projet

J'ai assure le role de lead technique sur le projet Thumalien, couvrant l'ensemble de la chaine de valeur : de la collecte des donnees sur Bluesky jusqu'au deploiement du dashboard de visualisation, en passant par le developpement des modeles de detection de fake news.

Responsabilites principales

- Architecture technique et infrastructure Docker
 - Developpement du collecteur Bluesky (AT Protocol)
 - Pipeline NLP complet (V1.0 a V7)
 - Fine-tuning des modeles Transformer (CamemBERT, RoBERTa)
 - Explicabilite SHAP
 - Gold Test Set annotation
 - Dashboard Streamlit interactif
 - Documentation technique
 - Conformite RGPD et AI Act
-

2. Contributions techniques detaillees

2.1 Infrastructure et collecte (Dec 2025)

- Mise en place de l'architecture Docker Compose (MongoDB, Jupyter, Streamlit, Collecteur)
- Developpement du collecteur Bluesky avec gestion des erreurs et deduplication
- Configuration MongoDB avec index unique et volumes persistants
- Resultat : 188 553 posts collectes depuis decembre 2025

2.2 Pipeline NLP (Jan - Avril 2026)

- Baseline V1.0 : TF-IDF + LogisticRegression (F1=0.99, identifie le biais Reuters)
- Audit qualite : decouverte du data leakage Reuters (99.2% identifiable par style)

- V1.5 : pipeline bilingue + 12 features linguistiques + modele emotions
- V2.0 : integration 3 datasets sociaux, seuil calibre 0.44
- V3.0 : correction du bug preprocessing (5/12 features nulles)
- V4.0 : augmentation FR court (+32% F1)
- V5.0 : +10K posts synthétiques, F1 global = 0.913
- V6.0 : modele style-only topic-agnostic (28 features stylistiques + 7 emotions, GradientBoosting, CV F1=0.830)
- V7.0 : ensemble hybride meta-learner V5+V6 avec explicabilite SHAP, FP reduits de 57 a 25 sur gold set
- 30+ commits sur le depot Git

2.3 Modeles Transformer (Avril 2026)

- Fine-tuning CamemBERT V1/V2 pour le francais (F1 ultra-court = 0.957)
- Fine-tuning RoBERTa EN V1/V2 pour l'anglais (F1 ultra-court = 0.874)
- Pipeline hybride stacking V5 + CamemBERT V2

2.4 Dashboard Streamlit (Mars 2026)

- Design glassmorphism dark theme
- 3 pages : vue globale, prediction live, explicabilite
- Radar charts, metriques temps reel, connexion MongoDB

2.5 Modele d'emotions (Jan 2026)

- MLP PyTorch bilingue, 7 classes d'emotions
- Early stopping + class weights pour gerer le desequilibre
- Integration comme features dans le pipeline NLP

2.6 Gold Test Set (Avril 2026)

- Creation et annotation manuelle de 200 posts Bluesky
- Double annotation avec calcul du kappa de Cohen (0.808)
- Evaluation systematique de tous les modeles V5-V7
- Identification du biais thematique (mot "coronavirus" coefficient +9.72)

2.7 Modele Style-Only V6 (Avril 2026)

- Conception de 28 features stylistiques en 6 blocs (structure, ponctuation, majuscules, lexique manipulation, credibilite, diversite)
- GradientBoosting topic-agnostic
- Gold F1 suspect = 0.103 (+18% vs V5)

2.8 Ensemble Hybride V7 + SHAP (Avril 2026)

- Meta-learner LogReg combinant scores V5 et V6
- Integration de SHAP TreeExplainer pour l'explicabilite
- V7 Combo accuracy = 0.840 (vs 0.685 V5), FP = 25 (vs 57 V5)

- Integration complete dans le dashboard Streamlit

3. Competences mobilisees et acquises

3.1 Competences techniques

Competence	Niveau avant	Niveau apres	Contexte d'application
Python avance	Intermediaire	Avance	Pipeline complet, 22 notebooks
NLP / Text Mining	Debutant	Avance	TF-IDF, features linguistiques, tokenization
Deep Learning (PyTorch)	Debutant	Intermediaire	MLP emotions, fine-tuning Transformers
Transformers (Hugging Face)	Debutant	Intermediaire	CamemBERT, RoBERTa, stacking
Docker / Docker Compose	Intermediaire	Avance	Architecture micro-services
MongoDB	Debutant	Intermediaire	Schema, index, aggregations
Streamlit	Debutant	Intermediaire	Dashboard interactif 3 pages
Git / GitHub	Intermediaire	Avance	Versioning, merge, collaboration
Explicabilite IA (SHAP)	Debutant	Intermediaire	TreeExplainer, feature importance, integration dashboard
Feature Engineering avance	Intermediaire	Avance	28 features stylistiques, meta-features, stacking
Ensemble Learning	Debutant	Intermediaire	Meta-learner, stacking, GradientBoosting

3.2 Competences transversales

Competence	Mise en pratique
Gestion de projet	Planification iterative, priorisation des taches, respect des delais
Resolution de problemes	Debugging du biais Reuters, correction preprocessing V3, migration TF->PyTorch
Communication technique	Redaction de 10+ documents, 22 notebooks commentaires
Esprit critique	Analyse des erreurs, tests de significativite, identification des biais

Autonomie	Apprentissage de PyTorch, CamemBERT, AT Protocol en autodidacte
-----------	---

4. Defis rencontres et solutions

Defi	Contexte	Solution	Apprentissage
Biais Reuters (F1=0.99 biaise)	Le modele detectait le style Reuters, pas les fake news	Debiaisage (BODY_AGENCY_TERMS), nettoyage des artefacts	L'evaluation est aussi importante que l'entrainement
TensorFlow incompatible M4	Apple Silicon non supporte par TF	Migration vers PyTorch	Toujours verifier la compatibilite hardware
Features nulles (5/12)	Bug de preprocessing dans le pipeline V2	Debug, correction, retraining V3	Les tests unitaires sont essentiels
F1 FR court = 0.65	Les textes courts de type reseau social mal classifies	Augmentation + vocabulaire enrichi + CamemBERT	Les modeles generalistes ne suffisent pas pour les textes courts
Merge Git avec conflits	Depot recree par un collegue	--allow-unrelated-histories + resolution manuelle	Toujours communiquer avant de restructurer un depot
Biais thematique (V5 detecte le sujet, pas la desinformation)	Gold test set revelait 57 FP sur posts "coronavirus" fiables	V6 style-only + V7 meta-learner reduisant FP de 57 a 25	L'evaluation sur donnees reelles est indispensable

5. Analyse critique et recul

Ce qui a bien fonctionne

- L'approche iterative (V1 -> V5) a permis d'ameliorer continuellement les performances
- La documentation au fil de l'eau (notebooks) facilite la tracabilite
- Le choix de Docker garantit la reproductibilite
- L'ajout de CamemBERT et RoBERTa a resolu le probleme des textes courts
- Le gold test set a revele des faiblesses invisibles en cross-validation
- L'approche V6 style-only a prouve qu'on peut detecter des patterns de desinformation sans analyser le contenu
- SHAP apporte une transparence complete sur les raisons de chaque prediction

Ce que j'aurais fait differemment

- Commencer par des tests unitaires des le debut (le bug des features nulles aurait ete detecte plus tot)
- Utiliser MLflow pour le tracking des experiences au lieu de notebooks individuels
- Prevoir une strategie d'annotation manuelle plus tot dans le projet

- Mieux repartir la charge de travail dans l'equipe

Limites identifiees

- Le modele reste dependant des datasets d'entrainement (pas de fact-checking reel)
 - L'absence de donnees annotees specifiquement pour Bluesky est une faiblesse
 - Le monitoring en production est minimal (pas de Grafana/Prometheus)
-

6. Bilan personnel

Ce projet m'a permis de mener un projet Data/IA de bout en bout, de la collecte au deploiement. J'ai particulierement progresse en NLP et Deep Learning, domaines dans lesquels j'etais debutante en debut de projet. La complexite du probleme (detection de fake news dans un contexte bilingue, multi-longueur) m'a appris que les solutions simples sont souvent les meilleures (TF-IDF + features > modele complexe mal entraine), et que l'iteration constante est la cle de l'amelioration.

La dimension ethique (biais, conformite RGPD, AI Act) a ete particulierement formatrice et sera un atout pour ma carriere professionnelle.

Rendu individuel - Azelie Bernard - Avril 2026