

Rendu Individuel - Sebastien Lazcanotegui

Projet Thumalien - Master Big Data, Sup de Vinci

Etudiant : Sebastien Lazcanotegui

Role principal : Consolidation ML, optimisation hyperparametres, revue de code

Date : Avril 2026

1. Mon role dans le projet

J'ai contribue au projet Thumalien en tant que specialiste consolidation ML, avec un focus sur l'optimisation des hyperparametres, le debiaisage du pipeline et la revue critique des choix techniques. Mon apport principal a ete la consolidation du modele NLP pour en ameliorer la robustesse.

Responsabilites principales

- Optimisation des hyperparametres du pipeline (GridSearch)
- Implementation du debiaisage des datasets (Reuters, agences de presse)
- Revue et challenge des choix techniques
- Contribution a la video MVP

2. Contributions techniques detaillees

2.1 Optimisation des hyperparametres

J'ai mene une campagne de GridSearch systematique pour identifier les hyperparametres optimaux du pipeline NLP :

Parametre	Avant	Apres	Justification
C (regularisation)	1.0	5.0	Meilleur F1 sur la grille exploree
min_df (frequence minimale)	3	5	Reduction du bruit, meilleure generalisation
ngram_range	(1,3)	(1,2)	Les trigrammes n'apportaient pas de valeur significative

Cette optimisation a contribue a l'amelioration globale du pipeline de la V2 a la V3.

2.2 Debiaisage du pipeline

J'ai identifie et implemente des mesures de debiaisage dans le pipeline NLP :

- BODY_AGENCY_TERMS : liste de patterns regex pour neutraliser les signatures d'agences de presse (Reuters, Associated Press, AFP) qui permettaient au modele de "tricher"
- ARTIFACT_YEAR_PATTERN : suppression des annees (2015-2020) qui etaient correlees aux articles de presse mais pas a la veracite
- Integration dans la fonction `clean_for_ml()` du pipeline expert

2.3 Simplification du pipeline

J'ai propose la suppression de blocs de code qui ajoutaient de la complexite sans gain mesurable :

- Suppression du bloc d'augmentation FR court (redondant avec V5)
- Suppression du chargement de donnees sociales supplementaires
- Nettoyage des parametres inutilises dans `prepare_bilingual_dataset()`

2.4 Revue critique

Participation aux revues de modele pour valider les choix techniques :

- Validation de la pertinence du seuil 0.44
- Revue des metriques par segment (FR/EN, court/long)
- Challenge sur les risques de surapprentissage

3. Competences mobilisees et acquises

3.1 Competences techniques

Competence	Niveau avant	Niveau apres	Contexte d'application
Machine Learning (scikit-learn)	Intermediaire	Avance	GridSearch, regularisation, evaluation
NLP / Text Mining	Debutant	Intermediaire	TF-IDF, debiaisage, features linguistiques
Python	Intermediaire	Intermediaire	Modification du pipeline, scripting
Git / GitHub	Debutant	Intermediaire	Commits, merge, collaboration
Analyse de donnees	Intermediaire	Intermediaire	Identification des biais, analyse des distributions

3.2 Competences transversales

Competence	Mise en pratique
Esprit critique	Identification des biais Reuters, remise en question des metriques
Rigueur scientifique	Protocole de GridSearch, comparaison systematique

Communication	Presentation des resultats d'optimisation a l'equipe
Travail en equipe	Coordination avec la lead technique, revues de code

4. Defis rencontres et solutions

Defi	Contexte	Solution	Apprentissage
Comprendre le pipeline existant	Code complexe avec 22 notebooks	Lecture methodique, discussions avec Azelie	L'importance de la documentation
GridSearch couteux en temps	Espace de recherche large, 145K textes	Reduction de l'espace, parallelisation	Equilibrer exhaustivite et pragmatisme
Merge Git catastrophique	Depot recree par erreur, conflits massifs	Resolution avec --allow-unrelated-histories	Toujours travailler sur une branche dediee
Debiaisage sans casser les performances	Retirer les signaux biaises sans degrader le F1	Approche incrementale, tests de non-regression	Le debiaisage est un equilibre delicat

5. Analyse critique et recul

Ce qui a bien fonctionne

- La specialisation des roles (lead technique vs consolidation ML) a ete efficace
- Le GridSearch a confirme et ameliore les choix d'hyperparametres
- Le debiaisage a rendu le modele plus robuste et generaliste

Ce que j'aurais fait differemment

- M'impliquer plus tot dans le projet pour avoir un impact plus large
- Proposer des tests automatises pour le debiaisage
- Documenter mes experimentations dans des notebooks dedies
- Contribuer davantage au code du collecteur et du dashboard

Limites de ma contribution

- Nombre de commits limite (1 commit principal de consolidation)
- Implication tardive dans le cycle de developpement
- Contribution concentree sur l'optimisation plutot que le developpement

6. Bilan personnel

Ce projet m'a permis de comprendre la complexite d'un pipeline NLP complet, de la collecte au deploiement. Ma contribution sur l'optimisation des hyperparametres et le debiaisage m'a appris que les ameliorations les plus

impactantes ne sont pas toujours les plus visibles : retirer un biais ou ajuster un hyperparametre peut avoir plus d'impact qu'ajouter une nouvelle fonctionnalite.

J'ai egalement pris conscience de l'importance de la collaboration continue dans un projet technique, et de la necessite de s'impliquer des le debut pour maximiser son apport.

Rendu individuel - Sebastien Lazcanotegui - Avril 2026