

Roles et Competences Projet Thumalien

Cartographie des professionnels necessaires a l'excellence du projet

Projet : Thumalien - Social Media Intelligence & AI Monitor

Auteur : Azelie Bernard

Formation : Master Big Data

Date : Avril 2026

Preambule - Pourquoi cette reflexion ?

Un projet comme Thumalien ne se resume pas a du code. Il mobilise des competences qui traversent l'ingenierie des donnees, l'intelligence artificielle, l'infrastructure, la visualisation et la gouvernance. Chaque brique du systeme - de la collecte Bluesky en temps reel jusqu'a la prediction de credibilite affichee sur le dashboard - exige un savoir-faire specifique.

Ce document identifie les roles professionnels indispensables, non pas comme une liste theorique, mais comme une reflexion ancree dans la realite concrete du projet : ses choix techniques, ses difficultes rencontrees et ses ambitions futures. Chaque role est pousse au plus haut niveau de competence attendu dans l'industrie, car la detection de desinformation est un sujet ou l'approximation n'est pas acceptable.

L'objectif est double :

- Comprendre quelles expertises sont mobilisees et pourquoi elles sont chacune critiques
 - Projeter le projet vers un niveau d'excellence professionnel en identifiant les standards de chaque discipline
-


Table des matieres

- Vue d'ensemble de l'equipe
 - Data Engineer - Architecte du pipeline de donnees
 - Machine Learning Engineer / NLP Specialist
 - Data Scientist Senior - Methodologue et analyste
 - MLOps Engineer - Industrialisation des modeles
 - Developpeur Dashboard / Data Visualization Engineer
 - DevOps / Cloud Architect
 - Chef de Projet Data / Product Owner
 - Expert Green IT & IA Responsable
 - Matrice de responsabilites RACI
 - Reflexion - La synergie comme condition de l'excellence
-

1. Vue d'ensemble de l'equipe

Architecture du projet et mapping des competences

Le projet Thumalien repose sur 4 briques techniques, chacune necessitant des competences specifiques :



Equipe minimale viable vs equipe d'excellence

Configuration	Effectif	Compromis
Solo (etat actuel)	1 personne	Polyvalence maximale, profondeur limitee
Equipe minimale	4 personnes	Data Engineer + ML Engineer + DevOps + Chef de projet
Equipe optimale	6 personnes	Ajout Data Scientist dedie + Dashboard Dev
Equipe d'excellence	8 personnes	Tous les roles specialises, expertise maximale par domaine

Reflexion : le projet Thumalien a ete realise en configuration solo, ce qui temoigne d'une polyvalence remarquable. Cependant, pour atteindre un niveau de production industrielle - ou chaque composant est pousse a son maximum - la specialisation de chaque role devient indispensable. Un ingenieur ML qui doit aussi gerer l'infrastructure Docker perd du temps sur l'optimisation de ses modeles. Un Data Engineer qui doit aussi concevoir le dashboard ne peut pas pousser la resilience de son pipeline au maximum.

2. Data Engineer - Architecte du pipeline de donnees

Identite du role

Attribut	Detail
Intitule	Data Engineer Senior / Lead Data Engineer
Seniorite requise	5 a 8 ans d'experience
Rattachement	Direction Technique / CTO
Certification de reference	Google Professional Data Engineer, AWS Data Analytics, Databricks Certified

Pourquoi ce role est obligatoire pour Thumalien

Le coeur de Thumalien est un flux de donnees continu : des posts Bluesky sont collectes en temps reel via WebSocket, transformes, stockes dans MongoDB, puis consommes par les modeles IA et le dashboard. Sans un Data Engineer de haut niveau, ce pipeline est fragile : perte de donnees en cas de deconnexion, absence de deduplication, pas de monitoring de la qualite des donnees entrantes.

Actuellement, le collecteur (src/collection/collect_bluesky.py) fonctionne avec une boucle de recherche par mots-cles toutes les 5 minutes avec 3 tentatives et backoff exponentiel. C'est une base solide, mais un Data Engineer senior pousse cette architecture beaucoup plus loin.

Missions detaillees

Mission 1 - Conception et industrialisation du pipeline d'ingestion

Objectif : Transformer le collecteur actuel en un pipeline de production resilient, scalable et observable.

Taches :

- Remplacer la boucle de polling par une architecture event-driven basee sur le Firehose Bluesky (AT Protocol com.atproto.sync.subscribeRepos) pour une collecte veritablement temps reel
- Implementer un systeme de message queue (Apache Kafka ou Redis Streams) entre le collecteur et MongoDB pour decoupler ingestion et stockage
- Concevoir un schema de deduplication robuste base sur le uri des posts (index unique MongoDB + bloom filter en memoire pour les verifications rapides)
- Implementer un mecanisme de replay : si le pipeline tombe, il doit pouvoir reprendre exactement la ou il s'est arrete grace a un cursor persistant
- Gerer le backpressure : si MongoDB est lent, le collecteur doit ralentir sans perdre de messages

Indicateurs de performance :

- Zero perte de donnees mesurable sur 30 jours
- Latence ingestion < 5 secondes entre l'emission du post Bluesky et son stockage en base
- Taux de disponibilite du pipeline > 99.5%

Mission 2 - Architecture et optimisation de la base de donnees

Objectif : Faire de MongoDB un socle performant capable de servir simultanement l'ingestion temps reel, les requetes analytiques et le dashboard.

Taches :

- Concevoir le schema MongoDB optimal pour les posts : choisir entre un schema plat (actuel) et un schema avec des sous-documents pour les enrichissements (emotions, score de credibilite)
- Creer les index adaptes : index compose sur (created_at, search_term) pour les requetes temporelles, index texte pour la recherche full-text, index TTL pour l'archivage automatique
- Implementer une strategie de partitionnement temporel (collections mensuelles ou sharding sur created_at) pour maintenir les performances quand la base depasse le million de documents
- Mettre en place des aggregation pipelines optimises pour les KPI du dashboard (repartition emotions, evolution temporelle, top termes)

- Configurer les write concerns et read preferences pour equilibrer coherence et performance

Indicateurs de performance :

- Temps de reponse des requetes dashboard < 500ms pour 1M+ documents
- Taille des index < 20% de la taille des donnees
- Zero downtime lors des migrations de schema

Mission 3 - Qualite et observabilite des donnees

Objectif : Garantir que les donnees qui alimentent les modeles IA sont fiables, completes et conformes aux attentes.

Taches :

- Implementer des checks de qualite automatises a l'ingestion : validation du schema JSON, detection des champs manquants, verification de la langue
- Creer un pipeline de data profiling quotidien : distribution des langues, longueur moyenne des textes, volume par mot-cle, detection d'anomalies (chute ou pic soudain de volume)
- Mettre en place des alertes (Slack, email) en cas d'anomalie : arret de la collecte, changement dans l'API Bluesky, degradation de la qualite
- Documenter le data lineage : d'ou vient chaque donnee, quelles transformations elle a subi, quand elle a ete collectee
- Implementer un systeme de data versioning pour les datasets d'entrainement (DVC - Data Version Control)

Indicateurs de performance :

- 100% des posts stockes ont tous les champs obligatoires
- Anomalies detectees en < 15 minutes
- Lineage tracable de bout en bout pour chaque prediction

Competences techniques requises au plus haut niveau

Domaine	Technologies	Niveau attendu
Streaming	Kafka, Redis Streams, AT Protocol Firehose	Expert - conception d'architectures event-driven
Bases NoSQL	MongoDB (sharding, aggregation framework, change streams)	Expert - optimisation pour > 10M documents
Orchestration	Airflow, Prefect, Dagster	Avance - conception de DAGs de production
Qualite	Great Expectations, dbt tests, DVC	Avance - mise en place de data contracts
Python	asyncio, aiohttp, pymongo (async)	Expert - programmation asynchrone performante
Monitoring	Prometheus, Grafana, ELK Stack	Avance - dashboards d'observabilite pipeline

3. Machine Learning Engineer / NLP Specialist

Identite du role

Attribut	Detail
Intitule	Machine Learning Engineer specialise NLP
Seniorite requise	5 a 10 ans d'experience dont 3+ en NLP
Rattachement	Equipe IA / Direction R&D
Certification de reference	Google ML Engineer, DeepLearning.AI NLP Specialization

Pourquoi ce role est obligatoire pour Thumalien

Thumalien repose sur deux modeles d'IA qui sont le coeur de sa proposition de valeur : la detection de fake news (LogReg + TF-IDF, pipeline expert V2) et l'analyse emotionnelle (MLP PyTorch). Le projet a deja rencontre des problemes majeurs que seul un ML Engineer senior aurait anticipes : le biais Reuters (le modele apprenait le style d'ecriture au lieu de la desinformation), le domain shift (F1 excellent sur articles longs mais 77% de faux suspects sur Bluesky), et le choix du seuil de decision (0.44 au lieu de 0.50).

Ces problemes sont classiques en NLP applique, mais ils sont subtils et destructeurs. Un ML Engineer de haut niveau les previent avant qu'ils n'impactent la production.

Missions detaillees

Mission 1 - Conception et optimisation des modeles de detection

Objectif : Porter le pipeline de detection de fake news au niveau de l'etat de l'art tout en preservant l'interpretabilite et la frugalite qui font la force du projet.

Taches :

- Auditer le pipeline V2 actuel (TF-IDF 30K features + 12 features linguistiques + 7 emotions -> LogReg) et identifier les axes d'amelioration quantifies
- Concevoir le pipeline V3 avec Sentence-Transformers (all-MiniLM-L6-v2 ou multilingual-e5-base) : encoder les textes en vecteurs denses de 384 dimensions qui capturent la semantique, pas juste la frequence des mots
- Implementer une architecture hybride : embeddings semantiques + features linguistiques artisanales. Les features linguistiques (caps_ratio, sensationalism_score, punct_density) capturent des signaux structurels que les embeddings seuls ratent
- Concevoir un systeme d'ensemble : combiner les predictions du pipeline TF-IDF V2 et du pipeline V3 embeddings par stacking ou blending pour maximiser la robustesse
- Mener des experimentations rigoureuses avec cross-validation stratifiee, analyse des erreurs par type de texte (court/long, FR/EN, politique/sante)
- Optimiser le seuil de decision par une approche systematique : courbe precision-recall, analyse du cout metier des faux positifs vs faux negatifs, calibration de Platt

Indicateurs de performance :

- F1 > 0.85 sur textes courts (< 30 mots), contre 0.80 actuellement
- Maintien du F1 > 0.98 sur articles longs (pas de regression)
- Temps d'inference < 50ms par texte pour le serving temps reel

Mission 2 - Modele d'analyse emotionnelle avance

Objectif : Faire evoluer le MLP PyTorch actuel vers un modele plus performant et mieux calibre.

Taches :

- Evaluer le MLP actuel (Embedding 25K x 64 -> FC 64->48->24 -> 7 classes) sur des benchmarks standards (GoEmotions, SemEval)
- Concevoir un modele base sur des embeddings pre-entraînés multilingues (XLM-RoBERTa distille) avec fine-tuning sur les 7 emotions cibles
- Implementer une calibration des probabilités (temperature scaling) pour que les scores d'emotions soient des probabilités fiables, pas juste des scores relatifs
- Ajouter la detection de sarcasme et d'ironie, qui sont des vecteurs majeurs de desinformation sur les reseaux sociaux et qui perturbent l'analyse emotionnelle naive
- Creer un dataset d'evaluation bilingue specifique a Bluesky en annotant manuellement 1 000 posts (schema d'annotation inter-annotateurs, score kappa de Cohen)

Indicateurs de performance :

- Accuracy > 70% sur les 7 emotions (benchmark GoEmotions)
- Calibration ECE (Expected Calibration Error) < 0.05
- Support effectif des textes FR et EN sans degradation croisee

Mission 3 - Gestion du biais et de l'equite

Objectif : Garantir que les modeles ne discriminent pas systematiquement certains types de contenus, langues ou communautés.

Taches :

- Mener un audit de biais systematique : performance par langue (FR vs EN), par sujet (politique vs sante vs technologie), par longueur de texte
- Identifier et quantifier les biais residuels : le modele est-il plus severe sur les textes en francais ? Sur certains sujets ?
- Implementer des metriques d'equite (Equalized Odds, Demographic Parity) adaptees au contexte de la detection de desinformation
- Concevoir un pipeline de debiasing : reechantillonnage, regularisation adversariale, ou post-processing des scores
- Documenter les biais connus et les limites du modele dans une model card standardisee

Indicateurs de performance :

- Ecart de F1 entre FR et EN < 3 points
- Ecart de F1 entre sujets < 5 points
- Model card publiee et mise a jour a chaque version

Competences techniques requises au plus haut niveau

Domaine	Technologies	Niveau attendu
NLP classique	TF-IDF, n-grams, feature engineering linguistique	Expert - maitrise fine des parametres et de leurs impacts

NLP moderne	Transformers, Sentence-BERT, XLM-RoBERTa	Expert - fine-tuning, distillation, quantization
Frameworks ML	scikit-learn, PyTorch, Hugging Face	Expert - contribution-level understanding
Evaluation	Cross-validation, ablation studies, error analysis	Expert - methodologie experimentale rigoureuse
Multilingue	langdetect, polyglot, FastText language ID	Avance - gestion des specificites linguistiques FR/EN
Explicabilite	SHAP, LIME, coefficients LogReg, attention weights	Expert - interpretation et communication des decisions du modele

4. Data Scientist Senior - Methodologie et analyste

Identite du role

Attribut	Detail
Intitule	Data Scientist Senior / Lead Data Scientist
Seniorite requise	5 a 8 ans d'experience
Rattachement	Equipe Data Science / Direction R&D
Certification de reference	PhD ou Master en statistiques/ML, publications

Pourquoi ce role est obligatoire pour Thumalien

Le Data Scientist est le gardien de la rigueur methodologique. Dans Thumalien, c'est lui qui pose les bonnes questions : le F1 de 0.90 est-il reellement fiable ou est-il gonfle par un desequilibre dans le jeu de test ? Le seuil de 0.44 est-il robuste ou va-t-il deriver dans le temps ? Les 73.4% de posts "fiables" sur Bluesky refletent-ils la realite ou un biais du modele ?

Le rapport du projet montre deja une excellente demarche scientifique (analyse du biais Reuters, GridSearch systematique, comparaison de strategies d'adaptation). Le Data Scientist senior pousse cette rigueur encore plus loin.

Missions detaillees

Mission 1 - Cadrage methodologique et design experimental

Taches :

- Definir le protocole experimental pour chaque iteration du modele : hypothese, metriques, dataset de test, critere de succes
- Concevoir la strategie de split train/validation/test en tenant compte des biais temporels (les fake news evoluent dans le temps : un modele entraine sur 2020 ne detecte pas forcement les patterns de 2026)
- Implementer un framework de tests statistiques pour comparer les modeles : test de McNemar pour les classifieurs, bootstrap confidence intervals pour les metriques
- Definir les metriques metier en plus des metriques techniques : quel est le cout reel d'un faux positif (classer un texte fiable comme suspect) vs un faux negatif (laisser passer une fake news) ?

- Valider que le seuil de decision (actuellement 0.44) est optimal par rapport au cout metier, pas seulement au F1

Mission 2 - Analyse exploratoire et signal faibles

Taches :

- Concevoir des analyses exploratoires avancees sur les 188 553 posts collectes : clustering thematique (LDA, BERTopic), detection de communautes, evolution temporelle des sujets
- Identifier les signaux faibles : emergence de nouveaux themes, changement de tonalite emotionnelle sur un sujet, augmentation soudaine du score de suspicion sur un mot-cle
- Creer des rapports d'analyse automatisees hebdomadaires : tendances, anomalies, sujets emergents
- Mener des analyses de correlation entre le score de credibilite et les features emotionnelles : les posts suspects sont-ils systematiquement plus emotionnels ? Quelles emotions sont les plus correlees a la desinformation ?

Mission 3 - Validation et audit des modeles

Taches :

- Realiser des audits de robustesse : comment se comporte le modele face a des attaques adversariales (textes volontairement deformes pour tromper le classifieur) ?
- Tester la calibration du modele : quand il predit 70% de chance d'etre fiable, est-ce vraiment fiable 70% du temps ? (reliability diagram)
- Mener des analyses d'erreurs qualitatives : lire les 100 plus grosses erreurs du modele, les categoriser, en deduire des pistes d'amelioration
- Mesurer la derive du modele dans le temps (concept drift) : les performances se degradent-elles semaine apres semaine a mesure que les sujets d'actualite changent ?
- Proposer une strategie de retraining : a quelle frequence faut-il reentrainer le modele ? Sur quels criteres ?

Competences techniques requises au plus haut niveau

Domaine	Technologies	Niveau attendu
Statistiques	Tests d'hypotheses, intervalles de confiance, bootstrap	Expert - rigueur academique
Exploration	pandas, matplotlib, seaborn, Plotly	Expert - storytelling par la donnee
Topic modeling	LDA, BERTopic, UMAP, HDBSCAN	Avance - extraction de themes non supervisees
Evaluation ML	Precision-recall, ROC-AUC, calibration, ablation	Expert - au-dela des metriques de surface
Communication	Rapports, presentations, vulgarisation	Expert - traduire la complexite en decisions

5. MLOps Engineer - Industrialisation des modeles

Identite du role

Attribut	Detail
Intitule	MLOps Engineer / ML Platform Engineer
Seniorite requise	3 a 6 ans d'experience
Rattachement	Equipe Infrastructure / Equipe IA
Certification de reference	Google MLOps, AWS ML Specialty

Pourquoi ce role est obligatoire pour Thumalien

Actuellement, le modele Thumalien est un fichier .pkl charge manuellement par le dashboard. Il n'y a pas de versioning des modeles, pas de pipeline de retraining automatise, pas de monitoring de la performance en production. Le jour ou le modele commence a deriver (parce que les sujets d'actualite changent, parce que les patterns de desinformation evoluent), personne ne le saura.

Le MLOps Engineer est celui qui transforme un prototype de notebook en un systeme de production fiable et auto-surveillant.

Missions detaillees

Mission 1 - Pipeline de training automatise

Taches :

- Mettre en place un pipeline de training reproductible et automatise avec MLflow ou Weights & Biases : chaque run enregistre les hyperparametres, les metriques, les artefacts (modele, vectorizer, scaler)
- Implementer le versioning des modeles : chaque modele entraine recoit un identifiant unique, est teste automatiquement, et n'est promu en production que s'il passe les tests de non-regression
- Creer un pipeline de retraining declenche par des criteres automatiques : derive detectee, nouveau dataset disponible, planification mensuelle
- Automatiser la generation des model cards et des rapports de performance a chaque retraining
- Gerer les artefacts : stockage des modeles (model_expert_v2.pkl, vectorizer_expert_v2.pkl, emotion_model.pth) dans un registre centralise avec historique complet

Mission 2 - Serving et inference en production

Taches :

- Concevoir l'architecture de serving : remplacer le chargement direct du .pkl dans Streamlit par une API de prediction (FastAPI + model server)
- Implementer le batching des predictions : quand le dashboard charge 2 000 posts, les predictions doivent etre parallelisees et cachees
- Optimiser le temps d'inference : profiler le pipeline (TF-IDF transform + LogReg predict + emotions predict), identifier les goulots d'etranglement
- Mettre en place un A/B testing framework : pouvoir servir 2 versions du modele simultanement et comparer leurs performances sur le trafic reel
- Gerer le fallback : si le modele V3 echoue, revenir automatiquement sur le V2

Mission 3 - Monitoring et alerting en production

Taches :

- Implementer le monitoring de la derive des donnees (data drift) : la distribution des textes Bluesky entrants change-t-elle par rapport aux donnees d'entrainement ?
- Implementer le monitoring de la derive du modele (concept drift) : la distribution des scores de credibilite evolue-t-elle dans le temps ?
- Creer des dashboards MLOps : taux de prediction par heure, distribution des scores, temps d'inference, erreurs
- Configurer des alertes : si le taux de posts suspects depasse 50% sur 24h (contre 26.6% attendu), declencher une investigation
- Mettre en place des health checks automatises : le modele repond-il ? Ses predictions sont-elles coherentes ?

Competences techniques requises au plus haut niveau

Domaine	Technologies	Niveau attendu
ML Tracking	MLflow, W&B, Neptune	Expert - conception de plateformes ML
Serving	FastAPI, BentoML, TF Serving, Triton	Avance - optimisation de latence
CI/CD ML	GitHub Actions, Jenkins, Argo Workflows	Expert - pipelines de test automatises
Monitoring	Prometheus, Grafana, Evidently AI	Expert - detection de derive
Conteneurs	Docker, Kubernetes, Helm	Avance - deployment de services ML

6. Developpeur Dashboard / Data Visualization Engineer

Identite du role

Attribut	Detail
Intitule	Data Visualization Engineer / Developpeur Full-Stack Data
Seniorite requise	3 a 5 ans d'experience
Rattachement	Equipe Produit / Equipe Data
Certification de reference	Certifications Tableau/Plotly, UX Design

Pourquoi ce role est obligatoire pour Thumalien

Le dashboard est l'interface entre l'intelligence du systeme et ses utilisateurs. Un modele IA aussi performant soit-il est inutile si sa restitution est confuse, lente ou peu lisible. Le dashboard Streamlit actuel offre deja 3 pages (Vue Globale, Analyse temps reel, Metriques & Transparence), mais un specialiste de la visualisation transforme cette interface en un veritable outil d'aide a la decision.

Missions detaillees

Mission 1 - Conception de l'experience utilisateur analytique

Taches :

- Mener des interviews utilisateurs (analystes OSINT, journalistes, fact-checkers) pour comprendre leurs besoins reels : quelles questions posent-ils aux donnees ? Quels workflows suivent-ils ?
- Concevoir des wireframes et prototypes pour chaque vue du dashboard, en respectant les principes de data visualization d'Edward Tufte : maximiser le ratio donnees/encre, eliminer le chartjunk
- Implementer des interactions avancees : drill-down sur un post suspect pour voir les features qui ont contribue a son score, filtrage temporel fluide, comparaison de periodes
- Creer un systeme d'alertes visuelles : mettre en evidence les anomalies (pic de posts suspects, emergence d'un nouveau sujet) sans surcharger l'interface
- Optimiser l'accessibilite : contraste, taille de police, navigation clavier, support ecran large et mobile

Mission 2 - Visualisations avancees et storytelling

Taches :

- Concevoir des visualisations adaptees a chaque type de donnee :
 - Timeline interactive : evolution du ratio fiable/suspect au fil du temps avec annotations des evenements marquants
 - Heatmap emotionnelle : croisement emotions x sujets x temps pour identifier les combinaisons a risque
 - Network graph : relations entre termes de recherche, emotions dominantes et score de credibilite
 - Radar multi-dimensionnel : profil emotionnel d'un post ou d'un sujet sur les 7 emotions
- Implementer l'explicabilite visuelle : quand un utilisateur clique sur un post, afficher les top features (mots TF-IDF, features linguistiques) qui expliquent le score
- Creer des rapports exportables (PDF, CSV) pour les analyses qui doivent etre partagees en dehors du dashboard

Mission 3 - Performance et architecture frontend

Taches :

- Optimiser les requetes MongoDB depuis Streamlit : pagination, caching (st.cache_data, st.cache_resource), pre-calcul des aggregations
- Implementer le chargement progressif : afficher les metriques principales immediatement, charger les details en arriere-plan
- Gerer l'etat applicatif proprement via session_state : eviter les recalculs inutiles, maintenir les filtres utilisateur entre les pages
- Concevoir une architecture modulaire : chaque composant du dashboard (graphique, KPI, tableau) est un composant reutilisable et testable

Competences techniques requises au plus haut niveau

Domaine	Technologies	Niveau attendu
Dashboard	Streamlit, Dash, Panel	Expert - composants customs, optimisation
Visualisation	Plotly, D3.js, Altair	Expert - visualisations sur mesure
UX/UI	Figma, principes Tufte, accessibilite	Avance - design centre utilisateur

Backend	MongoDB aggregation, caching, pagination	Avance - optimisation des performances
Python	pandas, numpy, async	Avance - manipulation de donnees efficace

7. DevOps / Cloud Architect

Identite du role

Attribut	Detail
Intitule	DevOps Engineer / Cloud Infrastructure Architect
Seniorite requise	5 a 8 ans d'experience
Rattachement	Direction Infrastructure / CTO
Certification de reference	AWS Solutions Architect, CKA (Kubernetes), Terraform Associate

Pourquoi ce role est obligatoire pour Thumalien

Thumalien repose sur une architecture Docker Compose avec 4 services (MongoDB, Collector, Jupyter, Streamlit). C'est adapte au developpement et au prototypage, mais insuffisant pour une production serieuse. Un DevOps senior transforme cette architecture en un systeme resilient, securise, scalable et observable.

Missions detaillees

Mission 1 - Infrastructure as Code et conteneurisation avancee

Taches :

- Migrer de Docker Compose a Kubernetes (ou Docker Swarm pour une premiere etape) pour beneficier de l'auto-scaling, du self-healing et du rolling update
- Ecrire l'infrastructure en code (Terraform ou Pulumi) : chaque composant est reproductible, versionne et auditable
- Optimiser les images Docker : multi-stage builds pour reduire la taille (l'image Python avec TensorFlow + PyTorch + scikit-learn peut depasser 5 GB), separation des images par service
- Implementer des health checks et liveness probes pour chaque service : si MongoDB ne repond plus, Kubernetes le redemarrera automatiquement
- Gerer les secrets proprement : les identifiants Bluesky (.env) doivent etre stockes dans un vault (HashiCorp Vault, AWS Secrets Manager), pas dans des fichiers

Mission 2 - CI/CD et automatisations

Taches :

- Concevoir le pipeline CI/CD complet : a chaque push sur main, les tests unitaires tournent, les images Docker sont reconstruites, le deploiement est automatique si les tests passent
- Implementer des tests d'integration : le pipeline doit verifier que le collecteur se connecte bien a MongoDB,

que le modele charge et predit correctement, que le dashboard s'affiche

- Automatiser le deploiement blue/green : la nouvelle version du dashboard est deployee en parallele de l'ancienne, le trafic est bascule progressivement
- Mettre en place des rollbacks automatiques : si la nouvelle version a un taux d'erreur superieur a 1%, retour automatique a la version precedente

Mission 3 - Securite et conformite

Taches :

- Auditer la securite de l'infrastructure : scans de vulnerabilites sur les images Docker (Trivy, Snyk), analyse des dependances Python (safety, pip-audit)
- Implementer le chiffrement : donnees au repos (MongoDB encryption at rest), donnees en transit (TLS entre les services), secrets en vault
- Gerer les acces : RBAC (Role-Based Access Control) pour les differents utilisateurs du dashboard et de l'API
- Assurer la conformite RGPD : les posts Bluesky collectes contiennent des donnees personnelles (handles, textes), un mecanisme de suppression sur demande doit etre implemente
- Mettre en place des logs d'audit : qui a accede a quoi, quand, pourquoi

Competences techniques requises au plus haut niveau

Domaine	Technologies	Niveau attendu
Conteneurs	Docker, Kubernetes, Helm	Expert - architecture de production
IaC	Terraform, Pulumi, Ansible	Expert - infrastructure reproductible
CI/CD	GitHub Actions, ArgoCD, Jenkins	Expert - pipelines complexes
Cloud	AWS/GCP/Azure (au moins un)	Expert - services manages (EKS, Atlas, CloudRun)
Securite	Vault, TLS, RBAC, scanning	Expert - securite by design
Monitoring	Prometheus, Grafana, ELK, Jaeger	Expert - observabilite complete

8. Chef de Projet Data / Product Owner

Identite du role

Attribut	Detail
Intitule	Chef de Projet Data / Product Owner Intelligence
Seniorite requise	7 a 10 ans d'experience dont 3+ en data/IA
Rattachement	Direction Produit / Direction Generale
Certification de reference	PMP, Scrum Product Owner (PSPO), CDMP

Pourquoi ce role est obligatoire pour Thumalien

Thumalien n'est pas qu'un exercice technique. C'est un outil de detection de desinformation qui touche a des questions ethiques, legales et societales. Le Chef de Projet est celui qui maintient la vision : pourquoi construit-on cet outil ? Pour

qui ? Avec quelles limites ? Il arbitre entre les ambitions techniques et les contraintes reelles.

Missions detaillees

Mission 1 - Vision produit et roadmap

Taches :

- Definir la vision produit a 6, 12 et 24 mois : quelles fonctionnalites, pour quels utilisateurs, avec quels criteres de succes
- Prioriser le backlog en fonction de l'impact utilisateur et de la faisabilite technique : la V3 avec Sentence-Transformers est-elle plus prioritaire que l'API REST ? L'amelioration du dashboard est-elle plus urgente que le support de nouvelles langues ?
- Mener des etudes utilisateurs : interviews avec des analystes OSINT, des journalistes, des fact-checkers, des chercheurs en sciences de l'information
- Definir les KPI produit : nombre d'utilisateurs actifs, temps moyen passe sur le dashboard, taux de confiance dans les predictions, NPS
- Piloter les sprints et les ceremonies Agile : planning, review, retrospective

Mission 2 - Gouvernance des donnees et conformite

Taches :

- Assurer la conformite RGPD du projet : les posts Bluesky sont des donnees publiques, mais les handles sont des donnees personnelles. Faut-il les anonymiser ? Les conserver combien de temps ?
- Anticiper le cadre de l'AI Act europeen : Thumalien est-il un systeme d'IA a haut risque ? Quelles obligations de transparence, d'explicabilite et de supervision humaine s'appliquent ?
- Rediger la documentation de conformite : registre de traitement, analyse d'impact (AIPD), politique de retention des donnees
- Definir les limites ethiques du systeme : Thumalien ne doit pas devenir un outil de censure. Comment garantir que le label "suspect" est utilise pour informer, pas pour restreindre ?
- Coordonner avec le DPO (Delegue a la Protection des Donnees) si l'organisation en dispose

Mission 3 - Coordination et communication

Taches :


- Faciliter la communication entre les profils techniques (Data Engineer, ML Engineer, DevOps) et les parties prenantes non techniques (direction, utilisateurs, partenaires)
- Gerer les risques projet : identifier les dependances critiques (API Bluesky peut changer, datasets d'entrainement peuvent devenir indisponibles), les mitiger
- Produire des rapports d'avancement synthetiques pour la direction
- Organiser les revues de modeles : chaque nouvelle version du modele est presentee, ses performances discutees, ses limites documentees avant mise en production
- Gerer les partenariats externes : fournisseurs de datasets, communaute Bluesky, autres equipes de fact-checking

Competences requises au plus haut niveau

Domaine	Competence	Niveau attendu

Gestion de projet

Agile/Scrum, Kanban, OKR



Reglementation	RGPD, AI Act, DSA	Expert - conformite reglementaire
Data Literacy	Comprehension des pipelines ML, metriques	Avance - dialoguer avec les equipes techniques
Communication	Vulgarisation, presentations, rapports	Expert - pont entre technique et metier
Ethique IA	Biais, equite, transparence	Avance - cadrage ethique des systemes IA

9. Expert Green IT & IA Responsable

Identite du role

Attribut	Detail
Intitule	Expert Green IT / Responsable IA Responsable
Seniorite requise	3 a 6 ans d'experience
Rattachement	Equipe Transverse / RSE
Certification de reference	INR (Institut du Numerique Responsable), ISO 14001, AI Ethics

Pourquoi ce role est obligatoire pour Thumalien

Thumalien integre deja CodeCarbon pour mesurer l'empreinte carbone des entrainements (0.55 g CO2 au total - exemplaire). Mais la demarche Green IT ne se limite pas a la mesure : elle doit guider les choix d'architecture, de modeles et d'infrastructure. Le choix de LogReg plutot que RoBERTa est un choix Green IT autant que technique (10-100x moins d'energie). Cet expert formalise et pousse cette logique.

Missions detaillees

Mission 1 - Mesure et optimisation de l'empreinte environnementale

Taches :

- Etendre la mesure CodeCarbon au-dela de l'entrainement : mesurer l'inference (chaque prediction consomme de l'energie), le stockage (MongoDB tourne 24/7), la collecte (requetes API continues)
- Calculer l'empreinte totale du projet : entrainement + inference + infrastructure + stockage + reseau
- Definir un budget carbone pour le projet : combien de g CO2 par mois sont acceptables ? Comment le reduire ?
- Optimiser l'efficacite energetique : batch les predictions au lieu de les faire une par une, eteindre les services non utilises (Jupyter la nuit), compresser les donnees en base
- Comparer l'empreinte de Thumalien avec des solutions equivalentes : combien consommerait un pipeline base sur GPT-4 ou RoBERTa ? Quantifier l'avantage du choix frugal

Mission 2 - IA de confiance et explicabilite

Taches :

- Implementer SHAP (SHapley Additive exPlanations) pour expliquer chaque prediction : quels mots et features ont le plus contribue au score de credibilite
- Concevoir l'interface d'explicabilite dans le dashboard : quand un utilisateur voit un post classe "suspect", il doit pouvoir comprendre pourquoi en un clic
- Rediger la documentation d'explicabilite exigee par l'AI Act : comment le modele fonctionne, quelles sont ses limites, comment contester une prediction
- Implementer un mecanisme de feedback utilisateur : si un analyste juge qu'une prediction est erronee, cette information est enregistree et utilisee pour ameliorer le modele
- Auditer les biais en collaboration avec le ML Engineer : les populations francophones sont-elles traitees equitalement ? Les sujets sensibles (sante, religion) sont-ils geres sans discrimination ?

Mission 3 - Gouvernance et sensibilisation

Taches :

- Former l'equipe aux pratiques de numerique responsable : choix d'algorithmes frugaux, optimisation des requetes, dimensionnement adequat de l'infrastructure
- Produire un rapport Green IT trimestriel : evolution de l'empreinte, actions d'optimisation, comparaison avec les objectifs
- Participer aux choix d'architecture avec un regard environnemental : faut-il migrer vers le cloud (plus efficient car mutualise) ou rester on-premise (plus controle mais moins optimise) ?
- Veiller a la conformite avec les standards émergents : AI Act europeen, norme ISO 42001 (IA), Green Software Foundation

Competences techniques requises au plus haut niveau

Domaine	Technologies	Niveau attendu
Mesure carbone	CodeCarbon, Green Algorithms, Carbontracker	Expert - mesure et optimisation
Explicabilite	SHAP, LIME, ELI5, Captum (PyTorch)	Avance - integration dans les pipelines
Ethique IA	Fairness metrics, model cards, datasheets	Avance - audit systematique
Reglementation	AI Act, RGPD, normes ISO	Avance - veille reglementaire
Eco-conception	Optimisation algorithmique, frugalite	Avance - choix d'architecture verts

10. Matrice de responsabilites RACI

La matrice RACI definit, pour chaque activite du projet, qui est Responsable (fait le travail), Approbateur (valide), Consulte (donne un avis) et Informe (tenu au courant).

Activite	Data Eng.	ML Eng.	Data Sci.	MLOps	Dashboard	DevOps	Chef Proj.	Green IT
Pipeline collecte	R	I	C	C	I	A	I	C

Architecture MongoDB	R	C	C	I	C	A	I	I
Modele fake news	C	R	A	C	I	I	I	C
Modele emotions	I	R	A	C	I	I	I	C
GridSearch / optim	I	R	A	I	I	I	I	I
MLOps / serving	C	C	I	R	I	A	I	I
Dashboard UI/UX	I	C	C	I	R	I	A	C
Visualisations	I	C	R	I	R	I	A	I
Infrastructure Docker	C	I	I	C	I	R	I	C
CI/CD	I	I	I	C	I	R	I	I
Securite / RGPD	I	I	I	I	I	R	A	C
Conformite AI Act	I	C	C	I	I	I	R	R
Bilan carbone	I	C	I	I	I	C	I	R
Explicabilite	I	R	C	I	C	I	A	R
Roadmap produit	C	C	C	C	C	C	R	C

11. Reflexion - La synergie comme condition de l'excellence


Ce que le projet Thumalien nous enseigne

Thumalien, dans sa forme actuelle, est un projet remarquable par sa completude : un pipeline de bout en bout, de la collecte temps reel a la visualisation, en passant par deux modeles d'IA, le tout conteneurise et mesure en empreinte carbone. Le fait qu'il ait ete realise par une seule personne dans le cadre d'un Master en temoigne d'une polyvalence exceptionnelle.

Mais c'est precisement cette polyvalence qui revele la necessite des roles specialises. Chaque defi rencontre dans le projet - le biais Reuters, le domain shift, le choix du seuil 0.44, la gestion du multilingue - est un probleme classique pour le specialiste concerne, mais un obstacle potentiellement bloquant pour un generaliste qui decouvre le probleme en contexte.

La hierarchie invisible des competences

Dans un projet d'excellence, les roles ne sont pas simplement juxtaposes : ils s'emboitent selon une logique de dependances qui revele leur importance relative.



Le Data Engineer et le ML Engineer sont les deux piliers : sans donnees fiables, le meilleur modele est inutile ; sans modele performant, les meilleures donnees sont inexploitees. Le Data Scientist garantit que le lien entre les deux est rigoureux. Le MLOps transforme le prototype en produit. Le Dashboard rend le produit utilisable. Le Green IT rend le tout responsable. Et le Chef de Projet s'assure que l'ensemble converge vers un objectif clair.

L'excellence n'est pas la perfection technique - c'est l'adequation

Un projet d'excellence n'est pas celui qui utilise les technologies les plus avancees. C'est celui qui fait les bons choix pour le bon contexte. Thumalien l'illustre parfaitement :

- Choisir LogReg plutot que RoBERTa n'est pas un compromis, c'est un choix d'ingenierie : F1 comparable, 100x moins d'energie, interpretabilite totale, deploiement trivial
- Choisir un seuil de 0.44 plutot que 0.50 n'est pas un hack, c'est une calibration metier : optimiser pour le cas d'usage reel (textes courts Bluesky), pas pour une metrique abstraite
- Ajouter 3 datasets sociaux pour resoudre le domain shift n'est pas du bricolage, c'est de l'ingenierie des donnees d'entrainement au service du cas d'usage

Chaque professionnel decrit dans ce document doit porter cette philosophie : la meilleure solution est celle qui resout le probleme de l'utilisateur, pas celle qui impressionne le plus sur un CV.

Le facteur humain

Au-dela des competences techniques, l'excellence d'une equipe data repose sur des qualites humaines souvent sous-estimees :

- La curiosite intellectuelle : comprendre pourquoi un modele echoue, pas juste comment le corriger
- L'humilite methodologique : remettre en question ses propres resultats, chercher les failles avant les autres
- La communication : un ML Engineer qui ne sait pas expliquer son modele a un non-technique produit un outil que personne n'adoptera
- L'ethique : nous construisons un outil qui etiquette des contenus comme "suspects". Cette responsabilite ne doit jamais etre prise a la legere

Conclusion

Ce document n'est pas une fiche de poste. C'est une vision de ce que signifie porter un projet de Social Media Intelligence au plus haut niveau d'excellence. Chaque role decrit ici est une composante indispensable d'un systeme ou la qualite de l'ensemble depend de la qualite de chaque partie.

Le projet Thumalien a demontre qu'une seule personne peut construire un prototype fonctionnel et intelligent. L'etape suivante - transformer ce prototype en un produit d'excellence - necessite une equipe ou chaque membre apporte une expertise profonde dans son domaine, tout en comprenant suffisamment les autres domaines pour collaborer efficacement.

L'excellence n'est pas un etat, c'est une discipline collective.

Document genere dans le cadre du projet Thumalien - Master Big Data - Avril 2026