

Guide de Production Video MVP

Thumalien - Social Media Intelligence & AI Monitor

VI.2 - VIDEO & MVP - SAVOIR CONVAINCRE

Equipe : Azelie Bernard (Lead Technique) / Sebastien Lazcanotegui (Optimisation ML & Doc)

Formation : Master Big Data - Sup de Vinci

Duree cible : 15-18 minutes

Livable : MP4 1920x1080 ou lien YouTube non repertorie

1. Strategie de differenciation

Ce que font les autres groupes

PowerPoint filme avec voix off monotone
Demo basique en fin de video
Pas de storytelling, pas d'emotion

Ce que NOUS allons faire

- **Storytelling 'enquete'** : commencer par le probleme (vrais posts suspects Bluesky), pas par la solution
- **Plot twist V1** : raconter comment notre V1 a 99.6% etait en realite cassee - montre la maturite
- **Demo live interactive** : taper des textes en direct (FR et EN) et voir le verdict en temps reel
- **Radar emotionnel** : exploiter le radar chart 7 emotions du dashboard (visuellement tres fort)
- **Chiffres d'impact** : 188K posts, 11 versions, 0.55g CO2 - des metriques concretes

2. Moyens techniques de production

2.1 Capture video

Outil	Usage	Prix	Plateforme
OBS Studio	Ecran + webcam simultanee	Gratuit	Mac/Win/Linux
QuickTime Player	Capture ecran simple	Gratuit	Mac
Loom	Ecran + webcam + partage	Gratuit (5min) / 15\$/m	Web

Recommandation : OBS Studio - picture-in-picture, scenes pre-configurees, bandeau nom

Configuration OBS recommandee :

- Resolution : 1920x1080 @ 30fps
- Encodeur : x264, CRF 18 (qualite elevee)
- Audio : micro USB ou AirPods Pro (pas le micro integre du laptop)
- 4 scenes : Slide (plein ecran), Demo (ecran+webcam), Speaker (webcam+bandeau), Split (50/50)

2.2 Montage video

Outil	Niveau	Prix	Avantage
iMovie	Debutant	Gratuit (Mac)	Simple, couper/assembler
DaVinci Resolve	Intermediaire/Pro	Gratuit	Etalonnage, effets, titrage pro
CapCut Desktop	Debutant/Intermed.	Gratuit	Sous-titres auto, templates

Recommandation : CapCut Desktop pour sous-titres auto + templates bandeaux nom

2.3 Slides / Visuels

Outil	Usage	Prix
Canva	Slides, schemas, bandeaux	Gratuit / Pro etudiant
Google Slides	Slides collaboratifs	Gratuit
Figma	Schemas sur mesure	Gratuit
Mermaid Live Editor	Diagrammes depuis le code	Gratuit

2.4 Son

Micro-casque USB ou AirPods Pro - jamais le micro integre du laptop

Enregistrer dans une piece calme, porte fermee

Test de 30 secondes + reecoute AVANT de filmer

Post-traitement si necessaire : Audacity (gratuit) - reduction de bruit

3. Comment l'IA peut nous aider

3.1 Generation de visuels

Tache	Outil IA	Comment
Slides professionnelles	Canva AI (Magic Design)	Generer slides theme dark/tech
Schema d'architecture	Claude (artefact)	Schema SVG ou Mermaid du pipeline
Illustrations	DALL-E / Midjourney	Visuels cybersecurity, data analysis
Logo Thumalien	Canva AI / DALL-E	Logo style tech/surveillance

3.2 Script et voix

Tache	Outil IA	Comment
Script detaille	Claude	Texte mot-a-mot (inclus dans ce doc)
Sous-titres auto	CapCut AI	Genere les sous-titres FR
Corrections audio	Adobe Podcast AI	Ameliore qualite, supprime bruit

3.3 Remotion via Claude - Video programmatique

Remotion (remotion.dev) est un framework React pour creer des videos par le code. Claude peut generer le code pour :

- Animations de graphiques (courbe F1 qui monte version apres version)
- Bandeaux nom animes
- Transitions entre slides
- Affichage progressif du tableau des 11 versions

Avantages : rendu pixel-perfect, reproductible, animations fluides, Claude ecrit le code

Inconvenients : necessite Node.js + React, ~2h de setup

Verdict : approche **HYBRIDE** recommandee - Remotion pour les animations, OBS pour les screencasts, assemblage dans CapCut/DaVinci

3.4 Alternative sans code : Canva + CapCut

1. Canva : creer toutes les slides avec animations, exporter en MP4
2. CapCut : assembler slides + screencasts OBS + sous-titres auto
3. Claude : generer le script, textes des slides, talking points

4. Script detaille - 15 minutes

ACTE 1 - 'Le Probleme' (Sebastien, 3 min)

[0:00-0:30] Accroche

Ecran noir + texte : 'Sur Bluesky, 1 post sur 4 que nous analysons est suspect.'

[Sebastien]

Chaque jour, des milliers de posts circulent sur Bluesky.
Certains informent. D'autres manipulent.
A l'oeil nu, la difference est parfois invisible.
Comment faire le tri dans 188 000 posts, en francais ET en anglais,
quand chaque texte ne fait que 10 mots ?

[0:30-1:30] La problematique

[Sebastien]

Bluesky est un reseau social decentralise base sur le protocole AT.
Contrairement a Twitter, il n'y a pas de moderation centralisee.
C'est un terrain fertile pour la desinformation.

Notre defi :

- Des textes ultra-courts : 5 a 20 mots en moyenne
- Deux langues : francais et anglais
- Un volume massif : plus de 188 000 posts collectes
- Et zero budget cloud : tout tourne en local.

Un humain met 3 minutes pour verifier un seul post.
Pour 188 000 posts, c'est plus d'un an de travail non-stop.
C'est pour ca qu'on a cree Thumalien.

[1:30-2:30] Presentation de l'equipe

[Sebastien]

Je suis Sebastien Lazcanotegui. Mon role : l'optimisation
du machine learning et la coherence documentaire.
J'ai travaille sur le debiasage, le GridSearch, et la consolidation.

Ma collegue Azelie Bernard est la lead technique.
C'est elle qui a concu l'ensemble du pipeline :
de la collecte Bluesky au dashboard, en passant par
les 11 versions du modele et les fine-tunings Transformer.

[2:30-3:00] Teaser solution

[Sebastien]

Voici Thumalien en un schema : Bluesky, collecteur, MongoDB,
pipeline NLP, dashboard. Tout conteneurise avec Docker.
Une commande, et le systeme entier demarre.

ACTE 2 - 'Le Parcours' (Sebastien, 4 min)

[3:00-4:00] Methodologie

[Sebastien]

On ne construit pas un modele d'IA en une fois.
On suit le cycle CRISP-DM adapte a l'IA :
comprendre, explorer, preparer, modeliser, evaluer, deployer.
Et surtout : iterer. Encore et encore.

[4:00-5:30] Le plot twist - La V1 a 99.6%

MOMENT CLE DE LA VIDEO - Montre la maturite intellectuelle du projet

[Sebastien]

Notre premier modele affichait 99.6% de precision.
(pause)
99.6%. On pourrait se feliciter et rentrer chez nous.

Sauf que quand on a regarde les mots les plus predictifs,
on a trouve... 'reuters', 'reporting by', 'editing by'.

Le modele ne detectait pas les fake news.
Il detectait les articles Reuters. C'etait un biais de donnees.

C'est LA lecon de ce projet : des metriques parfaites
peuvent cacher un modele completement inutile.
Il faut toujours tester sur des donnees reelles.

[5:30-7:00] 11 versions en 5 mois

[Sebastien]

A partir de ce constat, on a itere. 11 fois.

V1.5 : debiaisage Reuters, ajout du francais.
V2 : tweets et titres courts. Bluesky passe de 23% a 73% fiable.
V3 : 5 features sur 12 etaient a zero - bug de preprocessing.
V4 : augmentation FR court, +32% de F1.
V5 : 10 000 posts sociaux synthetiques, test 12/12.

Puis les transformers :
CamemBERT V2 : F1 0.957 sur ultra-courts FR.
RoBERTa V2 : F1 0.874 sur ultra-courts EN, test 16/18.

De mon cote, j'ai optimise les hyperparametres par GridSearch
et ajoute le debiaisage residuel des agences et annees artefacts.

Le tout pour 0.55 gramme de CO2.

ACTE 3 - 'La Demo' (Azellie, 6 min)

[7:00-8:00] Architecture technique

[Azellie]

4 containers Docker. Le collecteur se connecte a Bluesky via le protocole AT, stocke dans MongoDB, le pipeline NLP analyse chaque texte, et Streamlit affiche tout en temps reel. On lance tout avec une seule commande.
(montrer docker-compose up dans le terminal)

[8:00-9:30] Collecte + MongoDB

[Azellie]

Le collecteur tourne en continu. En 5 mois : 188 553 posts.
(montrer MongoDB : les documents, le count)
Indexes, validation de schema, monitoring qualite.

[9:30-11:30] Demo Dashboard - Le moment cle

MOMENT WOW - Le design glassmorphism dark va impressionner

[Azellie]

Voici le dashboard Thumalien.
(ouvrir Streamlit - KPIs, distribution, emotions)

Test en direct :

1. 'SCANDALE ! Le gouvernement cache la verite sur les vaccins !'
-> Score 0.02 -> SUSPECT (verdict rouge) + radar colere/peur
2. 'Le CNRS publie une etude sur le changement climatique.'
-> Score 0.95 -> FIABLE (verdict vert) + radar neutre
3. 'SHARE before they DELETE this!! The truth about 5G!'
-> Score 0.02 -> SUSPECT - 'Le modele detecte aussi en anglais.'
4. 'The city council approved the new budget.'
-> Score 0.81 -> FIABLE

'Le modele ne fait pas que classer vrai ou faux.
Il analyse l'emotion derriere chaque texte.'

[11:30-13:00] Sous le capot

[Azellie]

Le pipeline combine 3 types de features :
- TF-IDF : 30 000 n-grammes
- 12 features linguistiques : majuscules, ponctuation, sensationnalisme
- 7 probabilites emotionnelles : MLP PyTorch

Le tout dans une regression logistique. Pourquoi pas un Transformer ?

Parce qu'on peut EXPLIQUER chaque prediction.
Ce n'est pas une boîte noire.

ACTE 4 - 'L'Impact' (2 min)

[13:00-14:00] ROI (Azalie)

[Azalie]

188 000 posts analyses automatiquement - 1 an de travail humain.
Zero euro de cloud GPU. 0.55g de CO2.
100% open source, 100% reproductible.
Scalable : Docker Compose vers Kubernetes.

[14:00-15:00] Conclusion (Sebastien)

[Sebastien]

Prochaines etapes : API REST FastAPI, detection multimodale, plus de langues.

Ce projet montre qu'avec les bonnes donnees, la bonne methodologie,
et un esprit critique sur ses propres resultats,
on peut construire un outil de lutte contre la desinformation
efficace, interpretable, et eco-responsable.

Merci pour votre attention.

5. Planning de production

Etape	Qui	Duree	Livrable
1. Creer slides (Canva)	Les deux	3h	10 slides PNG/MP4
2. Repeter le script	Chacun	2x 30min	Fluide, < 15 min
3. Configurer OBS	Azelie	1h	4 scenes configurees
4. Enregistrer Actes 1+2	Sebastien	1-2h	Rushes Sebastien
5. Enregistrer Actes 3+4	Azelie	1-2h	Rushes + screencasts
6. Montage + sous-titres	Les deux	3h	Video assemblee
7. Relecture + corrections	Les deux	1h	Version finale
8. Export + upload	Azelie	30min	Livrable final

TOTAL ESTIME : 12 a 15 heures de travail

6. Checklist avant tournage

- ☐ Dashboard Streamlit démarre et fonctionne (docker-compose up)
- ☐ MongoDB avec des données (188K posts)
- ☐ OBS Studio installé + 4 scènes configurées
- ☐ Micro testé (30s + reécoute)
- ☐ Slides Canva finalisées et exportées
- ☐ Script imprimé ou sur écran secondaire
- ☐ Pièce calme, porte fermée, notifications désactivées
- ☐ Webcam cadrée (visage centre, fond neutre)
- ☐ Bandeau nom préparé dans OBS

7. Nomenclature du livrable

Solution 1 - Fichier ZIP

PE_2526_[codepromo]_Bernard_Lazcanotegui.zip
 -> PE-2526_[codepromo]_BernardAzalie.mp4

Solution 2 - Lien YouTube

PE_2526_[codepromo]_Bernard_Lazcanotegui.txt
 -> contient le lien YouTube (non répertorié)