

PROMPTEUR v4 — THUMACHECK

Niamato Consulting pour Thumalien

Version corrigée — Juillet 2026

*Changements v3 -> v4** :*

- *Chiffres mis à jour (537 tests, 465 textes gold, 17 features)*
- *Ton recentre client Thumalien (moins de jargon ML)*
- *Module emotions rendu visible (exigences EMO du CDC)*
- *Contextualisation du F1 gold 0.67 (kappa, subjectivité)*
- *Sécurité et mode demo mentionnés*
- *XAI vulgarisée pour audience dirigeante*

En decembre 2025,
on collecte 100 000 posts Bluesky.

On entraine un modele
de detection de fake news.

On obtient un F1-score de 0,99
en cross-validation.

Et c'est precisement a ce moment-la
qu'on aurait du s'inquieter.

[SLIDE 1 : Titre projet]

Bonjour, je suis Azelie Bernard,
lead technique chez Niamato Consulting.

Nous sommes un cabinet d'expertise
Data et Intelligence Artificielle,
et vous nous avez mandates
pour developper une solution
de detection de desinformation sur Bluesky.

Vos equipes de fact-checking passent
en moyenne 3 a 5 minutes par post
pour evaluer sa fiabilite.

A 60 000 posts publics par jour
sur Bluesky, c'est intenable.

ThumaCheck est la solution
que nous avons construite pour vous.

Elle analyse un texte
en 1,5 milliseconde,
avec une explication auditable
a chaque decision.

Et si votre base MongoDB
est temporairement indisponible,
le dashboard continue de fonctionner
en mode demonstration —
vos equipes ne sont jamais bloques.

Bonjour, je suis Sebastien Lazcanotegui,
consultant chez Niamato Consulting.

Mon role :

la validation et la qualite
du machine learning.

J'ai pilote l'annotation du gold set —
465 textes Bluesky annotes
par deux annotateurs humains —
le debiaisage des donnees,
et l'optimisation des hyperparametres.

Azelie a concu l'architecture du pipeline,
le dashboard
et les trois niveaux d'explicabilite.

Bluesky :

35 millions d'utilisateurs,
protocole AT entierement ouvert,
plus de 60 000 posts publics par jour
analysables.

Aucune equipe de moderation centralisee.

Ce que nous vous livrons :

classifier un post
comme fiable ou suspect
en moins de 5 millisecondes,
en francais comme en anglais,
avec une explication
que vos equipes peuvent defendre
aupres de votre direction
et de vos regulateurs.

[SLIDE 4 : Les 4 exigences]

Des le depart,
nous avons fixe avec vous
quatre exigences non-negociables.

Transparence :
chaque score est explicable.

Bilinguisme :
français et anglais
à performance équivalente.

Frugalité :
moins de 5 ms par texte,
empreinte carbone mesurée.

Et conforme au RGPD
et à l'AI Act européen,
applicable en août 2026.

Ces quatre exigences
structurent toute la solution
que nous vous présentons aujourd'hui.

[ECRAN : notebook Jupyter, sortie F1=0.99]

Voici notre premiere version du pipeline.

Logistic Regression sur du TF-IDF,
30 000 features,
entrainee sur 197 782 articles.

Cross-validation a 5 plis :

F1 macro de 0,99.

Sur le papier, le projet est termine.

[SLIDE 5 : F1=0.99 — LE PIEGE]

Sauf qu'on a regarde
quels mots avaient le plus de poids.

Et on a trouve :

reuters, afp, associated press.

Le modele n'apprenait pas
a detecter la desinformation.

Il apprenait a reconnaitre
le style des agences de presse.

C'est moi qui ai pilote le debiaisage :
creation de la liste de termes d'agences
pour neutraliser ces signatures,
filtrage des annees artefacts 2015-2020,
et les tests de non-regression
apres chaque correction.

En parallele, j'ai lance
un GridSearch systematique
sur les hyperparametres du modele.

De la version 2 a la version 5,
on a corrige ce biais
et ajoute des donnees bilingues.

Le F1 en cross-validation

est descendu a 0,91.

Mais cette fois,

c'est un F1 honnête.

A partir de cette base saine,
j'ai itere l'architecture
jusqu'a la version 9 actuelle.

[SLIDE 6 : Architecture C4]

Voici notre architecture.

Le flux suit trois couches :
donnees, intelligence artificielle, decision.

Premiere couche — les donnees.
Le collecteur se connecte a Bluesky
via le protocole AT
et stocke les posts dans MongoDB.
245 000 posts collectes a ce jour,
avec deduplication automatique
et reprise sur erreur reseau.

Deuxieme couche — l'intelligence artificielle.
Le pipeline analyse chaque texte
avec trois modeles complementaires.

V5 — notre modele principal :
il combine TF-IDF avec 17 features linguistiques
et 7 emotions detectees automatiquement.
C'est lui qui repond en 1,5 milliseconde.

V6 — un classifieur qui analyse
uniquement le style d'ecriture,
independamment du sujet.

Et CamemBERT — un modele de deep learning
specialise sur les textes courts en francais.

Le meta-learner V8
combine les trois pour la decision finale.

Troisième couche — la décision.

Le dashboard Streamlit expose les résultats avec cinq pages dédiées à vos équipes et trois niveaux d'explication.

Le tout est conteneurisé avec Docker Compose — une seule commande pour tout démarrer.

[SLIDE 7 : Pipeline cascade]

En production,
le pipeline fonctionne
en deux étapes.

La première étape sépare
les opinions des faits —
parce que l'AI Act interdit
de qualifier une opinion de désinformation.

La seconde étape analyse uniquement
les contenus factuels.

Cette cascade a réduit
vos faux positifs de 57 à 21
sur notre jeu de test —
soit une baisse de 67 %,
validée statistiquement.

Concrètement pour vous :
moins d'alertes inutiles
dans les files de modération
de vos équipes.

[ECRAN : dashboard Streamlit plein écran]

Voici le dashboard ThumaCheck —
l'interface que vos équipes
utiliseront au quotidien.

Cinq pages.

Vue Globale :

245 000 posts collectes,
67 % classes fiables.

Chaque visualisation
a été pensée pour la décision :
la jauge de score utilise
un code couleur vert-rouge intuitif,
les barres d'explication montrent
ce qui pousse vers fiable ou suspect,
et la heatmap de mots-clés
guide l'œil de vos analystes
vers les passages critiques.

[ECRAN : soumettre texte fiable]

Premier test : un communiqué scientifique.
Score 0,89 — classe fiable.

Ce qui distingue ThumaCheck
d'un outil boîte noire :
trois niveaux d'explication.

Premier niveau :
les mots les plus influents.
Ce n'est pas une approximation —
c'est la formule exacte du modèle.

Deuxième niveau :
l'analyse du style d'écriture.
La présence de citations

et la diversité du vocabulaire
confirment un contenu fiable.

Troisième niveau :

la décomposition complète de la décision.

On lit le poids de chaque critère,
coefficient par coefficient.

Vos analystes ont tout ce qu'il faut
pour justifier chaque décision
auprès de votre hiérarchie —
et auprès de vos régulateurs.

[ÉCRAN : soumettre texte suspect]

Deuxième test :
un texte sensationnaliste.

Score 0,12 de crédibilité,
donc 88 % suspect.

Les explications s'inversent :
le sensationnalisme du langage
est identifié comme signal fort.

Et la heatmap d'attention
surligne directement les mots problématiques :
"SCANDALE" et "mentent"
s'affichent en rouge.

C'est exactement ce que vos analystes
veulent voir pour défendre leur décision.

[ÉCRAN : page émotions ou analyse]

Un dernier point sur cette démonstration.
Chaque texte est aussi analysé
sur 7 dimensions émotionnelles :
colère, dégoût, joie, neutre,

peur, surprise, tristesse.

Pour vos équipes,
c'est un signal complémentaire.

Un post qui combine un score suspect
et une forte charge de colère
peut être priorisé dans votre file.

C'est ce que votre cahier des charges
demandait sous le nom
d'analyse émotionnelle.

[SLIDE 8 : Faithfulness methode]

Vous pourriez nous demander :
comment savez-vous que ces explications
refletent vraiment
le comportement du modele ?

C'est une question legitime.

Un outil qui explique mal
est pire qu'un outil qui n'explique pas.

On a mis en place un protocole de verification.

Le principe est simple :

on identifie les criteres
que l'explication designe comme les plus importants,
on les masque dans le texte,
et on regarde si la prediction du modele change.

Si elle change fortement,
c'est que l'explication pointait
les bons criteres.

[SLIDE 9 : courbe AOPC]

Le resultat :
nos explications sont 5,6 fois
plus predictives
qu'une attribution au hasard.

Dit autrement :
quand notre outil vous dit
"ce mot a fait basculer la decision",
c'est verifie et mesurable.

Pour les modeles de deep learning
comme CamemBERT,
on a utilise une technique d'attribution
au niveau de chaque mot.

On a aussi identifié les cas limites :
quand le modèle est très confiant,
les gradients saturent
et l'explication perd en précision.

C'est documenté dans notre Model Card —
on sait où nos explications sont fiables
et où elles doivent être lues
avec précaution.

Cette transparence sur les limites,
c'est exactement ce que l'AI Act
attend d'un système responsable.

Quand vous evaluez une solution,
vous regardez aussi la qualite du code —
est-ce que ca tiendra en production ?

537 tests automatises.

80 % de couverture de code.

Un quality gate sur notre CI/CD
qui rejette automatiquement
toute modification
descendant sous 75 %.

On a aussi fait du mutation testing —
on introduit volontairement
des erreurs dans le code
pour verifier que nos tests les detectent.

Sur le module le plus critique :
178 erreurs injectees,
143 detectees.

Taux de detection de 80,3 % —
au-dessus de la moyenne
des equipes Google.

En complement, un scan de securite
Trivy tourne a chaque commit
pour detecter les vulnerabilites connues.

Vos identifiants et mots de passe
sont isolees dans des variables d'environnement,
jamais exposes dans le code source.

C'est ce qui separe un prototype
d'un systeme que votre equipe
peut reprendre et maintenir.

[SLIDE 11 : Conformite]

Sur la conformite reglementaire —
un point crucial pour vous
si vous deployez de l'IA en Europe.

L'AI Act entre en application
le 2 aout 2026.

Nous avons classe ThumaCheck
en risque limite selon l'article 50.
Ca veut dire : obligation de transparence,
mais pas les contraintes des systemes a haut risque.

Article 13 — transparence :
couvert par notre Model Card,
un document standardise
qui decrit le modele, ses performances
et ses limites.

Article 14 — supervision humaine :
vos operateurs peuvent comprendre
et contester chaque decision
grace aux trois niveaux d'explication.

Cote RGPD :
article 22 — le droit d'explication
est couvert par nos outils d'explicabilite.

L'analyse d'impact sur la vie privee
est documentee.

Base legale : interet legitime
sur des posts publics.

Et si un utilisateur Bluesky
exerce son droit a l'effacement,
nous pouvons supprimer ses donnees
en moins de 5 secondes.

[SLIDE 12 : Green IT]

Le bilan carbone total
de tout le projet —
neuf versions de modeles,
six entrainements,
le pipeline d'explicabilite —
represente 6,9 grammes de CO₂.

C'est l'equivalent
d'un kilometre en voiture.

En production,
le modele principal V5 :
1,5 milliseconde par texte,
0,6 gramme de CO₂ par jour.

Les modeles lourds comme CamemBERT
ne servent qu'en analyse approfondie,
pas en traitement temps reel.

C'est un choix d'architecture
documente et assume :
performance et sobriete
ne sont pas incompatibles.

Notre methodologie suit le cycle CRISP-DM

adapte au machine learning :

comprendre, explorer, preparer,
modeliser, evaluer, deployer.

9 versions en 6 mois,

chacune documentee

avec metriques avant et apres.

La gestion de projet :

un planning detaille avec 16 lots de travail

et 28 jalons,

versionne sur GitHub.

Nos outils :

Git avec integration continue,

Docker Compose, MongoDB,

FastAPI pour l'API,

CodeCarbon pour le suivi carbone.

Le tout reproductible

en une seule commande.

[SLIDE 14 : ROI & Budget]

Parlons chiffres.

Le projet ThumaCheck
a coute environ 50 000 euros,
essentiellement en ressources humaines —
110 jours-homme repartis
entre le developpement
et la validation.

Zero euro de licence :
notre stack est 100 % open source.

Zero euro de cloud :
tout tourne en local sur Docker.

Le seul cout additionnel :
750 euros pour l'annotation
du jeu de test de reference.

En exploitation,
le cout mensuel
est d'environ 930 euros :
un serveur a 30 euros
et 2 jours de maintenance.

Pour 1,8 million de posts
analyses par mois,
ca revient a 0,0005 centime par post.

Ce que vous gagnez :
un facteur x10 de productivite
pour vos modérateurs,
une couverture de 60 000 posts par jour —
200 fois plus qu'un humain seul —
et une reduction de 67 %

des faux positifs
qui encombrent aujourd'hui
vos files de moderation.

[SLIDE 15 : Roadmap V10-V12]

En toute transparence, les limites.

L'accord entre nos deux annotateurs humains est de 0,498 sur l'échelle de Cohen — c'est un accord modéré.

Ca ne veut pas dire que le modèle est mauvais. Ca veut dire que la frontière entre fiable et suspect est intrinsèquement subjective, même pour des humains.

Notre F1 macro sur le jeu de test est de 0,67.

En cross-validation sur les données d'entraînement, il est de 0,91.

L'écart s'explique par cette subjectivité. C'est pourquoi ThumaCheck donne un score de confiance, pas un verdict définitif.

Vos analystes gardent le dernier mot.

ThumaCheck détecte des signaux de désinformation — le style, le ton, le sensationnalisme — pas la vérité factuelle.

C'est un outil d'aide à la décision, pas un juge.

La roadmap :

V10 intègre le suivi de modèles pour détecter les baisses de performance.

V11 ajoute la verification factuelle
avec des outils comme ClaimBuster.

Et V12 prevoit un audit d'equite
pour garantir que le modele
traite tous les sujets de maniere equilibree.

Pour conclure,
je reviens au F1 de 0,99 du debut.
Ce chiffre flatteur cachait un biais.
Nous l'avons detecte,
corrige,
et documente.

Aujourd'hui, ThumaCheck V9
est valide par 537 tests automatises,
80 % de taux de detection en mutation testing,
une analyse d'impact vie privree,
une Model Card,
et une explicabilite
dont on a prouve la fidelite.

ThumaCheck n'est pas un classifieur.
C'est un systeme de decision auditable —
defendable devant vos analystes,
devant vos regulateurs,
et devant votre direction.

Un score sans explication
est un verdict sans proces.
C'est la phrase qui a guide
chacune de nos decisions techniques
tout au long de ce projet.

Merci pour votre attention.
Le repository, le rapport technique
et la Model Card
sont accessibles via les QR codes

a l'ecran.

Nous sommes a votre disposition
pour vos questions.

FIN DU SCRIPT