

PROMPTEUR v5 — THUMACHECK

Niamato Consulting pour Thumalien

Presentation solo Azelie — Juillet 2026

AZELIE — HOOK (00:00 - 00:30)

[CAMERA] Bandeau : Azelie Bernard — Lead Technique & Architecture

En decembre 2025,

on collecte 100 000 posts Bluesky.

On entraine un modele

de detection de fake news.

On obtient un F1-score de 0,99

en cross-validation.

Et c'est precisement a ce moment-la

qu'on aurait du s'inquieter.

AZELIE — CONTEXTE CLIENT (00:30 - 01:30)

[SLIDE 1 : Titre projet]

Bonjour, je suis Azelie Bernard,

lead technique chez Niamato Consulting.

Nous sommes un cabinet d'expertise

Data et Intelligence Artificielle,

et vous nous avez mandates

pour developper une solution

de detection de desinformation sur Bluesky.

Vos equipes de fact-checking passent

en moyenne 3 a 5 minutes par post

pour evaluer sa fiabilite.

A 60 000 posts publics par jour

sur Bluesky, c'est intenable.

ThumaCheck est la solution

que nous avons construite pour vous.

Elle analyse un texte

en 1,5 milliseconde,

avec une explication auditable

a chaque decision.

Et si votre base de donnees

est temporairement indisponible,
le dashboard continue de fonctionner
en mode demonstration —
vos equipes ne sont jamais bloquées.

AZELIE — EQUIPE + PROBLEMATIQUE (01:30 - 03:00)

[SLIDE 2 : Equipe et roles]

Ce projet a ete realise
en binome.
Mon collegue Sebastien Lazcanotegui
a pris en charge la validation
et la qualite du machine learning.
C'est lui qui a pilote
l'annotation du gold set —
465 textes Bluesky annotes
par deux annotateurs humains —
le debiaisage des donnees,
et l'optimisation des hyperparametres.
De mon cote,
j'ai concu l'architecture du pipeline,
le dashboard
et les trois niveaux d'explicabilite.

[SLIDE 3 : Chiffres cles]

Bluesky :
35 millions d'utilisateurs,
protocole AT entierement ouvert,
plus de 60 000 posts publics par jour
analysables.
Aucune equipe de moderation centralisee.

Ce que nous vous livrons :
classifier un post
comme fiable ou suspect
en moins de 5 millisecondes,
en francais comme en anglais,
avec une explication
que vos equipes peuvent defendre
aupres de votre direction
et de vos regulateurs.

[SLIDE 4 : Les 4 exigences]

Des le depart,
nous avons fixe avec vous
quatre exigences non-negociables.

Transparence :
chaque score est explicable.

Bilinguisme :
français et anglais
à performance équivalente.

Frugalité :
moins de 5 ms par texte,
empreinte carbone mesurée.

Et conforme au RGPD
et à l'AI Act européen,
applicable en août 2026.

Ces quatre exigences
structurent toute la solution
que nous vous présentons aujourd'hui.

AZELIE — BIAIS REUTERS + ITERATIONS (03:00 - 04:30)

[ECRAN : notebook Jupyter, sortie F1=0.99]

Voici notre première version du pipeline.

Logistic Regression sur du TF-IDF,
30 000 features,
entraînée sur 197 782 articles.

Cross-validation à 5 plis :
F1 macro de 0,99.

Sur le papier, le projet est terminé.

[SLIDE 5 : F1=0.99 — LE PIEGE]

Sauf qu'on a regardé
quels mots avaient le plus de poids.

Et on a trouvé :
reuters, afp, associated press.

Le modèle n'apprenait pas
à détecter la désinformation.

Il apprenait à reconnaître
le style des agences de presse.

Sebastien a pilote le debiasage :
creation de la liste de termes d'agences
pour neutraliser ces signatures,
filtrage des annees artefacts 2015-2020,
et les tests de non-regression
apres chaque correction.
En parallele, il a lance
un GridSearch systematique
sur les hyperparametres du modele.

De la version 2 a la version 5,
on a corrige ce biais
et ajoute des donnees bilingues.
Le F1 en cross-validation
est descendu a 0,91.
Mais cette fois,
c'est un F1 honnete.

AZELIE — ARCHITECTURE (04:30 - 06:30)

[SLIDE 6 : Architecture C4]

A partir de cette base saine,
j'ai itere l'architecture
jusqu'a la version 9 actuelle.
Voici notre architecture.
Le flux suit trois couches :
donnees, intelligence artificielle, decision.

Premiere couche — les donnees.
Le collecteur se connecte a Bluesky
via le protocole AT
et stocke les posts dans MongoDB.
245 000 posts collectes a ce jour,
avec deduplication automatique
et reprise sur erreur reseau.

Deuxieme couche — l'intelligence artificielle.
Le pipeline analyse chaque texte
avec trois modeles complementaires.

V5 — notre modele principal :
il combine TF-IDF avec 17 features linguistiques

et 7 emotions detectees automatiquement.

C'est lui qui repond en 1,5 milliseconde.

V6 — un classifieur qui analyse

uniquement le style d'ecriture,

independamment du sujet.

Et CamemBERT — un modele de deep learning

specialise sur les textes courts en francais.

Le meta-learner V8 combine les trois

pour la decision finale.

Troisieme couche — la decision.

Le dashboard expose les resultats

avec cinq pages dediees a vos equipes

et trois niveaux d'explication.

Le tout est conteneurise avec Docker Compose —

une seule commande pour tout demarrer.

[SLIDE 7 : Pipeline cascade]

En production,

le pipeline fonctionne

en deux etapes.

La premiere etape separe

les opinions des faits —

parce que l'AI Act interdit

de qualifier une opinion de desinformation.

La seconde etape analyse uniquement

les contenus factuels.

Cette cascade a reduit

vos faux positifs de 57 a 21

sur notre jeu de test —

soit une baisse de 67 %,

validee statistiquement.

Concretement pour vous :

moins d'alertes inutiles

dans les files de moderation

de vos equipes.

AZELIE — DEMO DASHBOARD (06:30 - 09:30)

[ECRAN : dashboard Streamlit plein ecran]

Voici le dashboard ThumaCheck —

l'interface que vos équipes
utiliseront au quotidien.

Cinq pages.

Vue Globale :

245 000 posts collectes,
67 % classes fiables.

Chaque visualisation
a été pensée pour la décision :
la jauge de score utilise
un code couleur vert-rouge intuitif,
les barres d'explication montrent
ce qui pousse vers fiable ou suspect,
et la heatmap de mots-clés
guide l'œil de vos analystes
vers les passages critiques.

[ECRAN : soumettre texte fiable]

Premier test :

une dépêche scientifique du CNRS
publiée dans Nature.

Avant même d'évaluer la fiabilité,
le pipeline effectue un premier filtre.
Il vérifie si le texte exprime un fait
ou une opinion —
parce que l'AI Act interdit
de qualifier une opinion de désinformation.
Ici, le contenu est factuel.
On passe à l'étape d'analyse.

Regardons les trois modèles
travailler en parallèle.

V5 — TF-IDF principal —
score 0,94. Très fiable.

V6 — détecteur de style —
0,05 de suspicion.

Le style est neutre et informatif.

Le meta-learner V8 combine les deux
avec CamemBERT :
verdict FIABLE.

Le désaccord V5 / V6 : 0,01.

Quasi nul.

Les trois modeles sont en accord.

Emotion dominante : neutre a 65,8 %.

Pas de charge emotionnelle excessive.

Coherent avec un contenu scientifique.

Maintenant les trois niveaux
d'explication.

Premier niveau :

contributions SHAP par feature de style.

Ce sont les contributions exactes
de chaque caracteristique linguistique
au score V6.

Deuxieme niveau :

la heatmap d'attention CamemBERT.

CamemBERT decoupe le texte
en sous-unites de mots.

Les tokens en rouge intense —
ce sont les ancrs semantiques
qui ont guide la decision du modele.

Troisieme niveau :

la decomposition complete du meta-learner.

Le logit z vaut -0,918.

En probabilite : 28,5 % de suspicion.

Donc 71,5 % de fiabilite.

Decision FIABLE, seuil franchi.

On lit le poids exact de chaque modele,
coefficient par coefficient.

Vos analystes ont tout ce qu'il faut
pour justifier chaque decision
aupres de votre hierarchie —
et aupres de vos regulateurs.

[ECRAN : soumettre texte suspect]

Deuxieme test :

un texte sensationnaliste
typique des reseaux sociaux.

Stage 1 : factuel a 48 %.

On passe a l'analyse.

V5 — TF-IDF principal —

score 0,00 de fiabilité.

Zero. Aucun signal de crédibilité.

V6 — détecteur de style —

0,98 de suspicion.

Majuscules, points d'exclamation,

appel au partage, injonction à la peur.

Le meta-learner V8 :

logit $z = +0,991$.

72,9 % de suspicion.

Décision SUSPECT.

Désaccord V5/V6 : 0,02.

Les deux modèles sont en accord total.

Le dashboard liste automatiquement

les mots sensationnalistes :

"scandale", "on vous ment",

"partagez avant censure".

Ce sont exactement les marqueurs

que vos analystes cherchent

manuellement aujourd'hui.

Heatmap CamemBERT :

CamemBERT découpe les mots

en sous-unités —

SCANDALE → SC-AND-ALE,

CACHE → CA-CHE.

Les sous-tokens en rouge

sont ceux sur lesquels

le modèle concentre son attention.

Les termes alarmants ressortent.

Premier contributeur dans V8 :

score_v6_suspect à +0,567 vers SUSPECT.

C'est le style qui a fait basculer

la décision.

Pas le sujet — le style.

[ÉCRAN : page émotions ou analyse]

Dernier élément de cette démo :

l'émotion dominante.

Sur le texte fiable :

neutre à 65,8 %.

Sur ce texte suspect :

surprise a 74,6 %.

Les contenus de desinformation
utilisent deliberement la surprise
et la peur
pour contourner le sens critique.

Pour vos equipes,
un post SUSPECT
avec surprise elevee :
a prioriser en tete de file.

ThumaCheck analyse
7 dimensions emotionnelles :
colere, degout, joie, neutre,
peur, surprise, tristesse.
C'est ce que votre cahier des charges
demandait sous le nom
d'analyse emotionnelle.

AZELIE — XAI + FAITHFULNESS (09:30 - 12:00)

[SLIDE 8 : Faithfulness methode]

Vous pourriez nous demander :
comment savez-vous que ces explications
refletent vraiment
le comportement du modele ?
C'est une question legitime.
Un outil qui explique mal
est pire qu'un outil qui n'explique pas.

On a mis en place un protocole de verification.
Le principe est simple :
on identifie les criteres
que l'explication designe comme les plus importants,
on les masque dans le texte,
et on regarde si la prediction du modele change.
Si elle change fortement,
c'est que l'explication pointait
les bons criteres.

[SLIDE 9 : courbe AOPC]

Le resultat :

nos explications sont 5,6 fois
plus predictives

qu'une attribution au hasard.

Dit autrement :

quand notre outil vous dit

"ce mot a fait basculer la decision",

c'est verifie et mesurable.

Pour les modeles de deep learning

comme CamemBERT,

on a utilise une technique d'attribution

au niveau de chaque mot.

On a aussi identifie les cas limites :

quand le modele est tres confiant,

les gradients saturent

et l'explication perd en precision.

C'est documente dans notre Model Card —

on sait ou nos explications sont fiables

et ou elles doivent etre lues

avec precaution.

Cette transparence sur les limites,

c'est exactement ce que l'AI Act

attend d'un systeme responsable.

AZELIE — QUALITE INDUSTRIELLE (12:00 - 13:30)

[SLIDE 10 : Qualite industrielle]

Quand vous evaluez une solution,

vous regardez aussi la qualite du code —

est-ce que ca tiendra en production ?

537 tests automatises.

80 % de couverture de code.

Un quality gate sur notre CI/CD

qui rejette automatiquement

toute modification

descendant sous 75 %.

Sebastien a egalement mis en place

du mutation testing —

on introduit volontairement

des erreurs dans le code
pour vérifier que nos tests les détectent.
Sur le module le plus critique :
178 erreurs injectées,
143 détectées.
Taux de détection de 80,3 % —
au-dessus de la moyenne
des équipes Google.

En complément, un scan de sécurité
Trivy tourne à chaque commit
pour détecter les vulnérabilités connues.
Vos identifiants et mots de passe
sont isolés dans des variables d'environnement,
jamais exposés dans le code source.

C'est ce qui sépare un prototype
d'un système que votre équipe
peut reprendre et maintenir.

AZELIE — CONFORMITE + GREEN IT (13:30 - 15:00)

[SLIDE 11 : Conformité]
Sur la conformité réglementaire —
un point crucial pour vous
si vous déployez de l'IA en Europe.
L'AI Act entre en application
le 2 août 2026.

Nous avons classé ThumaCheck
en risque limité selon l'article 50.
Ca veut dire : obligation de transparence,
mais pas les contraintes des systèmes à haut risque.

Article 13 — transparence :
couvert par notre Model Card,
un document standardisé
qui décrit le modèle, ses performances
et ses limites.

Article 14 — supervision humaine :
vos opérateurs peuvent comprendre
et contester chaque décision
grâce aux trois niveaux d'explication.

Cote RGPD :

article 22 — le droit d'explication

est couvert par nos outils d'explicabilite.

L'analyse d'impact sur la vie privée

est documentée.

Base légale : intérêt légitime

sur des posts publics.

Et si un utilisateur Bluesky

exerce son droit à l'effacement,

nous pouvons supprimer ses données

en moins de 5 secondes.

[SLIDE 12 : Green IT]

Le bilan carbone total

de tout le projet —

neuf versions de modèles,

six entraînements,

le pipeline d'explicabilite —

représente 6,9 grammes de CO₂.

C'est l'équivalent

d'un kilomètre en voiture.

En production,

le modèle principal V5 :

1,5 milliseconde par texte,

0,6 gramme de CO₂ par jour.

Les modèles lourds comme CamemBERT

ne servent qu'en analyse approfondie,

pas en traitement temps réel.

C'est un choix d'architecture

documenté et assumé :

performance et sobriété

ne sont pas incompatibles.

AZELIE — METHODOLOGIE (15:00 - 15:45)

[SLIDE 13 : Methodologie]

Notre méthodologie suit le cycle CRISP-DM

adapté au machine learning :

comprendre, explorer, préparer,

modéliser, évaluer, déployer.

9 versions en 6 mois,
chacune documentée
avec métriques avant et après.

La gestion de projet :
un planning détaillé avec 16 lots de travail
et 28 jalons,
versionné sur GitHub.

Nos outils :
Git avec intégration continue,
Docker Compose, MongoDB,
FastAPI pour l'API,
CodeCarbon pour le suivi carbone.
Le tout reproductible
en une seule commande.

AZELIE — ROI & BUDGET (15:45 - 16:30)

[SLIDE 14 : ROI & Budget]

Parlons chiffres.
Le projet ThumaCheck
a coûté environ 50 000 euros,
essentiellement en ressources humaines —
110 jours-homme répartis
entre le développement
et la validation.

Zéro euro de licence :
notre stack est 100 % open source.

Zéro euro de cloud :
tout tourne en local sur Docker.

Le seul coût additionnel :
750 euros pour l'annotation
du jeu de test de référence.

En exploitation,
le coût mensuel
est d'environ 930 euros :
un serveur à 30 euros
et 2 jours de maintenance.
Pour 1,8 million de posts
analyses par mois,

ca revient a 0,0005 centime par post.

Ce que vous gagnez :

un facteur x10 de productivite

pour vos modérateurs,

une couverture de 60 000 posts par jour —

200 fois plus qu'un humain seul —

et une reduction de 67 %

des faux positifs

qui encombrent aujourd'hui

vos files de moderation.

AZELIE — LIMITES + ROADMAP (16:30 - 17:00)

[SLIDE 15 : Roadmap V10-V12]

En toute transparence, les limites.

L'accord entre nos deux annotateurs humains

est de 0,498 sur l'echelle de Cohen —

c'est un accord modere.

Ca ne veut pas dire

que le modele est mauvais.

Ca veut dire que la frontiere

entre fiable et suspect

est intrinsequement subjective,

meme pour des humains.

Notre F1 macro sur le jeu de test

est de 0,67.

En cross-validation sur les donnees

d'entrainement, il est de 0,91.

L'ecart s'explique par cette subjectivite.

C'est pourquoi ThumaCheck

donne un score de confiance,

pas un verdict definitif.

Vos analystes gardent le dernier mot.

ThumaCheck detecte

des signaux de desinformation —

le style, le ton, le sensationnalisme —

pas la verite factuelle.

C'est un outil d'aide a la decision,

pas un juge.

La roadmap :

V10 integre le suivi de modeles

pour detecter les baisses de performance.

V11 ajoute la verification factuelle

avec des outils comme ClaimBuster.

Et V12 prevoit un audit d'equite

pour garantir que le modele

traite tous les sujets de maniere equilibree.

AZELIE — CONCLUSION (17:00 - 18:00)

[SLIDE 16 : Citation]

Pour conclure,

je reviens au F1 de 0,99 du debut.

Ce chiffre flatteur cachait un biais.

Nous l'avons detecte,

corrige,

et documente.

Aujourd'hui, ThumaCheck V9

est valide par 537 tests automatises,

80 % de taux de detection en mutation testing,

une analyse d'impact vie privree,

une Model Card,

et une explicabilite

dont on a prouve la fidelite.

ThumaCheck n'est pas un classifieur.

C'est un systeme de decision auditable —

defendable devant vos analystes,

devant vos regulateurs,

et devant votre direction.

Un score sans explication

est un verdict sans proces.

C'est la phrase qui a guide

chacune de nos decisions techniques

tout au long de ce projet.

[SLIDE 17 : Remerciements + QR codes]

Merci pour votre attention.

Le repository, le rapport technique

et la Model Card
sont accessibles via les QR codes
a l'ecran.
Je suis a votre disposition
pour vos questions.

FIN DU SCRIPT