

# **PROMPTEUR v5 — THUMACHECK**

**Niamato Consulting pour Thumalien**

**Presentation solo Azelie — Juillet 2026**



En decembre 2025,  
on collecte 100 000 posts Bluesky.

On entraine un modele  
de detection de fake news.

On obtient un F1-score de 0,99  
en cross-validation.

Et c'est precisement a ce moment-la  
qu'on aurait du s'inquieter.



[SLIDE 1 : Titre projet]

Bonjour, je suis Azelie Bernard,  
lead technique chez Niamato Consulting.

Nous sommes un cabinet d'expertise  
Data et Intelligence Artificielle,  
et vous nous avez mandates  
pour developper une solution  
de detection de desinformation sur Bluesky.

Vos equipes de fact-checking passent  
en moyenne 3 a 5 minutes par post  
pour evaluer sa fiabilite.

A 60 000 posts publics par jour  
sur Bluesky, c'est intenable.

ThumaCheck est la solution  
que nous avons construite pour vous.

Elle analyse un texte  
en 1,5 milliseconde,  
avec une explication auditable  
a chaque decision.

Et si votre base de donnees  
est temporairement indisponible,  
le dashboard continue de fonctionner  
en mode demonstration —  
vos equipes ne sont jamais bloques.



## [SLIDE 2 : Equipe et roles]

Ce projet a ete realise  
en binome.

Mon collegue Sebastien Lazcanotegui  
a pris en charge la validation  
et la qualite du machine learning.

C'est lui qui a pilote  
l'annotation du gold set —  
465 textes Bluesky annotes  
par deux annotateurs humains —  
le debiaisage des donnees,  
et l'optimisation des hyperparametres.

De mon cote,  
j'ai concu l'architecture du pipeline,  
le dashboard  
et les trois niveaux d'explicabilite.

## [SLIDE 3 : Chiffres cles]

Bluesky :  
35 millions d'utilisateurs,  
protocole AT entierement ouvert,  
plus de 60 000 posts publics par jour  
analysables.

Aucune equipe de moderation centralisee.

Ce que nous vous livrons :  
classifier un post  
comme fiable ou suspect  
en moins de 5 millisecondes,  
en francais comme en anglais,  
avec une explication  
que vos equipes peuvent defendre

aupres de votre direction  
et de vos regulateurs.

[SLIDE 4 : Les 4 exigences]

Des le depart,  
nous avons fixe avec vous  
quatre exigences non-negociables.

Transparence :  
chaque score est explicable.

Bilinguisme :  
français et anglais  
à performance équivalente.

Frugalité :  
moins de 5 ms par texte,  
empreinte carbone mesurée.

Et conforme au RGPD  
et à l'AI Act européen,  
applicable en août 2026.

Ces quatre exigences  
structurent toute la solution  
que nous vous présentons aujourd'hui.





[ECRAN : notebook Jupyter, sortie F1=0.99]

Voici notre premiere version du pipeline.

Logistic Regression sur du TF-IDF,  
30 000 features,  
entrainee sur 197 782 articles.

Cross-validation a 5 plis :

F1 macro de 0,99.

Sur le papier, le projet est termine.

[SLIDE 5 : F1=0.99 — LE PIEGE]

Sauf qu'on a regarde  
quels mots avaient le plus de poids.

Et on a trouve :  
reuters, afp, associated press.

Le modele n'apprenait pas  
a detecter la desinformation.

Il apprenait a reconnaitre  
le style des agences de presse.

Sebastien a pilote le debiaisage :  
creation de la liste de termes d'agences  
pour neutraliser ces signatures,  
filtrage des annees artefacts 2015-2020,  
et les tests de non-regression  
apres chaque correction.

En parallele, il a lance  
un GridSearch systematique  
sur les hyperparametres du modele.

De la version 2 a la version 5,  
on a corrige ce biais  
et ajoute des donnees bilingues.

Le F1 en cross-validation

est descendu a 0,91.

Mais cette fois,

c'est un F1 honnête.



[SLIDE 6 : Architecture C4]

A partir de cette base saine,  
j'ai itere l'architecture  
jusqu'a la version 9 actuelle.

Voici notre architecture.

Le flux suit trois couches :  
donnees, intelligence artificielle, decision.

Premiere couche — les donnees.  
Le collecteur se connecte a Bluesky  
via le protocole AT  
et stocke les posts dans MongoDB.  
245 000 posts collectes a ce jour,  
avec deduplication automatique  
et reprise sur erreur reseau.

Deuxieme couche — l'intelligence artificielle.  
Le pipeline analyse chaque texte  
avec trois modeles complementaires.

V5 — notre modele principal :  
il combine TF-IDF avec 17 features linguistiques  
et 7 emotions detectees automatiquement.  
C'est lui qui repond en 1,5 milliseconde.

V6 — un classifieur qui analyse  
uniquement le style d'ecriture,  
independamment du sujet.

Et CamemBERT — un modele de deep learning  
specialise sur les textes courts en francais.

Le meta-learner V8 combine les trois  
pour la decision finale.

Troisieme couche — la decision.  
Le dashboard expose les resultats

avec cinq pages dédiées à vos équipes  
et trois niveaux d'explication.

Le tout est conteneurisé avec Docker Compose —  
une seule commande pour tout démarrer.

[SLIDE 7 : Pipeline cascade]

En production,  
le pipeline fonctionne  
en deux étapes.

La première étape sépare  
les opinions des faits —  
parce que l'AI Act interdit  
de qualifier une opinion de désinformation.

La seconde étape analyse uniquement  
les contenus factuels.

Cette cascade a réduit  
vos faux positifs de 57 à 21  
sur notre jeu de test —  
soit une baisse de 67 %,   
validée statistiquement.

Concrètement pour vous :  
moins d'alertes inutiles  
dans les files de modération  
de vos équipes.



[ECRAN : dashboard Streamlit plein écran]

Voici le dashboard ThumaCheck —  
l'interface que vos équipes  
utiliseront au quotidien.

Cinq pages.

Vue Globale :

245 000 posts collectes,  
67 % classes fiables.

Chaque visualisation  
a été pensée pour la décision :  
la jauge de score utilise  
un code couleur vert-rouge intuitif,  
les barres d'explication montrent  
ce qui pousse vers fiable ou suspect,  
et la heatmap de mots-cles  
guide l'œil de vos analystes  
vers les passages critiques.

[ECRAN : soumettre texte fiable]

Premier test : un communiqué scientifique.  
Score 0,89 — classe fiable.

Ce qui distingue ThumaCheck  
d'un outil boîte noire :  
trois niveaux d'explication.

Premier niveau :  
les mots les plus influents.  
Ce n'est pas une approximation —  
c'est la formule exacte du modèle.

Deuxième niveau :  
l'analyse du style d'écriture.  
La présence de citations



et la diversité du vocabulaire  
confirment un contenu fiable.

Troisième niveau :

la décomposition complète de la décision.

On lit le poids de chaque critère,  
coefficient par coefficient.

Vos analystes ont tout ce qu'il faut  
pour justifier chaque décision  
auprès de votre hiérarchie —  
et auprès de vos régulateurs.

[ECRAN : soumettre texte suspect]

Deuxième test :  
un texte sensationnaliste.

Score 0,12 de crédibilité,  
donc 88 % suspect.

Les explications s'inversent :  
le sensationnalisme du langage  
est identifié comme signal fort.

Et la heatmap d'attention  
surligne directement les mots problématiques :  
"SCANDALE" et "mentent"  
s'affichent en rouge.

C'est exactement ce que vos analystes  
veulent voir pour défendre leur décision.

[ECRAN : page émotions ou analyse]

Un dernier point sur cette démonstration.  
Chaque texte est aussi analysé  
sur 7 dimensions émotionnelles :  
colère, dégoût, joie, neutre,

peur, surprise, tristesse.

Pour vos équipes,  
c'est un signal complémentaire.

Un post qui combine un score suspect  
et une forte charge de colère  
peut être priorisé dans votre file.

C'est ce que votre cahier des charges  
demandait sous le nom  
d'analyse émotionnelle.



[SLIDE 8 : Faithfulness methode]

Vous pourriez nous demander :  
comment savez-vous que ces explications  
refletent vraiment  
le comportement du modele ?

C'est une question legitime.

Un outil qui explique mal  
est pire qu'un outil qui n'explique pas.

On a mis en place un protocole de verification.

Le principe est simple :

on identifie les criteres  
que l'explication designe comme les plus importants,  
on les masque dans le texte,  
et on regarde si la prediction du modele change.

Si elle change fortement,  
c'est que l'explication pointait  
les bons criteres.

[SLIDE 9 : courbe AOPC]

Le resultat :  
nos explications sont 5,6 fois  
plus predictives  
qu'une attribution au hasard.

Dit autrement :  
quand notre outil vous dit  
"ce mot a fait basculer la decision",  
c'est verifie et mesurable.

Pour les modeles de deep learning  
comme CamemBERT,  
on a utilise une technique d'attribution  
au niveau de chaque mot.

On a aussi identifié les cas limites :  
quand le modèle est très confiant,  
les gradients saturent  
et l'explication perd en précision.

C'est documenté dans notre Model Card —  
on sait où nos explications sont fiables  
et où elles doivent être lues  
avec précaution.

Cette transparence sur les limites,  
c'est exactement ce que l'AI Act  
attend d'un système responsable.



[SLIDE 10 : Qualite industrielle]

Quand vous evaluez une solution,  
vous regardez aussi la qualite du code —  
est-ce que ca tiendra en production ?

537 tests automatises.

80 % de couverture de code.

Un quality gate sur notre CI/CD  
qui rejette automatiquement  
toute modification  
descendant sous 75 %.

Sebastien a egalement mis en place  
du mutation testing —  
on introduit volontairement  
des erreurs dans le code  
pour verifier que nos tests les detectent.

Sur le module le plus critique :  
178 erreurs injectees,  
143 detectees.

Taux de detection de 80,3 % —  
au-dessus de la moyenne  
des equipes Google.

En complement, un scan de securite  
Trivy tourne a chaque commit  
pour detecter les vulnerabilites connues.

Vos identifiants et mots de passe  
sont isoles dans des variables d'environnement,  
jamais exposes dans le code source.

C'est ce qui separe un prototype  
d'un systeme que votre equipe

peut reprendre et maintenir.





[SLIDE 11 : Conformite]

Sur la conformite reglementaire —  
un point crucial pour vous  
si vous deployez de l'IA en Europe.

L'AI Act entre en application  
le 2 aout 2026.

Nous avons classe ThumaCheck  
en risque limite selon l'article 50.  
Ca veut dire : obligation de transparence,  
mais pas les contraintes des systemes a haut risque.

Article 13 — transparence :  
couvert par notre Model Card,  
un document standardise  
qui decrit le modele, ses performances  
et ses limites.

Article 14 — supervision humaine :  
vos operateurs peuvent comprendre  
et contester chaque decision  
grace aux trois niveaux d'explication.

Cote RGPD :  
article 22 — le droit d'explication  
est couvert par nos outils d'explicabilite.

L'analyse d'impact sur la vie privee  
est documentee.

Base legale : interet legitime  
sur des posts publics.

Et si un utilisateur Bluesky  
exerce son droit a l'effacement,  
nous pouvons supprimer ses donnees  
en moins de 5 secondes.

[SLIDE 12 : Green IT]

Le bilan carbone total  
de tout le projet —  
neuf versions de modeles,  
six entrainements,  
le pipeline d'explicabilite —  
represente 6,9 grammes de CO<sub>2</sub>.

C'est l'equivalent  
d'un kilometre en voiture.

En production,  
le modele principal V5 :  
1,5 milliseconde par texte,  
0,6 gramme de CO<sub>2</sub> par jour.

Les modeles lourds comme CamemBERT  
ne servent qu'en analyse approfondie,  
pas en traitement temps reel.

C'est un choix d'architecture  
documente et assume :  
performance et sobriete  
ne sont pas incompatibles.



[SLIDE 13 : Methodologie]

Notre methodologie suit le cycle CRISP-DM  
adapte au machine learning :  
comprendre, explorer, preparer,  
modeliser, evaluer, deployer.

9 versions en 6 mois,  
chacune documentee  
avec metriques avant et apres.

La gestion de projet :  
un planning detaille avec 16 lots de travail  
et 28 jalons,  
versionne sur GitHub.

Nos outils :  
Git avec integration continue,  
Docker Compose, MongoDB,  
FastAPI pour l'API,  
CodeCarbon pour le suivi carbone.

Le tout reproductible  
en une seule commande.



[SLIDE 14 : ROI & Budget]

Parlons chiffres.

Le projet ThumaCheck  
a coute environ 50 000 euros,  
essentiellement en ressources humaines —  
110 jours-homme repartis  
entre le developpement  
et la validation.

Zero euro de licence :  
notre stack est 100 % open source.

Zero euro de cloud :  
tout tourne en local sur Docker.

Le seul cout additionnel :  
750 euros pour l'annotation  
du jeu de test de reference.

En exploitation,  
le cout mensuel  
est d'environ 930 euros :  
un serveur a 30 euros  
et 2 jours de maintenance.

Pour 1,8 million de posts  
analyses par mois,  
ca revient a 0,0005 centime par post.

Ce que vous gagnez :  
un facteur x10 de productivite  
pour vos modérateurs,  
une couverture de 60 000 posts par jour —  
200 fois plus qu'un humain seul —  
et une reduction de 67 %

des faux positifs  
qui encombrent aujourd'hui  
vos files de moderation.





[SLIDE 15 : Roadmap V10-V12]

En toute transparence, les limites.

L'accord entre nos deux annotateurs humains est de 0,498 sur l'échelle de Cohen — c'est un accord modéré.

Ca ne veut pas dire que le modèle est mauvais. Ca veut dire que la frontière entre fiable et suspect est intrinsèquement subjective, même pour des humains.

Notre F1 macro sur le jeu de test est de 0,67.

En cross-validation sur les données d'entraînement, il est de 0,91.

L'écart s'explique par cette subjectivité. C'est pourquoi ThumaCheck donne un score de confiance, pas un verdict définitif.

Vos analystes gardent le dernier mot.

ThumaCheck détecte des signaux de désinformation — le style, le ton, le sensationnalisme — pas la vérité factuelle.

C'est un outil d'aide à la décision, pas un juge.

La roadmap :

V10 intègre le suivi de modèles pour détecter les baisses de performance.

V11 ajoute la verification factuelle  
avec des outils comme ClaimBuster.

Et V12 prevoit un audit d'equite  
pour garantir que le modele  
traite tous les sujets de maniere equilibree.



[SLIDE 16 : Citation]

Pour conclure,  
je reviens au F1 de 0,99 du debut.  
Ce chiffre flatteur cachait un biais.  
Nous l'avons detecte,  
corrige,  
et documente.

Aujourd'hui, ThumaCheck V9  
est valide par 537 tests automatises,  
80 % de taux de detection en mutation testing,  
une analyse d'impact vie privée,  
une Model Card,  
et une explicabilite  
dont on a prouve la fidelite.

ThumaCheck n'est pas un classifieur.  
C'est un systeme de decision auditable —  
defendable devant vos analystes,  
devant vos regulateurs,  
et devant votre direction.

Un score sans explication  
est un verdict sans proces.  
C'est la phrase qui a guide  
chacune de nos decisions techniques  
tout au long de ce projet.

[SLIDE 17 : Remerciements + QR codes]

Merci pour votre attention.  
Le repository, le rapport technique  
et la Model Card  
sont accessibles via les QR codes

a l'ecran.

Je suis a votre disposition  
pour vos questions.

**FIN DU SCRIPT**