

Script video 18 min — ThumaCheck (v4 client)

Duree cible : 18 min (15-20 min cadre MASTERE)

Format : screencast + voix off + inserts camera (intro, transitions, conclusion)

Speakers : Azelie Bernard (A) / Sebastien Lazcanotegui (S) — repartition 50/50

Entreprise : Niamato Consulting (expertise Data & IA)

Client : Thumalien (societe de fact-checking et veille mediatique)

Solution : ThumaCheck — pipeline NLP + dashboard de detection de desinformation

Audience : equipe dirigeante Thumalien + jury evaluateur

Objectif : convaincre Thumalien que ThumaCheck resout son probleme de moderation, avec ROI mesurable

Changements v3 -> v4** :

- Chiffres corriges (537 tests, 465 gold set, 17 features linguistiques)
- Ton recentre 100% client Thumalien (moins de jargon ML, plus de benefices)
- Module emotions rendu visible (exigences EMO-01 a EMO-05 du CDC)
- Securite mentionnee (exigences SEC-01 a SEC-04 du CDC)
- Mode demo mentionne (exigence DASH-05 du CDC)
- F1 gold 0.67 contextualise (kappa, subjectivite, outil d'aide)
- XAI vulgarise pour audience non-technique
- AI Act : date effective aout 2026, classification art. 50 risk limite
- RGPD : droit a l'effacement operationnel (< 5s)

Repartition du temps de parole

| Speaker | Sections | Duree |

| Azelie | Hook + Contexte client + Architecture + Demo dashboard + Emotions + XAI + Conclusion | ~9 min |

| Sebastien | Equipe + Problematique + Iterations + Qualite industrielle + Securite + Conformite + Green IT + Methodologie + Limites + ROI | ~9 min |

Arc narratif en 3 actes

Acte 1 — Le besoin (0:00 - 4:30) : le probleme client, l'equipe, le piege F1=0.99

Acte 2 — La solution (4:30 - 12:00) : architecture, demo live, emotions, explicabilite

Acte 3 — La valeur (12:00 - 18:00) : qualite, securite, conformite, ROI, methodologie, roadmap

Script chronometre

Notation** :

- `[A-CAM]` = Azelie face camera
- `[S-CAM]` = Sebastien face camera
- `[SCREEN]` = capture ecran ou demo live
- `[SLIDE N]` = slide projetee (numerotation PPTX 1-17)
- Bandeau nom affiche pour chaque prise de parole camera

00:00 - 00:30 — Hook (Azelie, camera)

[A-CAM] Bandeau : Azelie Bernard — Lead Technique & Architecture

En decembre 2025, on collecte 100 000 posts Bluesky.

On entraine un modele de detection de fake news.

*On obtient un F1-score de 0,99 en cross-validation.
Et c'est précisément a ce moment-la qu'on aurait du s'inquieter.*

00:30 - 01:30 — Contexte client et besoin (Azélie)

[SLIDE 1 : Titre projet]

*Bonjour, je suis Azélie Bernard, lead technique chez Niamato Consulting.
Nous sommes un cabinet d'expertise Data et Intelligence Artificielle,
et vous nous avez mandates pour développer une solution
de détection de désinformation sur Bluesky.*

*Vos équipes de fact-checking passent en moyenne
3 à 5 minutes par post pour évaluer sa fiabilité.
À 60 000 posts publics par jour sur Bluesky, c'est intenable.*

*ThumaCheck est la solution que nous avons construite pour vous.
Elle analyse un texte en 1,5 milliseconde,
avec une explication auditable à chaque décision.*

*Et si votre base de données est temporairement indisponible,
le dashboard continue de fonctionner en mode démonstration —
vos équipes ne sont jamais bloquées.*

01:30 - 03:00 — Équipe + problématique (Sébastien, caméra)

[S-CAM] Bandeau : Sébastien Lazcanotegui — Validation & Qualité ML

[SLIDE 2 : Équipe et rôles]

Bonjour, je suis Sébastien Lazcanotegui, consultant chez Niamato Consulting.

*Mon rôle : la validation et la qualité du machine learning.
J'ai piloté l'annotation du gold set — 465 textes Bluesky annotés
par deux annotateurs humains — le débiaisage des données,
et l'optimisation des hyperparamètres.*

*Azélie a conçu l'architecture du pipeline, le dashboard
et les trois niveaux d'explicabilité.*

[SLIDE 3 : Chiffres clés]

*Bluesky : 35 millions d'utilisateurs, protocole AT entièrement ouvert,
plus de 60 000 posts publics par jour analysables.
Aucune équipe de modération centralisée.*

*Ce que nous vous livrons :
classifier un post comme fiable ou suspect
en moins de 5 millisecondes, en français comme en anglais,
avec une explication que vos équipes peuvent défendre
auprès de votre direction et de vos régulateurs.*

[SLIDE 4 : Les 4 exigences]

*Dès le départ, nous avons fixé avec vous
quatre exigences non-négociables.
Transparence : chaque score est explicable.
Bilinguisme : français et anglais à performance équivalente.*

*Frugalite : moins de 5 ms par texte, empreinte carbone mesuree.
Et conforme au RGPD et a l'AI Act europeen,
applicable en aout 2026.
Ces quatre exigences structurent toute la solution
que nous vous presentons aujourd'hui.*

03:00 - 04:30 — La fausse victoire et les iterations (Sebastien)

[SCREEN : notebook Jupyter, sortie F1=0.99]

*Voici notre premiere version du pipeline.
Logistic Regression sur du TF-IDF, 30 000 features,
entrainee sur 197 782 articles.
Cross-validation a 5 plis : F1 macro de 0,99.
Sur le papier, le projet est termine.*

[SLIDE 5 : F1=0.99 — LE PIEGE]

*Sauf qu'on a regarde quels mots avaient le plus de poids.
Et on a trouve : reuters, afp, associated press.

Le modele n'apprenait pas a detecter la desinformation.
Il apprenait a reconnaitre le style des agences de presse.

C'est moi qui ai pilote le debiaisage : creation de la liste
de termes d'agences pour neutraliser ces signatures,
filtrage des annees artefacts 2015-2020, et les tests de non-regression
apres chaque correction.

En parallele, j'ai lance un GridSearch systematique
sur les hyperparametres du modele.

De la version 2 a la version 5, on a corrige ce biais
et ajoute des donnees bilingues.
Le F1 en cross-validation est descendu a 0,91.
Mais cette fois, c'est un F1 honnete.*

04:30 - 06:30 — Architecture et pipeline cascade (Azalie)

[A-CAM] Bandeau : Azalie Bernard — Lead Technique & Architecture

*A partir de cette base saine, j'ai itere l'architecture
jusqu'a la version 9 actuelle.*

[SLIDE 6 : Architecture C4]

*Voici notre architecture.
Le flux suit trois couches : donnees, intelligence artificielle, decision.

Premiere couche — les donnees.
Le collecteur se connecte a Bluesky via le protocole AT
et stocke les posts dans MongoDB.
245 000 posts collectes a ce jour,
avec deduplication automatique et reprise sur erreur reseau.

Deuxieme couche — l'intelligence artificielle.
Le pipeline analyse chaque texte avec trois modeles complementaires.*

V5 — notre modele principal : il combine TF-IDF avec 17 features linguistiques et 7 emotions detectees automatiquement. C'est lui qui repond en 1,5 milliseconde.

V6 — un classifieur qui analyse uniquement le style d'ecriture, independamment du sujet.

Et CamemBERT — un modele de deep learning specialise sur les textes courts en francais.

Le meta-learner V8 combine les trois pour la decision finale.

Troisieme couche — la decision.

Le dashboard expose les resultats avec cinq pages dediees a vos equipes et trois niveaux d'explication.

Le tout est conteneurise avec Docker Compose — une seule commande pour tout demarrer.

[SLIDE 7 : Pipeline cascade]

En production, le pipeline fonctionne en deux etapes.

La premiere etape separe les opinions des faits — parce que l'AI Act interdit de qualifier une opinion de desinformation.

La seconde etape analyse uniquement les contenus factuels.

Cette cascade a reduit vos faux positifs de 57 a 21 sur notre jeu de test — soit une baisse de 67 %, validee statistiquement.

Concretement pour vous : moins d'alertes inutiles dans les files de moderation de vos equipes.

06:30 - 09:30 — Demo dashboard live + Emotions (Azalie)

[SCREEN : dashboard Streamlit plein ecran]

Voici le dashboard ThumaCheck — l'interface que vos equipes utiliseront au quotidien.

Cinq pages. Vue Globale : 245 000 posts collectes, 67 % classes fiables.

Chaque visualisation a ete pensee pour la decision : la jauge de score utilise un code couleur vert-rouge intuitif, les barres d'explication montrent ce qui pousse vers fiable ou suspect, et la heatmap de mots-cles guide l'oeil de vos analystes vers les passages critiques.

[SCREEN : soumettre texte fiable]

Premier test : un communique scientifique.

Score 0,89 — classe fiable.

Ce qui distingue ThumaCheck d'un outil boite noire : trois niveaux d'explication.

Premier niveau : les mots les plus influents.

Ce n'est pas une approximation — c'est la formule exacte du modele.

Deuxieme niveau : l'analyse du style d'ecriture.

*La presence de citations et la diversite du vocabulaire
confirment un contenu fiable.*

Troisieme niveau : la decomposition complete de la decision.

On lit le poids de chaque critere, coefficient par coefficient.

Vos analystes ont tout ce qu'il faut

*pour justifier chaque decision aupres de votre hierarchie —
et aupres de vos regulateurs.*

[SCREEN : soumettre texte suspect]

Deuxieme test : un texte sensationnaliste.

Score 0,12 de credibilite, donc 88 % suspect.

Les explications s'inversent :

le sensationnalisme du langage est identifie comme signal fort.

Et la heatmap d'attention surligne directement les mots problematiques :

SCANDALE' et 'mentent' s'affichent en rouge.

C'est exactement ce que vos analystes

veulent voir pour defendre leur decision.

[SCREEN : page emotions ou analyse]

Un dernier point sur cette demo.

Chaque texte est aussi analyse

sur 7 dimensions emotionnelles :

colere, degout, joie, neutre, peur, surprise, tristesse.

Pour vos equipes, c'est un signal complementaire.

Un post qui combine un score suspect

et une forte charge de colere

peut etre priorise dans votre file.

C'est ce que votre cahier des charges demandait

sous le nom d'analyse emotionnelle.

09:30 - 12:00 — XAI et faithfulness (Azalie)

[SLIDE 8 : Faithfulness methode]

Vous pourriez nous demander :

comment savez-vous que ces explications

refletent vraiment le comportement du modele ?

C'est une question legitime.

Un outil qui explique mal est pire

qu'un outil qui n'explique pas.

On a mis en place un protocole de verification.

Le principe est simple :

on identifie les criteres que l'explication designe

comme les plus importants, on les masque dans le texte,

et on regarde si la prediction du modele change.

Si elle change fortement, c'est que l'explication

pointait les bons criteres.

[SLIDE 9 : courbe AOPC]

*Le resultat : nos explications sont 5,6 fois plus predictives
qu'une attribution au hasard.*

*Dit autrement : quand notre outil vous dit
ce mot a fait basculer la decision', c'est verifie et mesurable.*

*Pour les modeles de deep learning comme CamemBERT,
on a utilise une technique d'attribution au niveau de chaque mot.*

*On a aussi identifie les cas limites :
quand le modele est tres confiant, les gradients saturent
et l'explication perd en precision.*

*C'est documente dans notre Model Card —
on sait ou nos explications sont fiables
et ou elles doivent etre lues avec precaution.
Cette transparence sur les limites, c'est exactement
ce que l'AI Act attend d'un systeme responsable.*

12:00 - 13:30 — Qualite industrielle + Securite (Sebastien)

[S-CAM] Bandeau : Sebastien Lazcanotegui — Validation & Qualite ML

[SLIDE 10 : Qualite industrielle]

*Quand vous evaluez une solution,
vous regardez aussi la qualite du code —
est-ce que ca tiendra en production ?*

537 tests automatises. 80 % de couverture de code.

*Un quality gate sur notre CI/CD
qui rejette automatiquement toute modification
descendant sous 75 %.*

*On a aussi fait du mutation testing —
on introduit volontairement des erreurs dans le code
pour verifier que nos tests les detectent.*

*Sur le module le plus critique :
178 erreurs injectees, 143 detectees.
Taux de detection de 80,3 % —
au-dessus de la moyenne des equipes Google.*

*En complement, un scan de securite Trivy
tourne a chaque commit pour detecter les vulnerabilites connues.
Vos identifiants et mots de passe sont isolees
dans des variables d'environnement,
jamais exposes dans le code source.*

*C'est ce qui separe un prototype
d'un systeme que votre equipe peut reprendre et maintenir.*

13:30 - 15:00 — Conformite + Green IT (Sebastien)

[SLIDE 11 : Conformite]

*Sur la conformité réglementaire —
un point crucial pour vous si vous déployez de l'IA en Europe.
L'AI Act entre en application le 2 août 2026.*

*Nous avons classé ThumaCheck en risque limité selon l'article 50.
Ca veut dire : obligation de transparence,
mais pas les contraintes des systèmes à haut risque.*

*Article 13 — transparence : couvert par notre Model Card,
un document standardisé qui décrit le modèle,
ses performances et ses limites.*

*Article 14 — supervision humaine :
vos opérateurs peuvent comprendre et contester chaque décision
grâce aux trois niveaux d'explication.*

*Cote RGPD : article 22 — le droit d'explication
est couvert par nos outils d'explicabilité.*

L'analyse d'impact sur la vie privée est documentée.

Base légale : intérêt légitime sur des posts publics.

*Et si un utilisateur Bluesky exerce son droit à l'effacement,
nous pouvons supprimer ses données en moins de 5 secondes.*

[SLIDE 12 : Green IT]

*Le bilan carbone total de tout le projet —
neuf versions de modèles, six entraînements,
le pipeline d'explicabilité — représente 6,9 grammes de CO₂.
C'est l'équivalent d'un kilomètre en voiture.*

En production, le modèle principal V5 :

1,5 milliseconde par texte, 0,6 gramme de CO₂ par jour.

*Les modèles lourds comme CamemBERT ne servent qu'en analyse approfondie,
pas en traitement temps réel.*

*C'est un choix d'architecture documenté et assumé :
performance et sobriété ne sont pas incompatibles.*

15:00 - 15:45 — Méthodologie et organisation (Sebastien)

[S-CAM] Bandeau : Sebastien Lazcanotegui — Validation & Qualité ML

[SLIDE 13 : Méthodologie]

*Notre méthodologie suit le cycle CRISP-DM adapté au ML :
comprendre, explorer, préparer, modéliser, évaluer, déployer.
9 versions en 6 mois, chacune documentée avec métriques avant et après.*

*La gestion de projet : un planning détaillé avec 16 lots de travail
et 28 jalons, versionné sur GitHub.*

Nos outils : Git avec intégration continue,

Docker Compose, MongoDB, FastAPI pour l'API,

CodeCarbon pour le suivi carbone.

Le tout reproductible en une seule commande.

15:45 - 16:30 — ROI, budget et valeur business (Sebastien)

[SLIDE 14 : ROI & Budget]

Parlons chiffres. Le projet ThumaCheck a coute environ 50 000 euros, essentiellement en ressources humaines — 110 jours-homme repartis entre le developpement et la validation.

Zero euro de licence : notre stack est 100 % open source.

Zero euro de cloud : tout tourne en local sur Docker.

Le seul cout additionnel : 750 euros pour l'annotation du jeu de test de reference.

En exploitation, le cout mensuel est d'environ 930 euros : un serveur a 30 euros et 2 jours de maintenance.

Pour 1,8 million de posts analyses par mois, ca revient a 0,0005 centime par post.

Ce que vous gagnez : un facteur x10 de productivite pour vos modérateurs, une couverture de 60 000 posts par jour — 200 fois plus qu'un humain seul — et une reduction de 67 % des faux positifs qui encombrent aujourd'hui vos files de moderation.

16:30 - 17:00 — Limites et roadmap (Sebastien)

[SLIDE 15 : Roadmap V10-V12]

En toute transparence, les limites.

L'accord entre nos deux annotateurs humains est de 0,498 sur l'echelle de Cohen — c'est un accord modere.

Ca ne veut pas dire que le modele est mauvais.

Ca veut dire que la frontiere entre fiable et suspect est intrinsequement subjective, meme pour des humains.

Notre F1 macro sur le jeu de test est de 0,67.

En cross-validation sur les donnees d'entrainement, il est de 0,91.

L'ecart s'explique par cette subjectivite.

C'est pourquoi ThumaCheck donne un score de confiance, pas un verdict definitif. Vos analystes gardent le dernier mot.

ThumaCheck detecte des signaux de desinformation — le style, le ton, le sensationnalisme — pas la verite factuelle.

C'est un outil d'aide a la decision, pas un juge.

La roadmap : V10 integre le suivi de modeles pour detecter les baisses de performance.

V11 ajoute la verification factuelle avec des outils comme ClaimBuster.

Et V12 prevoit un audit d'equite pour garantir que le modele traite tous les sujets de maniere equilibree.

17:00 - 18:00 — Conclusion (Azalie, camera)

[A-CAM] Bandeau : Azelie Bernard — Lead Technique & Architecture

[SLIDE 16 : Citation]

*Pour conclure, je reviens au F1 de 0,99 du debut.
Ce chiffre flatteur cachait un biais.
Nous l'avons detecte, corrige, et documente.
Aujourd'hui, ThumaCheck V9
est valide par 537 tests automatises,
80 % de taux de detection en mutation testing,
une analyse d'impact vie privree, une Model Card,
et une explicabilite dont on a prouve la fidelite.
ThumaCheck n'est pas un classifieur.
C'est un systeme de decision auditable —
defendable devant vos analystes,
devant vos regulateurs, et devant votre direction.
Un score sans explication est un verdict sans proces.
C'est la phrase qui a guide
chacune de nos decisions techniques tout au long de ce projet.*

[SLIDE 17 : Remerciements + QR codes]

*Merci pour votre attention.
Le repository, le rapport technique et la Model Card
sont accessibles via les QR codes a l'ecran.
Nous sommes a votre disposition pour vos questions.*

Tableau recapitulatif du temps de parole

Section	Speaker	Duree	Slides
Hook intro	Azelie	0:30	— (camera)
Contexte client + besoin + mode demo	Azelie	1:00	1
Equipe + problematique + exigences	Sebastien	1:30	2, 3, 4
Biais Reuters + iterations	Sebastien	1:30	5
Architecture + pipeline cascade	Azelie	2:00	6, 7
Demo dashboard + emotions	Azelie	3:00	— (screencast)
XAI + faithfulness	Azelie	2:30	8, 9
Qualite industrielle + securite	Sebastien	1:30	10
Conformite + Green IT	Sebastien	1:30	11, 12
Methodologie + organisation	Sebastien	0:45	13
ROI et valeur business	Sebastien	0:45	14
Limites + roadmap	Sebastien	0:30	15
Conclusion	Azelie	1:00	16, 17
TOTAL Azelie		~9:00	
TOTAL Sebastien		~9:00	

Couverture des exigences CDC (CDC-THUM-2026-001)

Module CDC	Exigences	Couvert dans la video	Timing
COL	COL-01 a COL-08	COL-01 (AT Protocol), COL-04 (deduplication), COL-05 (reprise erreur)	04:30
STO	STO-01 a STO-06	STO-01 (MongoDB), STO-02 (245K docs), STO-06 (enrichissements)	04:30
DET	DET-01 a DET-12	Tous couverts (F1, bilinguisme, seuil, explicabilite, debiaisage)	03:00-06:30
EMO	EMO-01 a EMO-05	EMO-01 (7 emotions), EMO-04 (bilingue), EMO-05 (features pipeline)	08:30
DASH	DASH-01 a DASH-09	DASH-01 (Streamlit), DASH-02 (5 pages), DASH-04 (analyse), DASH-05 (mode demo), DASH-06 (XAI), DASH-07 (dark theme)	06:30-09:30
XAI	XAI-01 a XAI-05	Tous couverts (SHAP, faithfulness, IG, attention, audience)	09:30-12:00
PERF	PERF-01 a PERF-06	PERF-02 (< 5ms), PERF-05 (modele leger)	04:30, 14:30
SEC	SEC-01 a SEC-04	SEC-01/02 (.env), SEC-04 (Trivy)	12:00-13:30
FIA	FIA-01 a FIA-05	FIA-04 (Docker restart), FIA-05 (volumes)	04:30, 15:00

Checklist conformite cadre pedagogique

- [x] 15-20 minutes (cible 18 min)
- [x] Prise de parole des deux membres (50/50)
- [x] Bandeau nom affiche pour chaque speaker
- [x] Structure besoin - solution - demo
- [x] Presentation de l'entreprise/contexte client et de l'equipe
- [x] Analyse de la problematique et introduction a la solution
- [x] Organisation et methodologies (CRISP-DM, Gantt, CI/CD)
- [x] Presentation de la solution technique
- [x] Pipeline donnees - IA - decision (explicitement nomme)
- [x] Metriques d'evaluation detaillees
- [x] Demo live du dashboard (screencast)
- [x] Module emotions demontre (7 classes, signal complementaire)
- [x] Securite (variables env, scan Trivy, isolation)
- [x] ROI et impact quantifie (temps, volume, risque, cout)
- [x] Conformite reglementaire (AI Act art. 50, RGPD art. 22, AIPD)
- [x] Limites assumees + contextualisation (kappa, subjectivite)
- [x] Perspectives et roadmap (V10-V12)
- [x] Qualite industrielle (537 tests, coverage, mutation)
- [x] Posture professionnelle (ton client, pas academique)
- [x] Valorisation dataviz (choix visuels justifies dans la demo)
- [x] Green IT avec donnees reelles + comparaison tangible (1 km voiture)
- [x] Mode demo mentionne (DASH-05)
- [x] Droit a l'effacement RGPD operationnel (< 5s)

Ordre d'enregistrement recommande

Session 1 — Sebastien (toutes ses sections)

1. Section equipe + problematique (01:30-03:00) — 2 prises
2. Section biais Reuters + iterations (03:00-04:30) — 2 prises
3. Section qualite industrielle + securite (12:00-13:30) — 2 prises
4. Section conformite + Green IT (13:30-15:00) — 2 prises
5. Section methodologie (15:00-15:45) — 2 prises
6. Section ROI (15:45-16:30) — 2 prises
7. Section limites + roadmap (16:30-17:00) — 2 prises

Session 2 — Azelie (toutes ses sections)

1. Hook intro (00:00-00:30) — 5 prises (c'est l'ouverture, soigner)
2. Contexte client (00:30-01:30) — 2 prises
3. Section architecture (04:30-06:30) — 2 prises
4. Section demo dashboard + emotions (06:30-09:30) — 3 prises (la demo peut rater)
5. Section XAI + faithfulness (09:30-12:00) — 2 prises
6. Conclusion (17:00-18:00) — 5 prises (c'est la fermeture, soigner)

Session 3 — Captures ecran (sans voix)

Enregistrer toutes les navigations dashboard separement,
puis synchroniser au montage.

Script video Thumalien V9 — v4 client — Juillet 2026