

Script video 18 min — ThumaCheck (v5 solo)

****Duree cible**** : 18 min (15-20 min cadre MASTERE)

****Format**** : screencast + voix off + inserts camera (intro, transitions, conclusion)

****Speaker**** : Azelie Bernard (presentation solo)

****Entreprise**** : Niamato Consulting (expertise Data & IA)

****Client**** : Thumalien (societe de fact-checking et veille mediatique)

****Solution**** : ThumaCheck — pipeline NLP + dashboard de detection de desinformation

****Audience**** : equipe dirigeante Thumalien + jury evaluateur

****Objectif**** : convaincre Thumalien que ThumaCheck resout son probleme de moderation, avec ROI mesurable

*Changements v4 -> v5** :*

- *Presentation solo Azelie (Sebastien absent pour l'enregistrement)*
- *Sections de Sebastien reecrites a la 3e personne, presentees par Azelie*
- *Credits explicites a Sebastien sur ses contributions (debiasage, annotation, mutation testing)*
- *Directions camera simplifiees (plus de [S-CAM])*
- *Conclusion adaptee ("je suis a votre disposition" au singulier)*

Arc narratif en 3 actes

****Acte 1 — Le besoin (0:00 - 4:30)**** : le probleme client, l'equipe, le piege $F1=0.99$

****Acte 2 — La solution (4:30 - 12:00)**** : architecture, demo live, emotions, explicabilite

****Acte 3 — La valeur (12:00 - 18:00)**** : qualite, securite, conformite, ROI, methodologie, roadmap

Script chronometre

*Notation** :*

- *`[A-CAM]` = Azelie face camera*
- *`[SCREEN]` = capture ecran ou demo live*
- *`[SLIDE N]` = slide projetee (numerotation PPTX 1-17)*
- *Bandeau nom affiche pour chaque prise de parole camera*

00:00 - 00:30 — Hook (Azelie, camera)

*`[A-CAM]` *Bandeau : Azelie Bernard — Lead Technique & Architecture**

En decembre 2025, on collecte 100 000 posts Bluesky.

On entraine un modele de detection de fake news.

On obtient un F1-score de 0,99 en cross-validation.

Et c'est precisement a ce moment-la qu'on aurait du s'inquieter.

00:30 - 01:30 — Contexte client et besoin (Azelie)

`[SLIDE 1 : Titre projet]`

*Bonjour, je suis Azelie Bernard, lead technique chez Niamato Consulting.
Nous sommes un cabinet d'expertise Data et Intelligence Artificielle,
et vous nous avez mandates pour developper une solution
de detection de desinformation sur Bluesky.*

>

*Vos equipes de fact-checking passent en moyenne
3 a 5 minutes par post pour evaluer sa fiabilite.
A 60 000 posts publics par jour sur Bluesky, c'est intenable.*

>

*ThumaCheck est la solution que nous avons construite pour vous.
Elle analyse un texte en 1,5 milliseconde,
avec une explication auditable a chaque decision.*

>

*Et si votre base de donnees est temporairement indisponible,
le dashboard continue de fonctionner en mode demonstration —
vos equipes ne sont jamais blokees.*

01:30 - 03:00 — Equipe + problematique (Azelie)

`[A-CAM]` *Bandeau : Azelie Bernard — Lead Technique & Architecture*

`[SLIDE 2 : Equipe et roles]`

Ce projet a ete realise en binome.

>

*Mon collegue Sebastien Lazcanotegui a pris en charge
la validation et la qualite du machine learning.
C'est lui qui a pilote l'annotation du gold set —
465 textes Bluesky annotes par deux annotateurs humains —
le debiaisage des donnees,
et l'optimisation des hyperparametres.*

>

*De mon cote, j'ai concu l'architecture du pipeline,
le dashboard et les trois niveaux d'explicabilite.*

`[SLIDE 3 : Chiffres cles]`

*Bluesky : 35 millions d'utilisateurs, protocole AT entierement ouvert,
plus de 60 000 posts publics par jour analysables.
Aucune equipe de moderation centralisee.*

>

*Ce que nous vous livrons :
classifier un post comme fiable ou suspect
en moins de 5 millisecondes, en francais comme en anglais,
avec une explication que vos equipes peuvent defendre*

aupres de votre direction et de vos regulateurs.

`[SLIDE 4 : Les 4 exigences]`

Des le depart, nous avons fixe avec vous

quatre exigences non-negociables.

Transparence : chaque score est explicable.

Bilinguisme : francais et anglais a performance equivalente.

Frugalite : moins de 5 ms par texte, empreinte carbone mesuree.

Et conformite au RGPD et a l'AI Act europeen,

applicable en aout 2026.

Ces quatre exigences structurent toute la solution

que nous vous presentons aujourd'hui.

03:00 - 04:30 — La fausse victoire et les iterations (Azalie)

`[SCREEN : notebook Jupyter, sortie F1=0.99]`

Voici notre premiere version du pipeline.

Logistic Regression sur du TF-IDF, 30 000 features,

entrainee sur 197 782 articles.

Cross-validation a 5 plis : F1 macro de 0,99.

Sur le papier, le projet est termine.

`[SLIDE 5 : F1=0.99 — LE PIEGE]`

Sauf qu'on a regarde quels mots avaient le plus de poids.

Et on a trouve : reuters, afp, associated press.

>

Le modele n'apprenait pas a detecter la desinformation.

Il apprenait a reconnaitre le style des agences de presse.

>

Sebastien a pilote le debiaisage : creation de la liste

de termes d'agences pour neutraliser ces signatures,

filtrage des annees artefacts 2015-2020, et les tests de non-regression

apres chaque correction.

>

En parallele, il a lance un GridSearch systematique

sur les hyperparametres du modele.

>

De la version 2 a la version 5, on a corrige ce biais

et ajoute des donnees bilingues.

Le F1 en cross-validation est descendu a 0,91.

Mais cette fois, c'est un F1 honnete.

04:30 - 06:30 — Architecture et pipeline cascade (Azalie)

`[A-CAM]` *Bandeau : Azelie Bernard — Lead Technique & Architecture*

*A partir de cette base saine, j'ai itere l'architecture
jusqu'a la version 9 actuelle.*

`[SLIDE 6 : Architecture C4]`

Voici notre architecture.

Le flux suit trois couches : donnees, intelligence artificielle, decision.

>

Premiere couche — les donnees.

*Le collecteur se connecte a Bluesky via le protocole AT
et stocke les posts dans MongoDB.*

*245 000 posts collectes a ce jour,
avec deduplication automatique et reprise sur erreur reseau.*

>

Deuxieme couche — l'intelligence artificielle.

Le pipeline analyse chaque texte avec trois modeles complementaires.

*V5 — notre modele principal : il combine TF-IDF
avec 17 features linguistiques et 7 emotions detectees automatiquement.
C'est lui qui repond en 1,5 milliseconde.*

*V6 — un classifieur qui analyse uniquement le style d'ecriture,
independamment du sujet.*

*Et CamemBERT — un modele de deep learning
specialise sur les textes courts en francais.*

Le meta-learner V8 combine les trois pour la decision finale.

>

Troisieme couche — la decision.

*Le dashboard expose les resultats avec cinq pages dediees
a vos equipes et trois niveaux d'explication.*

*Le tout est conteneurise avec Docker Compose —
une seule commande pour tout demarrer.*

`[SLIDE 7 : Pipeline cascade]`

En production, le pipeline fonctionne en deux etapes.

*La premiere etape separe les opinions des faits —
parce que l'AI Act interdit de qualifier une opinion de desinformation.*

La seconde etape analyse uniquement les contenus factuels.

>

*Cette cascade a reduit vos faux positifs de 57 a 21
sur notre jeu de test — soit une baisse de 67 %,
validee statistiquement.*

*Concretement pour vous :
moins d'alertes inutiles dans les files de moderation*

de vos équipes.

06:30 - 09:30 — Demo dashboard live + Emotions (Azélie)

`[SCREEN : dashboard Streamlit plein écran]`

Voici le dashboard ThumaCheck —

l'interface que vos équipes utiliseront au quotidien.

*Cinq pages. Vue Globale : 245 000 posts collectes,
67 % classes fiables.*

>

Chaque visualisation a été pensée pour la décision :

la jauge de score utilise un code couleur vert-rouge intuitif,

les barres d'explication montrent ce qui pousse vers fiable ou suspect,

et la heatmap de mots-clés guide l'œil de vos analystes

vers les passages critiques.

`[SCREEN : soumettre texte fiable]`

Premier test : une dépêche scientifique du CNRS publiée dans Nature.

>

Avant même d'évaluer la fiabilité, le pipeline effectue un premier filtre.

Il vérifie si le texte exprime un fait ou une opinion —

parce que l'AI Act interdit de qualifier une opinion de désinformation.

Ici, le contenu est bien factuel. On passe à l'étape d'analyse.

>

Regardons maintenant les trois modèles travailler en parallèle.

V5 — notre modèle TF-IDF principal — donne un score de 0,94.

Tres fiable.

V6 — le détecteur de style — affiche 0,05 de suspicion.

Le style d'écriture est neutre et informatif.

Le meta-learner V8 combine ces deux signaux avec CamemBERT

et rend son verdict : FIABLE.

>

Le désaccord entre V5 et V6 est de 0,01 — quasi nul.

Les trois modèles sont en accord. C'est un signal fort de cohérence.

>

L'émotion dominante : neutre à 65,8 %.

Pas de charge émotionnelle excessive. Cohérent avec un contenu scientifique.

>

Maintenant les trois niveaux d'explication.

>

Premier niveau : les contributions SHAP par feature de style.

Ce ne sont pas des approximations — ce sont les contributions exactes

de chaque caractéristique linguistique au score V6.

>

Deuxieme niveau : la heatmap d'attention CamemBERT.

*Les tokens surlignés en rouge sont ceux sur lesquels
le modele de deep learning a concentre son attention.*

CNRS et Nature ont un poids fort — des ancres de credibilite.

>

Troisieme niveau : la decomposition complete du meta-learner V8.

Le logit z vaut -0,918. Transforme en probabilite : 28,5 % de suspicion.

Donc 71,5 % de fiabilite. Decision FIABLE, seuil franchi.

*On lit le poids exact de chaque modele dans la decision finale,
coefficient par coefficient.*

>

*Vos analystes ont tout ce qu'il faut
pour justifier chaque decision aupres de votre hierarchie —
et aupres de vos regulateurs.*

`[SCREEN : soumettre texte suspect]`

Deuxieme test : un texte sensationnaliste.

Score 0,12 de credibilite, donc 88 % suspect.

Les explications s'inversent :

le sensationnalisme du langage est identifie comme signal fort.

>

Et la heatmap d'attention surligne directement les mots problematiques :

'SCANDALE' et 'mentent' s'affichent en rouge.

*C'est exactement ce que vos analystes
veulent voir pour defendre leur decision.*

`[SCREEN : page emotions ou analyse]`

Un dernier point sur cette demo.

*Chaque texte est aussi analyse
sur 7 dimensions emotionnelles :
colere, degout, joie, neutre, peur, surprise, tristesse.*

>

Pour vos equipes, c'est un signal complementaire.

*Un post qui combine un score suspect
et une forte charge de colere
peut etre priorise dans votre file.*

*C'est ce que votre cahier des charges demandait
sous le nom d'analyse emotionnelle.*

09:30 - 12:00 — XAI et faithfulness (Azalie)

`[SLIDE 8 : Faithfulness methode]`

*Vous pourriez nous demander :
comment savez-vous que ces explications
refletent vraiment le comportement du modele ?*

>

*C'est une question legitime.
Un outil qui explique mal est pire
qu'un outil qui n'explique pas.*

>

*On a mis en place un protocole de verification.
Le principe est simple :
on identifie les criteres que l'explication designe
comme les plus importants, on les masque dans le texte,
et on regarde si la prediction du modele change.
Si elle change fortement, c'est que l'explication
pointait les bons criteres.*

`[SLIDE 9 : courbe AOPC]`

*Le resultat : nos explications sont 5,6 fois plus predictives
qu'une attribution au hasard.
Dit autrement : quand notre outil vous dit
'ce mot a fait basculer la decision', c'est verifie et mesurable.*

>

*Pour les modeles de deep learning comme CamemBERT,
on a utilise une technique d'attribution au niveau de chaque mot.
On a aussi identifie les cas limites :
quand le modele est tres confiant, les gradients saturent
et l'explication perd en precision.*

>

*C'est documente dans notre Model Card —
on sait ou nos explications sont fiables
et ou elles doivent etre lues avec precaution.
Cette transparence sur les limites, c'est exactement
ce que l'AI Act attend d'un systeme responsable.*

12:00 - 13:30 — Qualite industrielle + Securite (Azalie)

`[A-CAM]` *Bandeau : Azalie Bernard — Lead Technique & Architecture*

`[SLIDE 10 : Qualite industrielle]`

*Quand vous evaluez une solution,
vous regardez aussi la qualite du code —
est-ce que ca tiendra en production ?*

>

537 tests automatisés. 80 % de couverture de code.
Un quality gate sur notre CI/CD
qui rejette automatiquement toute modification
descendant sous 75 %.

>

Sebastien a également mis en place du mutation testing —
on introduit volontairement des erreurs dans le code
pour vérifier que nos tests les détectent.
Sur le module le plus critique :
178 erreurs injectées, 143 détectées.
Taux de détection de 80,3 % —
au-dessus de la moyenne des équipes Google.

>

En complément, un scan de sécurité Trivy
tourne à chaque commit pour détecter les vulnérabilités connues.
Vos identifiants et mots de passe sont isolés
dans des variables d'environnement,
jamais exposés dans le code source.

>

C'est ce qui sépare un prototype
d'un système que votre équipe peut reprendre et maintenir.

13:30 - 15:00 — Conformité + Green IT (Azélie)

`[SLIDE 11 : Conformité]`

Sur la conformité réglementaire —
un point crucial pour vous si vous déployez de l'IA en Europe.
L'AI Act entre en application le 2 août 2026.

>

Nous avons classé ThumaCheck en risque limité selon l'article 50.
Ca veut dire : obligation de transparence,
mais pas les contraintes des systèmes à haut risque.

>

Article 13 — transparence : couvert par notre Model Card,
un document standardisé qui décrit le modèle,
ses performances et ses limites.
Article 14 — supervision humaine :
vos opérateurs peuvent comprendre et contester chaque décision
grâce aux trois niveaux d'explication.

>

*Cote RGPD : article 22 — le droit d'explication
est couvert par nos outils d'explicabilite.
L'analyse d'impact sur la vie privree est documentee.
Base legale : interet legitime sur des posts publics.
Et si un utilisateur Bluesky exerce son droit a l'effacement,
nous pouvons supprimer ses donnees en moins de 5 secondes.*

`[SLIDE 12 : Green IT]`

*Le bilan carbone total de tout le projet —
neuf versions de modeles, six entrainements,
le pipeline d'explicabilite — represente 6,9 grammes de CO2.
C'est l'equivalent d'un kilometre en voiture.*

>

*En production, le modele principal V5 :
1,5 milliseconde par texte, 0,6 gramme de CO2 par jour.
Les modeles lourds comme CamemBERT ne servent qu'en analyse approfondie,
pas en traitement temps reel.
C'est un choix d'architecture documente et assume :
performance et sobriete ne sont pas incompatibles.*

15:00 - 15:45 — Methodologie et organisation (Azalie)

`[A-CAM]` *Bandeau : Azalie Bernard — Lead Technique & Architecture*

`[SLIDE 13 : Methodologie]`

*Notre methodologie suit le cycle CRISP-DM adapte au ML :
comprendre, explorer, preparer, modeliser, evaluer, deployer.
9 versions en 6 mois, chacune documentee avec metriques avant et apres.*

>

*La gestion de projet : un planning detaille avec 16 lots de travail
et 28 jalons, versionne sur GitHub.
Nos outils : Git avec integration continue,
Docker Compose, MongoDB, FastAPI pour l'API,
CodeCarbon pour le suivi carbone.
Le tout reproductible en une seule commande.*

15:45 - 16:30 — ROI, budget et valeur business (Azalie)

`[SLIDE 14 : ROI & Budget]`

*Parlons chiffres. Le projet ThumaCheck a coute environ 50 000 euros,
essentiellement en ressources humaines — 110 jours-homme repartis
entre le developpement et la validation.*

>

Zero euro de licence : notre stack est 100 % open source.

Zero euro de cloud : tout tourne en local sur Docker.
Le seul cout additionnel : 750 euros pour l'annotation
du jeu de test de reference.

>

En exploitation, le cout mensuel est d'environ 930 euros :
un serveur a 30 euros et 2 jours de maintenance.
Pour 1,8 million de posts analyses par mois,
ca revient a 0,0005 centime par post.

>

Ce que vous gagnez : un facteur x10 de productivite
pour vos modérateurs,
une couverture de 60 000 posts par jour —
200 fois plus qu'un humain seul —
et une reduction de 67 % des faux positifs
qui encombrent aujourd'hui vos files de moderation.

16:30 - 17:00 — Limites et roadmap (Azalie)

`[SLIDE 15 : Roadmap V10-V12]`

En toute transparence, les limites.

>

L'accord entre nos deux annotateurs humains est de 0,498
sur l'echelle de Cohen — c'est un accord modere.
Ca ne veut pas dire que le modele est mauvais.
Ca veut dire que la frontiere entre fiable et suspect
est intrinsequement subjective, meme pour des humains.

>

Notre F1 macro sur le jeu de test est de 0,67.
En cross-validation sur les donnees d'entrainement, il est de 0,91.
L'ecart s'explique par cette subjectivite.
C'est pourquoi ThumaCheck donne un score de confiance,
pas un verdict definitif. Vos analystes gardent le dernier mot.

>

ThumaCheck detecte des signaux de desinformation —
le style, le ton, le sensationnalisme — pas la verite factuelle.
C'est un outil d'aide a la decision, pas un juge.

>

La roadmap : V10 integre le suivi de modeles
pour detecter les baisses de performance.
V11 ajoute la verification factuelle avec des outils
comme ClaimBuster.

*Et V12 prévoit un audit d'équité
pour garantir que le modèle traite tous les sujets
de manière équilibrée.*

17:00 - 18:00 — Conclusion (Azélie, caméra)

`[A-CAM]` *Bandeau : Azélie Bernard — Lead Technique & Architecture*

`[SLIDE 16 : Citation]`

*Pour conclure, je reviens au F1 de 0,99 du début.
Ce chiffre flatteur cachait un biais.
Nous l'avons détecté, corrigé, et documenté.*

>

*Aujourd'hui, ThumaCheck V9
est valide par 537 tests automatisés,
80 % de taux de détection en mutation testing,
une analyse d'impact vie privée, une Model Card,
et une explicabilité dont on a prouvé la fidélité.*

>

*ThumaCheck n'est pas un classifieur.
C'est un système de décision auditable —
défendable devant vos analystes,
devant vos régulateurs, et devant votre direction.*

>

*Un score sans explication est un verdict sans procès.
C'est la phrase qui a guidé
chacune de nos décisions techniques tout au long de ce projet.*

`[SLIDE 17 : Remerciements + QR codes]`

*Merci pour votre attention.
Le repository, le rapport technique et la Model Card
sont accessibles via les QR codes à l'écran.
Je suis à votre disposition pour vos questions.*

Tableau récapitulatif

Section | Durée | Slides

Hook intro | 0:30 | — (caméra)

Contexte client + besoin + mode demo | 1:00 | 1

Équipe + problématique + exigences | 1:30 | 2, 3, 4

Biais Reuters + itérations | 1:30 | 5

Architecture + pipeline cascade | 2:00 | 6, 7

Demo dashboard + émotions | 3:00 | — (screencast)

XAI + faithfulness | 2:30 | 8, 9
Qualite industrielle + securite | 1:30 | 10
Conformite + Green IT | 1:30 | 11, 12
Methodologie + organisation | 0:45 | 13
ROI et valeur business | 0:45 | 14
Limites + roadmap | 0:30 | 15
Conclusion | 1:00 | 16, 17
****TOTAL**** | ****~18:00**** |

Couverture des exigences CDC (CDC-THUM-2026-001)

Module CDC | Exigences | Couvert dans la video | Timing

****COL**** | COL-01 a COL-08 | COL-01 (AT Protocol), COL-04 (deduplication), COL-05 (reprise erreur) | 04:30

****STO**** | STO-01 a STO-06 | STO-01 (MongoDB), STO-02 (245K docs), STO-06 (enrichissements) | 04:30

****DET**** | DET-01 a DET-12 | Tous couverts (F1, bilinguisme, seuil, explicabilite, debiaisage) | 03:00-06:30

****EMO**** | EMO-01 a EMO-05 | EMO-01 (7 emotions), EMO-04 (bilingue), EMO-05 (features pipeline) | 08:30

****DASH**** | DASH-01 a DASH-09 | DASH-01 (Streamlit), DASH-02 (5 pages), DASH-04 (analyse), DASH-05 (mode demo), DASH-06 (XAI), DASH-07 (dark theme) | 06:30-09:30

****XAI**** | XAI-01 a XAI-05 | Tous couverts (SHAP, faithfulness, IG, attention, audience) | 09:30-12:00

****PERF**** | PERF-01 a PERF-06 | PERF-02 (< 5ms), PERF-05 (modele léger) | 04:30, 14:30

****SEC**** | SEC-01 a SEC-04 | SEC-01/02 (.env), SEC-04 (Trivy) | 12:00-13:30

****FIA**** | FIA-01 a FIA-05 | FIA-04 (Docker restart), FIA-05 (volumes) | 04:30, 15:00

****MAI**** | MAI-01 a MAI-05 | MAI-01 (modules), MAI-02 (versioning), MAI-05 (CodeCarbon) | 15:00

Checklist conformite cadre pedagogique

- * 15-20 minutes (cible 18 min)
- * Presentation de l'equipe et repartition des roles (credit Sebastien)
- * Bandeau nom affiche pour chaque prise de parole camera
- * Structure besoin - solution - demo
- * Presentation de l'entreprise/contexte client et de l'equipe
- * Analyse de la problematique et introduction a la solution
- * Organisation et methodologies (CRISP-DM, Gantt, CI/CD)
- * Presentation de la solution technique
- * Pipeline donnees - IA - decision (explicitement nomme)
- * Metriques d'evaluation detaillees
- * Demo live du dashboard (screencast)
- * Module emotions demontre (7 classes, signal complementaire)
- * Securite (variables env, scan Trivy, isolation)

- * ROI et impact quantifie (temps, volume, risque, cout)
- * Conformite reglementaire (AI Act art. 50, RGPD art. 22, AIPD)
- * Limites assumees + contextualisation (kappa, subjectivite)
- * Perspectives et roadmap (V10-V12)
- * Qualite industrielle (537 tests, coverage, mutation)
- * Posture professionnelle (ton client, pas academique)
- * Valorisation dataviz (choix visuels justifies dans la demo)
- * Green IT avec donnees reelles + comparaison tangible (1 km voiture)
- * Mode demo mentionne (DASH-05)
- * Droit a l'effacement RGPD operationnel (< 5s)

Ordre d'enregistrement recommande (solo)

****Session 1 — Sections camera (face Azelie)****

1. Hook intro (00:00-00:30) — 5 prises (c'est l'ouverture, soigner)
2. Contexte client (00:30-01:30) — 2 prises
3. Equipe + problematique (01:30-03:00) — 2 prises
4. Architecture intro (04:30) — 2 prises
5. Qualite industrielle intro (12:00) — 2 prises
6. Methodologie intro (15:00) — 2 prises
7. Conclusion (17:00-18:00) — 5 prises (c'est la fermeture, soigner)

****Session 2 — Sections screencast + slides (voix off)****

1. Biais Reuters + iterations (03:00-04:30) — 2 prises
2. Architecture + pipeline cascade (04:30-06:30) — 2 prises
3. Demo dashboard + emotions (06:30-09:30) — 3 prises (la demo peut rater)
4. XAI + faithfulness (09:30-12:00) — 2 prises
5. Qualite + securite (12:00-13:30) — 2 prises
6. Conformite + Green IT (13:30-15:00) — 2 prises
7. Methodologie (15:00-15:45) — 2 prises
8. ROI (15:45-16:30) — 2 prises
9. Limites + roadmap (16:30-17:00) — 2 prises

****Session 3 — Captures ecran (sans voix)****

Enregistrer toutes les navigations dashboard separement,
puis synchroniser au montage.

Script video Thumalien V9 — v5 solo — Juillet 2026